

Appunti di Statistica

MIROLO MANUELE / ALESSIO BRUSINI / MICHELE TEDESCHINI

a.a. 2025/26

Indice

1	Rappresentazione grafica e Grandezze Statistiche	1
1.1	Metodo dei Minimi Quadrati	5
2	Momenti e Distribuzioni	8
2.1	Momenti della funzione di distribuzione	8
2.2	Distribuzioni Uniformi e Funzione Generatrice e Caratteristica . . .	10
2.3	Distribuzione Binomiale e Approssimazioni	14
3	Distribuzione di Poisson e Approssimazioni	16
4	La Distribuzione Normale	28
5	Teorema del Limite Centrale	32
5.1	Generazione di Numeri Casuali Normali	36
5.2	La Trasformazione di Box-Muller	37
6	Distribuzione di Cauchy e Legge dei grandi numeri	40
6.1	Distribuzione di Cauchy come rapporto di due normali standard . .	40
6.2	Legge dei grandi numeri	41
7	Processi di Poisson, Esponenziale ed Erlang	46
7.1	Distribuzione Esponenziale	46
7.2	Distribuzione di Erlang	48
8	Metodi Monte Carlo	49
8.1	Metodo Accept-Reject	50
8.2	Metodo della Funzione di Ripartizione (Inversione)	53
9	Variabili Casuali bidimensionali	54
9.1	Distribuzioni congiunte, marginali e condizionate	54
9.2	Momenti: Matrice delle Covarianze e Combinazioni Lineari	55
9.3	Coefficiente di correlazione	59

10	Distribuzione normale in più dimensioni (o multinormale)	62
11	Distribuzione Multi-normale (Variabili dipendenti)	64
12	Teoria della Stima dei Parametri	68
13	Stime, Propagazione e Likelihood	70
	13.1 Dimostrazione della Propagazione degli Errori	73
	13.2 Metodo della Massima Verosimiglianza (MLE), (Maximum Likelihood)	74
14	PDF Gaussiane e Limite di Cramér-Rao	77
	14.1 Efficienza e Disuguaglianza di Cramér-Rao	79
15	Stime, Binned Ml ed EML	85
	15.1 Varianza della stima e Disuguaglianza di Cramer-Rao	86
	15.2 Binned Maximum Likelihood	89
	15.3 Extended Maximum Likelihood (EML)	90
16	Dal Metodo di Maximum Likelihood ai Minimi Quadrati	91
	16.1 Caso del fit lineare $y = mx + q$	92
	16.2 Caso $y = mx + q$ con errori σ_i differenti	94
17	Binned Chi Squared	96
	17.1 Distribuzione del χ^2	98
18	Fit non lineari	106
	18.1 Fit non lineare	106
19	Test di Ipotesi	110
	19.1 Test del χ^2	113
	19.2 Overfitting e Test F (Modelli Annidati)	118
	19.3 Test di Kolmogorov-Smirnov	120
20	Compatibilità tra due misure	125
	20.1 Derivazione della Distribuzione t-Student	127

1 Rappresentazione grafica e Grandezze Statistiche

Rappresentazione grafica dei dati

Le nostre misure saranno del tipo $x_1, x_2, \dots, x_N$, il nostro obiettivo è quello di rappresentare questi dati per capire il fenomeno fisico che stiamo studiando.

Per quanto riguarda la parte grafica, la rappresentazione dipende dai dati a disposizione:

- **Istogramma:** Avendo molte misure di una sola grandezza, la rappresentazione tipica è l'istogramma. Per farlo si divide l'intervallo atteso delle misure in intervalli più piccoli detti *bin*, e si conta quante misure cadono in ogni intervallino.
- **Scatter Plot:** Avendo poche misure di due o più variabili correlate, la rappresentazione più utile è un plot a dispersione (punti (x, y) sul piano cartesiano).

Scatter Plot ed Errori

Nello scatter plot, plottiamo una grandezza rispetto all'altra e aggiungiamo per ogni punto gli errori di misura:


$$(x_i \pm \sigma_{x_i}, \quad y_i \pm \sigma_{y_i})$$

In questa rappresentazione è stato usato un numero per rappresentare una misura di x ed è stato associato ad esso una stima dell'errore fatto nella singola misura.

Gli errori da associare dipendono dalla situazione pratica:

- In alcuni casi si può fare un'analisi statistica ripetendo le misure molte volte.
- Nella maggior parte dei casi questo non si può fare (strumento non abbastanza sensibile o fenomeno non ripetibile). In tal caso si associa l'errore di sensibilità dello strumento.

Istogramma



Grandezze Statistiche: Media e Varianza

Media Aritmetica

Consideriamo il caso ottimistico in cui si riesce a misurare tante volte la stessa grandezza nelle stesse condizioni. In questo caso, se si vuole usare un solo numero per descrivere le misure, il migliore è senz'altro la **media aritmetica**:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \quad (1)$$

Deviazione Standard e correzione di Bessel

La varianza ha però la scomodità di avere un'unità di misura al quadrato rispetto a x . Si preferisce quindi la **deviazione standard**:

$$\sigma_N = \sqrt{\text{Var}(x)}$$

Osservazione 1 (Correzione di Bessel). La formula sopra è corretta se le misure rappresentano tutta la popolazione. Nella maggior parte dei casi x_i è solo un **campione**. Per tener conto del bias dovuto all'uso della media campionaria $\bar{x}$ invece della media vera μ , si usa $N - 1$ al denominatore:

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2} \quad (2)$$

Questa correzione diventa trascurabile per N grande, ma è fondamentale per piccoli set di dati.

Esempio (Python)

Di seguito mostriamo come calcolare media e deviazione standard (con e senza correzione) simulando delle misure gaussiane, simuliamo $N = 100$ misure con due strumenti diversi ($\sigma_1 = 1$ e $\sigma_2 = 0.2$).

```
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulo N misure di una grandezza fisica (es. corrente)
N = 100
valore_simulato = 8.0 # Valore vero [mA]
# Caso 1: sigma = 1, Caso 2: sigma = 0.2
misure1 = np.random.normal(loc=valore_simulato, scale=1.0, size=N)
misure2 = np.random.normal(loc=valore_simulato, scale=0.2, size=N)

# 2. Calcolo Media
media1 = np.mean(misure1)
print(f"Media Caso 1: {media1:.4f} mA")

# 3. Calcolo Deviazione Standard (ddof=1 applica la correzione di Bessel N-1)
sigma1_corr = np.std(misure1, ddof=1)
print(f"Sigma Corretto (Bessel): {sigma1_corr:.4f}")

# 4. Istogramma
plt.hist(misure1, alpha=0.7, bins=30, edgecolor='black', label='Caso 1')
plt.hist(misure2, alpha=0.7, bins=30, edgecolor='black', label='Caso 2')
plt.xlabel('Misura, I [mA]')
plt.title('Istogramma delle misure ripetute')
plt.legend()
plt.show()
```

Listing 1: Calcolo di Media e Deviazione Standard




Figura 1: Istogramma comparativo delle due serie di misure simulate.

Errore di sensibilità e Propagazione

Propagazione degli Errori

Data una funzione $f(x, y)$ di variabili casuali indipendenti, la varianza si propaga come:

$$\sigma_f^2 = \left(\frac{\partial f}{\partial x}\right)^2 \sigma_x^2 + \left(\frac{\partial f}{\partial y}\right)^2 \sigma_y^2 \quad (3)$$

Esempio. Esempio numerico: Calcolo dello spazio percorso in un moto uniformemente accelerato

Dati: $v = 200 \pm 10 \text{ m/s}$, $a = 12 \pm 2 \text{ m/s}^2$, $t = 6 \text{ s}$ (errore trascurabile).

$$s = vt + \frac{1}{2}at^2 = (200 \cdot 6) + \frac{1}{2} \cdot 12 \cdot 6^2 = 1200 + 216 = 1416 \text{ m}$$

Errore associato σ_s :

$$\sigma_s^2 = \left(\frac{\partial s}{\partial v}\right)^2 \sigma_v^2 + \left(\frac{\partial s}{\partial a}\right)^2 \sigma_a^2 = (t)^2 \sigma_v^2 + \left(\frac{1}{2}t^2\right)^2 \sigma_a^2$$

$$\sigma_s = \sqrt{6^2 \cdot 10^2 + (18)^2 \cdot 2^2} = \sqrt{3600 + 1296} = \sqrt{4896} \approx 70 \text{ m}$$

Risultato: $s = 1416 \pm 70 \text{ m}$.

Errore di Sensibilità

Quando non è possibile ripetere molte volte la misura, associamo alle misure l'errore dovuto alla sensibilità dello strumento. Questo errore si ottiene leggendo il minimo scarto della variabile consentito dallo strumento (risoluzione):

$$\Delta x = \frac{x_{max} - x_{min}}{2}$$

Questo è l'errore massimo $x \pm \Delta x$. Statisticamente, assumere che il valore vero si trovi in $[x_{min}, x_{max}]$ equivale ad assumere una **densità di probabilità uniforme** $P(x)$ di larghezza 2Δ . La densità deve essere normalizzata a 1:

$$\int_{-\Delta}^{\Delta} C dx = 1 \implies C(2\Delta) = 1 \implies C = \frac{1}{2\Delta}$$

Quindi:

$$P(x) = \begin{cases} \frac{1}{2\Delta} & x \in [-\Delta, \Delta] \\ 0 & \text{altrove} \end{cases}$$

Per una distribuzione uniforme tra $[-\Delta, \Delta]$:

- Media: $\mu = 0$
- Varianza: $\sigma^2 = \int_{-\Delta}^{\Delta} x^2 \frac{1}{2\Delta} dx = \frac{\Delta^2}{3}$

Quindi, se si vuole convertire un errore massimo Δ in una deviazione standard σ :

$$\sigma = \frac{\Delta}{\sqrt{3}} \quad (4)$$

1.1 Metodo dei Minimi Quadrati

L'obiettivo è dedurre informazioni fisiche dai dati (fit). Partiamo dalle ipotesi:

1. Ho effettuato misure (x_i, y_i) dove l'errore su x è trascurabile.
2. Per ogni x fisso, ho misurato y con incertezza σ_i .
3. Esiste una legge $y = f(x; p)$ (dove p sono i parametri).

Il metodo consiste nel minimizzare la somma degli scarti quadratici pesati, detta **Chi Quadro** χ^2 :

$$\chi^2 = \sum_{i=1}^N \left[\frac{y_i - f(x_i; p)}{\sigma_i} \right]^2 \quad (5)$$

Minimizzare significa porre le derivate rispetto ai parametri uguali a zero: $\frac{\partial \chi^2}{\partial p} = 0$.

Fit Lineare ($y = mx + q$)

Nel caso di funzione lineare $f(x) = mx + q$ e $\sigma_i = \sigma$ costanti, risolvendo il sistema delle derivate parziali $\frac{\partial \chi^2}{\partial m} = 0$ e $\frac{\partial \chi^2}{\partial q} = 0$, si ottengono le stime analitiche:

Definiamo le somme:

$$S_x = \sum x_i, \quad S_y = \sum y_i, \quad S_{xx} = \sum x_i^2, \quad S_{xy} = \sum x_i y_i$$
$$D = NS_{xx} - (S_x)^2$$

Le stime dei parametri sono:

$$m = \frac{NS_{xy} - S_x S_y}{D}, \quad q = \frac{S_{xx} S_y - S_x S_{xy}}{D} \quad (6)$$

E gli errori associati (tramite propagazione):

$$\sigma_m = \sqrt{\frac{N\sigma^2}{D}}, \quad \sigma_q = \sqrt{\frac{\sigma^2 S_{xx}}{D}} \quad (7)$$

Esempio (Fit Lineare)

```
# Dati simulati: Moto uniforme s = v*t + s0
t = np.array([0, 1, 2, 3, 4, 5])      # Tempo [s]
s = np.array([2, 17, 27, 37, 47, 63]) # Spazio [mm]
sigma_s = 2                          # Incertezza [mm]
N = len(t)

# Calcolo Somme
Sx = np.sum(t); Sy = np.sum(s)
Sxx = np.sum(t**2); Sxy = np.sum(t * s)

# Calcolo Parametri
D = N * Sxx - Sx**2
m = (N * Sxy - Sx * Sy) / D
q = (Sxx * Sy - Sx * Sxy) / D

print(f"Velocita' (m): {m:.2f} mm/s")
print(f"Posizione init (q): {q:.2f} mm")

# Plot
plt.errorbar(t, s, yerr=sigma_s, fmt='o', label='Dati')
plt.plot(t, m*t + q, label='Fit Lineare')
plt.xlabel('Tempo [s]'); plt.ylabel('Spazio [mm]')
plt.legend(); plt.show()
```

Listing 2: Fit Lineare dei Minimi Quadrati




Figura 2: Fit Lineare

Caso Non Lineare e Linearizzazione

se $f(x; p)$ non è lineare spesso si cerca un'espressione linearizzata cambiando variabili.

Esempio: Caduta grave $h = \frac{1}{2}gt^2$ oppure la formula inversa per calcolare g dai tempi:

$$t = \sqrt{\frac{2}{g}}\sqrt{d} + t_0$$

Questa equazione è del tipo $Y = mX + q$ se poniamo:

$$Y = t, \quad X = \sqrt{d}, \quad m = \sqrt{\frac{2}{g}}, \quad q = t_0$$

Una volta calcolato $\hat{m}$ con i minimi quadrati, inverto la relazione per trovare g :

$$\hat{m}^2 = \frac{2}{g} \implies g = \frac{2}{\hat{m}^2}$$

Per l'errore, uso la propagazione:

$$\sigma_g = \left| \frac{\partial g}{\partial m} \right| \sigma_m = \left| -\frac{4}{m^3} \right| \sigma_m$$

Esempio Computazionale (Linearizzazione)

```
# Dati: Tempo t vs Spazio s
t = np.array([0.16, 0.40, 0.58, 0.72, 0.97])
s = np.array([0.20, 1.0, 2.0, 3.0, 5.0])
rad_s = np.sqrt(s) # Variabile linearizzata X

# ... (Codice per calcolo m e q su t vs rad_s omissso per brevit ...)
# Supponiamo m sia stato calcolato:
m_calc = 0.45
sigma_m = 0.01

# Calcolo fisico
g = 2 / m_calc**2
sigma_g = (4 / m_calc**3) * sigma_m

print(f"g misurato: {g:.2f} +/- {sigma_g:.2f} m/s^2")
```

Listing 3: Linearizzazione per calcolo di g

2 Momenti e Distribuzioni

2.1 Momenti della funzione di distribuzione

Il valore di aspettazione e la varianza di una variabile casuale sono due particolari “momenti” della funzione densit  di probabilit  $f_X(x) \equiv f(x)$.

Possiamo distinguere tra momenti calcolati rispetto all’origine e momenti calcolati rispetto al valore di aspettazione (la media). In entrambi i casi, si tratta di valori di aspettazione (dunque quantit  numeriche) delle potenze di x o di $x - \mu_x$. Nello specifico, definiamo:

Definizione: Momento algebrico di ordine k (o k-esimo momento algebrico): calcolato rispetto all’origine.

$$\mu_k = E[x^k] = \int_{\Omega} x^k f(x) dx$$

Osservazioni:

- Per $k = 0 \rightarrow \mu_0 = \int_{\Omega} f(x) dx = 1$ (Normalizzazione della funzione di probabilit ).
- Per $k = 1 \rightarrow \mu_1$ rappresenta il valore di aspettazione o media (il baricentro della distribuzione).

Definizione: Momenti centrali di ordine k:


$$\bar{\mu}_k = E[(x - \mu)^k] = \int_{\Omega} (x - \mu)^k f(x) dx$$

Osservazione:

- Per $k = 0 \rightarrow \bar{\mu}_0 = \int_{\Omega} f(x)dx = 1$.
- Per $k = 1 \rightarrow \bar{\mu}_1 = 0$.
Dimostrazione: $\int_{\Omega} (x - \mu)f(x)dx = \int_{\Omega} xf(x)dx - \mu \int_{\Omega} f(x)dx = \mu - \mu \cdot 1 = 0$.
- Per $k = 2 \rightarrow \bar{\mu}_2 = \sigma^2$ (Varianza).
- Per $k = 3 \rightarrow \bar{\mu}_3$ è legato all'*indice di asimmetria* (o *skewness*). Esso indica quanto la distribuzione sia simmetrica rispetto alla media:


- per una distribuzione simmetrica (es. Gaussiana) $\bar{\mu}_3 = 0$;

Simmetrica ($\bar{\mu}_3 = 0$)




- per una distribuzione asimmetrica a destra (es. Maxwell-Boltzmann) $\bar{\mu}_3 > 0$;

Asimmetrica a destra ($\bar{\mu}_3 > 0$)



- per una distribuzione asimmetrica a sinistra $\bar{\mu}_3 < 0$

Asimmetrica a sinistra ($\bar{\mu}_3 < 0$)



- Per $k = 4 \rightarrow \bar{\mu}_4$ è legato all'*indice di curtosi* (o *kurtosis*). Questo parametro valuta il peso delle "code" della distribuzione, ovvero l'influenza dei valori estremi (*outliers*).

2.2 Distribuzioni Uniformi e Funzione Generatrice e Caratteristica

Distribuzione uniforme discreta

Consideriamo una variabile X che può assumere n valori discreti. Se tutti i valori sono equiprobabili, imponendo la condizione di normalizzazione si ottiene che la probabilità per ogni valore è $p = 1/n$. Di conseguenza, il valore medio è:

$$\mu_x = \frac{1}{n} \sum_{i=1}^n x_i$$

che corrisponde alla media aritmetica dei possibili valori (analogo al lancio di un dado). La varianza è data da:

$$\sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

Distribuzione uniforme continua

Una variabile casuale continua definita nell'intervallo (a, b) possiede una distribuzione uniforme se la sua densità di probabilità è costante, ovvero $f_X(x) = \text{cost.}$ Affinché sia soddisfatta la condizione di normalizzazione (l'area sotto la curva deve essere 1), la funzione deve essere:

$$f_X(x) = \frac{1}{b-a}$$

Il valore medio si calcola come:

$$\mu_x = \int_a^b x f(x) dx = \frac{a+b}{2}$$

Per la varianza, sfruttando la proprietà $E[x^2] - E[x]^2$, si ottiene:

$$\sigma_x^2 = \frac{(b-a)^2}{12}$$

Nota: Collegamento con la trattazione degli errori.

Quando si passa dalla teoria degli errori massimi a quella statistica, il risultato di una misura viene espresso come $x \pm \Delta x$. Questo intervallo corrisponde a una distribuzione uniforme di larghezza $b - a = 2\Delta x$.

Sostituendo nella formula della varianza ricavata sopra ($\sigma_x^2 = \frac{(b-a)^2}{12}$), otteniamo la deviazione standard:

$$\sigma_x = \frac{b-a}{2\sqrt{3}} \Rightarrow \Delta x = \sigma_x \sqrt{3}$$

È interessante calcolare la probabilità che il valore x cada all'interno dell'intervallo di una deviazione standard dalla media ($\mu_x \pm \sigma_x$). Tale probabilità risulta essere:

$$P(\mu_x - \sigma_x < x \leq \mu_x + \sigma_x) = \frac{1}{\sqrt{3}} \approx 0.577$$

Dimostrazione:

$$\int_{\mu_x - \sigma_x}^{\mu_x + \sigma_x} f(x) dx = \frac{1}{b-a} \int_{\mu_x - \sigma_x}^{\mu_x + \sigma_x} dx = \frac{1}{b-a} (2\sigma_x) = \frac{2\sigma_x}{2\sigma_x \sqrt{3}} = \frac{1}{\sqrt{3}}$$

Funzioni Generatrici e Funzione Caratteristica

L'introduzione dei momenti risulta utile per diversi motivi. Un risultato fondamentale è il seguente: se due variabili casuali X e Y possiedono gli stessi momenti, allora le loro funzioni di distribuzione di probabilità (f_X e f_Y) sono identiche.

Definizione: Funzione generatrice dei momenti: La funzione generatrice dei momenti, indicata con $M_x(t)$, è definita come il valore atteso di e^{tx} . La sua espressione varia a seconda che la variabile casuale sia continua o discreta:

$$M_x(t) = E[e^{tx}] = \begin{cases} \int_{\Omega} e^{tx} f(x) dx & \text{caso continuo} \\ \sum_i p_i e^{tx_i} & \text{caso discreto} \end{cases}$$

Questa funzione è fondamentale perché permette di "generare" i momenti della distribuzione (come media, varianza, ecc.) attraverso l'operazione di derivazione. Calcolando la derivata m -esima rispetto a t e valutandola in $t = 0$, si ottiene il momento m -esimo semplice:

$$\left[\frac{\partial^m M_x}{\partial t^m} \right]_{t=0} = E[x^m] = \mu_m$$

Dimostrazione: Per dimostrare questa proprietà, sviluppiamo e^{tx} in serie di Maclaurin:

$$e^{tx} = \sum_{k=0}^{\infty} \frac{(tx)^k}{k!}$$

Sostituendo questo sviluppo nell'integrale della definizione (assumendo il caso continuo per generalità) e sfruttando la linearità dell'integrale, otteniamo:

$$M_x(t) = \int_{\Omega} \left(\sum_{k=0}^{\infty} \frac{(tx)^k}{k!} \right) f(x) dx = \sum_{k=0}^{\infty} \frac{t^k}{k!} \int_{\Omega} x^k f(x) dx$$

Poiché l'integrale $\int_{\Omega} x^k f(x) dx$ corrisponde esattamente al momento k -esimo μ_k , possiamo scrivere:

$$M_x(t) = \sum_{k=0}^{\infty} \frac{t^k}{k!} \mu_k = \mu_0 + \mu_1 t + \frac{\mu_2 t^2}{2!} + \dots$$

Se calcoliamo la derivata prima rispetto a t :

$$\frac{\partial M_x}{\partial t} = \mu_1 + \frac{2\mu_2 t}{2!} + \dots = \mu_1 + \mu_2 t + \dots$$

Ponendo $t = 0$, tutti i termini con t si annullano, lasciando solo il coefficiente μ_1 :

$$\left[\frac{\partial M_x}{\partial t} \right]_{t=0} = \mu_1 = E[x]$$

Definizione: Funzione generatrice dei momenti centrali: Analogamente, è possibile definire la funzione che genera i momenti rispetto alla media μ (momenti centrali):

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = \begin{cases} \int_{\Omega} e^{t(x-\mu)} f(x) dx & \text{caso continuo} \\ \sum_i p_i e^{t(x-\mu_i)} & \text{caso discreto} \end{cases}$$

Anche in questo caso vale la proprietà delle derivate:

$$\left[\frac{\partial^m \bar{M}_x}{\partial t^m} \right]_{t=0} = E[(x - \mu)^m] = \bar{\mu}_m$$

Esiste una relazione diretta tra la funzione generatrice dei momenti semplici e quella dei momenti centrali. Sfruttando le proprietà dell'esponenziale e la linearità del valore atteso, si ha:

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = E[e^{tx} e^{-t\mu}] = e^{-t\mu} E[e^{tx}] = e^{-t\mu} M_x(t)$$

Infine se due variabili casuali X e Y possiedono la stessa funzione generatrice dei momenti ($M_x(t) = M_y(t)$) o la stessa funzione generatrice dei momenti centrali ($\bar{M}_x(t) = \bar{M}_y(t)$), allora le loro distribuzioni di probabilità (f_X e f_Y) sono identiche.

Definizione: Funzione caratteristica: Una variante importante è la funzione caratteristica, definita come:

$$\phi(x) = E[e^{itx}] = \int_{\Omega} e^{itx} f(x) dx$$

Questa corrisponde formalmente alla **Trasformata di Fourier** della densità di probabilità.

Consideriamo una variabile aleatoria $Z = X + Y$, somma di due variabili aleatorie **indipendenti** X e Y . La funzione generatrice dei momenti della somma è il prodotto delle singole funzioni generatrici:

$$M_Z(t) = E[e^{tZ}] = E[e^{t(X+Y)}] = E[e^{tX} e^{tY}]$$

Essendo X e Y indipendenti, il valore atteso del prodotto è il prodotto dei valori attesi:

$$M_Z(t) = E[e^{tX}] E[e^{tY}] = M_X(t) M_Y(t)$$

Questo è dovuto al fatto che $\Omega_X \cap \Omega_Y = \emptyset$, dunque vale che $f_{X+Y}(x) = f_X(x) f_Y(x)$

Approfondimento sulla funzione caratteristica

Quella che noi abbiamo visto come i momenti algebrici e centrali, in realtà sono solo due casi particolari di una famiglia più ampia di momenti, che possono essere generati da funzioni più generali. La funzione caratteristica è un esempio di funzione generatrice dei momenti che utilizza l'esponenziale complesso e^{itx} invece di e^{tx} .

La funzione caratteristica è la trasformata della mia p.d.f (probability density function); essa è ben definita valendo $f_X(x) \in L^2[\mathbb{R}]$

$$\phi(t) = \int_{-\infty}^{\infty} e^{itx} f_X(x) dx = E[e^{itx}]$$

In questo caso vale la stessa dimostrazione attraverso l'espansione dell'esponenziale per mostrare come da questa si possono ricavare i momenti, dove i momenti sono definiti come:

$$E[x^m] = \mu_m = \left[\frac{\partial^m \phi(t)}{\partial (it)^m} \right]_{t=0}$$

La funzione caratteristica è particolarmente utile perché, essendo la trasformata di Fourier della p.d.f., permette di ricavare la distribuzione di probabilità a partire dalla funzione caratteristica stessa tramite la trasformata inversa di Fourier:

$$f_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t) dt$$

Dunque due distribuzioni di probabilità che hanno gli stessi momenti (dunque la stessa funzione caratteristica), sono la stessa distribuzione di probabilità. Questo è dovuto al fatto che la $\mathcal{F}$ -trasformata in $L^2[\mathbb{R}]$ rappresenta una biezione tra due spazi.

2.3 Distribuzione Binomiale e Approssimazioni

La distribuzione binomiale descrive un fenomeno che può verificarsi solo con due modalità mutualmente esclusive: successo (con probabilità p) o insuccesso (con probabilità $q = 1 - p$).

Se ripetiamo l'esperimento n volte, la probabilità di ottenere esattamente k successi è data dalla funzione:

$$P(k; n, p) = \binom{n}{k} p^k q^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Casi particolari immediati:

- Probabilità di n successi (tutti): p^n
- Probabilità di 0 successi (nessuno): q^n
- Probabilità di 1 successo: npq^{n-1} (nota: il coefficiente binomiale $\binom{n}{1} = n$)
- Probabilità di $n - 1$ successi: $np^{n-1}q$

Esempio. Consideriamo 3 oggetti ($n = 3$) chiamati A, B, C . Vogliamo sceglierne 2 ($k = 2$). Le possibili combinazioni sono: AB, BC, AC . Calcolando con la formula del coefficiente binomiale otteniamo conferma:

$$\binom{3}{2} = \frac{3!}{2!(3-2)!} = \frac{3 \cdot 2 \cdot 1}{2 \cdot 1 \cdot 1} = 3$$

Proprietà della distribuzione binomiale

- **Normalizzazione:** La somma di tutte le probabilità è 1. Questo deriva dallo sviluppo del binomio di Newton:

$$\sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = (p+q)^n = (1)^n = 1$$

- **Calcolo diretto della media:** Possiamo derivare la media manipolando la sommatoria. Derivando l'identità $(p+q)^n$ rispetto a p :

$$p \frac{\partial}{\partial p} (p+q)^n = p \cdot n(p+q)^{n-1} \xrightarrow{p+q=1} np$$

Dall'altro lato della sommatoria:

$$p \frac{\partial}{\partial p} \sum_{k=0}^n \binom{n}{k} p^k q^{n-k} = \sum_{k=0}^n k \binom{n}{k} p^k p^{-1} q^{n-k} \cdot p = \sum_{k=0}^n k \binom{n}{k} p^k q^{n-k} = E[k]$$

Uguagliando i risultati otteniamo il valore atteso: $E[k] = np$.

- **Varianza:** La varianza è data da $\sigma_x^2 = E[x^2] - E[x]^2 = npq$.

Funzione generatrice dei momenti della Binomiale

Calcoliamo il momento generatore per la binomiale:

$$M_k(t) = E[e^{tk}] = \sum_{k=0}^n e^{tk} \binom{n}{k} p^k q^{n-k} = \sum_{k=0}^n \binom{n}{k} (pe^t)^k q^{n-k}$$

Riconoscendo la forma del binomio di Newton $(a+b)^n$ con $a = pe^t$ e $b = q$, otteniamo:

$$M_k(t) = (pe^t + q)^n$$

Da qui possiamo ricalcolare i momenti derivando rispetto a t :

1. **Valore atteso (Media)**: Calcoliamo la derivata prima:

$$M'_k(t) = n(pe^t + q)^{n-1} \cdot pe^t$$

Ponendo $t = 0$ (ricordando che $e^0 = 1$ e $p + q = 1$):

$$\mu = M'_k(0) = n(p + q)^{n-1}p = np$$

2. **Varianza**: Calcoliamo la derivata seconda (regola del prodotto):

$$M''_k(t) = n(n-1)(pe^t + q)^{n-2}(pe^t)^2 + n(pe^t + q)^{n-1}pe^t$$

Ponendo $t = 0$:

$$E[x^2] = M''_k(0) = n(n-1)p^2 + np$$

Ora calcoliamo la varianza usando $Var(x) = E[x^2] - E[x]^2$:

$$\sigma^2 = [n(n-1)p^2 + np] - (np)^2 = n^2p^2 - np^2 + np - n^2p^2 = np - np^2 = np(1-p) = npq$$

3. **Asimmetria (Terzo momento centrale)**: Il terzo momento centrale è $\bar{\mu}_3 = npq(1-2p)$. Questo indice ci dice la forma della distribuzione:

- Se $\bar{\mu}_3 > 0$: distribuzione **asimmetrica positiva** (coda a destra).
- Se $\bar{\mu}_3 = 0$: distribuzione **simmetrica**.
- Se $\bar{\mu}_3 < 0$: distribuzione **asimmetrica negativa** (coda a sinistra).

Limiti della Binomiale: La distribuzione binomiale è estremamente importante in fisica perché, al limite per $n \rightarrow \infty$, approssima altre distribuzioni fondamentali:

- Tende alla **distribuzione di Gauss** se p rimane costante.
- Tende alla **distribuzione di Poisson** se il prodotto np rimane costante (ovvero se $p \rightarrow 0$ mentre $n \rightarrow \infty$).

Applicazione agli istogrammi: Consideriamo un istogramma dove n è il numero totale di eventi e ci focalizziamo su un particolare intervallo (bin) i . Il numero atteso di eventi in quell'intervallo è $E[n_i] = np_i$.

La varianza del numero di eventi nell'intervallo è data dalla binomiale:

$$\sigma_{n_i}^2 = np_i(1 - p_i) = n_i(1 - p_i) \simeq n_i \left(1 - \frac{n_i}{n}\right)$$

Se stimiamo la probabilità p_i tramite i dati misurati come $\hat{p}_i = n_i^{mis}/n$, nel caso in cui la probabilità sia molto piccola ($p \rightarrow 0$, regime di Poisson), il termine $(1 - p_i) \approx 1$. Di conseguenza, l'errore standard (deviazione standard) sul conteggio di un bin è approssimabile con la radice quadrata del conteggio stesso:

$$\sigma_{n_i} \approx \sqrt{n_i^{mis}}$$

3 Distribuzione di Poisson e Approssimazioni

Esempi Python: La Distribuzione Binomiale

In questo esercizio simuliamo il lancio di una moneta per applicare la distribuzione binomiale. **Problema:** Lanciamo una moneta $n = 10$ volte. Qual è la probabilità di ottenere esattamente $k = 6$ teste?

Poiché una moneta può dare testa o croce, la probabilità di successo (testa) è $p = 0.5$. Utilizzeremo la distribuzione binomiale con i parametri:

- $n = 10$ (numero di lanci)
- $k = 6$ (numero di successi richiesti)
- $p = 0.5$ (probabilità singolo evento)

1. Calcolo Analitico e con Librerie

Possiamo calcolare la probabilità sia implementando la formula matematica, sia utilizzando la libreria `scipy`.

```
import math
from scipy.stats import binom

# Parametri del problema
k = 6
n = 10
p = 0.5

# METODO 1: Formula matematica
# P = coeff_binomiale * (p^k) * ((1 - p)^(n - k))
coeff_binomiale = math.comb(n, k)
```

```

P = coeff_binomiale * (p**k) * ((1 - p)**(n - k))

print(f"Probabilita' (formula): {P}")

# METODO 2: Libreria Scipy
# Esiste una funzione dedicata per ottenere lo stesso risultato
P_scipy = binom.pmf(k, n, p)

print(f"Probabilita' (scipy): {P_scipy}")

```

Listing 4: Calcolo probabilità Binomiale

Il risultato ottenuto è circa 0.205. Questo significa che, se ripetiamo molte volte l'esperimento dei 10 lanci, nel $\approx 20\%$ dei casi otterremo esattamente 6 teste.

2. Simulazione Monte Carlo

Possiamo verificare il risultato teorico simulando l'esperimento più volte. Prima simuliamo un singolo set di 10 lanci, poi ripetiamo l'esperimento 100 volte per contare la frequenza del risultato "6 teste".

```

import random

# --- Parte A: Singola simulazione di 10 lanci ---
testa = 0
croce = 0
for i in range(10):
    lancio = random.randint(0, 1) # 0 = Testa, 1 = Croce
    if lancio == 0:
        testa += 1
    else:
        croce += 1
print(f"Esito singolo: {testa} Teste e {croce} Croci")

# --- Parte B: Ripetiamo l'esperimento 100 volte ---
testa_l = [] # Lista per salvare i risultati di ogni esperimento

for i in range(100): # 100 esperimenti totali
    testa = 0 # Azzero il contatore per il nuovo esperimento
    for j in range(10): # Ogni esperimento consiste in 10 lanci
        lancio = random.randint(0, 1)
        if lancio == 0:
            testa += 1
    # Fine dei 10 lanci, salvo il risultato
    testa_l.append(testa)

# Contiamo quante volte e' uscito esattamente 6
risultato = testa_l.count(6)
print(f"Su 100 esperimenti, ho ottenuto 6 teste {risultato} volte")

```

Listing 5: Simulazione dei lanci

Dalla Binomiale alla Poissoniana

La distribuzione **Binomiale** descrive casi in cui un risultato particolare si ottiene in un numero preciso e finito di tentativi (n).

La distribuzione di **Poisson**, invece, si usa per descrivere casi in cui si contano eventi rari in un continuo (tempo o spazio), dove non si ha un'idea precisa del numero di tentativi totali, né ha senso parlare di casi "sfavorevoli" nel senso classico.

Esempi:

- Il numero di fulmini durante un temporale: sarà un numero intero, ma non ha senso parlare di "non-fulmini" (non esiste un non-evento osservabile come nel caso "Testa o Croce").

In questi processi si vuole stimare la probabilità k di eventi, noto il numero medio λ (o μ) di eventi che generalmente si presentano. Il processo non ha memoria: un evento verificatosi non influenza la probabilità dei successivi.

Dimostrazione del limite

Matematicamente, la Poisson si ottiene dalla Binomiale attraverso i limiti:

$$n \rightarrow \infty \quad \text{e} \quad p \rightarrow 0$$

in modo tale che il loro prodotto $\lambda = np$ rimanga costante ($\lambda = \text{cost}$).

Supponiamo di attenderci λ eventi in un certo intervallo di tempo Δt . Dividiamo questo intervallo in n sotto-intervalli $\Delta t'$ molto piccoli ($n \rightarrow \infty$), talmente piccoli che la probabilità che due eventi cadano nello stesso sia trascurabile (al massimo un evento per intervallo). La probabilità che un evento si verifichi in un singolo $\Delta t'$ è:

$$p = \frac{\lambda}{n}$$

La probabilità di trovare k eventi negli n intervallini è data dalla distribuzione Binomiale con $p = \lambda/n$:

$$P\left(k; n, \frac{\lambda}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

Riorganizziamo i termini per calcolare il limite:

$$P\left(k; n, \frac{\lambda}{n}\right) = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n!}{(n-k)! n^k}}_{(A)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{n-k}}_{(B)}$$

1. Il termine fattoriale (A):

$$\frac{n!}{(n-k)!} = n \cdot (n-1) \cdot (n-2) \cdots (n-k+1)$$

Ci sono esattamente k termini al numeratore. Per $n \rightarrow \infty$, possiamo trascurare le sottrazioni rispetto a n (es. $n - 1 \approx n$). Quindi:

$$\lim_{n \rightarrow \infty} \frac{n!}{(n-k)!} \approx \underbrace{n \cdot n \cdot \dots \cdot n}_{k \text{ volte}} = n^k$$

(Esempio con $k = 5$: $\frac{n(n-1)(n-2)(n-3)(n-4)}{1} \rightarrow n^5$). Di conseguenza, il rapporto tende a 1:

$$\lim_{n \rightarrow \infty} \frac{n!}{(n-k)! n^k} = \frac{n^k}{n^k} = 1$$

2. Il termine esponenziale (B): Scriviamo il termine $(1 - \frac{\lambda}{n})^{n-k}$ come prodotto di due fattori:

$$\left(1 - \frac{\lambda}{n}\right)^n \cdot \left(1 - \frac{\lambda}{n}\right)^{-k}$$

Per $n \rightarrow \infty$, il secondo fattore tende a $(1 - 0)^{-k} = 1$. Il primo fattore è un limite notevole dell'analisi matematica:

$$\lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n = e^x \implies \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

Sostituendo i limiti calcolati ($n \rightarrow \infty, p \rightarrow 0, np = \lambda$) nell'espressione della binomiale, otteniamo la forma chiusa della distribuzione. La probabilità di ottenere k eventi, dato un numero medio di eventi attesi λ , è:

$$\boxed{P(k; \lambda) = \frac{e^{-\lambda} \lambda^k}{k!} \quad \text{con } 0 \leq k < \infty} \quad (8)$$

Condizioni di validità: Il modello è valido per eventi rari in un continuo, dove il numero di prove tende all'infinito. Un esempio classico è il **decadimento radioattivo**, in quanto il numero di decadimenti nucleari in un intervallo di tempo è discreto e casuale, ma con un tasso medio ben definito.

Calcolo dei Momenti tramite la Funzione Generatrice dei Momenti

Per calcolare valore atteso e varianza in modo elegante, utilizziamo la **Funzione Generatrice dei Momenti**, definita come il valore atteso di e^{tk} :

$$M_k(t) = E[e^{tk}] = \sum_{k=0}^{+\infty} e^{tk} P(k; \lambda) = \sum_{k=0}^{+\infty} e^{tk} \frac{e^{-\lambda} \lambda^k}{k!}$$

Portiamo fuori dalla sommatoria i termini costanti rispetto a k (il termine $e^{-\lambda}$) e accorpriamo le potenze di k :

$$M_k(t) = e^{-\lambda} \sum_{k=0}^{+\infty} \frac{(e^t \lambda)^k}{k!}$$

Riconosciamo nella sommatoria lo sviluppo in serie di Taylor dell'esponenziale $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$, dove in questo caso l'argomento è $x = \lambda e^t$.

$$M_k(t) = e^{-\lambda} \cdot e^{(\lambda e^t)} = e^{\lambda e^t - \lambda}$$

Possiamo quindi scrivere la forma finale della Funzione Generatrice dei Momenti per la Poissoniana:

$$\boxed{M_k(t) = e^{\lambda(e^t - 1)}} \quad (9)$$

Calcolo di Media e Varianza

Dalle proprietà della Funzione Generatrice dei Momenti sappiamo che la derivata prima valutata in $t = 0$ fornisce la media, mentre la derivata seconda fornisce il momento secondo.

1. Media (Valore Atteso): Deriviamo $M_k(t)$ rispetto a t :

$$\frac{\partial M_k}{\partial t} = \frac{\partial}{\partial t} \left(e^{\lambda(e^t - 1)} \right) = e^{\lambda(e^t - 1)} \cdot \frac{\partial}{\partial t} (\lambda e^t - \lambda) = e^{\lambda(e^t - 1)} \cdot \lambda e^t$$

Valutiamo in $t = 0$:

$$E[k] = \left[\frac{\partial M_k}{\partial t} \right]_{t=0} = e^{\lambda(1-1)} \cdot \lambda \cdot 1 = 1 \cdot \lambda = \lambda$$

Risultato: $\mu = \lambda$. Questo conferma che il parametro λ rappresenta il numero medio di eventi.

2. Varianza: Per la varianza usiamo la relazione $\text{Var}(k) = E[k^2] - (E[k])^2$. Calcoliamo la derivata seconda (derivata del prodotto $f(t) \cdot g(t)$ dove f è l'esponenziale composto e g è λe^t):

$$\begin{aligned} \frac{\partial^2 M_k}{\partial t^2} &= \frac{\partial}{\partial t} \left(\underbrace{e^{\lambda(e^t - 1)}}_{f(t)} \cdot \underbrace{\lambda e^t}_{g(t)} \right) \\ &= \underbrace{e^{\lambda(e^t - 1)} \lambda e^t}_{f'(t)} + \underbrace{e^{\lambda(e^t - 1)}}_{f(t)} \cdot \underbrace{\lambda e^t}_{g'(t)} \end{aligned}$$

Raccogliendo i termini:

$$\frac{\partial^2 M_k}{\partial t^2} = e^{\lambda(e^t - 1)} (\lambda^2 e^{2t} + \lambda e^t)$$

Valutando in $t = 0$:

$$E[k^2] = 1 \cdot (\lambda^2 + \lambda) = \lambda^2 + \lambda$$

Ora calcoliamo la varianza sottraendo il quadrato della media:

$$\text{Var}(k) = (\lambda^2 + \lambda) - (\lambda)^2 = \lambda$$

Conclusione: Per la distribuzione di Poisson, media e varianza coincidono.

$$\boxed{\mu = \lambda, \quad \sigma^2 = \lambda} \quad (10)$$

Relazione con la Binomiale e Somma di Variabili

Limite della Funzione Generatrice dei Momenti Binomiale

Si può dimostrare formalmente che la Funzione Generatrice della Binomiale tende a quella della Poissoniana. La Funzione Generatrice dei Momenti della Binomiale è $M_{bin}(t) = (pe^t + 1 - p)^n = [1 + p(e^t - 1)]^n$. Sostituendo $p = \lambda/n$:

$$M_{bin}(t) = \left[1 + \frac{\lambda(e^t - 1)}{n} \right]^n$$

Utilizzando il limite notevole $\lim_{n \rightarrow \infty} (1 + \frac{a}{n})^n = e^a$ con $a = \lambda(e^t - 1)$, otteniamo:

$$\lim_{n \rightarrow \infty} M_{bin}(t) = e^{\lambda(e^t - 1)}$$

Che è esattamente la Funzione Generatrice dei Momenti della Poissoniana derivata in precedenza.

Confronto delle forme (Code della distribuzione)

- **Varianza:** La varianza della Poissoniana è $\lambda = np$. La varianza della Binomiale è $np(1 - p)$. Poiché $(1 - p) < 1$, la varianza binomiale è sempre minore di quella Poissoniana equivalente.
- **Code:** La distribuzione binomiale è limitata superiormente ($k \leq n$). La Poissoniana non ha limite superiore ($0 \leq k < \infty$). Questo, unito alla varianza maggiore, implica che la Poissoniana ha **code più lunghe**: è relativamente più probabile osservare valori lontani dalla media rispetto a una binomiale, specialmente quando la media è piccola.

Somma di Poissoniane Indipendenti

Se abbiamo due processi Poissoniani indipendenti A e B con medie λ_a e λ_b , la variabile somma $k = k_a + k_b$ segue ancora una distribuzione di Poisson con media $\lambda_{tot} = \lambda_a + \lambda_b$.

Dimostrazione: La Funzione Generatrice dei Momenti della somma di variabili indipendenti è il prodotto delle Funzione Generatrice dei Momenti.

$$M_{tot}(t) = M_a(t) \cdot M_b(t) = e^{\lambda_a(e^t - 1)} \cdot e^{\lambda_b(e^t - 1)} = e^{(\lambda_a + \lambda_b)(e^t - 1)}$$

Questa forma corrisponde a una Poissoniana con parametro $\lambda_a + \lambda_b$. *Esempio fisico:* Un contatore Geiger che rileva radiazioni da due sorgenti diverse non distinguibili; il conteggio totale sarà ancora Poissoniano.

Esempi Python: Grafici e Confronti

Di seguito riportiamo il codice per visualizzare le distribuzioni e verificare numericamente le proprietà discusse.

1. Visualizzazione della Distribuzione Binomiale

Questo script mostra come varia la forma della distribuzione binomiale al variare di n (numero di prove) e p (probabilità).

```
import math
from matplotlib import pyplot as plt
import numpy as np

def binomiale_manual(k, n, p):
    return math.comb(n, k) * (p**k) * ((1 - p)**(n - k))

# Creiamo una matrice di grafici 2x2 per vedere diversi n
fig, axes = plt.subplots(2, 2, figsize=(8, 6))
axes = axes.flatten()

n_list = [5, 15, 30, 50]
p = 0.5

for ax, n in zip(axes, n_list):
    k_values = range(n + 1)
    P_binom = [binomiale_manual(k, n, p) for k in k_values]
    ax.bar(k_values, P_binom)


    # Linee per media e deviazione standard
    mu = n * p
    sigma = np.sqrt(n * p * (1 - p))

    ax.axvline(mu, linestyle="--", color="orange", label=f"$\mu$={mu:.1f}")
    y_lvl = max(P_binom)/2
    ax.plot([mu-sigma, mu+sigma], [y_lvl, y_lvl], color="red", label=f"$\sigma$={sigma:.1f}")


    ax.set_title(f"n={n}, p={p}")
    ax.legend()
    ax.grid(True)

plt.tight_layout()
plt.show()
```


Listing 6: Plot della Binomiale al variare di n e p



(a)



(b)



(c)

Figura 3: Distribuzioni Binomiale

2. Esercizio Poisson: La notte di San Lorenzo

Problema: Se ci si aspetta di osservare 15.7 stelle cadenti all'ora, qual è la probabilità di osservarne meno di 5 in 30 minuti?

```
from scipy.stats import binom, poisson
import math
import matplotlib.pyplot as plt

# --- PARTE 1: Calcolo Probabilita' ---
frequenza_h = 15.7
frequenza_30min = 15.7 / 2 # Il nostro lambda per 30 min

somma_prob = 0
print("Probabilita' di osservare k stelle in 30 min:")
for k in range(5): # k da 0 a 4
    prob = poisson.pmf(k, frequenza_30min)
    print(f"k={k}: {prob*100:.2f}%")
    somma_prob += prob

print(f"Probabilita' totale (< 5 stelle): {somma_prob*100:.2f}%")

# --- PARTE 2: Confronto Grafico Binomiale vs Poisson ---
# Mostriamo che per n grande e p piccolo le due coincidono

def confronto_binom_poiss(p, n_list):
    fig, axes = plt.subplots(2, 2, figsize=(8, 6))
    axes = axes.flatten()

    for ax, n in zip(axes, n_list):
        l = n * p # Lambda fissato da n*p
        n = int(n)

        # Definiamo il range di k interessante (attorno alla media)
        sigma = math.sqrt(l)
        k_max = int(l + 4*sigma)
        k_values = range(k_max)


        # Calcolo con librerie (piu' stabile per n grandi)
        P_binom = binom.pmf(k_values, n, p)
        P_poiss = poisson.pmf(k_values, l)

        ax.plot(k_values, P_poiss, "o", label="Poisson")
        ax.plot(k_values, P_binom, "x", label="Binomiale", alpha=0.7)
        ax.set_title(f"n={n}, p={p},  $\lambda={l:.1f}$ ")
        ax.legend()
        ax.grid(True)

    plt.tight_layout()
    plt.show()
```


```
# Eseguiamo il confronto al limite  
# Caso limite: p molto piccolo, n molto grande  
confronto_binom_poiss(p=0.01, n_list=[100, 1000, 5000, 10000])
```

Listing 7: Calcolo Poisson e confronto con Binomiale




(a)

(b)



(c)



(d)

Figura 4: Distribuzioni di Poisson e nel limite e confronto binomiale/poissoniana

Rappresentazione grafica dei dati (Istogrammi)

Consideriamo un esperimento volto a misurare una grandezza fisica continua X . Il modello teorico che descrive il fenomeno fornisce una densità di probabilità $P(x)$, tale che:

$$\int_{-\infty}^{+\infty} P(x) dx = 1 \quad (11)$$

Si effettuano N misure indipendenti di X , ottenendo un campione di dati $\{x_1, x_2, \dots, x_N\}$. Questi dati vengono rappresentati graficamente tramite un istogramma, suddividendo l'asse delle x in intervalli adiacenti chiamati *bin*. Considerando un generico bin i , definito nell'intervallo $[x_i, x_{i+1}]$, il numero di eventi M_i che cadono in tale intervallo è una variabile aleatoria discreta. La probabilità teorica che una singola misura cada nel bin i è data da:

$$P_i = \int_{x_i}^{x_{i+1}} P(x) dx \approx P\left(x_i + \frac{\Delta x}{2}\right) \Delta x \quad (12)$$

dove si assume che il bin sia sufficientemente stretto (Δx) da poter considerare $P(x)$ costante al suo interno, approssimandola con il valore nel punto centrale.

La variabile M_i segue una statistica binomiale, poiché per ogni singola misura si verificano due sole possibilità: il conteggio cade nel bin i (successo) oppure no (insuccesso). Il valore di aspettazione di M_i è $\langle M_i \rangle = NP_i$, mentre la varianza è $V_i = NP_i(1 - P_i)$. Al limite, per P_i piccolo e N grande, la distribuzione degli eventi tende a una Poissoniana. In questo caso, il valore di aspettazione è semplicemente M_i e la deviazione standard è stimata come $\sigma = \sqrt{M_i}$. Per questo motivo, quando si rappresenta un istogramma, si aggiungono spesso delle barre di errore verticali che rappresentano la deviazione standard $\sqrt{M_i}$.

È fondamentale sottolineare che l'istogramma non è una distribuzione di probabilità continua, ma una stima basata su un numero finito di eventi. Il fatto che la fluttuazione dei conteggi nei bin segua una statistica binomiale (o approssimativamente Poissoniana) riguarda il processo di misura e campionamento, ed è concettualmente distinto dalla forma funzionale $P(x)$ del processo fisico sottostante.

Se P_i fosse nota a priori, per un confronto visivo con l'istogramma si potrebbe graficare la curva teorica sopra i dati. Tuttavia, è necessario scalare opportunamente la funzione, poiché l'istogramma riporta il numero di conteggi $M_i \approx P(x_{\text{centro}})\Delta x N$.

Nota:

1. L'approssimazione binomiale e Poissoniana per i conteggi nei bin è valida propriamente se N non è fissato a priori, ma è esso stesso una variabile aleatoria (ad esempio, se si acquisiscono conteggi per un intervallo di tempo fissato, il numero totale N di eventi varierà da esperimento a esperimento). Se invece N è fissato rigorosamente (si decide di acquisire esattamente un certo numero di eventi totali), la distribuzione congiunta dei conteggi nei vari bin segue una distribuzione **multinomiale**.
2. Qualunque confronto tra l'istogramma e la curva teorica $P(x)$ basato sulla sovrapposizione grafica è puramente qualitativo. Esistono metodi statistici quantitativi (test di bontà del fit) per valutare la compatibilità, che verranno trattati in seguito.

Esempio. Se abbiamo una generazione causale di numeri che segue una distribuzione uniforme: $U(0,1)$, allora avrò:

$$P_i = \int_{x_i}^{x_{i+1}} 1 \, dx = \Delta x$$

poichè la distribuzione è fatta così

$$U(0,1) = \begin{cases} \text{cost.} & \text{se } x \in (0,1) \\ 0 & \text{altrimenti} \end{cases}$$

poichè deve essere normalizzata deve essere $\text{cost.} = 1$

4 La Distribuzione Normale

Definizione di distribuzione normale

La funzione di distribuzione di Gauss, o distribuzione normale, è descritta dalla seguente funzione (Gauss la utilizzò per descrivere gli errori di misura, notando che molti fenomeni naturali tendono a distribuirsi attorno a un valore medio):

$$P(x; \mu, \sigma) = N(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (13)$$

dove il simbolo N indica che si tratta di una distribuzione normale. Graficamente ha la forma di una campana simmetrica centrata in $x = \mu$. La larghezza della curva è determinata dal parametro σ , che rappresenta la deviazione standard della distribuzione (mentre μ rappresenta il valore atteso): se σ è grande, la distribuzione risulta molto allargata; viceversa, se σ è piccolo, la distribuzione è stretta. Variare μ equivale a traslare la distribuzione lungo l'asse x senza alterarne la forma, mentre variare σ modifica l'ampiezza della curva senza cambiarne il centro.

Nel caso specifico in cui $\mu = 0$ e $\sigma^2 = 1$, si parla di **distribuzione normale standard**, indicata con $N(0,1)$:

$$N(0,1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (14)$$

È importante notare che, attraverso il cambiamento di variabile $z = \frac{x-\mu}{\sigma}$, una qualsiasi gaussiana può essere ridotta alla forma normale standard in funzione di z :

$$P_z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \quad (15)$$

Da un punto di vista pratico, questa proprietà è molto utile per i calcoli: se x è una variabile con distribuzione $N(\mu, \sigma^2)$ e z ha una densità di probabilità $N(0,1)$, possiamo passare da z a x utilizzando la formula di trasformazione:

$$z = \frac{x - \mu}{\sigma} \quad (16)$$

Utilizzando la formula inversa, possiamo ricavare x noto z :

$$z\sigma = x - \mu \implies x = \mu + z\sigma \quad (17)$$

Nota: [Note sul Cambio di Variabile] Quando si effettua un cambio di variabile, la condizione di normalizzazione della probabilità deve essere preservata:

$$\int_{-\infty}^{+\infty} P_z(z) dz = \int_{-\infty}^{+\infty} P_x(x) dx = 1$$

La relazione tra le densità di probabilità è data da:

$$P_z(z) = P_x[x(z)] \left| \frac{dx}{dz} \right|$$

Dato che $x(z) = \mu + z\sigma$, la derivata risulta $\frac{dx}{dz} = \sigma$. Sostituendo nella formula precedente si ottiene:

$$P_z(z) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

che conferma il passaggio alla forma standard.

Calcolo del Valore di Aspettazione e della Varianza

Come per le altre distribuzioni, possiamo utilizzare la funzione generatrice dei momenti per calcolare il valore di aspettazione e la varianza. A differenza delle distribuzioni discrete viste in precedenza, notiamo che in questo caso x è una variabile continua.

Partiamo dalla funzione generatrice dei momenti centrali:

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = \int_{-\infty}^{+\infty} e^{t(x-\mu)} P(x) dx \quad (18)$$

Sostituendo l'espressione di $P(x)$:

$$\bar{M}_x(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} e^{t(x-\mu)} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} \exp \left[t(x-\mu) - \frac{(x-\mu)^2}{2\sigma^2} \right] dx \quad (19)$$

Per risolvere l'integrale, riscriviamo l'esponente completando il quadrato:

$$t(x-\mu) - \frac{(x-\mu)^2}{2\sigma^2} = -\frac{[(x-\mu) - \sigma^2 t]^2}{2\sigma^2} + \frac{\sigma^2 t^2}{2} \quad (20)$$

Infatti, svolgendo il quadrato al numeratore si verifica l'uguaglianza:

$$-\frac{[(x-\mu)-\sigma^2 t]^2}{2\sigma^2} = -\frac{(x-\mu)^2 - 2\sigma^2 t(x-\mu) + \sigma^4 t^2}{2\sigma^2} = -\frac{(x-\mu)^2}{2\sigma^2} + t(x-\mu) - \frac{\sigma^2 t^2}{2} \quad (21)$$

Quindi, il termine aggiuntivo $-\frac{\sigma^2 t^2}{2}$ viene compensato aggiungendo $+\frac{\sigma^2 t^2}{2}$. L'integrale diventa:

$$\begin{aligned} \bar{M}_x(t) &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} \exp \left[-\frac{[(x-\mu)-\sigma^2 t]^2}{2\sigma^2} + \frac{\sigma^2 t^2}{2} \right] dx \\ &= e^{\frac{\sigma^2 t^2}{2}} \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} e^{-\frac{[(x-\mu)-\sigma^2 t]^2}{2\sigma^2}} dx}_{=1} \end{aligned} \quad (22)$$

L'integrale evidenziato vale 1 poiché rappresenta l'area totale di una gaussiana con media $\mu' = \mu + \sigma^2 t$ e varianza σ^2 . Pertanto otteniamo:

$$\boxed{\bar{M}_x(t) = e^{\frac{\sigma^2 t^2}{2}}} \quad (23)$$

Da questo risultato possiamo ricavare la funzione generatrice dei momenti rispetto all'origine $M_x(t)$ usando la relazione $M_x(t) = E[e^{tx}] = E[e^{t(x-\mu)} e^{\mu t}] = e^{\mu t} \bar{M}_x(t)$:

$$M_x(t) = e^{\mu t} \bar{M}_x(t) \quad (24)$$

Nel caso particolare di una gaussiana centrata in zero ($\mu = 0$) con varianza unitaria ($\sigma^2 = 1$), si ha $\bar{M}_x(t) = M_x(t)$. Per una gaussiana generale si ottiene quindi:

$$\boxed{M_x(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right)} \quad (25)$$

Ora possiamo calcolare il valore di aspettazione derivando $M_x(t)$:

$$\frac{dM_x}{dt} = \frac{d}{dt} \left[\exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right) \right] = (\mu + \sigma^2 t) e^{\mu t + \frac{\sigma^2 t^2}{2}} \quad (26)$$

Valutando la derivata in $t = 0$:

$$\left. \frac{dM_x}{dt} \right|_{t=0} = \mu = E[x] \quad (27)$$

Per calcolare la varianza è conveniente utilizzare la derivata seconda della funzione generatrice dei momenti centrali (o continuare a derivare M_x):

$$\left. \frac{d\bar{M}_x}{dt} \right|_{t=0} = 0 \quad \text{e} \quad \left. \frac{d^2 \bar{M}_x}{dt^2} \right|_{t=0} = \sigma^2 \quad (28)$$

Se calcoliamo la derivata seconda di $M_x(t)$:

$$\frac{d^2 M_x}{dt^2} = [\sigma^2 + (\mu + \sigma^2 t)^2] e^{\mu t + \frac{\sigma^2 t^2}{2}} \quad (29)$$

Tuttavia, usando la funzione generatrice dei momenti centrali $\bar{M}_x(t) = e^{\frac{\sigma^2 t^2}{2}}$, la derivata prima è $\sigma^2 t e^{\frac{\sigma^2 t^2}{2}}$ e la seconda:

$$\frac{d^2 \bar{M}_x}{dt^2} = (\sigma^2 + \sigma^4 t^2) e^{\frac{\sigma^2 t^2}{2}} \quad (30)$$

Per $t = 0$, l'esponenziale diventa 1, quindi:

$$\left. \frac{d^2 \bar{M}_x}{dt^2} \right|_{t=0} = \sigma^2 = \text{Var}(x) \quad (31)$$

Procedendo con le derivate successive si può osservare che tutti i momenti centrali di ordine dispari sono nulli ($\mu_3 = 0$, ecc.), il che conferma la simmetria della distribuzione.

In particolare, per la normale standard $N(0, 1)$, si ha:

$$M_x(t) = \bar{M}_x(t) = e^{\frac{t^2}{2}} \quad (32)$$

Variabili Aleatorie e Combinazioni Lineari

Si può dimostrare un importante teorema: una combinazione lineare di variabili casuali normali e statisticamente indipendenti è anch'essa distribuita secondo una legge normale. Per la dimostrazione utilizziamo la funzione generatrice dei momenti. Supponiamo di avere $X_1, X_2, \dots, X_M$ variabili aleatorie indipendenti, ognuna descritta da una gaussiana $N_i(\mu_i, \sigma_i^2)$. Una loro combinazione lineare può essere scritta come:

$$S = \sum_{i=1}^k a_i x_i \quad (33)$$

dove a_i sono i coefficienti scalari. Definendo $y_i = a_i x_i$, vogliamo dimostrare che S ha una densità di probabilità gaussiana. La funzione generatrice di momenti per ogni x_i è:

$$M_{x_i}(t) = \exp\left(\mu_i t + \frac{1}{2} \sigma_i^2 t^2\right) \quad (34)$$

Sappiamo che per la somma di variabili indipendenti $z = \sum x_i$ vale la proprietà:

$$M_z(t) = \prod_i M_{x_i}(t) \quad (35)$$

Inoltre, per il prodotto di una variabile per una costante $y = ax$, vale:

$$M_y(t) = E[e^{ty}] = E[e^{tax}] = M_x(at) \quad (36)$$

Applicando queste proprietà alla nostra somma $S = \sum_i y_i$ (dove $y_i = a_i x_i$), otteniamo:

$$M_s(t) = \prod_i M_{y_i}(t) = \prod_i M_{x_i}(a_i t) \quad (37)$$

Sostituendo la forma funzionale della gaussiana:

$$M_s(t) = \prod_i \left[\exp \left(\mu_i(a_i t) + \frac{1}{2} \sigma_i^2(a_i t)^2 \right) \right] \quad (38)$$

Utilizzando la proprietà degli esponenziali per cui il prodotto di esponenziali è l'esponenziale della somma degli esponenti:

$$M_s(t) = \exp \left[\left(\sum_i \mu_i a_i \right) t + \frac{1}{2} \left(\sum_i \sigma_i^2 a_i^2 \right) t^2 \right] \quad (39)$$

Il risultato mostra che la funzione generatrice di S ha la stessa forma funzionale di una gaussiana. Dunque, una variabile dipendente linearmente da altre variabili normali indipendenti avrà anch'essa distribuzione normale, con parametri:

$$\mu_s = \sum_i \mu_i a_i \quad (40)$$

$$\sigma_s^2 = \sum_i \sigma_i^2 a_i^2 \quad (41)$$

È importante notare che la gaussiana è l'unica distribuzione a varianza finita che gode di questa proprietà (stabilità rispetto alle combinazioni lineari). Ad esempio, per la distribuzione di Poisson, la somma di variabili indipendenti $y = \sum x_i$ è ancora una Poissoniana, ma la moltiplicazione per una costante non preserva la distribuzione. Se $y = ax$, la funzione generatrice diventa:

$$M_y(t) = M_x(at) = \exp[\lambda(e^{at} - 1)] \quad (42)$$

Questa espressione corrisponde a una Poissoniana solo se $a = 1$. Il motivo per cui il "trucco" funziona per la gaussiana risiede nel fatto che l'esponente della sua $M_x(t)$ è un polinomio di secondo grado in t : la sostituzione $t \rightarrow at$ mantiene il polinomio di secondo grado, preservando così la forma della distribuzione.

5 Teorema del Limite Centrale

Il Teorema del Limite Centrale è un risultato fondamentale della statistica. Esso giustifica l'utilizzo della distribuzione gaussiana (o normale) per descrivere i risultati di misurazioni fisiche, specialmente quando queste sono affette da molteplici cause di errore indipendenti.

Teorema. Consideriamo un insieme di n variabili aleatorie **indipendenti** $\{x_1, \dots, x_n\}$. Assumiamo che ciascuna variabile x_i abbia una densità di probabilità $P_i(x)$ e che il suo valore atteso (media) $E[x_i] = \mu_i$ e la sua varianza $\text{var}(x_i) = \sigma_i^2$ **esistano e siano finiti**.

Definiamo la variabile aleatoria S come la somma delle n variabili:

$$S = \sum_{i=1}^n x_i$$

Il valore atteso e la varianza di S sono dati da (proprietà dimostrabili per variabili indipendenti):

$$E[S] = \sum_{i=1}^n \mu_i \quad \text{var}(S) = \sum_{i=1}^n \sigma_i^2$$

Il teorema afferma che, per $n \rightarrow \infty$, la distribuzione di S tende a una distribuzione normale:

$$S \stackrel{n \rightarrow \infty}{\sim} \mathcal{N}\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Nella pratica, l'approssimazione è spesso già accettabile per $n \geq 10$.

È possibile riformulare il teorema utilizzando la variabile standardizzata. Applicando la trasformazione $z = \frac{\text{valore} - \text{media}}{\text{dev. std}}$, otteniamo:

$$Z_n = \frac{S - \sum_{i=1}^n \mu_i}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \stackrel{n \rightarrow \infty}{\sim} \mathcal{N}(0, 1)$$

Caso Particolare: Variabili I.I.D.

Un caso molto comune è quello in cui le variabili x_i sono **indipendenti e identicamente distribuite** (I.I.D.). In questo scenario, le ipotesi si semplificano:

- Tutte le variabili hanno la stessa distribuzione: $P_i(x) = P(x)$;
- Stessa media: $\mu_i = \mu$;
- Stessa deviazione standard: $\sigma_i = \sigma$.

Di conseguenza, i parametri della somma S diventano:

- $E[S] = \sum_{i=1}^n \mu = n\mu$
- $\text{var}(S) = \sum_{i=1}^n \sigma^2 = n\sigma^2$

La variabile standardizzata assume quindi la forma:

$$Z_n = \frac{S - n\mu}{\sqrt{n\sigma^2}} = \frac{S - n\mu}{\sigma\sqrt{n}} \quad (43)$$

Dividendo numeratore e denominatore per n , possiamo esprimere il risultato in termini della **media campionaria** $\bar{x} = \frac{S}{n} = \frac{\sum x_i}{n}$:

$$Z_n = \frac{\frac{S-n\mu}{n}}{\frac{\sigma\sqrt{n}}{n}} = \frac{\frac{S}{n} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \quad (44)$$

Questo implica che, per $n \rightarrow \infty$:

$$\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad (45)$$

Ovvero, la media campionaria $\bar{x}$ tende a distribuirsi secondo una normale con media μ e varianza ridotta:

$$\bar{x} \stackrel{n \rightarrow \infty}{\sim} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Per tornare alla variabile non standardizzata, invertiamo la relazione:

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \implies \bar{x} = \mu + z \frac{\sigma}{\sqrt{n}}$$

Dimostrazione (tramite Funzione Generatrice dei Momenti)

Dimostriamo il teorema nel caso I.I.D., ovvero proviamo che:

$$\lim_{n \rightarrow \infty} \frac{S - n\mu}{\sigma\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Per semplificare i calcoli, partiamo dalle variabili standardizzate delle singole x_i . Definiamo:

$$y_i = \frac{x_i - \mu}{\sigma}$$

Analizziamo le proprietà di y_i :

- Valore atteso:

$$E[y_i] = E\left[\frac{x_i - \mu}{\sigma}\right] = \frac{1}{\sigma}(E[x_i] - \mu) = \frac{1}{\sigma}(\mu - \mu) = 0$$

- Varianza:

$$\text{var}(y_i) = \text{var}\left(\frac{x_i - \mu}{\sigma}\right) = \frac{1}{\sigma^2} \text{var}(x_i) = \frac{\sigma^2}{\sigma^2} = 1$$

(Nota: abbiamo usato le proprietà $E[x - c] = E[x] - c$ e $\text{var}(a(x + c)) = a^2 E[(x + c)^2]$).

Definiamo ora la variabile somma standardizzata Z :

$$Z = \frac{\sum_{i=1}^n y_i}{\sqrt{n}}$$

Si noti che questa espressione è equivalente a $\frac{S - n\mu}{\sigma\sqrt{n}}$.

Calcoliamo la **Funzione Generatrice dei Momenti** (MGF) di Z , indicata con $M_Z(t)$. Poiché le y_i sono indipendenti, la MGF della somma è il prodotto delle MGF. Inoltre, ricordando che $M_{aX}(t) = M_X(at)$, otteniamo:

$$M_Z(t) = \prod_{i=1}^n M_{y_i} \left(\frac{t}{\sqrt{n}} \right) \quad (46)$$

Essendo le y_i identicamente distribuite, tutte le M_{y_i} sono uguali a una generica M_y :

$$M_Z(t) = \left[M_y \left(\frac{t}{\sqrt{n}} \right) \right]^n \quad (47)$$

Sviluppiamo $M_y(k) = E[e^{ky}]$ in serie di Taylor attorno a $k = 0$, ponendo $k = t/\sqrt{n}$:

$$e^{ky} = 1 + ky + \frac{k^2 y^2}{2} + \dots \implies e^{ty/\sqrt{n}} = 1 + \frac{ty}{\sqrt{n}} + \frac{t^2 y^2}{2n} + o\left(\frac{1}{n}\right) \quad (48)$$

Passando ai valori attesi e ricordando che $E[y] = 0$ e $E[y^2] = \text{var}(y) + E[y]^2 = 1$:

$$E \left[e^{ty/\sqrt{n}} \right] = 1 + \frac{t}{\sqrt{n}} \underbrace{E[y]}_0 + \frac{t^2}{2n} \underbrace{E[y^2]}_1 + \dots \simeq 1 + \frac{t^2}{2n} \quad (49)$$

Sostituendo questo risultato nella formula di $M_Z(t)$:

$$M_Z(t) \simeq \left(1 + \frac{t^2}{2n} \right)^n \quad (50)$$

Calcoliamo il limite per $n \rightarrow \infty$ sfruttando il limite notevole $(1 + \frac{a}{n})^n \rightarrow e^a$:

$$\lim_{n \rightarrow \infty} M_Z(t) = e^{t^2/2} \quad (51)$$

La funzione $e^{t^2/2}$ è esattamente la funzione generatrice dei momenti della normale standard $\mathcal{N}(0, 1)$. Per il teorema di unicità delle funzioni generatrici, concludiamo che Z converge in distribuzione alla normale standard.

Implicazioni del Teorema nell'Analisi Dati

Il teorema ha implicazioni cruciali: ci assicura che l'effetto cumulativo di molte piccole perturbazioni indipendenti produce una distribuzione gaussiana, indipendentemente dalla forma della distribuzione di partenza.

Nelle misure fisiche, se ripetiamo una misura n volte, la media aritmetica $\bar{x}$ tende a distribuirsi come $\mathcal{N}(\mu, \sigma^2/n)$. Questo significa che l'incertezza associata alla *media* (deviazione standard della media) è:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \quad (52)$$

dove σ è la deviazione standard della singola misura.

In un esperimento reale, non conosciamo il vero σ , ma lo stimiamo con la deviazione standard campionaria s :

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

Il risultato finale di n misure ripetute viene quindi riportato come:

$$\text{Risultato} = \bar{x} \pm \frac{s}{\sqrt{n}} \quad (53)$$

Questo intervallo ha un preciso significato probabilistico (intervalli di confidenza):

- $\bar{x} \pm 1\sigma_{\bar{x}}$ copre il 68.3% di probabilità;
- $\bar{x} \pm 2\sigma_{\bar{x}}$ copre il 95.5% di probabilità;
- $\bar{x} \pm 3\sigma_{\bar{x}}$ copre il 99.7% di probabilità.

5.1 Generazione di Numeri Casuali Normali

Una delle applicazioni informatiche del teorema è la generazione di numeri pseudo-casuali con distribuzione normale a partire da un generatore uniforme (disponibile in tutti i linguaggi di programmazione).

Consideriamo n variabili $\{u_1, \dots, u_n\}$ con distribuzione uniforme in $[0, 1]$. Per la distribuzione uniforme:

- Densità: $P(u) = 1$ per $u \in [0, 1]$, 0 altrimenti.
- Media: $E[u] = \int_0^1 u \, du = \frac{1}{2}$.
- Secondo momento: $E[u^2] = \int_0^1 u^2 \, du = \frac{1}{3}$.
- Varianza: $\text{var}(u) = E[u^2] - E[u]^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$.

Applicando il Teorema del Limite Centrale alla somma, la variabile standardizzata è:

$$Z = \frac{\sum u_i - nE[u]}{\sqrt{n\text{var}(u)}} = \frac{\sum u_i - n/2}{\sqrt{n/12}} \sim \mathcal{N}(0, 1) \quad (54)$$

Per semplificare il calcolo, si sceglie spesso $n = 12$. In questo caso il denominatore diventa $\sqrt{12/12} = 1$ e la formula si riduce a:

$$Z \approx \sum_{i=1}^{12} u_i - 6 \quad (55)$$

Quindi: si sommano 12 numeri uniformi e si sottrae 6. *Nota:* Questo metodo è veloce ma approssimato; le "code" della distribuzione (oltre 6σ) sono troncate, poiché la somma di variabili limitate è comunque limitata.

5.2 La Trasformazione di Box-Muller

Un metodo matematicamente esatto per generare numeri normali da numeri uniformi è la **trasformazione di Box-Muller**.

Questo metodo si basa sul cambiamento di variabili per le densità di probabilità. Se abbiamo variabili casuali x legate a variabili y da una trasformazione invertibile, la densità di probabilità congiunta si trasforma secondo:

$$P_y(y_1, \dots, y_n) = P_x(x_1, \dots, x_n) \cdot |J| \quad (56)$$

dove $|J|$ è il valore assoluto del determinante Jacobiano della trasformazione inversa (da y a x).

Siano x_1, x_2 due variabili indipendenti uniformi in $[0, 1]$. Definiamo due nuove variabili y_1, y_2 :

$$y_1 = \sqrt{-2 \ln x_1} \cos(2\pi x_2) \quad (57)$$

$$y_2 = \sqrt{-2 \ln x_1} \sin(2\pi x_2) \quad (58)$$

Per dimostrare che y_1 e y_2 sono gaussiane standard indipendenti, invertiamo il sistema per esprimere x in funzione di y :

- Dal rapporto $y_2/y_1 = \tan(2\pi x_2)$ otteniamo $x_2 = \frac{1}{2\pi} \arctan(y_2/y_1)$.
- Dalla somma dei quadrati $y_1^2 + y_2^2 = -2 \ln x_1$ otteniamo $x_1 = \exp\left[-\frac{1}{2}(y_1^2 + y_2^2)\right]$.

La densità congiunta delle variabili uniformi è $P_x(x_1, x_2) = 1$ (nel quadrato unitario). Calcoliamo lo Jacobiano $J = \det \frac{\partial(x_1, x_2)}{\partial(y_1, y_2)}$:

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix}$$

Calcolo delle derivate parziali:

- $\frac{\partial x_1}{\partial y_1} = -y_1 e^{-\frac{1}{2}(y_1^2 + y_2^2)}$
- $\frac{\partial x_1}{\partial y_2} = -y_2 e^{-\frac{1}{2}(y_1^2 + y_2^2)}$
- $\frac{\partial x_2}{\partial y_1} = \frac{1}{2\pi} \frac{1}{1 + (y_2/y_1)^2} \left(-\frac{y_2}{y_1^2}\right) = -\frac{1}{2\pi} \frac{y_2}{y_1^2 + y_2^2}$
- $\frac{\partial x_2}{\partial y_2} = \frac{1}{2\pi} \frac{1}{1 + (y_2/y_1)^2} \left(\frac{1}{y_1}\right) = \frac{1}{2\pi} \frac{y_1}{y_1^2 + y_2^2}$

Calcolando il determinante:

$$\begin{aligned} J &= (-y_1 e^{-\dots}) \left(\frac{y_1}{2\pi(y_1^2 + y_2^2)} \right) - (-y_2 e^{-\dots}) \left(-\frac{y_2}{2\pi(y_1^2 + y_2^2)} \right) \\ &= -\frac{1}{2\pi} e^{-\frac{1}{2}(y_1^2 + y_2^2)} \left(\frac{y_1^2 + y_2^2}{y_1^2 + y_2^2} \right) \\ &= -\frac{1}{2\pi} e^{-\frac{1}{2}(y_1^2 + y_2^2)} \end{aligned}$$

Prendendo il valore assoluto per la densità di probabilità:

$$P_y(y_1, y_2) = 1 \cdot |J| = \frac{1}{2\pi} e^{-\frac{y_1^2 + y_2^2}{2}} = \left(\frac{1}{\sqrt{2\pi}} e^{-y_1^2/2} \right) \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-y_2^2/2} \right) \quad (59)$$

Il risultato è il prodotto di due densità normali standard. Quindi y_1 e y_2 sono variabili $\mathcal{N}(0, 1)$ indipendenti.

```
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats

def gaussian_pdf(x, mu=0, sigma=1):
    return (1 / (sigma * np.sqrt(2 * np.pi))) * np.exp(-((x - mu) ** 2) / (2 *
        sigma ** 2))

# definisco una funzione che dato un array, costruisce l'istogramma e sovrappone
# una normale standard
def plot_histo_gauss(x, titolo):
    # Parametri richiesti
    # x: array di cui fare l'istogramma
    # titolo: stringa contenente il titolo dell'istogramma

    h, bins, _ = plt.hist(x, range=(-4,4), bins=80, alpha=0.6, label="istogramma
    ")
    delta_x = bins[1] - bins[0]
    centri = (bins[:-1] + bins[1:]) / 2
    # aggiungo una barra di errore seguendo l'approssimazione di Poisson
    plt.errorbar(centri, h, np.sqrt(h), delta_x/2, c='tab:grey', lw=1, fmt='none
    ', label="errore statistico")
    plt.plot(centri, gaussian_pdf(centri)*delta_x*len(x), label='normale standard
    ')
    plt.xlabel("x")
    plt.ylabel("Conteggi")
    plt.title(titolo)
    plt.legend()
    plt.show()

n = 12
m = 10000

# lista dove salvare i numeri generati
lista_gauss = []
for i in range(m):
    # genero n numeri random tra 0 e 1
    u = np.random.uniform(0, 1, n)

    # li sommo e sottraggo 6
    x = np.sum(u) - 6

    # aggiungo il numero ottenuto alla lista
    lista_gauss.append(x)
```

```

# ora faccio un istogramma degli elementi della lista e sovrappongo una normale
standard
plot_histo_gauss(lista_gauss, "Generazione da teorema del limite centrale")

# -- Caso della formula di Box-Muller --

# genero m numeri random e ottengo da essi due array x1 e x2 contenenti
rispettivamente la prima e la seconda meta' dell'array
x = np.random.uniform(0,1,m)
x1 = x[0:int(m/2)]
x2 = x[int(m/2):m]

print(f"elementi di x {len(x)}, elementi di x1 {len(x1)}, elementi di x2 {len(x2)}")
print(x1[-1],x2[0])

# uso la trasformazione di Box-Muller per ottenere valori distribuiti secondo
una normale standard
y1 = np.sqrt(-2*np.log(x1))*np.cos(2*np.pi*x2)
y2 = np.sqrt(-2*np.log(x1))*np.sin(2*np.pi*x2)
y = np.concatenate((y1,y2))
print(f"elementi di y {len(y)}, elementi di y1 {len(y1)}, elementi di y2 {len(y2)}")

plot_histo_gauss(y, "Generazione da Box-Muller")

```

Listing 8: Generazione numeri casuali: Teorema del Limite Centrale e Box-Muller




Figura 5: A sinistra: generazione di una normale standard tramite il Teorema del Limite Centrale. A destra: generazione tramite il metodo di Box-Muller. Entrambi si sovrappongono perfettamente alla curva teorica.

6 Distribuzione di Cauchy e Legge dei grandi numeri

6.1 Distribuzione di Cauchy come rapporto di due normali standard

Supponiamo che x_1, x_2 sono due variabili aleatorie indipendenti normali standard. La loro densità di probabilità congiunta è

$$P_x(x_1, x_2) = \frac{1}{2\pi} \exp \left[-(x_1^2 + x_2^2)/2 \right]$$

Quello che ci interessa è studiare la variabile

$$y_1 = \frac{x_1}{x_2}$$

Per comodità ci conviene introdurre la variabile $y_2 = x_2$, in modo che la trasformazione diventi:

$$\begin{cases} y_1 = x_1/x_2 \\ y_2 = x_2 \end{cases} \quad \text{e viceversa} \quad \begin{cases} x_1 = y_1 y_2 \\ x_2 = y_2 \end{cases}$$

Così facendo lo jacobiano della trasformazione è semplicemente

$$\frac{\partial x_1}{\partial y_1} \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \frac{\partial x_2}{\partial y_1} = y_2 - y_1 \cdot 0 = y_2$$

Si ha quindi che

$$P_y(y_1, y_2) = \frac{1}{2\pi} \exp \left[-(x_1^2 + x_2^2)/2 \right] |y_2|$$

Ora scrivo l'esponente in termini di y_1 e y_2 e ho

$$-(x_1^2 + x_2^2)/2 = -\frac{(y_1 y_2)^2 + y_2^2}{2} = -\frac{y_2^2(y_1^2 + 1)}{2}$$

quindi sostituendo ho

$$P_y(y_1, y_2) = \frac{|y_2|}{2\pi} \exp \left[-\frac{y_2^2(y_1^2 + 1)}{2} \right]$$

Ora a me serve calcolare $P_y(y_1)$ e per farlo marginalizzo rispetto a y_2 cioè integro $P_y(y_1, y_2)$ rispetto a y_2

$$P_y(y_1) = \int_{-\infty}^{+\infty} \frac{|y_2|}{2\pi} \exp \left[-\frac{y_2^2(y_1^2 + 1)}{2} \right] dy_2$$

Essendo la funzione integranda pari in y_2 avremo

$$P_y(y_1) = 2 \int_0^{+\infty} \frac{y_2}{2\pi} \exp \left[-\frac{y_2^2(y_1^2 + 1)}{2} \right] dy_2$$

L'integrale che resta è del tipo $\int_0^\infty x e^{-ax^2} dx$ con $a = \frac{y_1^2 + 1}{2}$. Questo integrale si può risolvere facendo il cambiamento di variabile $u = ax^2 \implies du = 2ax dx \implies x dx = \frac{1}{2a} du$

$$\int_0^\infty x e^{-ax^2} dx = \int_0^\infty \frac{1}{2a} du e^{-u} = \frac{1}{2a} \int_0^\infty e^{-u} du = \frac{1}{2a} [-e^{-u}]_0^\infty = \frac{1}{2a}$$

Sostituendo si ha quindi che

$$P_y(y_1) = \frac{1}{\pi} \frac{1}{1 + y_1^2}$$

La distribuzione di probabilità trovata è la funzione di Cauchy standard, il che dimostra che il rapporto fra due variabili normali segue la distribuzione di Cauchy.

Questa distribuzione, anche conosciuta come distribuzione di Breit-Wigner è molto usata in fisica delle particelle in cui la forma di solito è quella che si ottiene con un cambiamento di variabili del tipo $y_1 = \frac{x-x_0}{\Gamma} \implies x = \Gamma y_1 + x_0$

$$P_X(x) = \frac{1}{\pi} \frac{1}{1 + \left(\frac{x-x_0}{\Gamma}\right)^2} \cdot \left| \frac{dy_1}{dx} \right| = \frac{1}{\pi} \frac{\Gamma^2}{\Gamma^2 + (x-x_0)^2} \cdot \frac{1}{\Gamma} = \frac{1}{\pi} \frac{\Gamma}{\Gamma^2 + (x-x_0)^2}$$

Di solito questa funzione viene usata perché è una buona approssimazione per descrivere la massa invariante delle risonanze in fisica delle particelle o le intensità delle righe spettrali di emissione o assorbimento negli atomi. Nella formula x_0 rappresenta la locazione delle risonanze e Γ ha a che fare con la sua larghezza.

La caratteristica di questa distribuzione è che, anche se è simmetrica rispetto a x_0 (oppure 0 nella formulazione di Cauchy) si vede che gli integrali

$$\int_{-\infty}^0 xP(x)dx \quad \text{e} \quad \int_0^{+\infty} xP(x)dx$$

sono individualmente divergenti, il primo fa $-\infty$ e il secondo $+\infty$ e quindi tecnicamente il valore di aspettazione non è definito.

Intuitivamente il problema è che la distribuzione di Cauchy ha code così alte che la media non riesce a stabilizzarsi a un valore preciso. Quando si calcola la media di n eventi, al crescere di n , si vede che all'inizio sembra che la media si stabilizzi a zero poi si iniziano a presentare dei salti che spostano la media. Questo perché visto che i valori nelle code della distribuzione non sono tanto rari, ne viene aggiunto uno alla somma con l'effetto di spostare la media.

Analogamente la varianza e tutti i momenti di ordine superiore sono divergenti.

6.2 Legge dei grandi numeri

La legge dei grandi numeri è un altro dei teoremi fondamentali della statistica che serve a capire perché ha senso usare la media aritmetica. In sostanza dice che se ripetiamo un esperimento molte volte, la media dei risultati ottenuti tende al valore di aspettazione della densità di probabilità alla base del fenomeno.

In realtà esistono varie formulazioni, quella descritta è la legge debole dei grandi numeri. Per formularla in maniera più formale indichiamo con il simbolo $\text{Prob}(A)$ la probabilità che si verifichi un certo evento A . Più precisamente se X è una variabile aleatoria con densità di probabilità $P(x)$ allora

$$\text{Prob}(X > a) = \int_a^{+\infty} P(x)dx$$

Nel caso discreto cioè se X non è reale e ad ogni x_i posso associare una certa p_i allora si avrà che

$$\text{Prob}(X > a) = \sum_{x_i > a}^{+\infty} p_i$$

che si può scrivere anche $\text{Prob}(X > a) = \sum_{x_i > a} p_i$.

Matematicamente il modo in cui si formula la legge è: date n variabili aleatorie $\{X_1, X_2, \dots, X_n\}$ indipendenti e con la stessa densità di probabilità, quindi con lo stesso valore di aspettazione $E[X_i] = E[X] = \mu$ e varianza $\text{Var}(X_i) = \text{Var}(X) = \sigma^2$ che devono esistere finite, allora $\forall \varepsilon > 0$

$$\lim_{n \rightarrow \infty} \text{Prob}(|\bar{x} - \mu| \geq \varepsilon) = 0$$

cioè la probabilità che la media aritmetica di n variabili differisca dal valore di aspettazione va a zero per n che tende a infinito.

Dimostrazione

La dimostrazione richiede vari passaggi e dimostrazioni intermedie. Per semplicità consideriamo il caso di variabili discrete (si può passare al caso continuo sostituendo le sommatorie con gli integrali) e parto da una probabilità simile a quella della tesi ma non esattamente uguale cioè

$$\text{Prob}(|X - \mu| \geq \varepsilon) = \sum_{|x_i - \mu| \geq \varepsilon} p_i$$

quindi in questo caso la sommatoria è estesa solo ai valori di X_i che soddisfano $|x_i - \mu| \geq \varepsilon$ dove $\mu = E[X]$.

Per arrivare a dire qualcosa su questa probabilità usiamo la definizione di varianza nel caso discreto

$$\sigma^2 = E[(X - \mu)^2] = \sum_i p_i (x_i - \mu)^2$$

dove in questo caso la sommatoria è estesa a tutti i valori di i per cui x_i esiste (tipicamente $-\infty, +\infty$). Se consideriamo solo i valori di $x_i : |x_i - \mu| \geq \varepsilon$ allora avremo un sottoinsieme di tutti i valori possibili di x_i , quindi

$$\sigma^2 \geq \sum_{|x_i - \mu| \geq \varepsilon} p_i (x_i - \mu)^2 \geq \sum_{|x_i - \mu| \geq \varepsilon} p_i \varepsilon^2$$

dove l'ultimo passaggio viene dal fatto che dato che la sommatoria vale per $|x_i - \mu| \geq \varepsilon$ varrà in particolar quando vale $|x_i - \mu| = \varepsilon$ quindi se lo sostituisco dentro la sommatoria avrò in generale qualcosa di più piccolo.

Nella sommatoria che rimane ε^2 non dipende da i e quindi si può portare fuori:

$$\sigma^2 \geq \varepsilon^2 \sum_{|x_i - \mu| \geq \varepsilon} p_i$$

Qui posso sostituire la definizione iniziale

$$\sigma^2 \geq \varepsilon^2 \text{Prob}(|X - \mu| \geq \varepsilon)$$

E quindi invertendo ho

$$\text{Prob}(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

Questa disuguaglianza è nota come **disuguaglianza di Chebyshev** che si può trovare in letteratura anche nella forma che si ottiene da questa ponendo $\varepsilon = K\sigma$ cioè

$$\text{Prob}(|X - \mu| \geq K\sigma) \leq \frac{1}{K^2}$$

Useremo questa disuguaglianza per dimostrare la legge dei grandi numeri, ma prima vale la pena notare le sue implicazioni in generale. Senza aver fatto nessuna assunzione sulla densità di probabilità, questa disuguaglianza dà dei limiti superiori a quanto una qualunque variabile aleatoria X si possa allontanare da μ . Per esempio per $K = 2$ si ha che $\text{Prob}(|X - \mu| \geq 2\sigma) \leq \frac{1}{4} = 0.25$ cioè la probabilità che $|X - \mu| \geq 2\sigma$ non può superare il 25% o al contrario almeno nel 75% dei casi si ha $|X - \mu| < 2\sigma$. Ovviamente questo è un limite inferiore e vale per qualsiasi distribuzione. Abbiamo visto che nel caso della gaussiana vale in particolare $P(|X - \mu| < 2\sigma) \sim 95\%$.

```
import numpy as np
import matplotlib.pyplot as plt
import math

# Parametri della gaussiana
mu = 0
sigma = 1

# Funzione densità di probabilità (PDF) della gaussiana con normale come default
def gaussian_pdf(x, mu=0, sigma=1):
    return (1 / (sigma * math.sqrt(2 * math.pi))) * np.exp(-((x - mu) ** 2) / (2 * sigma ** 2))

# Calcolo l'integrale con il metodo numerico dei rettangoli
def integra(a, b, n=200000):
    # a partire dall'intervallo [a,b] costruisco n rettangolini tutti larghi uguali con base:
    base = (b - a) / n
    somma = 0.0
    # ora sommo le altezze di tutti i rettangolini
    for k in range(n):
        x_mid = a + (k + 0.5) * base
        somma += gaussian_pdf(x_mid)
    # uso la formula base*altezza per calcolare la somma delle aree di tutti i rettangolini
    return base * somma

print("Integrazione numerica della gaussiana standard\n")

for sigma in [1, 2, 3]:
    area = integra(-sigma, sigma)
    print(f"La probabilità che x assuma valori compresi entro {sigma} deviazioni standard è {area:.6f}")
```

```

    print(f"Viceversa la probabilità che  $x > \{\text{sigma}\}\text{sigma}$  è  $\{1-\text{area}:.6f\}\backslash n$ ")

# Metodo alternativo: estraggo numeri casuali con densità di probabilità
# gaussiana,
# creo un istogramma con questi numeri e poi sommo i contenuti dei bin

# estrazione dei numeri casuali
N = 300000
campioni = np.random.normal(0, 1, N)

# creo l'istogramma senza la parte grafica al momento
bins = np.linspace(-4, 4, 81) # larghezza bin = 0.1
conteggi, bordi = np.histogram(campioni, bins=bins)

bin_width = bordi[1] - bordi[0]
centri = (bordi[:-1] + bordi[1:]) / 2

# Creo una mappa dei colori per intervalli sigma che userò successivamente per
# il grafico
for sigma, colore in zip([1,2,3], ['green','orange','purple']):
    colors = []
    area = 0
    for c, h in zip(centri, conteggi):
        if abs(c) <= sigma:
            colors.append(colore)
            area += h
        else:
            colors.append('white')

    print(f"Area tra  $-\{\text{sigma}\}\text{sigma}$  e  $\{\text{sigma}\}\text{sigma}$  =  $\{\text{area}/N:.6f\}$ ")

# Disegno istogramma usando delle barre colorate con la mappa di prima
plt.figure(figsize=(8,5))
plt.bar(centri, conteggi, width=bin_width, color=colors, alpha=0.5, label =
f"Integrale =  $\{\text{area}/N:.4f\}$ ")

# Gaussiana teorica moltiplicata per  $\text{deltax}$  e per N
x = np.linspace(-4,4,1000)
plt.plot(x, gaussian_pdf(x)*bin_width*np.sum(conteggi), 'r', linewidth=2,
label="Gaussiana teorica")

# Linea sigma
plt.axvline(sigma, linestyle='--', color=colore, label=f" $\pm \{\text{sigma}\}\text{sigma}$ ")
plt.axvline(-sigma, linestyle='--', color=colore)

plt.title("Istogramma con colori per intervalli  $\pm n\text{sigma}$ ")
plt.xlabel("$x$")
plt.ylabel("Densità di probabilità")
plt.legend()
plt.grid(True)

```

```
plt.margins(x=0)
plt.show()
```

Listing 9: Calcolo probabilità e plot della Gaussiana (1, 2 e 3 deviazioni standard)




Figura 6: Visualizzazione dell'area sottesa alla gaussiana standard nell'intervallo $\pm 2\sigma$. Come previsto dalla teoria, l'area copre circa il 95.4% dei casi, un limite ben più stringente del 75% garantito dalla disuguaglianza di Chebyshev.

Torniamo ora al caso della media $\bar{x}$ e applicando la disuguaglianza di prima avremo

$$\text{Prob}(|\bar{x} - E[\bar{x}]| \geq \varepsilon) \leq \frac{\text{Var}(\bar{x})}{\varepsilon^2}$$

dove $E[\bar{x}] = E\left[\frac{\sum_i x_i}{n}\right] = \frac{1}{n} \sum_i E[x_i] = \frac{1}{n} n\mu = \mu$

mentre $\text{Var}(\bar{x}) = \text{Var}\left(\frac{1}{n} \sum_i x_i\right) = \frac{1}{n^2} \sum_i \text{Var}(x_i) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$

Sostituendo si ha quindi

$$\text{Prob}(|\bar{x} - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2}$$

Al limite per $n \rightarrow \infty$, $\frac{1}{n} \rightarrow 0$ per cui questo dimostra che

$$\lim_{n \rightarrow \infty} \text{Prob}(|\bar{x} - \mu| \geq \varepsilon) = 0$$

$$\begin{aligned} \star \quad & \text{Prob}(|X - \mu| \geq K\sigma) = 1 - \text{Prob}(|X - \mu| < K\sigma) \leq \frac{1}{K^2} \\ \implies & \text{Prob}(|X - \mu| < K\sigma) \geq 1 - \frac{1}{K^2} \end{aligned}$$

Cenni di Distribuzione Esponenziale

$$P_{\text{exp}}(x; \tau) = \frac{1}{\tau} e^{-x/\tau} \quad 0 \leq x \leq +\infty$$

Il valore di aspettazione e la varianza si calcolano facilmente dalla funzione generatrice dei momenti

$$\begin{aligned}M_X(t) &= E[e^{tx}] = \int_0^\infty e^{tx} \frac{1}{\tau} e^{-x/\tau} dx = \frac{1}{\tau} \int_0^\infty e^{(t-1/\tau)x} dx \\&= \frac{1}{\tau} \frac{1}{t-1/\tau} [e^{(t-1/\tau)x}]_0^\infty = \frac{1}{t\tau-1} [0-1] = \frac{1}{1-t\tau}\end{aligned}$$

Per calcolare il valore di aspettazione la derivo:

$$\begin{aligned}M'_X(t) &= \frac{-1}{(1-t\tau)^2}(-\tau) = \frac{\tau}{(1-t\tau)^2} \\M'_X(0) &= \tau = E[X]\end{aligned}$$

Calcolo la derivata seconda ($D(x^{-2}) = -2x^{-3}$)

$$\begin{aligned}M''_X(t) &= -\frac{2\tau}{(1-t\tau)^3}(-\tau) = \frac{2\tau^2}{(1-t\tau)^3} \\M''_X(0) &= 2\tau^2 = E[X^2]\end{aligned}$$

Ora calcolo la varianza come

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 2\tau^2 - \tau^2 = \tau^2$$

7 Processi di Poisson, Esponenziale ed Erlang

7.1 Distribuzione Esponenziale

La distribuzione esponenziale descrive il tempo che intercorre tra due eventi consecutivi in un processo di Poisson.

Ricaviamola dalla **Distribuzione di Poisson**. Se un fenomeno segue la **distribuzione di Poisson**, la probabilità di osservare k eventi, dato un numero medio di eventi attesi ν , è:

$$P(k; \nu) = \frac{e^{-\nu} \nu^k}{k!} \quad (60)$$

Se definiamo λ come il numero di eventi attesi per **unità di tempo**, allora il numero medio di eventi attesi in un intervallo t è λt . La probabilità di osservare k eventi nell'intervallo t diventa:

$$P(k; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^k}{k!} \quad (61)$$

Definiamo una nuova variabile casuale T come l'intervallo di tempo che intercorre tra due eventi successivi. Affinché il tempo di attesa T sia maggiore di un certo valore t ($T > t$), non deve verificarsi alcun evento nell'intervallo $[0, t]$.

Pertanto, la probabilità che $T > t$ coincide con la probabilità di osservare zero eventi nel periodo t :

$$\text{Prob}(T > t) = P(0; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^0}{0!} = e^{-\lambda t} \quad (62)$$

Proprietà dell'Esponenziale

La **funzione di ripartizione** (o distribuzione cumulativa $F_X(x)$) indica la probabilità che una variabile x' assuma un valore minore o uguale a x :

$$F_X(x) = \text{Prob}(x' \leq x) = \int_{-\infty}^x P_X(z) dz \quad (63)$$

Dalle proprietà della probabilità, segue la normalizzazione: $\int_{-\infty}^{+\infty} P_X(x) dx = 1$.

Per la variabile tempo T , la funzione di ripartizione è:

$$F_T(t) = \text{Prob}(T \leq t) = 1 - \text{Prob}(T > t) = 1 - e^{-\lambda t} \quad (64)$$

La **densità di probabilità** $P_T(t)$ si ottiene derivando la funzione di ripartizione:

$$P_T(t) = \frac{d}{dt} F_T(t) = \frac{d}{dt} (1 - e^{-\lambda t}) = \lambda e^{-\lambda t} \quad (65)$$

Questa è la densità di probabilità esponenziale. Indica che i tempi di attesa brevi sono più probabili, mentre quelli lunghi sono meno probabili.

Confronto tra PDF e CDF Esponenziale ($\lambda = 1$)




Figura 7: La PDF decresce partendo da λ , mentre la CDF satura asintoticamente a 1.

Proprietà di Assenza di Memoria

Una caratteristica fondamentale è l'**assenza di memoria**: il tempo che resta da aspettare affinché un evento si verifichi è indipendente da quanto abbiamo già aspettato. Usando la probabilità condizionata $\text{Prob}(A|M) = \frac{\text{Prob}(A \cap M)}{\text{Prob}(M)}$:

- s : tempo già aspettato.
- t : tempo addizionale da aspettare.
- $A \rightarrow T > s + t$

- $M \rightarrow T > s$

$$\text{Prob}(T > s + t \mid T > s) = \frac{\text{Prob}(T > s + t)}{\text{Prob}(T > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(T > t) \quad (66)$$

Parametrizzazione con τ Spesso si scrive la distribuzione utilizzando $\tau = 1/\lambda$, dove τ rappresenta il **tempo medio** tra due eventi (mentre λ è la frequenza):

$$P_{exp}(x; \tau) = \frac{1}{\tau} e^{-x/\tau} \quad \text{per } 0 \leq x \leq +\infty \quad (67)$$

7.2 Distribuzione di Erlang

La distribuzione di Erlang è una generalizzazione della distribuzione esponenziale. Mentre l'esponenziale regola il tempo tra due eventi successivi ($k = 1$), la distribuzione di Erlang regola il tempo di attesa per il **k-esimo evento**.

Sia T_k il tempo di attesa fino al k -esimo evento.

- $P_1(t; \lambda) = \lambda e^{-\lambda t}$ (Esponenziale)
- Per P_2 , supponiamo che il primo evento avvenga a x ($0 < x < t$) e il secondo nel tempo restante $t - x$:

$$P_2(t; \lambda) = \int_0^t P_1(x; \lambda) P_1(t - x; \lambda) dx = \int_0^t \lambda e^{-\lambda x} \lambda e^{-\lambda(t-x)} dx = \lambda^2 t e^{-\lambda t} \quad (68)$$

Procedendo per induzione per P_3 :

$$P_3(t; \lambda) = \int_0^t P_2(x; \lambda) P_1(t - x; \lambda) dx = \int_0^t \lambda^2 x e^{-\lambda x} \lambda e^{-\lambda(t-x)} dx = \frac{t^2}{2} \lambda^3 e^{-\lambda t} \quad (69)$$




Figura 8: Schema temporale per il calcolo della distribuzione di Erlang P_2 .

Continuando ricorsivamente, si ottiene la densità di probabilità di Erlang:

$$P_k(t; \lambda) = \frac{t^{k-1}}{(k-1)!} \lambda^k e^{-\lambda t} \quad (70)$$

Momenti della distribuzione:

- Valore di aspettazione: $E[t] = \frac{k}{\lambda}$
- Varianza: $Var(t) = \frac{k}{\lambda^2}$

Distribuzione Gamma (approfondimento)

Cosideriamo α e β due costati maggiori di zero, allora la *Gamma distribution* è definita come:

$$f(x; \alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-\frac{x}{\beta}} \quad (71)$$

con la condizione di $0 \leq x < \infty$.

Questa risulta normalizzata in base alla condizione sulla funzione gamma:

$$\Gamma(\alpha) = \int_0^\infty y^{\alpha-1} e^{-y} dy$$

con la condizione di $\alpha > 0$; ricordiamo per correttezza la proprietà della funzione Gamma:

$$\Gamma(\alpha) = (\alpha - 1)\Gamma(\alpha - 1)$$




Figura 9: Al variare del parametro α trovo diverse pdf, il fattore β rappresenta un riscaldamento

Nel caso in cui $\alpha \in \mathbb{N}$, vado a ritrovare la *distribuzione di Erlang*(69); nel caso in cui si ha $\beta = 2$ e $\alpha = \frac{\nu}{2}$, con $\nu \in \mathbb{N}$, allora questa è la χ^2 *distribution*.

8 Metodi Monte Carlo

I metodi Monte Carlo sono algoritmi computazionali che sfruttano la generazione di numeri casuali per risolvere problemi matematici complessi. Questo campionamento casuale ha un certo numero di applicazioni, ma una delle più utili è che consente di calcolare in modo pratico integrali altrimenti impossibili.

Esempio Per calcolare l'area di una superficie irregolare:

1. Si lancia un numero N di chicchi di riso a caso su un foglio di area nota.
2. Si conta quanti chicchi cadono dentro l'area cercata (N_{in}).
3. Il rapporto N_{in}/N fornisce una stima dell'area, che diventa più accurata al crescere di N .

8.1 Metodo Accept-Reject

È un metodo generale per generare variabili continue secondo una distribuzione $f(x)$ non standard. Dati un intervallo $[x_{min}, x_{max}]$ e un valore massimo della funzione f_{max} :

1. Si genera x_i con distribuzione uniforme tra x_{min} e x_{max} : $x_i = x_{min} + r_1(x_{max} - x_{min})$.
2. Si genera y_i con distribuzione uniforme tra 0 e f_{max} .
3. Se $y_i < f(x_i)$, si **accetta** il valore x_i ; altrimenti lo si rifiuta.

L'efficienza η è il rapporto tra l'area sotto $f(x)$ e l'area del rettangolo:

$$\eta = \frac{1}{(x_{max} - x_{min})f_{max}} \int_{x_{min}}^{x_{max}} f(x) dx \quad (72)$$

Esempio: Algoritmo Hit-or-Miss in Python Il seguente script implementa il metodo Accept-Reject per campionare una distribuzione di probabilità legata allo scattering angolare (distribuzione di Cowen): $f(x) = \frac{3}{8}(1 + x^2)$.

```
import numpy as np
import matplotlib.pyplot as plt

def mia_funz(x):
    return 3/8*(1+x**2)

# Parametri del dominio e numero di punti
xmin, xmax = -1, 1
fmax = 3/4
N = 5000

accepted_x, accepted_y = [], []
rejected_x, rejected_y = [], []


# Ciclo Accept-Reject
while len(accepted_x) < N:
    x = np.random.uniform(xmin, xmax)
    y = np.random.uniform(0, fmax)

    if y <= mia_funz(x):
        accepted_x.append(x)
        accepted_y.append(y)
    else:
```

```
rejected_x.append(x)
rejected_y.append(y)

# Visualizzazione dei risultati
plt.figure(figsize=(8,6))
x_plot = np.linspace(xmin, xmax, 400)
plt.plot(x_plot, mia_funz(x_plot), label='f(x) teorica', lw=3)
plt.scatter(accepted_x, accepted_y, color='tab:green', s=4, label='Accettati')
plt.scatter(rejected_x, rejected_y, color='tab:red', s=4, label='Rifiutati')
plt.legend()
plt.show()
```

Listing 10: Implementazione del metodo Accept-Reject

Figura 10: Andamento della funzione teorica $f(x) = \frac{3}{8}(1 + x^2)$ nell'intervallo $[-1, 1]$.




Figura 11: Visualizzazione del metodo Hit-or-Miss: i punti in verde sono accettati perché cadono sotto la curva, quelli in rosso sono rifiutati.




Figura 12: Validazione del metodo: l'istogramma dei punti accettati segue fedelmente la curva teorica attesa (punti arancioni).

8.2 Metodo della Funzione di Ripartizione (Inversione)

Un metodo più efficiente dell'Accept-Reject si basa sull'inversione della CDF. Dato che $F(x) = \int_{-\infty}^x P(z) dz$ ha valori compresi tra 0 e 1, se generiamo un numero casuale $u \sim \mathcal{U}(0, 1)$, allora:

$$x = F^{-1}(u) \quad (73)$$

Il valore x così ottenuto sarà distribuito secondo la $P(x)$ originale.

Esempio per la distribuzione esponenziale:

- $P(x) = \frac{1}{\tau} \exp\left(-\frac{x}{\tau}\right)$
- $F(x) = 1 - \exp\left(-\frac{x}{\tau}\right) = u$
- Invertendo: $x = -\tau \ln(1 - u)$

Esempio: Integrazione Numerica e CDF Questo script mostra come calcolare numericamente la funzione di ripartizione (CDF) partendo dalla densità di probabilità (PDF) e come visualizzare il legame tra le due.

```
import numpy as np
import matplotlib.pyplot as plt
import math

# Funzione densita di probabilita (PDF) Gaussiana
def gaussian_pdf(x, mu=0, sigma=1):
    return (1 / (sigma * math.sqrt(2 * math.pi))) * np.exp(-((x - mu) ** 2) / (2 * sigma ** 2))

# Integrazione numerica con il metodo dei rettangoli
def integra(a, b, n=200000):
    base = (b - a) / n
    somma = 0.0
    for k in range(n):
        x_mid = a + (k + 0.5) * base
        somma += gaussian_pdf(x_mid)
    return base * somma

# Esempio probabilita entro sigma
for s in [1, 2, 3]:
    area = integra(-s, s)
    print(f"Probabilita entro {s} sigma: {area:.6f}")

# Plot PDF e CDF per una distribuzione esponenziale
tau = 5
x_axis = np.arange(0, 30, 0.1)
func_exp = np.exp(-x_axis/tau)/tau
cum_exp = 1 - np.exp(-x_axis/tau)

fig, axes = plt.subplots(1, 2, figsize=(12, 5))
```



```
axes[0].plot(x_axis, func_exp, label='PDF Esponenziale')
axes[1].plot(x_axis, cum_exp, label='CDF Esponenziale', color='orange')
plt.show()
```

Listing 11: Integrazione numerica della Gaussiana e PDF/CDF Esponenziale





Figura 13: Densità di probabilità (sinistra) e Funzione di ripartizione (destra) per la distribuzione esponenziale generata dal codice Python.

Figura 14: Analisi della distribuzione normale: PDF (sinistra) e CDF (destra). Le linee tratteggiate indicano i valori corrispondenti a $\pm 1\sigma$.

9 Variabili Casuali bidimensionali

9.1 Distribuzioni congiunte, marginali e condizionate

Abbiamo già accennato ad alcune proprietà delle distribuzioni di più variabili, adesso concentriamoci sul caso più semplice di distribuzione di più variabili, ovvero quando le variabili sono due.

Supponiamo allora di avere una coppia di variabili aleatorie X e Y (caso di un esperimento in cui si misurano due quantità).

La **densità di probabilità congiunta** $P(x, y)$ indica la probabilità che una certa realizzazione X di x e una certa realizzazione Y di y abbiano valori, rispettivamente, in

$(x, x + dx)$ e $(y, y + dy)$ per $dx \rightarrow 0$ e $dy \rightarrow 0$.

Come nel caso unidimensionale, si può usare $P(x, y)$ per definire altre funzioni, per esempio la **funzione di distribuzione congiunta**:

$$F(x, y) = \int_{-\infty}^x du \int_{-\infty}^y dv P(u, v) = \text{Prob}(X \leq x, Y \leq y) \quad (74)$$

che indica la probabilità di ottenere valori delle due variabili non superiori a quantità prefissate x, y . A partire dalla $F(x, y)$ si può scrivere la condizione di normalizzazione come $F(+\infty, +\infty) = 1$, cioè:

$$\int_{-\infty}^{+\infty} dx \int_{-\infty}^{+\infty} dy P(x, y) = 1 \quad (75)$$

A partire da $P(x, y)$ si può calcolare la densità di probabilità per una delle due variabili *qualunque valore abbia l'altra*, cioè le funzioni di **distribuzioni marginali**:

$$P_X(x) = \int_{-\infty}^{+\infty} P(x, y) dy \quad \text{e} \quad P_Y(y) = \int_{-\infty}^{+\infty} P(x, y) dx \quad (76)$$

Altre distribuzioni che si definiscono nel caso di più variabili sono le **funzioni di distribuzione condizionate**, che rappresentano la densità di probabilità dei valori di una variabile fissato il valore dell'altra, che indicheremo con $\prod(x|y)$ e $\prod(y|x)$. La cui espressione si può ricavare dal calcolo:

$$P(x, y) dx dy = P_X(x) dx \cdot \prod(y|x) dy = P_Y(y) dy \cdot \prod(x|y) dx \quad (77)$$

Si ha quindi:

$$\prod(y|x) = \frac{P(x, y)}{P_X(x)} \quad \text{e} \quad \prod(x|y) = \frac{P(x, y)}{P_Y(y)} \quad (78)$$

Nel caso in cui X e Y siano **indipendenti**, allora aver fissato il valore di una variabile non dovrebbe alterare la distribuzione dell'altra, cioè ci aspettiamo che sia:

$$\prod(x|y) = P_X(x) \quad \text{e} \quad \prod(y|x) = P_Y(y) \quad (79)$$

Se sostituiamo in una delle equazioni precedenti, per esempio in $\prod(y|x) = P(x, y)/P_X(x)$, abbiamo:

$$P_Y(y) = \frac{P(x, y)}{P_X(x)} \implies P(x, y) = P_X(x)P_Y(y) \quad (80)$$

9.2 Momenti: Matrice delle Covarianze e Combinazioni Lineari

Come nel caso unidimensionale si può calcolare il valore di aspettazione, però stavolta per generalizzare, considero una qualunque funzione di x e y , $f(x, y)$, e definisco il suo **valore di aspettazione** come:

$$\mathbb{E}[f(x, y)] = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{+\infty} dy f(x, y) P(x, y) \quad (81)$$

A partire da ciò posso definire i **momenti rispetto all'origine** come:

$$\mu_{mn} = \mathbb{E}[X^m Y^n] \quad (82)$$

per cui:

$$\begin{aligned}\mu_{00} &= \mathbb{E}[1] = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{+\infty} dy P(x, y) = 1 \\ \mu_{10} &= \mathbb{E}[X] \\ \mu_{01} &= \mathbb{E}[Y]\end{aligned}$$

Analogamente è possibile definire i **momenti rispetto al valore di aspettazione** di X e Y (momenti centrali) come:

$$\bar{\mu}_{mn} = \mathbb{E}[(X - \mathbb{E}[X])^m (Y - \mathbb{E}[Y])^n] \quad (83)$$

dove i più notevoli sono:

$$\begin{aligned}\bar{\mu}_{20} &= \mathbb{E}[(X - \mathbb{E}[X])^2] = \text{Var}(X) \\ \bar{\mu}_{02} &= \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \text{Var}(Y) \\ \bar{\mu}_{11} &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \text{Cov}(X, Y)\end{aligned}$$

Quest'ultima quantità si chiama **covarianza** ed è un parametro importante nel caso di più variabili perché *indica come sono correlate fra loro le variabili*. Infatti si può dimostrare che $\text{Cov}(X, Y) = 0$ se X e Y sono indipendenti l'una dall'altra.

Dimostrazione nel caso discreto

Per dimostrarlo è conveniente trovare un altro modo di scrivere la covarianza che si ricava più facilmente assumendo il caso discreto. Consideriamo il caso di 2 variabili discrete X e Y ; il valore di aspettazione di una determinata funzione è dato da:

$$\mathbb{E}[f(x, y)] = \sum_{i,j} P_{X,Y}(x_i, y_i) f(x_i, y_i)$$

dunque la covarianza è descrivibile da:

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \text{caso discreto} \\ &= \sum_{i,j} P_{ij}(x_i - \mathbb{E}[X])(y_j - \mathbb{E}[Y]) = \quad (\text{svolgo il prodotto}) \\ &= \sum_{i,j} P_{ij} x_i y_j - \sum_{i,j} P_{ij} x_i \mathbb{E}[Y] - \sum_{i,j} P_{ij} y_j \mathbb{E}[X] + \sum_{i,j} P_{ij} \mathbb{E}[X] \mathbb{E}[Y]\end{aligned}$$

Riconosciamo i vari termini:

- $\sum_{i,j} P_{ij} x_i y_j = \text{valore di aspettazione del prodotto } XY = \mathbb{E}[XY]$
- $\sum_{i,j} P_{ij} x_i = \mathbb{E}[X]$
- $\sum_{i,j} P_{ij} y_j = \mathbb{E}[Y]$
- $\sum_{i,j} P_{ij} \mathbb{E}[X] \mathbb{E}[Y] = \mathbb{E}[X] \mathbb{E}[Y] \sum_{i,j} P_{ij} = \mathbb{E}[X] \mathbb{E}[Y] \cdot 1 = \mathbb{E}[X] \mathbb{E}[Y]$

Quindi mettendo tutto insieme:

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y] - \mathbb{E}[Y] \mathbb{E}[X] + \mathbb{E}[X] \mathbb{E}[Y] \\ &= \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y] \end{aligned} \quad (84)$$

Questa formula vale in generale, ma nel caso in cui le variabili siano indipendenti allora nella sommatoria il termine P_{ij} si può scrivere come prodotto di un termine che dipende solo da i (che indico con $P_{X,i}$) e un termine che dipende solo da j (che indico con $P_{Y,j}$), in analogia a $P(x, y) = P_X(x)P_Y(y)$. Quindi:

$$\mathbb{E}[XY] = \sum_{i,j} P_{ij} x_i y_j = \sum_{i,j} P_{X,i} x_i P_{Y,j} y_j = \mathbb{E}[X] \mathbb{E}[Y]$$

Di conseguenza, in questo caso, $\text{Cov}(X, Y) = 0$.

Matrice delle covarianze (e combinazioni lineari di variabili)

Quando si lavora con più variabili si costruisce di solito la matrice delle covarianze che serve a semplificare la notazione. Il tipico esempio che fa capire da dove salta fuori è il calcolo del valore di aspettazione e varianza per una nuova variabile ottenuta come combinazione lineare di altre variabili.

Il caso più semplice è quello di $Z = aX + bY$, dove a e b sono degli scalari e X e Y sono due variabili aleatorie che per semplicità supponiamo abbiano $\mathbb{E}[X] = \mathbb{E}[Y] = 0$. Il valore di aspettazione di Z vale:

$$\mathbb{E}[Z] = a\mathbb{E}[X] + b\mathbb{E}[Y] = 0$$

La varianza di Z vale:

$$\begin{aligned} \text{Var}(Z) &= \mathbb{E}[(Z - \mathbb{E}[Z])^2] = \mathbb{E}[Z^2] = \mathbb{E}[(aX + bY)^2] = \\ &= \mathbb{E}[a^2 X^2] + \mathbb{E}[b^2 Y^2] + \mathbb{E}[2abXY] = \\ &= a^2 \mathbb{E}[X^2] + b^2 \mathbb{E}[Y^2] + 2ab \mathbb{E}[XY] \end{aligned}$$

il che si può scrivere in funzione delle varianze e della covarianza dato che $\mathbb{E}[X] = \mathbb{E}[Y] = 0$, cioè:

$$\boxed{\text{Var}(Z) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)} \quad (85)$$

Il risultato sulla varianza si può generalizzare al caso in cui $\mathbb{E}[X] \neq 0$ e $\mathbb{E}[Y] \neq 0$ perché basta fare il cambiamento di variabili $X' = X - \mathbb{E}[X]$ e $Y' = Y - \mathbb{E}[Y]$ che evidentemente hanno $\mathbb{E}[X'] = 0$ e $\mathbb{E}[Y'] = 0$. Inoltre:

$$\text{Var}(X') = \text{Var}(X - \mathbb{E}[X]) = \text{Var}(X)$$

(aggiungere o sottrarre una costante a una variabile non altera la varianza). Analogamente $\text{Var}(Y') = \text{Var}(Y)$, e infine si ha che:

$$\text{Cov}(X', Y') = \mathbb{E}[(X' - \mathbb{E}[X'])(Y' - \mathbb{E}[Y'])] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \text{Cov}(X, Y)$$

Quindi anche se le variabili non hanno valore di aspettazione nullo vale la stessa formula per $\text{Var}(Z)$.

Formulazione Matriciale

Risulta utile esprimere questo risultato sotto forma di moltiplicazioni di matrici (soprattutto quando si estende a più dimensioni) ed è a questo punto che si definisce la **matrice delle covarianze** (che è simmetrica) come:

$$V = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix} \quad (86)$$

Quindi V ha nella diagonale principale le varianze e nelle altre le covarianze. Si definisce poi la matrice dei coefficienti $A = \begin{pmatrix} a \\ b \end{pmatrix}$, la cui trasposta è $A^T = (a \ b)$, in modo che la formula di prima si può scrivere come:

$$\text{Var}(Z) = A^T V A \quad (87)$$

Nota: Ci si convince abbastanza facilmente del risultato se si fa il conto:

$$\begin{aligned} (a \ b) \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} &= [a \text{Var}(X) + b \text{Cov}(X, Y) \quad a \text{Cov}(X, Y) + b \text{Var}(Y)] \begin{pmatrix} a \\ b \end{pmatrix} \\ &= a^2 \text{Var}(X) + ab \text{Cov}(X, Y) + ab \text{Cov}(X, Y) + b^2 \text{Var}(Y) \end{aligned}$$

Si può poi ancora di più generalizzare al caso di N variabili aleatorie X_i come $Z = \sum_{i=1}^N a_i X_i$, e avremo ancora $\text{Var}(Z) = A^T V A$, dove stavolta la matrice delle covarianze ha elementi $V_{ij} = \text{Cov}(X_i, X_j)$. Essendo la diagonale:

$$V_{ii} = \text{Cov}(X_i, X_i) = \mathbb{E}[(X_i - \mathbb{E}[X_i])(X_i - \mathbb{E}[X_i])] = \mathbb{E}[(X_i - \mathbb{E}[X_i])^2] = \text{Var}(X_i)$$

Quindi V è qualcosa come:

$$V = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_N) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_N) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_N, X_1) & \text{Cov}(X_N, X_2) & \cdots & \text{Var}(X_N) \end{pmatrix} \quad (88)$$

mentre la matrice $A = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{pmatrix}$. È chiaro che se le variabili X_i sono indipendenti allora V assume una forma molto semplice in cui gli elementi non nulli sono solo nella diagonale.

9.3 Coefficiente di correlazione

Una ultima quantità che si introduce parlando del caso di due variabili casuali X e Y è il **coefficiente di correlazione lineare** (che indica la forza e la direzione della relazione lineare tra due variabili) definito come:

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \quad (89)$$

È chiaro dalla definizione che ρ è **adimensionale** (mentre la covarianza non lo è!), che $\rho = 0$ se X e Y sono statisticamente indipendenti (visto che in tal caso $\text{Cov}(X, Y) = 0$), e si può dimostrare che:

$$-1 \leq \rho \leq 1 \quad (90)$$

Dimostrazione: Esistono vari modi per dimostrarlo, una possibilità è definire la variabile $Z = \sigma_Y X - \sigma_X Y$ e calcolare $\text{Var}(Z)$ sfruttando la formula precedente:

$$\text{Var}(Z) = \sigma_Y^2 \text{Var}(X) + \sigma_X^2 \text{Var}(Y) - 2\sigma_X \sigma_Y \text{Cov}(X, Y)$$

ma $\text{Var}(X) = \sigma_X^2$ e $\text{Var}(Y) = \sigma_Y^2$, quindi:

$$\text{Var}(Z) = 2\sigma_X^2 \sigma_Y^2 - 2\sigma_X \sigma_Y \text{Cov}(X, Y)$$

Per come è definita sappiamo che $\text{Var}(Z) \geq 0$, quindi:

$$\begin{aligned} 2\sigma_X^2 \sigma_Y^2 - 2\sigma_X \sigma_Y \text{Cov}(X, Y) &\geq 0 \\ \implies \sigma_X^2 \sigma_Y^2 &\geq \sigma_X \sigma_Y \text{Cov}(X, Y) \\ \implies \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} &\leq 1 \implies \rho \leq 1 \end{aligned}$$

Viceversa se si definisce $Z = \sigma_Y X + \sigma_X Y$ e si fa lo stesso conto si trova $\rho \geq -1$.

Esempio. È istruttivo vedere quanto vale ρ nel caso di due variabili legate da una relazione lineare come $Y = mX + q$, cioè l'equazione della retta. In questo caso si può calcolare ρ partendo da:


- $\mathbb{E}[Y] = m\mathbb{E}[X] + q$
- $\text{Var}(Y) = m^2 \text{Var}(X)$
- $\mathbb{E}[XY] = \mathbb{E}[X(mX + q)] = \mathbb{E}[mX^2 + qX] = m\mathbb{E}[X^2] + q\mathbb{E}[X]$
- $\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \\ &= m\mathbb{E}[X^2] + q\mathbb{E}[X] - \mathbb{E}[X](m\mathbb{E}[X] + q) = \\ &= m\mathbb{E}[X^2] + q\mathbb{E}[X] - m\{\mathbb{E}[X]\}^2 - q\mathbb{E}[X] = \\ &= m(\mathbb{E}[X^2] - \{\mathbb{E}[X]\}^2) = m\text{Var}(X) \end{aligned}$

Premesso questo posso calcolare ρ come:

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{m \text{Var}(X)}{\sqrt{m^2 [\text{Var}(X)]^2}} = \frac{m}{|m|} = \pm 1 \quad (91)$$

Quindi ρ vale 1 con il segno del coefficiente angolare della retta. Questo mostra che man mano che la relazione tra X e Y approssima una relazione lineare il valore di $|\rho|$ si avvicina a 1.

Visualizzazione dei casi



Come in precedenza, quanto detto per due variabili si può facilmente estendere al caso di N variabili X_i , e in tal caso il coefficiente di correlazione si calcola comunque per una coppia delle N variabili:

$$\rho_{ij} = \frac{\text{Cov}(X_i, X_j)}{\sigma_i \sigma_j} \quad (92)$$

Si noti anche che da questo segue che $\text{Cov}(X_i, X_j) = \sigma_i \sigma_j \rho_{ij}$ e quindi la matrice delle covarianze si può anche scrivere come:

$$V_{ij} = \sigma_i \sigma_j \rho_{ij} \quad (93)$$

(Approfondimento facoltativo: Significato quantitativo di ρ) ¹

Finora abbiamo definito il coefficiente di correlazione e le sue proprietà teoriche. Tuttavia, in un caso reale, ci si trova sempre a lavorare con un **campione finito** di N coppie di misure (x_i, y_i) .

Supponiamo di calcolare il coefficiente di correlazione per i nostri dati misurati e di ottenere un valore, che chiameremo ρ_{oss} (correlazione *osservata*), per esempio $\rho_{oss} = 0,8$. La domanda sorge spontanea: *questo valore è sufficiente per affermare con certezza che le variabili sono correlate linearmente?*

Per rispondere, dobbiamo fare un ragionamento al contrario, basato sul calcolo delle probabilità. Supponiamo che le variabili X e Y siano in realtà **completamente non correlate** (ovvero, nel limite di infinite misure avremmo $\rho = 0$). Poiché abbiamo effettuato solo un numero finito N di misure, è quasi impossibile che il calcolo dia esattamente 0; per puro caso, i dati mostreranno sempre una qualche correlazione spuria.

Si definisce quindi la probabilità:

$$P_N(|\rho| \geq |\rho_{oss}|) \quad (94)$$

¹Fonte: John R. Taylor, *Introduzione all'analisi degli errori - Lo studio delle incertezze nelle misure fisiche*, 3^a ed., Bologna, Zanichelli Editore SpA, 2023

che rappresenta la probabilità che N misure di due variabili *non correlate* producano, per puro caso, un coefficiente di correlazione in valore assoluto grande almeno quanto quello osservato.

- Se questa probabilità è **alta**, il valore ρ_{oss} ottenuto potrebbe benissimo essere frutto del caso. Non abbiamo prove di una vera correlazione.
- Se questa probabilità è **bassa**, è estremamente improbabile che variabili scorrelate abbiano prodotto quel valore. Concludiamo quindi che le variabili sono quasi certamente correlate.

Per convenzione, si considera una correlazione:

- **Significativa:** se la probabilità è $\leq 5\%$
- **Altamente significativa:** se la probabilità è $\leq 1\%$

Il calcolo esatto di queste probabilità è complesso, ma i risultati per alcuni valori rappresentativi sono riportati nella tabella seguente:

Tabella 1: Probabilità percentuale $P_N(|\rho| \geq |\rho_{oss}|)$ che N misure di due variabili non correlate producano un coefficiente di correlazione $\geq |\rho_{oss}|$. Gli spazi vuoti indicano valori inferiori allo 0,05%.

N	$ \rho_{oss} $										
	0	0,1	0,2	0,3	0,4	0,5	0,6	0,7	0,8	0,9	1
3	100	94	87	81	74	67	59	51	41	29	0
6	100	85	70	56	43	31	21	12	6	1	0
10	100	78	58	40	25	14	7	2	0,5		0
20	100	67	40	20	8	2	0,5	0,1			0
50	100	49	16	3	0,4						0

Esempio. *Facendo riferimento alla tabella, si può notare come il numero di dati N influenzi drasticamente la significatività di un risultato. Supponiamo di aver calcolato un coefficiente $\rho_{oss} = 0,7$:*

- Con sole $N = 3$ misure, la probabilità che variabili totalmente scorrelate diano $|\rho| \geq 0,7$ per puro caso è del **51%**. Il risultato non dimostra assolutamente nulla.
- Con $N = 6$ misure, la probabilità scende al **12%**. La situazione migliora, ma non è ancora considerabile "significativa" (siamo sopra la soglia del 5%).
- Con $N = 20$ misure, la probabilità crolla allo **0,1%**. In questo caso l'evidenza è fortissima ("altamente significativa"): possiamo escludere quasi con certezza che le variabili non siano correlate.

In sintesi, un coefficiente di correlazione non ha significato pratico se non viene contestualizzato rispetto al numero di misurazioni effettuate.

10 Distribuzione normale in più dimensioni (o multinormale)

Caso di variabili indipendenti

La distribuzione gaussiana che abbiamo visto in una dimensione si può estendere al caso di due o più dimensioni partendo dal caso più semplice in cui le variabili sono indipendenti. Supponiamo quindi che X abbia densità di probabilità:

$$P_X(x) = \frac{1}{\sigma_X \sqrt{2\pi}} \exp \left[-\frac{(x - \mu_X)^2}{2\sigma_X^2} \right] \quad (95)$$

e analogamente Y ha densità di probabilità:

$$P_Y(y) = \frac{1}{\sigma_Y \sqrt{2\pi}} \exp \left[-\frac{(y - \mu_Y)^2}{2\sigma_Y^2} \right] \quad (96)$$

Essendo indipendenti, la densità di probabilità congiunta sarà:

$$\begin{aligned} P(x, y) &= P_X(x)P_Y(y) \\ &= \frac{1}{2\pi\sigma_X\sigma_Y} \exp \left[-\frac{(x - \mu_X)^2}{2\sigma_X^2} \right] \cdot \exp \left[-\frac{(y - \mu_Y)^2}{2\sigma_Y^2} \right] \end{aligned}$$

Essendo $e^a e^b = e^{a+b}$ posso riscrivere come:

$$P(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y} \cdot \exp \left\{ -\left[\frac{(x - \mu_X)^2}{2\sigma_X^2} + \frac{(y - \mu_Y)^2}{2\sigma_Y^2} \right] \right\} \quad (97)$$

Se si definisce la quantità:

$$Q^2 = \frac{(x - \mu_X)^2}{\sigma_X^2} + \frac{(y - \mu_Y)^2}{\sigma_Y^2} \quad (98)$$

allora si può riscrivere la probabilità come:

$$P(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y} \cdot \exp \left(-\frac{Q^2}{2} \right) \quad (99)$$

La definizione di Q^2 è utile perché le intersezioni di $P(x, y)$ con piani paralleli al piano XY sono definite proprio dall'equazione $Q^2 = \text{costante}$. Questo si capisce facilmente perché occorre fare l'intersezione con il piano $Z = K$, quindi servono valori di X e Y tali che $P(x, y) = K$, ma l'unica dipendenza da X e Y è contenuta in Q , per il resto si tratta di costanti:

$$\begin{aligned} \frac{1}{2\pi\sigma_X\sigma_Y} \exp \left(-\frac{Q^2}{2} \right) &= K \\ \exp \left(-\frac{Q^2}{2} \right) &= K 2\pi\sigma_X\sigma_Y \\ -\frac{Q^2}{2} &= \ln(2\pi\sigma_X\sigma_Y K) \\ Q^2 &= -2 \ln(2\pi\sigma_X\sigma_Y K) = C \end{aligned}$$

Scrivendo esplicitamente si ha:

$$\frac{(x - \mu_X)^2}{\sigma_X^2} + \frac{(y - \mu_Y)^2}{\sigma_Y^2} = C \quad (100)$$

che è l'equazione di un'ellisse centrata in (μ_X, μ_Y) .





Figura 15: Rappresentazione 3D della densità di probabilità congiunta. La linea rossa rappresenta l'intersezione con il piano $z = K$, la cui proiezione sul piano XY è un'ellisse di equazione $Q^2 = C$. Per provare il grafico interattivo: https://colab.research.google.com/drive/1mZmU06E-0UsUTA-w0U_cUEBHEPlPrn5u?usp=sharing

Essendo Q^2 dato dalla somma di quadrati di variabili normali, si può dimostrare che la sua distribuzione di probabilità è una distribuzione notevole che si chiama **distribuzione del chi quadro**, indicata con χ^2 , che vedremo meglio più avanti. Per ora quello che è utile sapere è che si può calcolare, per ogni valore di C , la probabilità che il generico punto (X, Y) cada dentro l'ellisse $Q^2 \leq C$.

Per esempio, per $C = 1$ (il che equivale al caso in cui l'ellisse ha come semiassi σ_X e σ_Y) si vede che tale probabilità è **0.39**.



Si noti che se io considerassi il rettangolo che circoscrive l'ellisse, mi aspetterei ²:

$$\begin{aligned} \text{Prob}\left(\mu_X - \sigma_X \leq X \leq \mu_X + \sigma_X \ \& \ \mu_Y - \sigma_Y \leq Y \leq \mu_Y + \sigma_Y\right) = \\ = 0.68 \cdot 0.68 = 0.46 \end{aligned}$$

In maniera analoga è facile graficamente intuire che forma avranno le **densità di probabilità condizionate** $\Pi(x|y)$ e $\Pi(y|x)$: nel caso di variabili indipendenti saranno ancora delle gaussiane e rappresentano le intersezioni con i piani del tipo $X = \text{costante}$ e $Y = \text{costante}$.

11 Distribuzione Multi-normale (Variabili dipendenti)

Richiamo al caso di variabili indipendenti

Abbiamo visto che per due variabili indipendenti con distribuzione normale si trova:

$$P(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \cdot \exp\left(-\frac{Q^2}{2}\right) \quad (101)$$

essendo la forma quadratica Q^2 definita come:

$$Q^2 = \frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \quad (102)$$

Per estendere il discorso al caso di variabili *correlate*, è utile esprimere Q^2 sotto forma di prodotto di matrici usando la **matrice delle covarianze** V , che per due variabili indipendenti ha la forma diagonale:

$$V = \begin{pmatrix} \sigma_x^2 & 0 \\ 0 & \sigma_y^2 \end{pmatrix} \quad (103)$$

Se si indicano i vettori colonna:

$$\vec{x} = \begin{pmatrix} x \\ y \end{pmatrix} \quad \text{e} \quad \vec{\mu} = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}$$

²Ricordando che integrando la gaussiana entro un sigma ottengo una probabilità del 68%

allora si vede che la rappresentazione compatta di Q^2 è:

$$Q^2 = (\vec{x} - \vec{\mu})^T V^{-1} (\vec{x} - \vec{\mu}) \quad (104)$$

Questo si può verificare facilmente ricavando innanzitutto quanto vale V^{-1} . Ricordiamo che per una generica matrice 2×2 del tipo $M = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$, la sua inversa è $M^{-1} = \frac{1}{\det M} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$. Nel nostro caso, $\det V = \sigma_x^2 \sigma_y^2$, quindi:

$$V^{-1} = \frac{1}{\sigma_x^2 \sigma_y^2} \begin{pmatrix} \sigma_y^2 & 0 \\ 0 & \sigma_x^2 \end{pmatrix} = \begin{pmatrix} \sigma_x^{-2} & 0 \\ 0 & \sigma_y^{-2} \end{pmatrix} \quad (105)$$

Sostituendo si ottiene esattamente l'espressione nota di Q^2 :

$$\begin{aligned} (\vec{x} - \vec{\mu})^T V^{-1} (\vec{x} - \vec{\mu}) &= (x - \mu_x \quad y - \mu_y) \begin{pmatrix} \sigma_x^{-2} & 0 \\ 0 & \sigma_y^{-2} \end{pmatrix} \begin{pmatrix} x - \mu_x \\ y - \mu_y \end{pmatrix} \\ &= \begin{pmatrix} \frac{x - \mu_x}{\sigma_x^2} & \frac{y - \mu_y}{\sigma_y^2} \end{pmatrix} \begin{pmatrix} x - \mu_x \\ y - \mu_y \end{pmatrix} \\ &= \frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} = Q^2 \end{aligned}$$

Generalizzazione a n dimensioni

Mettendo tutto insieme ed estendendo al caso di n dimensioni (e usando $\det V$ al posto di $\sigma_x^2 \sigma_y^2$), si ottiene l'espressione generale:

$$P(\vec{x}) = \frac{1}{(2\pi)^{n/2} |\det V|^{1/2}} \exp \left[-\frac{1}{2} (\vec{x} - \vec{\mu})^T V^{-1} (\vec{x} - \vec{\mu}) \right] \quad (106)$$

Il caso binormale correlato

Scritta così, l'espressione vale *anche nel caso in cui le variabili non siano indipendenti*. Ritornando al caso particolare di 2 variabili, la matrice V assume la forma:

$$V = \begin{pmatrix} \text{var}(x) & \text{cov}(x, y) \\ \text{cov}(x, y) & \text{var}(y) \end{pmatrix} = \begin{pmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{pmatrix} \quad (107)$$

Il suo determinante è:

$$\det V = \sigma_x^2 \sigma_y^2 - \rho^2 \sigma_x^2 \sigma_y^2 = \sigma_x^2 \sigma_y^2 (1 - \rho^2) \quad (108)$$

Per calcolare Q^2 bisogna calcolare V^{-1} , che in questo caso vale:

$$V^{-1} = \frac{1}{\sigma_x^2 \sigma_y^2 (1 - \rho^2)} \begin{pmatrix} \sigma_y^2 & -\rho \sigma_x \sigma_y \\ -\rho \sigma_x \sigma_y & \sigma_x^2 \end{pmatrix} \quad (109)$$

Svolgendo tutti i calcoli matriciali, si trova la forma quadratica espansa:

$$Q^2 = \frac{1}{1 - \rho^2} \left[\frac{(x - \mu_x)^2}{\sigma_x^2} - 2\rho \frac{(x - \mu_x)(y - \mu_y)}{\sigma_x \sigma_y} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right] \quad (110)$$

E la gaussiana in 2D diventa:

$$P(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1 - \rho^2}} \exp\left(-\frac{Q^2}{2}\right) \quad (111)$$

Interpretazione geometrica: L'ellisse

La cosa interessante è che ponendo $Q^2 = c$ si ottiene ancora un'ellisse, ma stavolta è *inclinata*, cioè non ha gli assi paralleli agli assi cartesiani x ed y .

Data la geometria del problema, dalla forma dell'ellisse si potrebbe riuscire a ricavare ρ . Infatti:

- La retta $x = \mu_x$ interseca l'ellisse nei punti di coordinate $y = \mu_y \pm \sigma_y \sqrt{1 - \rho^2}$.
- La retta $y = \mu_y$ interseca l'ellisse nei punti di coordinate $x = \mu_x \pm \sigma_x \sqrt{1 - \rho^2}$.

Invece, le rette di equazione $x = \mu_x \pm \sigma_x$ (parallele all'asse y) sono tangenti all'ellisse, e i punti di intersezione/tangenza hanno coordinate $y = \mu_y \pm \sigma_y \rho$. Analogamente, le rette $y = \mu_y \pm \sigma_y$ sono tangenti all'ellisse nei punti di coordinate $x = \mu_x \pm \sigma_x \rho$.

Nota: Anche in questo caso, la probabilità che una misurazione (x, y) cada dentro l'ellisse $Q^2 \leq 1$ è approssimativamente 0.39.

Distribuzioni Marginali e Condizionate per la Multinormale

Per definizione, le distribuzioni marginali sono date da:

$$P_x(x) = \int_{-\infty}^{+\infty} P(x, y) dy \quad \text{e} \quad P_y(y) = \int_{-\infty}^{+\infty} P(x, y) dx \quad (112)$$

Nel caso in cui x e y siano **indipendenti**, per una binormale è ovvio che $P_x(x)$ e $P_y(y)$ rappresentano le singole gaussiane. Infatti:

$$P_x(x) = \int_{-\infty}^{+\infty} P_x(x) P_y(y) dy = P_x(x) \underbrace{\int_{-\infty}^{+\infty} P_y(y) dy}_{=1} = P_x(x)$$

Quindi $P_x(x) = \mathcal{N}(\mu_x, \sigma_x^2)$ e $P_y(y) = \mathcal{N}(\mu_y, \sigma_y^2)$.

Se x e y **non sono indipendenti**, si arriva allo stesso risultato ma con più passaggi. La sostanza del calcolo si basa sul fatto che Q^2 dipende dai quadrati dei termini $(x - \mu_x)^2$ e $(y - \mu_y)^2$; con un po' di passaggi algebrici si riescono ad ottenere due gaussiane.




Figura 16: Rappresentazione geometrica dell'ellisse di equazione $Q^2 = c$. Si notano le intersezioni con gli assi passanti per il centro e i punti di tangenza con il box $\mu \pm \sigma$, che permettono di ricavare visivamente il coefficiente di correlazione ρ .

Distribuzioni Condizionate

È più istruttivo calcolare con più dettaglio le **distribuzioni condizionate**. Si vede che anche queste sono gaussiane, ma con μ e σ alterati da ρ . Dalla definizione sappiamo che:

$$\pi(x|y) = \frac{P(x, y)}{P_y(y)} = \frac{F \exp[-Q^2/2]}{F_1 \exp[-Q_1^2/2]} \quad (113)$$

dove abbiamo scritto schematicamente le probabilità come prodotto di un fattore di normalizzazione (F e F_1) per degli esponenziali, ponendo $Q_1^2 = \frac{(y - \mu_y)^2}{\sigma_y^2}$.

Il calcolo più facile da fare è il rapporto dei coefficienti:

$$\frac{F}{F_1} = \frac{\frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}}}{\frac{1}{\sqrt{2\pi}\sigma_y}} = \frac{1}{\sqrt{2\pi}\sigma_x\sqrt{1-\rho^2}} \quad (114)$$

Da questo si nota che per avere la forma di una gaussiana normalizzata, la nuova deviazione standard deve essere:

$$\sigma_{x|y} = \sigma_x \sqrt{1 - \rho^2} \quad (115)$$

(Si noti che per $\rho = 0$ si ritrova $\sigma_{x|y} = \sigma_x$).

Calcolo della media condizionata

Per ricavare come varia μ bisogna calcolare come varia l'esponente. Per semplificare la notazione utilizziamo il cambiamento di variabili: $u = x - \mu_x$ e $v = y - \mu_y$.

Con questa scelta, il rapporto tra i due esponenziali è dipendente da:

$$Q^2 - Q_1^2 = \frac{1}{1 - \rho^2} \left(\frac{u^2}{\sigma_x^2} + \frac{v^2}{\sigma_y^2} - 2\rho \frac{uv}{\sigma_x \sigma_y} \right) - \frac{v^2}{\sigma_y^2}$$

Separiamo i termini che dipendono da x (cioè u) e quelli che dipendono solo da y (cioè v):

$$Q^2 - Q_1^2 = \frac{1}{1 - \rho^2} \left(\frac{u^2}{\sigma_x^2} - 2\rho \frac{uv}{\sigma_x \sigma_y} \right) - \left[\frac{1}{1 - \rho^2} - 1 \right] \frac{v^2}{\sigma_y^2}$$

Riscriviamo il termine in parentesi quadra come un quadrato di binomio mettendo in evidenza $\frac{1}{\sigma_x^2}$:

$$\frac{1}{\sigma_x^2} (u^2 - 2\rho \frac{\sigma_x}{\sigma_y} uv) = \frac{1}{\sigma_x^2} \left[\left(u - \rho \frac{\sigma_x}{\sigma_y} v \right)^2 - \rho^2 \frac{\sigma_x^2}{\sigma_y^2} v^2 \right]$$

Sostituendo nell'espressione precedente e semplificando i termini in v^2 :

$$\begin{aligned} Q^2 - Q_1^2 &= \frac{1}{1 - \rho^2} \left[\frac{1}{\sigma_x^2} \left(u - \rho \frac{\sigma_x}{\sigma_y} v \right)^2 - \rho^2 \frac{v^2}{\sigma_y^2} + \rho^2 \frac{v^2}{\sigma_y^2} \right] \\ &= \frac{1}{(1 - \rho^2) \sigma_x^2} \left(u - \rho \frac{\sigma_x}{\sigma_y} v \right)^2 \end{aligned}$$

Tornando alle variabili originarie x e y :

$$Q^2 - Q_1^2 = \frac{1}{(1 - \rho^2) \sigma_x^2} \left\{ (x - \mu_x) - \rho \frac{\sigma_x}{\sigma_y} (y - \mu_y) \right\}^2 \quad (116)$$

Da qui si evince che l'espressione di $\pi(x|y)$ è ancora una gaussiana con deviazione standard $\sigma_{x|y} = \sigma_x \sqrt{1 - \rho^2}$ (come visto prima) e con valore atteso:

$$\mu_{x|y} = \mu_x + \rho \frac{\sigma_x}{\sigma_y} (y - \mu_y) \quad (117)$$

Anche in questo caso, se $\rho = 0$ si ha $\mu_{x|y} = \mu_x$, mentre se $\rho \neq 0$, il valore atteso è spostato rispetto al valore μ_x originale in base al valore di y .

12 Teoria della Stima dei Parametri

Finora abbiamo parlato molto di distribuzioni teoriche, ma il problema che ci si trova spesso ad affrontare è trovare un modo di risalire ai **parametri della distribuzione della popolazione**, dato un insieme di misure di un campione.

Detto in maniera più formale, supponiamo che la densità di probabilità $P(x; \theta)$ di una variabile casuale x dipenda da un parametro θ , il cui **valore vero** θ_v ci sia ignoto (per esempio, se P è una gaussiana, avremo due parametri: μ e σ).

Avendo a disposizione N misure x_i della grandezza x , vogliamo trovare una funzione:

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_N)$$

che, a partire da esse, ci permetta di ricavare il valore di θ_v . Le funzioni $\hat{\theta}$ di questo tipo si chiamano **stime** (o stimatori).

Ovviamente si possono immaginare molte stime possibili, ma si cerca di preferire quelle che hanno tre proprietà fondamentali: **consistenza**, **imparzialità** ed **efficienza**.

Proprietà degli Stimatori (Consistenza, Imparzialità)

Consistenza

Definizione: Stimatore Consistente: Una stima si dice *consistente* quando tende al valore vero del parametro al tendere all'infinito del numero di campioni, cioè se:

$$\lim_{N \rightarrow \infty} \hat{\theta} = \theta_v$$

Per esempio, la legge dei grandi numeri ci garantisce che $\lim_{N \rightarrow \infty} \bar{x} = \mu$. Quindi la media aritmetica è una stima consistente del valore di aspettazione della distribuzione teorica che regola la popolazione.

Imparzialità (Non distorsione)

Definizione: Stimatore Imparziale Una stima si dice *imparziale* (o non distorta, in inglese *unbiased*) se il suo valore di aspettazione è uguale al valore vero, cioè:

$$\mathbb{E}[\hat{\theta}] = \theta_v$$

Si noti che, essendo $\hat{\theta}$ una funzione di variabili casuali, è essa stessa una variabile casuale, e quindi per questo si può parlare del suo valore atteso $\mathbb{E}[\hat{\theta}]$.

Più in generale si otterranno risultati del tipo:

$$\mathbb{E}[\hat{\theta}] = \theta_v + b(\theta_v) \quad (118)$$

dove la funzione b è solitamente dell'ordine di $1/N$ o inferiore.

Per esempio, nel caso della **media aritmetica** $\bar{x}$, si può facilmente verificare che soddisfa questa proprietà:

$$\mathbb{E}[\bar{x}] = \mathbb{E}\left[\frac{1}{N} \sum_{i=1}^N x_i\right] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[x_i] \quad (119)$$

Se tutte le x_i seguono la stessa $P(x)$ (cioè sono misure della stessa grandezza fisica), allora i valori attesi delle singole x_i sono tutti uguali: $\mathbb{E}[x_i] = \mathbb{E}[x]$. Sostituendo si ottiene:

$$\mathbb{E}[\bar{x}] = \frac{1}{N} \cdot N \cdot \mathbb{E}[x] = \mathbb{E}[x] = \mu$$

Quindi la media aritmetica è una stima non distorta del valore atteso della popolazione.

Efficienza

Definizione: Efficienza La proprietà dell'efficienza della stima ha a che fare con la dispersione della stima attorno al suo valore di aspettazione, misurata dalla **varianza**. In altre parole, una stima è *più efficiente* di un'altra se la sua *varianza è più piccola*.

Se la varianza è più piccola, il suo valore è più prossimo a $\mathbb{E}[\hat{\theta}]$, che coincide con θ_v se la stima è imparziale.

La scelta della migliore stima da usare non è sempre banale e richiede lo studio del singolo caso. Per esempio, l'efficienza di una stima può dipendere dal particolare problema considerato, oppure confrontando due stime si può trovare che la più efficiente è anche *distorta*; in tal caso bisogna decidere (in base al problema) se è più accettabile la distorsione o la bassa efficienza.

Per esempio si può dimostrare che sia la media che la mediana diano un risultato consistente e imparziali per quanto riguarda la posizione di una popolazione di variabili normali con varianza nota. La media però presenta una minore varianza rispetto alla mediana, dunque è da preferirsi per quanto riguarda l'efficienza.

La media aritmetica come stima ottimale

Consideriamo lo stimatore della media aritmetica: $\hat{\mu} = \bar{x}$. Abbiamo già notato che la media è una buona stima di μ perché è **consistente** e **imparziale**.

Inoltre, dal Teorema del Limite Centrale, sappiamo che la sua varianza è:

$$\text{var}(\bar{x}) = \frac{\sigma^2}{N}$$

dove σ è la deviazione standard della popolazione. In generale si vede che questa stima è la **più efficiente**, o almeno lo è per le densità di probabilità gaussiane.

13 Stime, Propagazione e Likelihood

Stima della Varianza e Correzione di Bessel

Si è visto nelle prime lezioni che il modo più naturale per misurare la dispersione rispetto alla media del campione è lo scarto quadratico medio, che indichiamo qui per comodità come s^2 :

$$s^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 \quad (120)$$

Si può quindi pensare che questa sia una buona stima della varianza della popolazione. Tuttavia si vede abbastanza facilmente che **questa stima è distorta**. Infatti, preso un

qualsiasi valore di x che indico con $\tilde{x}$, posso calcolare la quantità:

$$\begin{aligned} \frac{1}{N} \sum_{i=1}^N (x_i - \tilde{x})^2 &= \frac{1}{N} \sum_{i=1}^N [(x_i - \bar{x}) + (\bar{x} - \tilde{x})]^2 \\ &= \frac{1}{N} \left[\sum_{i=1}^N (x_i - \bar{x})^2 + \underbrace{\sum_{i=1}^N (\bar{x} - \tilde{x})^2}_{\text{non dipende da } i} + 2 \sum_{i=1}^N (x_i - \bar{x})(\bar{x} - \tilde{x}) \right] \end{aligned}$$

Analizzando l'ultimo termine, notiamo che $(\bar{x} - \tilde{x})$ si può tirare fuori dalla sommatoria, e rimane $\sum_i (x_i - \bar{x}) = \sum_i x_i - N\bar{x} = N\bar{x} - N\bar{x} = 0$. Il termine misto si annulla. L'espressione si riduce quindi a:

$$\begin{aligned} \frac{1}{N} \sum_{i=1}^N (x_i - \tilde{x})^2 &= \frac{1}{N} \left[\sum_{i=1}^N (x_i - \bar{x})^2 + N(\bar{x} - \tilde{x})^2 \right] \\ &= s^2 + (\bar{x} - \tilde{x})^2 \end{aligned}$$

Invertendo il risultato si ricava che s^2 si può scrivere come:

$$s^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \tilde{x})^2 - (\bar{x} - \tilde{x})^2 \quad (121)$$

Questo vale per un qualunque $\tilde{x}$ e quindi in particolare per il valore vero della media, cioè il valore di aspettazione μ :

$$s^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 - (\bar{x} - \mu)^2 \quad (122)$$

Se si calcola il valore di aspettazione di s^2 ho:

$$\mathbb{E}[s^2] = \frac{1}{N} \sum_{i=1}^N \mathbb{E}[(x_i - \mu)^2] - \mathbb{E}[(\bar{x} - \mu)^2] \quad (123)$$

Se le x_i hanno tutte la stessa densità di probabilità, allora $\mathbb{E}[(x_i - \mu)^2] = \mathbb{E}[(x - \mu)^2] = \text{Var}(x)$. Viceversa, essendo $\mathbb{E}[\bar{x}] = \mu$, allora il termine $\mathbb{E}[(\bar{x} - \mu)^2] = \mathbb{E}[(\bar{x} - \mathbb{E}[\bar{x}])^2] = \text{Var}(\bar{x}) = \frac{\text{Var}(x)}{N}$.

Sostituendo si ha quindi:

$$\mathbb{E}[s^2] = \frac{1}{N} N \text{Var}(x) - \frac{\text{Var}(x)}{N} = \frac{N-1}{N} \text{Var}(x) \quad (124)$$

In sostanza s^2 è una **stima distorta** della varianza e tende ad essere più piccola della varianza di un fattore $(N-1)/N$. Riflettendoci, si capisce che il risultato deriva dal fatto che nel caso ideale si vorrebbe conoscere μ e calcolare gli scarti rispetto a μ , invece che rispetto a $\bar{x}$, e da questo segue che $\mathbb{E}[s^2] < \text{Var}(x)$.

Correzione di Bessel Avendo però quantificato la relazione tra $\mathbb{E}[s^2]$ e la varianza vera, si può correggere il nostro calcolo definendo una nuova stima della varianza:

$$\sigma_m^2 = \frac{N}{N-1} s^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2 \quad (125)$$

Questa espressione prende il nome di *correzione di Bessel* e fornisce uno stimatore non distorto per la varianza.

Nota: si usa il pedice m per ricordare che questa è la stima della varianza a partire dalle misure.

Stima della Covarianza

Abbiamo visto che, date due variabili aleatorie x e y , la loro covarianza si calcola come:

$$\text{cov}(x, y) = \mathbb{E}[(x - \mathbb{E}[x])(y - \mathbb{E}[y])] \quad (126)$$

e nel caso in cui $x = y \implies \text{cov}(x, x) = \text{Var}(x)$.

Allora è abbastanza naturale utilizzare come stima della covarianza la quantità $\frac{1}{N} \sum_i (x_i - \bar{x})(y_i - \bar{y})$. Però, di nuovo, per la discussione fatta sulla varianza, questa stima è distorta. Quindi, per analogia, una stima migliore (imparziale) è:

$$\hat{\text{cov}}(x, y) = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) \quad (127)$$

Note sull'esercitazione: Errori Sistemati

In questa esercitazione simuleremo il caso di due misure indipendenti che diventano correlate quando c'è un errore sistematico.

Per considerare un esempio semplice, simuleremo le misure di due lunghezze il cui valore vero è $L1_v$ e $L2_v$, aggiungendo degli errori casuali gaussiani:

$$\begin{aligned} L1 &= L1_v + e_1 \\ L2 &= L2_v + e_2 \end{aligned}$$

dove $e_1 \sim \mathcal{N}(0, \sigma^2)$ e $e_2 \sim \mathcal{N}(0, \sigma^2)$ sono i due errori con la stessa σ . Essendo $L1_v$ e $L2_v$ delle costanti, questo equivale a simulare $L1 \sim \mathcal{N}(L1_v, \sigma^2)$ e $L2 \sim \mathcal{N}(L2_v, \sigma^2)$.

Ora introduciamo un **errore sistematico**, per esempio una deformazione dello strumento dovuta alla temperatura esterna. Questo vuol dire che le due misure vengono alterate nello stesso modo, per esempio di un valore S . Le misure saranno in questo caso:

$$\begin{aligned} L1_s &= L1 + S \\ L2_s &= L2 + S \end{aligned}$$

e supponiamo che $S \sim \mathcal{N}(0, \sigma_S^2)$.

Se facciamo N misure e simuliamo anche N errori di tipo S , ogni coppia di misure $L1[i]$ e $L2[i]$ sarà affetta dallo *stesso* errore $S[i]$ (ma in generale per un altro indice j l'errore $S[j]$ sarà diverso). Possiamo studiare la binormale ottenuta da $(L1_s, L2_s)$ e notare che $\text{cov}(L1_s, L2_s) \neq 0$, perché l'aggiunta di S ha creato una correlazione tra le due variabili.

Il valore di questa covarianza ci dà un'informazione su S . Per vederlo usiamo una notazione semplificata $x_s = x + S$ e $y_s = y + S$:

$$\begin{aligned}\text{cov}(x_s, y_s) &= \mathbb{E}[x_s y_s] - \mathbb{E}[x_s] \mathbb{E}[y_s] \\ &= \mathbb{E}[(x + S)(y + S)] - \mathbb{E}[x + S] \mathbb{E}[y + S] \\ &= \mathbb{E}[xy] + \mathbb{E}[xS] + \mathbb{E}[Sy] + \mathbb{E}[S^2] - \mathbb{E}[x] \mathbb{E}[y] - \mathbb{E}[x] \mathbb{E}[S] - \mathbb{E}[y] \mathbb{E}[S] - \mathbb{E}[S]^2 \\ &= \text{cov}(x, y) + \text{cov}(x, S) + \text{cov}(y, S) + \text{cov}(S, S) \\ &= \text{Var}(S)\end{aligned}$$

L'ultimo passaggio dipende dal fatto che le coppie (x, y) , (x, S) e (y, S) sono indipendenti (covarianza nulla). Nel nostro caso avremo quindi che:

$$\text{cov}(L1_s, L2_s) = \text{Var}(S) \quad (128)$$

Dato che il valore di S cambia in ogni misura, non è facile risalire al valore del singolo S e qui l'unico modo per eliminarlo è calcolare la differenza tra le due lunghezze:

$$L1_s - L2_s = L1 + S - (L2 + S) = L1 - L2$$

In questo caso serve un riferimento esterno per stimare l'errore sistematico. Per esempio, prima di misurare le lunghezze incognite, facciamo la stessa procedura con due lunghezze *note*. In tal caso, una stima di S può venire dalla media delle misure:

$$m = \frac{L1_s + L2_s}{2} = \frac{L1_v + e_1 + S + L2_v + e_2 + S}{2} = \frac{L1_v + L2_v}{2} + \frac{e_1 + e_2}{2} + S$$

Quindi $\hat{S}$ si può stimare togliendo da m la media delle misure vere che conosco:

$$\hat{S} = \frac{L1_s + L2_s}{2} - \frac{L1_v + L2_v}{2} = S + \frac{e_1 + e_2}{2} \quad (129)$$

Si ottiene quindi una sovrastima di S (spesso per gli errori sistematici si ha una sovrastima).

13.1 Dimostrazione della Propagazione degli Errori

Per completare il discorso sugli errori vediamo velocemente da dove viene la formula di propagazione degli errori. Se abbiamo una variabile $y = ax + b$, abbiamo visto dalle proprietà della varianza che:

$$\text{Var}(y) = \text{Var}(ax + b) = \text{Var}(ax) = a^2 \text{Var}(x)$$

Se ora supponiamo di avere una generica funzione $f(x)$ che sviluppiamo con la tipica formula di Taylor attorno a x_0 , e tronchiamo lo sviluppo al primo ordine, avremo:

$$f(x) \simeq f(x_0) + (x - x_0) \left. \frac{df}{dx} \right|_{x=x_0} \quad (130)$$

Applicando ora le formule precedenti (notando che $f(x_0) \rightarrow b$ e $\left. \frac{df}{dx} \right|_{x_0} \rightarrow a$), abbiamo:

$$\text{Var}(f) \approx \left(\left. \frac{df}{dx} \right|_{x_0} \right)^2 \text{Var}(x) \quad (131)$$

La formula ha senso per errori piccoli e la derivata va calcolata in x_0 , che di solito si assume essere il valore misurato.

Caso Multivariato

Nel caso di più variabili si procede in modo analogo. Per esempio nel caso di due variabili:

$$f(x, y) \simeq f(x_0, y_0) + (x - x_0) \left. \frac{\partial f}{\partial x} \right|_{x=x_0} + (y - y_0) \left. \frac{\partial f}{\partial y} \right|_{y=y_0}$$

Di nuovo la varianza si può calcolare in analogia al caso lineare $z = ax + by$, per cui abbiamo visto che:

$$\text{Var}(z) = a^2 \text{Var}(x) + b^2 \text{Var}(y) + 2ab \text{cov}(x, y)$$

L'espressione precedente è più del tipo $z' = ax + by + c$, ma $\text{Var}(z') = \text{Var}(z)$. Quindi possiamo ricavare la varianza di f per analogia:

$$\text{Var}(f) = \left(\left. \frac{\partial f}{\partial x} \right|_{x_0, y_0} \right)^2 \text{Var}(x) + \left(\left. \frac{\partial f}{\partial y} \right|_{x_0, y_0} \right)^2 \text{Var}(y) + 2 \left(\left. \frac{\partial f}{\partial x} \right|_{x_0, y_0} \right) \left(\left. \frac{\partial f}{\partial y} \right|_{x_0, y_0} \right) \text{cov}(x, y) \quad (132)$$

che, nel caso in cui le variabili siano indipendenti (covarianza nulla), si riduce alla formula che si conosce.

Nel caso più generale in cui f sia funzione di n variabili $f(x_1, x_2, \dots, x_n)$, allora:

$$\text{Var}(f) = \sum_{i=1}^n \left(\left. \frac{\partial f}{\partial x_i} \right|_{x_0} \right)^2 \text{Var}(x_i) + 2 \sum_{i < j} \left. \frac{\partial f}{\partial x_i} \right|_{x_0} \left. \frac{\partial f}{\partial x_j} \right|_{x_0} \text{cov}(x_i, x_j) \quad (133)$$

13.2 Metodo della Massima Verosimiglianza (MLE), (Maximum Likelihood)

Supponiamo di avere N misure $\{x_1, x_2, \dots, x_N\}$ di una certa grandezza fisica x . Queste misure sono delle variabili aleatorie descritte da una certa densità di probabilità P che dipende da un certo parametro θ il cui **valore vero** θ_v è **incognito**, cioè per ognuna ho $P(x_i; \theta_v)$.

Se si mette insieme, la densità congiunta è $\prod_i P(x_i; \theta_v)$ (se le x_i sono indipendenti). Se ora si prova a "ribaltare" il problema e assumo che, fissate le x_i (quindi avendo fissato un set di misure), si voglia ricavare θ_v , allora si può riscrivere la produttoria di prima come una funzione di θ :

Definizione: Funzione di Likelihood

$$\mathcal{L}(x_1, x_2, \dots, x_N; \theta) = \prod_{i=1}^N P(x_i; \theta) \quad (134)$$

Questa quantità si chiama *Likelihood* e indica la probabilità che il *particolare set di misure* $x_1, x_2, \dots, x_N$ sia prodotto da un dato θ (quindi fisso le x e la mia variabile incognita è θ).

Il metodo della massima verosimiglianza consiste nell'adottare come stima del parametro θ quel valore $\hat{\theta}$ che **rende massima la funzione di Likelihood**, cioè tale che:

$$\frac{d\mathcal{L}}{d\theta} = 0 \quad (135)$$




Figura 17: Rappresentazione grafica della funzione di Likelihood $\mathcal{L}(\theta)$. Il metodo della massima verosimiglianza individua il valore stimato $\hat{\theta}$ in corrispondenza del picco della curva, dove la derivata prima si annulla.

Questo certe volte consente di ottenere un'equazione che si può risolvere analiticamente per ottenere $\hat{\theta}$, a volte invece bisogna ricorrere a soluzioni numeriche.

La Log-Likelihood

Spesso risulta scomodo lavorare con $\mathcal{L}$ e si preferisce utilizzare il suo logaritmo, di solito in base e . Essendo $\ln(\mathcal{L})$ una funzione monotona crescente con il suo argomento, il massimo di $\ln(\mathcal{L})$ si trova per i valori dei parametri che rendono massima la $\mathcal{L}$. Quindi di solito il

problema diventa trovare i valori di θ per cui:

$$\frac{d(\ln \mathcal{L})}{d\theta} = 0 \quad (136)$$

Esempio: Funzione Esponenziale

Un esempio semplice di applicazione del metodo del Maximum Likelihood è il caso di un processo la cui densità di probabilità è data da:

$$P(t; \tau) = \frac{1}{\tau} e^{-t/\tau} \quad (137)$$

e abbiamo visto che questo regola i tempi di attesa tra due eventi consecutivi, se gli eventi seguono la statistica di Poisson, cioè eventi casuali con media fissa. Per esempio i decadimenti radioattivi sono un esempio di questo tipo di fenomeno.

Supponiamo quindi di aver accumulato N misure dei tempi t_i e vogliamo usarle per trovare $\hat{\tau}$ usando il metodo di ML. Dobbiamo innanzitutto trovare $\mathcal{L}$ che per definizione è data da:

$$\mathcal{L}(t_1, t_2, \dots, t_N; \tau) = \prod_{i=1}^N P(t_i; \tau) = \prod_{i=1}^N \frac{1}{\tau} e^{-t_i/\tau} \quad (138)$$

Come detto, qui è comodo prendere il logaritmo così i prodotti diventano somme:

$$\begin{aligned} \ln \mathcal{L}(x_1, \dots, x_N; \tau) &= \ln \left(\prod_{i=1}^N \frac{1}{\tau} e^{-t_i/\tau} \right) \\ &= \sum_{i=1}^N \ln \left(\frac{1}{\tau} e^{-t_i/\tau} \right) \\ &= \sum_{i=1}^N \left(-\ln \tau - \frac{t_i}{\tau} \right) \\ &= -N \ln \tau - \sum_{i=1}^N \frac{t_i}{\tau} \end{aligned}$$

Di questa dobbiamo trovare il massimo derivando rispetto a τ :

$$\begin{aligned} \frac{d \ln \mathcal{L}}{d\tau} &= \frac{d}{d\tau} \left(-N \ln \tau - \sum_i \frac{t_i}{\tau} \right) \\ &= -N \frac{1}{\tau} - \sum_i t_i \left(-\frac{1}{\tau^2} \right) \\ &= -\frac{N}{\tau} + \frac{\sum_i t_i}{\tau^2} \end{aligned}$$

La stima di τ , $\hat{\tau}$, sarà data dai valori che soddisfano:

$$-\frac{N}{\hat{\tau}} + \sum_i \frac{t_i}{\hat{\tau}^2} = 0 \quad (139)$$

Raccogliamo a fattore comune:

$$\underbrace{\frac{N}{\hat{\tau}^2}}_{\text{sempre } > 0} \left(-\hat{\tau} + \frac{1}{N} \sum_i t_i \right) = 0 \quad (140)$$

Affinché l'espressione sia nulla, deve annullarsi il termine in parentesi:

$$-\hat{\tau} + \frac{1}{N} \sum_i t_i = 0 \implies \hat{\tau} = \frac{1}{N} \sum_{i=1}^N t_i \quad (141)$$

Quindi la stima del valore atteso medio τ è data semplicemente dalla media aritmetica dei t_i .

14 PDF Gaussian e Limite di Cramér-Rao

Proprietà della Massima Verosimiglianza

Chiarimenti sulla stima ML

Si era visto che il procedimento standard consiste nel trovare lo stimatore $\hat{\theta}$ per cui si annulla la derivata della funzione di verosimiglianza (Likelihood):

$$\hat{\theta} : \frac{\partial \mathcal{L}}{\partial \theta} = 0 \quad (142)$$

In teoria bisognerebbe anche controllare che:

$$\left. \frac{\partial^2 \mathcal{L}}{\partial \theta^2} \right|_{\hat{\theta}} < 0 \quad (143)$$

per essere certi che si tratti di un massimo e non di un minimo o di un flesso. Di solito questo non si fa perché la $\mathcal{L}$ è spesso concava e ha sempre $\mathcal{L}'' < 0$ (o perlomeno questo è vero per i modelli più comuni), oppure perché è complicato da calcolare. Nei libri di solito si trova scritto: se $\mathcal{L}' = 0$ ha più soluzioni, si sceglie quella che massimizza $\mathcal{L}$, piuttosto che controllare $\mathcal{L}''$.

Stima ML per la media e varianza Gaussian

Un altro tipico esempio di uso del metodo Maximum Likelihood (ML) restituisce il valore noto della media. Supponiamo di avere N misure $\{x_1, x_2, \dots, x_N\}$ di una certa quantità x e supponiamo che tutte le misure abbiano lo stesso valore atteso μ incognito, e ognuna una deviazione standard σ_i nota, cioè:

$$P(x_i; \mu, \sigma_i) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left[-\frac{(x_i - \mu)^2}{2\sigma_i^2} \right] \quad (144)$$

La funzione di verosimiglianza è:

$$\mathcal{L}(x_i; \mu) = \frac{1}{(2\pi)^{N/2}} \prod_i \frac{1}{\sigma_i} \exp \left[-\frac{(x_i - \mu)^2}{2\sigma_i^2} \right] \quad (145)$$

Passando al logaritmo naturale (Log-Likelihood):

$$\ln \mathcal{L}(x_i; \mu) = -\frac{N}{2} \ln(2\pi) + \sum_i \ln \left(\frac{1}{\sigma_i} \right) - \sum_i \frac{(x_i - \mu)^2}{2\sigma_i^2} \quad (146)$$

Ora calcoliamo la derivata rispetto a μ :

$$\begin{aligned} \frac{\partial \ln \mathcal{L}}{\partial \mu} &= \frac{\partial}{\partial \mu} \left[-\sum_i \frac{(x_i - \mu)^2}{2\sigma_i^2} \right] \\ &= -\sum_i \frac{1}{2\sigma_i^2} \left[\frac{\partial}{\partial \mu} (x_i - \mu)^2 \right] \\ &= -\sum_i \frac{1}{2\sigma_i^2} [-2(x_i - \mu)] = \sum_i \frac{x_i - \mu}{\sigma_i^2} \end{aligned}$$

Da qui il massimo si trova ponendo a zero la derivata, quindi $\hat{\mu}$ è il valore per cui:

$$\sum_i \frac{x_i - \hat{\mu}}{\sigma_i^2} = 0 \implies \sum_i \frac{x_i}{\sigma_i^2} - \sum_i \frac{\hat{\mu}}{\sigma_i^2} = 0 \implies \sum_i \frac{x_i}{\sigma_i^2} = \hat{\mu} \sum_i \frac{1}{\sigma_i^2} \quad (147)$$

Da cui ricaviamo:

$$\boxed{\hat{\mu} = \frac{\sum_i (x_i / \sigma_i^2)}{\sum_i (1 / \sigma_i^2)}} \quad (148)$$

Il risultato ottenuto è quindi la **media pesata** in cui ogni x_i è pesato con $1/\sigma_i^2$.

Con un procedimento analogo si ricava che se le σ_i sono **tutte uguali** ($\sigma_i = \sigma$), allora si possono portare fuori dalla sommatoria:

$$\frac{\partial \ln \mathcal{L}}{\partial \mu} = 0 \implies \frac{1}{\sigma^2} \sum_i (x_i - \hat{\mu}) = 0 \implies \sum_i (x_i - \hat{\mu}) = 0 \implies \sum_i x_i - N\hat{\mu} = 0 \quad (149)$$

$$\boxed{\hat{\mu} = \frac{1}{N} \sum_i x_i} \quad (150)$$

che è la normale media aritmetica.

Se ora supponiamo che le σ siano tutte uguali ma **incognite**, allora per ricavare la stima di σ dovremo risolvere $\frac{\partial \ln \mathcal{L}}{\partial \sigma} = 0$. Calcoliamo prima la derivata parziale:

$$\begin{aligned} \frac{\partial \ln \mathcal{L}}{\partial \sigma} &= \frac{\partial}{\partial \sigma} \left[-\frac{N}{2} \ln(2\pi) + \sum_i \ln \left(\frac{1}{\sigma} \right) - \sum_i \frac{(x_i - \mu)^2}{2\sigma^2} \right] \\ &= \frac{\partial}{\partial \sigma} \left[-N \ln(\sigma) - \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2 \right] \\ &= -\frac{N}{\sigma} - \frac{(-2)}{2\sigma^3} \sum_i (x_i - \mu)^2 = -\frac{N}{\sigma} + \frac{1}{\sigma^3} \sum_i (x_i - \mu)^2 \end{aligned}$$

Si deve trovare $\hat{\sigma}$ tale che:

$$-\frac{N}{\hat{\sigma}} + \frac{1}{\hat{\sigma}^3} \sum_i (x_i - \mu)^2 = 0 \implies \frac{1}{\hat{\sigma}^3} \sum_i (x_i - \mu)^2 = \frac{N}{\hat{\sigma}} \quad (151)$$

$$\boxed{\hat{\sigma}^2 = \frac{1}{N} \sum_i (x_i - \mu)^2} \quad (152)$$

Come si può notare, questa è una stima *biased* (distorta) della varianza. È importante ricordare, tuttavia, che asintoticamente (per $N \rightarrow \infty$) questa stima converge, coincidendo con quella non distorta. La presenza di un bias su campioni di dimensione finita è una problematica tipica delle stime di σ ottenute con il metodo della Massima Verosimiglianza.

Invarianza per trasformazioni dei parametri

Un grande vantaggio del metodo ML, in compenso, è che si può dimostrare che tali stime sono *invarianti per trasformazione dei parametri*. Questo significa che, se si ha a disposizione lo stimatore $\hat{\theta}$ per un certo parametro θ , e si applica una trasformazione $f(\theta)$, è equivalente ricercare lo stimatore della funzione calcolando semplicemente la funzione dello stimatore:

$$\widehat{f(\theta)} = f(\hat{\theta}) \quad (153)$$

Per esempio, nel calcolo precedente saremmo arrivati allo stesso risultato se invece di calcolare $\frac{\partial \mathcal{L}}{\partial \sigma}$ avessimo calcolato $\frac{\partial \mathcal{L}}{\partial \sigma^2}$.

Questa è una proprietà molto comoda, che in generale non si applica a tutte le stime. Da questa proprietà deriva spesso il fatto che la stima di ML può risultare distorta: la stima di $f(\theta)$ è legata alla stima di θ dalla derivata $df/d\theta$, cioè ³:

$$\frac{\partial \mathcal{L}}{\partial \theta} = \frac{\partial \mathcal{L}}{\partial f} \frac{df}{d\theta} \quad (154)$$

L'aggiunta di questo $df/d\theta$ fa sì che se una stima $\hat{\theta}$ non è distorta, l'altra $f(\hat{\theta})$ potrebbe esserlo.

14.1 Efficienza e Disuguaglianza di Cramér-Rao

Una volta ottenuta la stima $\hat{\theta}$ di un parametro, è fondamentale quantificare l'incertezza statistica ad essa associata, la quale è rappresentata dalla varianza:

$$\text{Var}(\hat{\theta}) = \mathbb{E} \left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2 \right] \quad (155)$$

In molti casi si conosce già questa quantità per via analitica. Infatti, qualora lo stimatore coincida con la media campionaria⁴ ($\hat{\mu} = \bar{x}$), si ottiene direttamente che:

$$\text{Var}(\hat{\mu}) = \frac{\sigma^2}{N} \quad (156)$$

³in generale questo avviene quando f non è lineare, infatti dalla *disuguaglianza di Jensen*: $\mathbb{E}[f(\theta)] \neq f(\mathbb{E}[\theta])$

⁴Basti vedere, ad esempio, il caso del parametro τ della distribuzione esponenziale studiato precedentemente.

Un'alternativa, qualora il calcolo analitico risulti complesso (ad esempio supponendo di aver stimato un parametro $\hat{\tau}$ ma di non riuscire a calcolarne la varianza), è ricorrere a simulazioni **Monte Carlo**. Si procede in questo modo: si esegue la simulazione della stima di τ per M volte indipendenti e si riportano i risultati in un istogramma. Per il Teorema del Limite Centrale, queste stime avranno una distribuzione normale; ricavando la varianza empirica σ^2 da tale distribuzione, la si può considerare come un'ottima approssimazione numerica della $\text{Var}(\hat{\tau})$.

Oltre a questi approcci, si può sfruttare la **disuguaglianza di Cramér-Rao**. Questo importante teorema fornisce un *limite inferiore* (lower bound) teorico alla varianza di una stima, indipendentemente dal metodo con cui essa è stata calcolata (anche se differisce dal ML):

$$\text{Var}(\hat{\theta}) \geq \frac{1}{-\mathbb{E}\left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2}\right]} \quad (157)$$

Per applicare questa disuguaglianza bisogna fare attenzione a un requisito fondamentale: è richiesto che $\hat{\theta}$ sia una stima *unbiased* (non distorta), cioè che il suo valore atteso coincida col parametro vero, $\mathbb{E}[\hat{\theta}] = \theta_{\text{vero}}$.

Essendo questo un limite inferiore assoluto, quando si riesce a ottenere uno stimatore la cui varianza soddisfa l'uguaglianza, si può affermare con certezza che la stima effettuata è **efficiente** (ha la minima varianza possibile).

$$\text{Var}(\hat{\theta}) \geq \frac{1}{\mathbb{E}\left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta}\right)^2\right]} \quad (158)$$

che, come si può vedere, si scrive in maniera equivalente come:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{\mathbb{E}\left[-\frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2}\right]} \quad (159)$$

Se $\hat{\theta}$ è *biased*, cioè ha una distorsione b , allora nel numeratore di queste formule si aggiunge un ulteriore termine che dipende dall'entità del bias, e precisamente vale:

$$\left(1 + \frac{\partial b}{\partial \theta}\right)^2 \quad (160)$$

Consideriamo per il momento il caso più semplice senza bias, anche perché in tutti i casi che abbiamo visto il bias si elimina per $N \rightarrow \infty$.

In generale, quando la disuguaglianza vale con il **segno uguale**, allora la stima si può dire **efficiente** (nel senso che è la più efficiente dato che ha la varianza minima possibile).

Esempio 1: Efficienza della media Gaussiana Nel caso di una distribuzione gaussiana, la media aritmetica è una stima efficiente di μ perché si può vedere facilmente che la disuguaglianza vale col segno di uguale. Infatti abbiamo appena visto che se x_i seguono distribuzioni gaussiane con la stessa μ e la stessa σ , allora:

$$\ln \mathcal{L}(x_i; \mu) = -\frac{N}{2} \ln(2\pi) + \sum_i \ln\left(\frac{1}{\sigma}\right) - \sum_i \frac{(x_i - \mu)^2}{2\sigma^2} \quad (161)$$

$$\frac{\partial \ln \mathcal{L}}{\partial \mu} = \frac{1}{\sigma^2} \sum_i (x_i - \mu) = \frac{1}{\sigma^2} \left[\left(\sum_i x_i \right) - N\mu \right] \quad (162)$$

Se ora calcoliamo la derivata seconda avremo:

$$\frac{\partial^2 \ln \mathcal{L}}{\partial \mu^2} = -\frac{N}{\sigma^2} \quad (163)$$

Dato che questo non dipende più da x , allora il suo valore di aspettazione è il valore ottenuto, cioè:

$$\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \mu^2} \right] = \mathbb{E} \left[-\frac{N}{\sigma^2} \right] = -\frac{N}{\sigma^2} \quad (164)$$

Da cui invertendo si ricava che per la disuguaglianza di Cramér-Rao dovremmo avere:

$$\text{Var}(\hat{\mu}) \geq \frac{\sigma^2}{N} \quad (165)$$

Però da altre considerazioni avevamo ricavato che $\text{Var}(\hat{\mu}) = \frac{\text{Var}(x)}{N} = \frac{\sigma^2}{N}$. Quindi in questo caso la disuguaglianza vale col segno di "=" ed è una **stima efficiente**.

Esempio 2: Efficienza del parametro Esponenziale Un altro esempio analogo è quello dell'esponenziale decrescente. In quel caso se per il singolo t_i avevamo:

$$P(t_i; \tau) = \frac{1}{\tau} e^{-t_i/\tau} \quad (166)$$

avevamo trovato che:

$$\ln \mathcal{L} = -N \ln \tau - \sum_i \frac{t_i}{\tau} \quad (167)$$

e

$$\frac{\partial \ln \mathcal{L}}{\partial \tau} = -\frac{N}{\tau} + \sum_i \frac{t_i}{\tau^2} \quad (168)$$

Per cui la derivata seconda è:

$$\frac{\partial^2 \ln \mathcal{L}}{\partial \tau^2} = \frac{N}{\tau^2} - 2 \frac{\sum_i t_i}{\tau^3} = \frac{N}{\tau^2} \left(1 - 2 \frac{\hat{\tau}}{\tau} \right) \quad (169)$$

Avendo usato $\hat{\tau} = \frac{1}{N} \sum_i t_i$. Essendo $\hat{\tau} = \bar{t}$ allora $\mathbb{E}[\hat{\tau}] = \mathbb{E}[\bar{t}] = \tau$, per cui:

$$\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \tau^2} \right] = \mathbb{E} \left[\frac{N}{\tau^2} \left(1 - 2 \frac{\hat{\tau}}{\tau} \right) \right] = \frac{N}{\tau^2} \left(1 - 2 \frac{\tau}{\tau} \right) = -\frac{N}{\tau^2} \quad (170)$$

Di nuovo, sostituendo nella disuguaglianza avremo:

$$\text{Var}(\hat{\tau}) \geq \frac{\tau^2}{N} \quad (171)$$

e avendo visto prima che $\text{Var}(\hat{\tau}) = \frac{\tau^2}{N}$, di nuovo questa è una stima efficiente.

Nota: si è visto che in generale $\mathbb{E}[\hat{\theta}] = \theta_{\text{vero}}$, ma qui l'approccio è: θ_{vero} è fissato ma io non lo conosco. Quindi uso θ invece di θ_{vero} e considero come cambia $\mathbb{E}[\hat{\theta}]$ al variare di θ , e per semplificare uso $\mathbb{E}[\hat{\theta}] = \theta$. (In generale dovrei scrivere $\mathbb{E}[\hat{\theta}] = f(\theta)$ e fare il conto da lì).

Dimostrazione della Disuguaglianza di Cramér-Rao

La dimostrazione della disuguaglianza procede attraverso vari passaggi.

Parte 1: Condizione di stima non distorta

Parto dalla definizione di stima *unbiased*, cioè $\mathbb{E}[\hat{\theta}] = \theta$, che scritto esplicitamente è:

$$\int_{-\infty}^{+\infty} dx_1 \int_{-\infty}^{+\infty} dx_2 \dots \int_{-\infty}^{+\infty} dx_N \hat{\theta} \mathcal{L}(x_1, x_2, \dots, x_N; \theta) = \theta \quad (172)$$

Per semplificare uso la seguente notazione compatta:

$$\int_{-\infty}^{+\infty} \hat{\theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = \theta \quad (173)$$

(Per semplicità sto supponendo che gli estremi di integrazione siano $-\infty, +\infty$, ma in realtà il conto torna purché gli estremi di integrazione **non dipendano da θ**).

Ora calcolo la derivata rispetto a θ di ambo i membri dell'equazione precedente. Visto che $\hat{\theta}$ dipende solo dalle x_i , la derivata ha effetto solo su $\mathcal{L}$ e quindi ho:

$$\boxed{\int_{-\infty}^{+\infty} \hat{\theta} \frac{\partial \mathcal{L}}{\partial \theta} d\vec{x} = \frac{\partial \theta}{\partial \theta} = 1} \quad (174)$$

Ora scriviamo la derivata sfruttando il fatto che:

$$\frac{\partial \ln \mathcal{L}}{\partial \theta} = \frac{1}{\mathcal{L}} \frac{\partial \mathcal{L}}{\partial \theta} \implies \frac{\partial \mathcal{L}}{\partial \theta} = \mathcal{L} \frac{\partial \ln \mathcal{L}}{\partial \theta} \quad (175)$$

e sostituendo ho:

$$\boxed{\int_{-\infty}^{+\infty} \hat{\theta} \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = 1} \quad (1)$$

Parte 2: Condizione di normalizzazione

Questa volta partiamo dalla condizione di normalizzazione di $\mathcal{L}$:

$$\int_{-\infty}^{+\infty} \mathcal{L}(\vec{x}; \theta) d\vec{x} = 1 \quad (176)$$

Manipoliamo come prima questa equazione calcolando la derivata rispetto a θ :

$$\int_{-\infty}^{+\infty} \frac{\partial \mathcal{L}}{\partial \theta} d\vec{x} = \frac{\partial(1)}{\partial \theta} = 0 \quad (177)$$

e poi introduciamo la derivata del logaritmo:

$$\boxed{\int_{-\infty}^{+\infty} \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = 0} \quad (2)$$

e si noti che la (2) equivale a dire che $\mathbb{E}\left[\frac{\partial \ln \mathcal{L}}{\partial \theta}\right] = 0$.

Parte 3: Applicazione della Disuguaglianza di Schwarz

Ora moltiplichiamo la (2) per θ e lo sottraiamo alla (1), cioè calcoliamo $(1) - \theta \cdot (2)$ e avremo:

$$\int_{-\infty}^{+\infty} \hat{\theta} \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} - \int_{-\infty}^{+\infty} \theta \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = 1 - 0 \quad (178)$$

e scrivendo tutto come un unico integrale ho:

$$\boxed{\int_{-\infty}^{+\infty} (\hat{\theta} - \theta) \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = 1} \quad (3)$$

A questo punto si usa la **disuguaglianza di Schwarz**:

$$\left(\int_a^b f^2(x) dx \right) \left(\int_a^b g^2(x) dx \right) \geq \left(\int_a^b f(x)g(x) dx \right)^2 \quad (179)$$

estendendola al nostro caso con N dimensioni e usando come:

$$f(\vec{x}) = (\hat{\theta} - \theta) \sqrt{\mathcal{L}(\vec{x}; \theta)}$$

$$g(\vec{x}) = \frac{\partial \ln \mathcal{L}}{\partial \theta} \sqrt{\mathcal{L}(\vec{x}; \theta)}$$

in modo che $f(\vec{x})g(\vec{x})$ dà proprio la funzione integranda della (3) e se quindi sostituisco nella disuguaglianza di Schwarz avrò $1^2 = 1$ al secondo membro, e la disuguaglianza diventa:

$$\underbrace{\left(\int_{-\infty}^{+\infty} (\hat{\theta} - \theta)^2 \mathcal{L}(\vec{x}; \theta) d\vec{x} \right)}_{\mathbb{E}[(\hat{\theta} - \theta)^2] = \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2] = \text{Var}(\hat{\theta})} \underbrace{\left(\int_{-\infty}^{+\infty} \left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \mathcal{L}(\vec{x}; \theta) d\vec{x} \right)}_{\mathbb{E}\left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta}\right)^2\right]} \geq 1 \quad (180)$$

Sostituendo ho quindi:

$$\text{Var}(\hat{\theta}) \cdot \mathbb{E} \left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \right] \geq 1 \implies \text{Var}(\hat{\theta}) \geq \frac{1}{\mathbb{E} \left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \right]} \quad (181)$$

che è proprio una delle formulazioni della disuguaglianza di Cramér-Rao. La quantità al denominatore si chiama spesso **Informazione** seguendo una denominazione introdotta da Fisher e viene indicata con $I(\theta)$.

Parte 4: Formulazione alternativa della derivata seconda

Per ottenere l'altra formulazione della disuguaglianza si può partire dalla (2) e facendo di nuovo la derivata rispetto a θ si ottiene (ricordando che $D[f(x)g(x)] = f'(x)g(x) + f(x)g'(x)$):

$$\int_{-\infty}^{+\infty} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \mathcal{L}(\vec{x}; \theta) + \frac{\partial \ln \mathcal{L}}{\partial \theta} \frac{\partial \mathcal{L}}{\partial \theta} \right] d\vec{x} = 0 \quad (182)$$

e da qui, sfruttando di nuovo il fatto che $\frac{\partial \mathcal{L}}{\partial \theta} = \mathcal{L} \frac{\partial \ln \mathcal{L}}{\partial \theta}$, si ha:

$$\int_{-\infty}^{+\infty} \frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \mathcal{L}(\vec{x}; \theta) d\vec{x} = - \int_{-\infty}^{+\infty} \left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \mathcal{L}(\vec{x}; \theta) d\vec{x} \quad (183)$$

che equivale alla relazione tra i valori di aspettazione:

$$\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \right] = - \mathbb{E} \left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \right] \quad (4)$$

e quindi sostituendo si passa alla formulazione:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{-\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \right]} \quad (184)$$

Si noti che il primo passaggio della dimostrazione sfrutta il fatto che la stima **non è deformata** (unbiased); se lo fosse, bisognerebbe sostituire $\mathbb{E}[\hat{\theta}] = \theta + b(\theta)$ e questo darebbe al numeratore un termine:

$$\left(1 + \frac{\partial b}{\partial \theta} \right)^2 \quad (185)$$

Approfondimento sulla disuguaglianza di Cramér-Rao

Consideriamo la funzione $\mathcal{L}(\vec{x}; \theta) \in (C)^2$ e lo stimatore t di una funzione $\tau(\theta)$. Possiamo definire il suo valore di aspettazione come:

$$\int_{-\infty}^{+\infty} dx_1 \int_{-\infty}^{+\infty} dx_2 \dots \int_{-\infty}^{+\infty} dx_N t(\vec{x}) \mathcal{L}(x_1, x_2, \dots, x_N; \theta) = \tau(\theta) + b(\theta) \quad (186)$$

con il significato della (118). Con l'assunzione che il range di $\vec{x}$ sia indipendente da θ , allora ottengo il risultato:

$$\int_{-\infty}^{+\infty} t(\vec{x}) \frac{\partial \mathcal{L}}{\partial \theta} d\vec{x} = \frac{\partial \tau(\theta)}{\partial \theta} + \frac{\partial b(\theta)}{\partial \theta} \quad (187)$$

Eseguendo calcoli simili a quelli sopra (3) si va ad ottenere:

$$\int_{-\infty}^{+\infty} (t - \tau(\theta)) \frac{\partial \ln \mathcal{L}}{\partial \theta} \mathcal{L}(\vec{x}; \theta) d\vec{x} = \frac{\partial \tau(\theta)}{\partial \theta} + \frac{\partial b(\theta)}{\partial \theta} \quad (188)$$

che attraverso la disuguaglianza di Schwarz mi porta ad ottenere:

$$\text{Var}(\hat{\theta}) \geq \frac{\left(\frac{\partial \tau}{\partial \theta} + \frac{\partial b}{\partial \theta} \right)^2}{\mathbb{E} \left[\left(\frac{\partial \ln \mathcal{L}}{\partial \theta} \right)^2 \right]} \quad (189)$$

Nel caso in cui si ha $\tau(\theta) = \theta$ e $b = 0$, riottengo la formula (181). Condizione necessaria e sufficiente per avere un'uguaglianza al posto della disuguaglianza di Schwarz è la seguente:

$$\frac{\partial \ln(\mathcal{L})}{\partial \theta} = A(\theta)(t - \tau(\theta) - b(\theta)) \quad (190)$$

In questo caso vado ad ottenere una soluzione del tipo:

$$\text{Var}(\hat{\theta}) = \frac{\left(\frac{\partial \tau}{\partial \theta} + \frac{\partial b}{\partial \theta}\right)^2}{A(\theta)} \quad (191)$$

Definizione: Efficienza di uno stimatore

L'efficienza di uno stimatore è dato dal rapporto tra la MVB e la varianza dello stimatore:

$$\text{efficienza}(t) = \frac{\text{MVB}}{\text{Var}}$$

15 Stime, Binned ML ed EML

Note su radioattività ambientale

In generale, tutti i nuclei atomici tendono a raggiungere una condizione di stabilità e, per farlo, si frantumano dando luogo al *decadimento radioattivo*. Le tipologie più comuni di decadimento sono:

- α : emissione di 2 protoni + 2 neutroni;
- β : emissione di un elettrone o un positrone;
- γ : radiazione elettromagnetica ad alta energia.

Anche in assenza di sorgenti artificiali, il suolo, l'aria e i materiali che ci circondano possono contenere nuclei instabili. Siamo quindi circondati da un campo di radiazioni, che genera la cosiddetta *radioattività naturale*.

Abbiamo già visto che questo è l'esempio tipico di fenomeni descritti dalla **statistica di Poisson**, i cui tempi di attesa tra un evento e l'altro hanno un andamento esponenziale decrescente, mentre i tempi di attesa per la rilevazione di K eventi seguono l'andamento dato dalla *distribuzione di Erlang*.

Strumentazione per l'acquisizione

I dati delle prossime esercitazioni deriveranno dall'analisi di acquisizioni provenienti da un contatore Geiger. Esso serve ad analizzare i *decadimenti gamma*, la cui distribuzione è, come detto, data da una Poissoniana.

Per il loro rilevamento si è usato un tubo Geiger, che è un cilindro di metallo con all'interno un gas a bassa pressione. Quando una particella ionizzante attraversa il tubo, ionizza il gas e genera una scarica elettrica che viene rilevata da un circuito elettronico. Il segnale così rilevato viene poi convertito in digitale attraverso un Arduino, il quale, tramite l'accensione e lo spegnimento del circuito, misura la differenza di tempo fra due eventi. L'Arduino lavora a 48 GHz.

Esercitazione 4

1. Utilizziamo i dati forniti e grafichiamo l'istogramma dei tempi d'attesa;
2. Utilizziamo il metodo di Maximum Likelihood (ML) per calcolare analiticamente la stima di τ ($\hat{\tau} = \bar{t}$) e la sua varianza ($\sigma_{\hat{\tau}} = \sqrt{\frac{\bar{t}}{n}}$, dove n è il numero di misure);
3. Verifichiamo col metodo grafico (spiegato di seguito) se otteniamo valori compatibili. Ricordiamo che, plottando la distribuzione, dobbiamo graficare entro $\approx 2/3 \sigma_{\hat{\tau}}$, altrimenti non riusciremo a visualizzare bene la regione del massimo;
4. Attuiamo una stima Monte-Carlo per ricavare $\sigma_{\hat{\tau}}$:
 - (a) simulo n (uguale a quello dei dati) eventi con distribuzione $\frac{1}{\tau} e^{-\frac{t}{\tau}}$ ponendo $\tau = \hat{\tau}$;
 - (b) ripeto per m volte in modo da avere m stime di $\hat{\tau}$;
 - (c) costruisco un grafico con le m stime, mi aspetto una gaussiana centrata in $\hat{\tau}$ e con deviazione standard data da $\sqrt{\sum_i \frac{(\hat{\tau}_i - \hat{\tau})^2}{n}}$, e dovrei trovare che quest'ultimo valore è compatibile con i $\sigma_{\hat{\tau}}$ trovati in precedenza.

15.1 Varianza della stima e Disuguaglianza di Cramer-Rao

Abbiamo visto che la disuguaglianza di Cramer-Rao ci dice che, in generale, per la varianza di uno stimatore $\hat{\theta}$ vale:

$$Var(\hat{\theta}) \geq \frac{-1}{\mathbb{E} \left[\frac{d^2 \ln \mathcal{L}}{d\theta^2} \right]} = \frac{1}{\mathbb{E} \left[\left(\frac{d \ln \mathcal{L}}{d\theta} \right)^2 \right]} \quad (192)$$

Una cosa che si può notare è che, data la definizione della funzione di Likelihood per variabili indipendenti:

$$\mathcal{L}(x_1, x_2, \dots, x_N; \theta) = \prod_{i=1}^N P(x_i; \theta) \implies \ln \mathcal{L}(x_1, \dots, x_N; \theta) = \sum_{i=1}^N \ln P(x_i; \theta) \quad (193)$$

Se gli x_i vengono tutti dalla stessa popolazione, allora sono descritti dalla stessa densità di probabilità $P(x; \theta)$, per cui:

$$\frac{d^2 \ln \mathcal{L}}{d\theta^2} = \frac{d^2}{d\theta^2} \sum_i \ln P(x_i; \theta) = \sum_i \frac{d^2}{d\theta^2} \ln P(x_i; \theta)$$

e quindi, per il valore di aspettazione:

$$\mathbb{E} \left[\frac{d^2 \ln \mathcal{L}}{d\theta^2} \right] = \sum_i \mathbb{E} \left[\frac{d^2}{d\theta^2} \ln P(x_i; \theta) \right] = N \cdot \mathbb{E} \left[\frac{d^2}{d\theta^2} \ln P(x; \theta) \right]$$

visto che tutte le funzioni $P(x_i; \theta)$ sono uguali. Ne segue quindi che **la varianza minima è inversamente proporzionale alla dimensione del campione** ($1/N$).

Stima di $\hat{\theta}$ e $Var(\hat{\theta})$ per $N \rightarrow \infty$

Al limite per $N \rightarrow \infty$ si può vedere che l'uguaglianza regge e si ha:

$$Var(\hat{\theta}) = \frac{-1}{\frac{d^2 \ln \mathcal{L}}{d\theta^2} \Big|_{\theta=\theta_0}} = \frac{-1}{\mathbb{E} \left[\frac{d^2 \ln \mathcal{L}}{d\theta^2} \right]}$$

Visto che la stima migliore del valore vero θ_0 è data da $\hat{\theta}$, nei casi in cui il valore di aspettazione di $\mathcal{L}$ non è facilmente calcolabile, si approssima e si indica con $\hat{\sigma}_{\hat{\theta}}^2$:

$$Var(\hat{\theta}) \approx \frac{-1}{\frac{d^2 \ln \mathcal{L}}{d\theta^2} \Big|_{\theta=\hat{\theta}}} \implies \widehat{Var}(\hat{\theta}) = \hat{\sigma}_{\hat{\theta}}^2 \quad (194)$$

Questo si può usare per derivare un **metodo grafico** per stimare la $Var(\hat{\theta})$ sviluppando in serie di Taylor $\ln \mathcal{L}$ intorno a $\hat{\theta}$ (ometto la notazione vettoriale $\vec{x}$ per semplicità):

$$\ln \mathcal{L}(\theta) = \ln \mathcal{L}(\hat{\theta}) + \frac{d \ln \mathcal{L}}{d\theta} \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \frac{1}{2!} \frac{d^2 \ln \mathcal{L}}{d\theta^2} \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2 + \dots$$

Per definizione di $\hat{\theta}$, $\ln \mathcal{L}(\hat{\theta}) = \ln \mathcal{L}_{max}$, mentre **la derivata prima calcolata in $\hat{\theta}$ deve essere nulla** (punto di massimo). Troncando al secondo ordine rimane:

$$\ln \mathcal{L}(\theta) \simeq \ln \mathcal{L}_{max} + \frac{1}{2} \frac{d^2 \ln \mathcal{L}}{d\theta^2} \Big|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2$$

Sfruttando l'approssimazione per la varianza vista prima, si ha:

$$\ln \mathcal{L}(\theta) \simeq \ln \mathcal{L}_{max} - \frac{1}{2} \frac{(\theta - \hat{\theta})^2}{Var(\hat{\theta})} \quad (195)$$

Quindi (sempre per $N \rightarrow \infty$) la $\ln \mathcal{L}$ ha un andamento parabolico nell'intorno del massimo. In particolare, è una parabola il cui massimo si ha in corrispondenza di $\hat{\theta}$ e il cui asse è parallelo all'asse delle ordinate.

In particolare, ponendo dei valori di θ chiamati $\tilde{\theta}$ tali che:

$$\frac{(\tilde{\theta} - \hat{\theta})^2}{Var(\hat{\theta})} = 1 \implies (\tilde{\theta} - \hat{\theta})^2 = Var(\hat{\theta}) \implies \tilde{\theta} = \hat{\theta} \pm \sigma_{\hat{\theta}} \quad (196)$$

Sostituendo questo risultato nello sviluppo di Taylor, troviamo la caratteristica fondamentale del metodo grafico:

$$\ln \mathcal{L}(\tilde{\theta}) = \ln \mathcal{L}_{max} - \frac{1}{2} \quad (197)$$

Se graficamente si riesce a costruire la funzione $\ln \mathcal{L}(\theta)$ e a determinarne il massimo ($\hat{\theta}$), andando a cercare le intersezioni della parabola con la retta orizzontale posta a $\ln \mathcal{L}_{max} - 1/2$, si riesce a stimare graficamente anche l'errore $\sigma_{\hat{\theta}}$.




Figura 18: Metodo grafico per determinare la stima e l'errore.

Approfondimento dal Rotondi sull'equazione 196

Consideriamo l'espansione di Taylor eseguita in precedenza. Poiché sappiamo che la funzione ML è invariante sotto riparametrizzazioni di θ , cerchiamo una funzione $\nu(\theta)$ tale che la sua varianza sia $\frac{1}{\text{Var}(\hat{\nu})} = 1$. Possiamo allora riformulare l'espansione di Taylor come:

$$2 [\ln \mathcal{L}(\hat{\nu}) - \ln \mathcal{L}(\nu)] \approx (\hat{\nu} - \nu)^2$$

Poiché per N grande $\hat{\nu} \sim \mathcal{N}(\nu, 1)$, allora ho l'intervallo di confidenza del 68.3% (1σ) per l'intervallo $\hat{\nu} \pm 1$. Risolvendo per la likelihood otteniamo proprio la condizione usata nel grafico:

$$\ln \mathcal{L}(\hat{\nu}) - \ln \mathcal{L}(\nu) = 0.5 \implies \ln \mathcal{L}(\nu) = \ln \mathcal{L}_{max} - \frac{1}{2}$$

Likelihood di più parametri

Nel caso in cui, invece di avere un solo parametro θ , si debba determinare la stima di m parametri $\theta_1, \theta_2, \dots, \theta_m$, tutto quello che abbiamo visto sin qui semplicemente si generalizza. Per ottenere le stime dei parametri si risolve il sistema di m equazioni del tipo:

$$\frac{\partial \ln \mathcal{L}(x_1, x_2, \dots, x_N; \theta_1, \theta_2, \dots, \theta_m)}{\partial \theta_i} = 0 \quad \text{per } i = 1, 2, \dots, m \quad (198)$$

(si usa N per le misure x_i e m per i parametri θ_i).

Stavolta al limite per $N \rightarrow \infty$ la funzione di Likelihood tende ad una Gaussiana multi-dimensionale e si introduce quindi la **matrice delle covarianze**, estendendo la formula per stimare la varianza in questo modo:

$$\hat{V}^{-1} = \text{cov}^{-1}(\hat{\theta}_i, \hat{\theta}_j) = -\mathbb{E} \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta_i \partial \theta_j} \right] \approx - \left[\frac{\partial^2 \ln \mathcal{L}}{\partial \theta_i \partial \theta_j} \Big|_{\vec{\theta}=\hat{\vec{\theta}}} \right] \quad (199)$$

Stavolta la $\ln \mathcal{L}$ è più difficile da disegnare, ma per esempio nel caso di $m = 2$, la superficie di livello $\ln \mathcal{L}(\theta_1, \theta_2) = \ln \mathcal{L}_{\max} - \frac{1}{2}$ restituisce un'ellisse centrata in $\ln \mathcal{L}_{\max}$ che ci permette di determinare σ_{θ_1} e σ_{θ_2} graficamente tramite la proiezione delle tangenti all'ellisse sugli assi.




Figura 19: Determinazione grafica degli errori nel caso a 2 parametri ($m = 2$).

15.2 Binned Maximum Likelihood

Una variante del metodo ML comunemente usata nel caso in cui il nostro set di dati è molto ampio, e risulta complicato calcolare la somma di tutti i $\ln P(x_i; \theta)$, è il metodo **Binned**.

In questo caso si assume di avere molte misure x_i della stessa grandezza fisica che seguono la stessa legge di distribuzione $P(x; \theta)$. L'idea è di formare un **istogramma** con le nostre x_i . Se l'istogramma ha m bin e indichiamo con $n_1, n_2, \dots, n_m$ i conteggi degli m bin, abbiamo visto che il valore di aspettazione dei conteggi nel bin i -esimo è dato in generale da:

$$\mathbb{E}[n_i] = \nu_i(\theta) = N \int_{x_i - \Delta x/2}^{x_i + \Delta x/2} P(x; \theta) dx \approx N \cdot P(x_i; \theta) \Delta x \quad (200)$$

che stavolta dipende direttamente da θ .

Si può quindi pensare alla misura come a un vettore degli m conteggi n_i (invece che degli N dati puntuali x_i). La pdf congiunta di questi conteggi, cioè la $\mathcal{L}$, è data dalla **distribuzione multinomiale**.

Nota sulla Multinomiale: La multinomiale è un'estensione della binomiale. Nella binomiale ho 2 risultati possibili (successo/insuccesso) con probabilità p e q , e stimo la probabilità di avere K successi in N estrazioni. Nella multinomiale ho m risultati diversi possibili ognuno con la sua probabilità p_i e stimo la probabilità di ottenere n_1 eventi di tipo 1, n_2 di tipo 2, ecc... dal totale di N estrazioni.

Tornando al Binned ML, nel nostro caso le probabilità dei singoli bin sono date da

$p_i = \nu_i(\theta)/N$, e quindi la Likelihood diventa:

$$\mathcal{L}(n_1, \dots, n_m; \theta) = \frac{N!}{n_1! n_2! \dots n_m!} \prod_{i=1}^m p_i^{n_i} = \frac{N!}{n_1! n_2! \dots n_m!} \prod_{i=1}^m \left(\frac{\nu_i(\theta)}{N} \right)^{n_i} \quad (201)$$

Passando al logaritmo e prendendo solo i termini che dipendono da θ , otteniamo:

$$\ln \mathcal{L}(n_1, \dots, n_m; \theta) = \sum_{i=1}^m n_i \ln \left(\frac{\nu_i(\theta)}{N} \right) + \text{cost} \quad (202)$$

dove i termini costanti non dipendono da θ e quindi non influenzano la ricerca del massimo. Si procede quindi massimizzando numericamente questa likelihood per trovare $\hat{\theta}$ e con i metodi grafici si può stimare $\sigma_{\hat{\theta}}$.

15.3 Extended Maximum Likelihood (EML)

Il metodo ML classico permette di stimare i parametri θ e si concentra sulla *forma* della distribuzione. Il metodo EML estende questa stima considerando **anche il numero di eventi come una incognita**.

Questo ha senso in esperimenti in cui si prendono dati per un certo periodo di tempo fissato, in cui si osservano N eventi. Il valore di N sarà solo una stima del numero medio ν di eventi attesi per il processo considerato. Per cui si può moltiplicare la $\mathcal{L}$ vista prima per la probabilità (Poissoniana) di ottenere N eventi in un processo aleatorio per cui la media di eventi attesi è ν :

$$\mathcal{L}^E(x_1, \dots, x_N; \theta, \nu) = \left(e^{-\nu} \frac{\nu^N}{N!} \right) \cdot \prod_{i=1}^N P(x_i; \theta) \quad (203)$$

La likelihood, quindi, ora dipende da **due parametri** ν e θ . Passando ai logaritmi e ignorando i termini che dipendono solo da N (che fungono da costante per la massimizzazione):

$$\ln \mathcal{L}^E = \sum_{i=1}^N \ln P(x_i; \theta) - \nu + N \ln \nu + \text{cost} \quad (204)$$

Scrivendo $N \ln \nu = \sum_{i=1}^N \ln \nu$ e includendolo nel termine della sommatoria, si ha:

$$\ln \mathcal{L}^E(x_1, \dots, x_N; \theta, \nu) = \sum_{i=1}^N \ln [\nu P(x_i; \theta)] - \nu + \text{cost} \quad (205)$$

Quando si massimizza $\ln \mathcal{L}^E$ bisogna ora trattarla come nel caso bidimensionale e la presenza di ν influirà sulla stima di θ se c'è una correlazione tra ν e θ .

Nel caso in cui ν e θ siano **indipendenti**, derivando l'equazione (204) rispetto a ν ottengo:

$$\frac{\partial \ln \mathcal{L}^E}{\partial \nu} = 0 \implies -1 + \frac{N}{\nu} = 0 \implies \hat{\nu} = N \quad (206)$$

e la stima $\hat{\theta}$ è esattamente la stessa di quella che si otterrebbe con il metodo ML standard.

Applicazione: Segnale e Fondo

L'utilità del metodo EML traspare pienamente quando i dati hanno **due componenti: segnale e fondo**. Si vogliono stimare i parametri fisici θ_s (del segnale) e θ_b (del fondo) oltre che il numero di eventi attesi di segnale (ν_s) e di fondo (ν_b). In questo caso la funzione di densità di probabilità totale diventa una mistura pesata, e la Extended Likelihood dipende da 4 parametri trovando numericamente il massimo di qualcosa del tipo:

$$\ln \mathcal{L}^E(\nu_s, \nu_b, \theta_s, \theta_b) = -(\nu_s + \nu_b) + \sum_{i=1}^N \ln \left(\nu_s P_s(x_i; \theta_s) + \nu_b P_b(x_i; \theta_b) \right) \quad (207)$$

essendo P_s e P_b le densità di probabilità normalizzate del segnale e del fondo.

16 Dal Metodo di Maximum Likelihood ai Minimi Quadrati

Supponiamo che i nostri dati consistano in un set di coppie di valori (x_i, y_i) in cui supponiamo che le x_i siano note con esattezza (senza errore), mentre le y_i vengano misurate con una certa incertezza σ_i . Supponiamo inoltre che le y_i siano in teoria descritte da una certa funzione f delle x_i , che dipende da un certo parametro θ da stimare: $f(x_i; \theta) = y_i$.

Per il teorema del limite centrale possiamo assumere che le misurazioni y_i abbiano distribuzione gaussiana centrata sul valore vero $f(x_i; \theta)$:

$$P(y_i; \theta) = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left\{ -\frac{[y_i - f(x_i; \theta)]^2}{2\sigma_i^2} \right\} \quad (208)$$

Se si usa il metodo di Maximum Likelihood (ML), costruendo la funzione $\mathcal{L}(\vec{y}; \theta) = \prod_i P(y_i; \theta)$ e passandone al logaritmo, si ottiene:

$$\ln \mathcal{L}(\vec{y}; \theta) = -\sum_{i=1}^N \ln(\sigma_i \sqrt{2\pi}) - \frac{1}{2} \sum_{i=1}^N \frac{[y_i - f(x_i; \theta)]^2}{\sigma_i^2} \quad (209)$$

In questa espressione, il parametro θ entra solo nel secondo addendo. Per cui, trovare il $\hat{\theta}$ che massimizza $\ln \mathcal{L}$ equivale a trovare il $\hat{\theta}$ che **minimizza** la sommatoria finale, indicata abitualmente con χ^2 :

$$\chi^2 = \sum_{i=1}^N \left[\frac{y_i - f(x_i; \theta)}{\sigma_i} \right]^2 \quad (210)$$

Per trovare il θ che minimizza il χ^2 si procede ponendo la derivata prima pari a zero (non serve la derivata seconda perché, essendo una somma di quadrati, il χ^2 ha la forma di una parabola rivolta verso l'alto nell'intorno del minimo):

$$\frac{\partial \chi^2}{\partial \theta} = 0 \implies \sum_{i=1}^N \frac{1}{\sigma_i^2} \frac{\partial f(x_i; \theta)}{\partial \theta} [y_i - f(x_i; \theta)] = 0 \quad (211)$$

Se la funzione f dipende da m parametri $\theta_1, \theta_2, \dots, \theta_m$, si dovrà risolvere un sistema di m equazioni del tipo:

$$\frac{\partial \chi^2}{\partial \theta_k} = 0 \quad \text{per } k = 1, 2, \dots, m \quad (212)$$

Una cosa importante da notare è che, in generale, ci si aspetta che la differenza tra il valore misurato y_i e la stima teorica $f(x_i; \theta)$ sia dovuta all'errore sperimentale ϵ_i . Ovvero $y_i = f(x_i; \theta) + \epsilon_i$, con $\epsilon_i \sim \mathcal{N}(0, \sigma_i^2)$. Da ciò deriva che la quantità residua normalizzata:

$$\frac{y_i - f(x_i; \theta)}{\sigma_i} \sim \mathcal{N}(0, 1) \quad (213)$$

16.1 Caso del fit lineare $y = mx + q$

Il caso più comune trattato con il metodo dei minimi quadrati è quello in cui si assume che **tutte le y_i abbiano lo stesso errore σ** (cosa verosimile se si tratta di misurazioni della stessa grandezza fatte con lo stesso strumento) e siano legate alle x_i dalla relazione lineare $y = mx + q$.

I parametri da determinare sono la pendenza m e l'intercetta q . Essendo σ costante, il suo valore può essere portato fuori dalla sommatoria e non influenza la posizione del minimo. Dobbiamo minimizzare la quantità:

$$\sum_{i=1}^N (y_i - mx_i - q)^2 \quad (214)$$

Risolviamo il sistema derivando rispetto ai due parametri:

$$\begin{cases} \frac{\partial}{\partial m} \sum_i (y_i - mx_i - q)^2 = 0 \\ \frac{\partial}{\partial q} \sum_i (y_i - mx_i - q)^2 = 0 \end{cases} \implies \begin{cases} \sum_i 2(-x_i)(y_i - mx_i - q) = 0 & (1) \\ \sum_i 2(-1)(y_i - mx_i - q) = 0 & (2) \end{cases} \quad (215)$$

Ignorando i fattori costanti (-2), lavoriamo sull'equazione (2). Sfruttando la proprietà distributiva della sommatoria:

$$\sum_i y_i - m \sum_i x_i - \sum_i q = 0 \implies \sum_i y_i - m \sum_i x_i - Nq = 0$$

Dividendo per N , e introducendo le notazioni delle medie ($\bar{y} = \frac{\sum y_i}{N}$ e $\bar{x} = \frac{\sum x_i}{N}$):

$$\hat{q} = \bar{y} - \hat{m}\bar{x} \quad (216)$$

Sostituendo questo risultato nell'equazione (1) (che divisa per N diventa $\overline{xy} - m\overline{x^2} - q\bar{x} = 0$):

$$\begin{aligned} \overline{xy} - m\overline{x^2} - (\bar{y} - m\bar{x})\bar{x} &= 0 \\ \overline{xy} - m\overline{x^2} - \bar{y}\bar{x} + m(\bar{x})^2 &= 0 \implies m(\overline{x^2} - \bar{x}^2) = \overline{xy} - \bar{x}\bar{y} \end{aligned}$$

Da cui si ottiene la stima per m :

$$\hat{m} = \frac{\overline{xy} - \bar{x}\bar{y}}{x^2 - (\bar{x})^2} \quad (217)$$

E ri-sostituendo nella (216) si ottiene la forma esplicita per $\hat{q}$:

$$\hat{q} = \bar{y} - \left[\frac{\overline{xy} - \bar{x}\bar{y}}{x^2 - (\bar{x})^2} \right] \bar{x} = \frac{\bar{y}x^2 - \overline{xy}\bar{x}}{x^2 - (\bar{x})^2} \quad (218)$$

Notazione compatta

L'uso delle medie rende la notazione compatta da scrivere, ma per i calcoli al computer risulta scomoda per le troppe divisioni per N . Si è soliti definire le somme:

$$S_x = \sum_i x_i, \quad S_y = \sum_i y_i, \quad S_{xx} = \sum_i x_i^2, \quad S_{xy} = \sum_i x_i y_i$$

E il denominatore comune $D = NS_{xx} - (S_x)^2$. Le stime si riscrivono come:

$$\begin{cases} \hat{m} = \frac{NS_{xy} - S_x S_y}{D} \\ \hat{q} = \frac{S_y S_{xx} - S_x S_{xy}}{D} \end{cases} \quad (219)$$

Nota: $\hat{m}$ e $\hat{q}$ non dipendono da σ . Quindi le stime dei parametri si possono calcolare anche se non si conosce a priori l'errore sperimentale, purché si assuma che sia lo stesso per tutti i punti.

Errori associati alle stime

Per calcolare gli errori su $\hat{m}$ e $\hat{q}$ applichiamo la legge di propagazione degli errori. Poiché le uniche variabili aleatorie con errore sono le y_i , la varianza su una generica funzione $f(y_1 \dots y_N)$ è: $\sigma_f^2 = \sum_i \left(\frac{\partial f}{\partial y_i} \right)^2 \sigma_{y_i}^2$.

Riscriviamo $\hat{m}$ mettendo in evidenza y_i :

$$\hat{m} = \frac{\sum_i \frac{x_i y_i}{N} - \bar{x} \sum_i \frac{y_i}{N}}{x^2 - (\bar{x})^2} = \sum_{i=1}^N \underbrace{\left[\frac{x_i - \bar{x}}{x^2 - (\bar{x})^2} \frac{1}{N} \right]}_{\text{costante rispetto a } y_i} y_i$$

Calcoliamo ora la varianza, ricordando che l'errore $\sigma_{y_i} = \sigma$ è costante:

$$\sigma_{\hat{m}}^2 = \sum_{i=1}^N \left(\frac{\partial \hat{m}}{\partial y_i} \right)^2 \sigma^2 = \sum_{i=1}^N \left[\frac{x_i - \bar{x}}{x^2 - (\bar{x})^2} \frac{1}{N} \right]^2 \sigma^2 \quad (220)$$

Ricordando la definizione di varianza campionaria $\frac{1}{N} \sum_i (x_i - \bar{x})^2 = \overline{x^2} - (\bar{x})^2$, e semplificando i termini, si ottiene:

$$\sigma_m^2 = \frac{\sigma^2}{N[\overline{x^2} - (\bar{x})^2]} = \frac{N\sigma^2}{D} \quad (221)$$

Con una procedura analoga per l'intercetta si ottiene:

$$\sigma_q^2 = \frac{\sigma^2 S_{xx}}{D} \quad (222)$$

Estrapolazione e Covarianza

Una volta trovata la retta di best fit $y = \hat{m}x + \hat{q}$, potremmo voler calcolare il valore previsto y e il suo errore associato per una nuova coordinata x . Le variabili aleatorie in questa equazione sono i parametri stimati $\hat{m}$ e $\hat{q}$ (la x è uno scalare da noi fissato). Per la propagazione degli errori su una somma $z = a\tilde{x} + b\tilde{y}$:

$$Var(y) = x^2 Var(\hat{m}) + Var(\hat{q}) + 2x \cdot cov(\hat{m}, \hat{q}) \quad (223)$$

Per fare questo calcolo ci serve il termine di covarianza. Usando la definizione di $\hat{q} = \bar{y} - \hat{m}\bar{x}$:

$$cov(\hat{m}, \hat{q}) = cov(\hat{m}, \bar{y} - \hat{m}\bar{x}) = \underbrace{cov(\hat{m}, \bar{y})}_{=0} - \bar{x} \cdot cov(\hat{m}, \hat{m}) = -\bar{x} \cdot \sigma_m^2 \quad (224)$$

Esplicitando si ottiene:

$$cov(\hat{m}, \hat{q}) = -\frac{\bar{x}\sigma^2}{N[\overline{x^2} - (\bar{x})^2]} \quad (225)$$

Trucco della traslazione: La cosa interessante di questa formula è che se $\bar{x} = 0$, la covarianza si annulla ($cov(\hat{m}, \hat{q}) = 0$), rendendo la formula della varianza su y molto più semplice. Per questo motivo, in alcuni casi è conveniente operare una traslazione, definendo $x' = x - \bar{x}$ (che ha per costruzione media nulla) ed eseguendo un nuovo fit $y = mx' + q'$. La pendenza della retta non cambia, ma cambia l'intercetta. Con le nuove coordinate si avrà semplicemente: $Var(y) = (x')^2 Var(\hat{m}) + Var(\hat{q}')$.

16.2 Caso $y = mx + q$ con errori σ_i differenti

Se gli errori σ_i non sono tutti uguali, la quantità da minimizzare non può espellere il σ_i dalla sommatoria:

$$\chi^2 = \sum_i \frac{(y_i - mx_i - q)^2}{\sigma_i^2} \quad (226)$$

Rifacendo la procedura precedente, si trovano formule del tutto simili, eccetto per il fatto che tutte le medie diventano **medie pesate** con peso $w_i = 1/\sigma_i^2$, e la normalizzazione non è più N ma la somma dei pesi. Definiamo:

$$W_x = \sum_i \frac{x_i}{\sigma_i^2}, \quad W_y = \sum_i \frac{y_i}{\sigma_i^2}, \quad W_{xx} = \sum_i \frac{x_i^2}{\sigma_i^2}, \quad W_{xy} = \sum_i \frac{x_i y_i}{\sigma_i^2}, \quad W = \sum_i \frac{1}{\sigma_i^2} \quad (227)$$

Il nuovo denominatore diventa $D_W = W \cdot W_{xx} - (W_x)^2$. Le nuove stime e i relativi errori sono:

$$\begin{cases} \hat{m} = \frac{W \cdot W_{xy} - W_x W_y}{D_W} \\ \hat{q} = \frac{W_y W_{xx} - W_x W_{xy}}{D_W} \end{cases} \quad \text{ed i rispettivi errori:} \quad \begin{cases} \sigma_{\hat{m}}^2 = \frac{W}{D_W} \\ \sigma_{\hat{q}}^2 = \frac{W_{xx}}{D_W} \end{cases} \quad (228)$$

In questo caso, **le stime di m e q dipendono dai σ_i** . Pertanto, se non conosco gli errori non posso calcolare il fit in maniera matematicamente rigorosa per i pesi sbilanciati.

Metodo dei minimi quadrati con istogrammi

Il metodo dei minimi quadrati si può applicare anche nel caso in cui abbiamo dati raccolti sotto forma di **istogramma** (misure di 1 sola grandezza). In tal caso, utilizziamo l'indice j per indicare i bin dell'istogramma ($j = 1, \dots, m$ bin) rispetto all'indice i usato prima per gli N dati. Sostituiamo:

- $y_i \longrightarrow m_j$ (conteggi effettivi nel bin j -esimo)
- $f(x_i; \theta) \longrightarrow \mathbb{E}[m_j] = \nu_j(\theta)$ (valore di aspettazione nel bin j -esimo)

Se immaginiamo di dividere l'asse x in bin di uguale larghezza Δx , centrati in $\tilde{x}_j$:

$$\mathbb{E}[m_j] = \nu_j(\theta) = N \int_{\tilde{x}_j - \frac{\Delta x}{2}}^{\tilde{x}_j + \frac{\Delta x}{2}} P(x; \theta) dx \approx N \cdot P(\tilde{x}_j; \theta) \Delta x \quad (229)$$

Il nostro χ^2 vale quindi:

$$\chi^2 = \sum_{j=1}^m \frac{[m_j - \nu_j(\theta)]^2}{\sigma_j^2} \quad (230)$$

Manca solo da definire σ_j^2 . Assumendo che i conteggi in ogni bin seguano una statistica **Poissoniana**, il valore atteso coincide con la varianza: $\sigma_j^2 \simeq \nu_j(\theta)$ (Metodo del χ^2 di *Pearson*).

$$\chi_{\text{Pearson}}^2 = \sum_{j=1}^m \frac{[m_j - \nu_j(\theta)]^2}{\nu_j(\theta)} \quad (231)$$

Molto spesso, per semplificare i conti, si usa l'approssimazione che la varianza del bin sia circa uguale ai conteggi misurati nel bin stesso, cioè $\sigma_j^2 \simeq m_j$ (Metodo del χ^2 di *Neyman*):

$$\chi_{\text{Neyman}}^2 = \sum_{j=1}^m \frac{[m_j - \nu_j(\theta)]^2}{m_j} \quad (232)$$

Questa ultima formula **funziona bene solo se i bin hanno molti conteggi** e se m_j non discosta molto da $\nu_j(\theta)$. In ogni caso bisogna prestare molta attenzione ai bin per cui $m_j = 0$ oppure $\nu_j(\theta) = 0$ (bisogna eventualmente escluderli dal calcolo per evitare divisioni per zero).

Metodo dei minimi quadrati non lineare

Nel caso in cui il modello non riesca a essere ricondotto ad una forma lineare per cui si hanno soluzioni esatte esplicite, si usano **procedure iterative numeriche**. Si parte da un valore iniziale θ_0 , si calcola il χ^2 , e si procede iterativamente aggiornando i parametri ($\theta_1 = \theta_0 + \Delta\theta$) seguendo il gradiente fino a quando non si trova il minimo di χ^2 .

Nella pratica esistono molti modi matematici e librerie per fare ciò, applicando metodi numerici più o meno sofisticati. Qualunque sia il metodo usato, **la scelta del valore iniziale θ_0 da cui partire è di solito fondamentale** per evitare di finire intrappolati in minimi locali.

Vale la pena visualizzare preliminarmente la funzione teorica (con il θ_0 scelto) sovrapposta ai dati sperimentali, per operare un "sanity check" del punto di partenza. Nel campo dell'analisi dati, in Python, tutto questo si fa usando librerie già scritte: ad esempio si può usare la funzione `curve_fit` contenuta nel modulo `scipy.optimize`.

17 Binned Chi Squared

Stima dell'errore nel caso Binned χ^2

Abbiamo visto che è possibile applicare il metodo dei minimi quadrati direttamente agli istogrammi. Nel caso del metodo *Binned Chi Squared*, la funzione da minimizzare è:

$$\chi^2(\theta) = \sum_{j=1}^m \frac{[m_j - \nu_j(\theta)]^2}{m_j} \quad (233)$$

dove m_j è il contenuto dei bin dell'istogramma e $\nu_j(\theta)$ è il valore di aspettazione di ogni bin dell'istogramma, approssimabile come $\nu_j(\theta) \simeq NP(x_j; \theta)\Delta x$.

Per trovare la stima $\hat{\theta}$ si procede trovando numericamente il minimo di χ^2 . Ma come si fa a trovare l'errore $\sigma_{\hat{\theta}}$? Il procedimento è analogo al metodo grafico visto nel caso della Maximum Likelihood (ML), poiché in fondo il χ^2 deriva da $\ln \mathcal{L}$.

Infatti, se i nostri dati sono coppie (x_i, y_i) e si conosce la funzione che lega le grandezze (cioè $y = f(x; \theta)$), assumendo che le y_i siano distribuite secondo gaussiane con errori σ_i , si arriva a scrivere la likelihood come:

$$\ln \mathcal{L}(\vec{y}; \theta) = -\frac{1}{2} \sum_i \frac{[y_i - f(x_i; \theta)]^2}{\sigma_i^2} + \text{cost} = -\frac{1}{2} \chi^2(\theta) + \text{cost} \quad (234)$$

Da cui otteniamo la relazione fondamentale:

$$\chi^2(\theta) = -2 \ln \mathcal{L}(\theta) + \text{cost}' \quad (235)$$

Questo ci è utile perché avevamo visto che per la varianza vale:

$$\text{var}(\hat{\theta}) \approx \frac{-1}{\left. \frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \right|_{\theta=\hat{\theta}}} \quad (236)$$

Derivando la (235) rispetto a θ , otteniamo:

$$\frac{\partial^2 \chi^2}{\partial \theta^2} = -2 \frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} \implies \frac{\partial^2 \ln \mathcal{L}}{\partial \theta^2} = -\frac{1}{2} \frac{\partial^2 \chi^2}{\partial \theta^2} \quad (237)$$

Sostituendo, ricaviamo la stima della varianza in funzione del χ^2 :

$$\sigma_{\hat{\theta}}^2 = \text{var}(\hat{\theta}) \approx \frac{2}{\left. \frac{\partial^2 \chi^2}{\partial \theta^2} \right|_{\theta=\hat{\theta}}} \quad (238)$$

Metodo Grafico per la determinazione dell'errore

Possiamo sviluppare $\chi^2(\theta)$ in serie di Taylor attorno al minimo $\hat{\theta}$:

$$\chi^2(\theta) = \chi^2(\hat{\theta}) + \left. \frac{\partial \chi^2}{\partial \theta} \right|_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \frac{1}{2} \left. \frac{\partial^2 \chi^2}{\partial \theta^2} \right|_{\theta=\hat{\theta}} (\theta - \hat{\theta})^2 + \dots \quad (239)$$

Essendo $\hat{\theta}$ un minimo, la derivata prima si annulla e poniamo $\chi^2(\hat{\theta}) = \chi_{\min}^2$. Sostituendo la derivata seconda con la varianza ricavata in precedenza:

$$\chi^2(\theta) \simeq \chi_{\min}^2 + \frac{1}{2} \left(\frac{2}{\text{var}(\hat{\theta})} \right) (\theta - \hat{\theta})^2 = \chi_{\min}^2 + \frac{(\theta - \hat{\theta})^2}{\text{var}(\hat{\theta})} \quad (240)$$

Definendo $\tilde{\theta}$ i valori tali per cui $\frac{(\tilde{\theta} - \hat{\theta})^2}{\text{var}(\hat{\theta})} = 1$, ovvero $\tilde{\theta} = \hat{\theta} \pm \sigma_{\hat{\theta}}$, avremo graficamente che:

$$\chi^2(\tilde{\theta}) = \chi_{\min}^2 + 1 \quad (241)$$

Quindi $\sigma_{\hat{\theta}}$ si ricava cercando le intersezioni della parabola locale con il valore del minimo +1.

Nota: Dalla definizione, cerchiamo il modello teorico che si discosta meno dalle misurazioni. Se il modello descrive bene i dati ci aspettiamo che il numeratore del χ^2 sia dell'ordine dell'errore al quadrato al denominatore. Un valore di χ^2 "troppo grande" indica problemi nel modello o nei dati, mentre un valore "troppo piccolo" (cioè varianza dei dati molto minore dell'errore stimato) può significare che stiamo sovrastimando gli errori.

Approfondimento dal Cowan di (241)

Per un modello lineare: $f = A\theta$, posso utilizzare la definizione di χ^2 e ricavare:

$$\chi^2(\theta) = (\mathbf{y} - A\theta)^T V^{-1} (\mathbf{y} - A\theta)$$

Volendo trovare $\hat{\theta}$ risolvo:

$$\frac{\partial \chi^2}{\partial \theta} = -2A^T V^{-1} (\mathbf{y} - A\theta) \implies \hat{\theta} = (A^T V^{-1} A)^{-1} A^T V^{-1} \mathbf{y} = B\mathbf{y}$$

Utilizzando la propagazione degli errori:

$$\text{cov}(\theta_i, \theta_j) = U = BVB^T = (A^T V^{-1} A)^{-1}$$

dove si è utilizzato quanto trovato sopra per calcolare BVB^T .

Espandendo χ^2 rispetto a θ otteniamo:

$$\begin{aligned}\chi^2(\theta) &= \chi^2(\hat{\theta}) + \frac{1}{2} \sum_{i,j} \left[\frac{\partial^2 \chi^2}{\partial \theta_i \partial \theta_j} \right]_{\theta=\hat{\theta}} (\theta_i - \hat{\theta}_i)(\theta_j - \hat{\theta}_j) = \\ \chi^2(\hat{\theta}) + \frac{1}{2} 2(A^T V^{-1} A)_{ij} (\theta_i - \hat{\theta}_i)(\theta_j - \hat{\theta}_j) &= \chi^2(\hat{\theta}) + \frac{1}{2} 2(U)_{ij} (\theta_i - \hat{\theta}_i)(\theta_j - \hat{\theta}_j) \\ \chi^2(\theta) &= \chi^2(\hat{\theta}) + (\theta - \hat{\theta})^T U^{-1} (\theta - \hat{\theta})\end{aligned}$$

Per definizione statistica, il contorno di confidenza a **una deviazione standard** (1 σ) per una distribuzione gaussiana multivariata è il luogo dei punti dove:

$$(\theta - \hat{\theta})^T U^{-1} (\theta - \hat{\theta}) = 1$$

Sostituendo questo valore nell'espansione:

$$\chi^2(\theta) = \chi^2(\hat{\theta}) + 1 = \chi^2_{\min} + 1 \quad (242)$$

17.1 Distribuzione del χ^2

Per avere un riferimento quantitativo con cui confrontare il risultato della minimizzazione, bisogna conoscere la distribuzione di probabilità $P(\chi^2)$. Seguiamo un ragionamento intuitivo. Se $y_i = f(x_i) + \varepsilon_i$, con errore di misura $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$, allora la variabile standardizzata:

$$u_i = \frac{y_i - f(x_i)}{\sigma_i} \sim \mathcal{N}(0, 1) \implies P_u(u_i) \propto e^{-u_i^2/2} \quad (243)$$

Nel χ^2 i termini appaiono al quadrato, definendo $z_i = u_i^2$. Con il cambio di variabile:

$$P_z(z_i) = P_u(u_i) \left| \frac{du_i}{dz_i} \right| = P_u(\sqrt{z_i}) \frac{1}{2\sqrt{z_i}} \propto \frac{1}{\sqrt{z_i}} e^{-z_i/2} \quad (244)$$

Per le proprietà degli esponenziali, la somma produce un termine del tipo $\prod_i e^{-z_i/2} = e^{-\sum z_i/2} = e^{-\chi^2/2}$. Tenendo conto di tutti i fattori e della normalizzazione, la distribuzione esatta è:

$$P(\chi^2; \nu) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} (\chi^2)^{\nu/2-1} e^{-\chi^2/2} \quad (245)$$

Dove $\Gamma(\alpha) = \int_0^{+\infty} y^{\alpha-1} e^{-y} dy$ è la funzione Gamma di Eulero, e ν è il **numero di gradi di libertà** (ndf).

Il parametro ν corrisponde al numero di elementi indipendenti della sommatoria:

$$\nu = N - \text{numero di parametri} - \text{numero di vincoli} \quad (246)$$

Esempio. Nel caso del Binned χ^2 , abbiamo il vincolo $\sum_{i=1}^m h_i = N$ (la normalizzazione che lega le altezze dei bin) ed un parametro stimato θ . Per cui i gradi di libertà sono $\nu = m - 1 - 1 = m - 2$.

Valore atteso e varianza della distribuzione sono:

$$\mathbb{E}[\chi^2] = \nu \quad \text{e} \quad \text{var}(\chi^2) = 2\nu \quad (247)$$




Figura 20: Distribuzione χ^2 per diversi gradi di libertà (ν). Si nota come all'aumentare di ν la distribuzione si sposti verso destra.

Comportamento Asintotico e χ^2 ridotto

Questo ci dà un riferimento importante: il valore atteso del minimo del χ^2 è $\approx \nu$. Si definisce quindi il χ^2 **ridotto**:

$$\chi_{\text{rid}}^2 = \frac{\chi^2}{\nu} \quad (248)$$

che in teoria dovrebbe essere ≈ 1 .

Caso ν grande ($\nu \gtrsim 30$)

Il controllo sul χ^2 ridotto ha senso quando ν è grande. Per il Teorema del Limite Centrale, la distribuzione tende a una Normale:

$$P(\chi^2; \nu) \xrightarrow{\nu \gg 1} \mathcal{N}(\nu, 2\nu) \quad (249)$$




Figura 21: Zoom per grandi valori di ν . Si apprezza l'ottima approssimazione a curva Gaussiana.

Per la variabile ridotta $y = \chi^2/\nu$:

$$P_y(y) = P_{\chi^2}(\nu y) \cdot \nu = \frac{1}{\sqrt{2\pi}\sqrt{2\nu}} e^{-\frac{(\nu y - \nu)^2}{2(2\nu)}} \cdot \nu = \frac{1}{\sqrt{2\pi}\sqrt{2/\nu}} e^{-\frac{(y-1)^2}{2(2/\nu)}} \quad (250)$$

Quindi $\chi^2/\nu \sim \mathcal{N}(1, \frac{2}{\nu})$. È una gaussiana centrata in 1, tanto più stretta quanto maggiore è ν .




Figura 22: Distribuzione del χ^2 ridotto. Per $\nu = 50$ si nota la perfetta sovrapposizione con la normale $\mathcal{N}(1, 2/\nu)$.

Caso ν piccolo

Per ν piccoli la distribuzione del χ^2 è fortemente asimmetrica con lunghe code a destra. Qui la probabilità di fluttuazioni grandi è molto alta, e usare la regola $\chi^2/\nu \approx 1$ non è più un criterio affidabile (grande dispersione).




Figura 23: Asimmetria della distribuzione per piccoli gradi di libertà.

Per ν piccoli, si preferisce usare la variabile casuale $z = \sqrt{2\chi^2}$. Calcoliamo la sua distribuzione tramite $x = z^2/2 \implies dx/dz = z$:

$$P_z(z) = P_x\left(\frac{z^2}{2}\right) \cdot z \quad (251)$$

Si dimostra che questa variabile si può ben approssimare (anche per ν piccoli) come:

$$\sqrt{2\chi^2} \sim \mathcal{N}(\sqrt{2\nu - 1}, 1) \quad (252)$$




Figura 24: Distribuzione della variabile ausiliaria $\sqrt{2\chi^2}$ che approssima una gaussiana di varianza 1 anche per bassi ν .

Esercitazione 5

L'esercitazione pratica si compone di diverse parti applicative.

Parte 1: Distribuzioni di Erlang e Poisson

Utilizziamo i dati dell'esercitazione precedente:

1. **Erlang** ($k = 2$): Sommiamo i tempi tra eventi consecutivi a coppie (tempo tra evento i ed $i + 2$) e costruiamo un istogramma. Aggiungiamo gli errori ($\sqrt{m_i}$) e facciamo il fit con la distribuzione di Erlang per ricavare la stima di τ .
2. **Stima di λ** : Considerando $\lambda = 1/\tau$, utilizziamo i metodi di Maximum Likelihood e Minimi Quadrati per stimarlo. Si calcoli il χ^2_{ridotto} controllando che sia prossimo a 1.

Nota: La sommatoria nel χ^2 va fatta solo sui bin non nulli ($m_i > 0$). Solo questi vengono contati nel calcolo dei gradi di libertà ν .
3. **Poisson**: Contiamo il numero di eventi in prefissati intervalli Δt (consigliato $\Delta t = 30$ s). Si tracci l'istogramma dei conteggi e si sovrapponga la distribuzione di Poisson teorica (per sovrapporla correttamente ai dati occorre utilizzare come parametro $\mu = \lambda\Delta t$).

Parte 2: Decadimento Radioattivo e Fit Lineare

Vogliamo eseguire un fit pesato con i conteggi di un contatore Geiger. Se λ è la probabilità di decadimento per unità di tempo, e $N(t)$ è il numero di nuclei non decaduti, la variazione di N nel tempo dt è:

$$dN = -\lambda N(t)dt \implies \frac{dN}{N} = -\lambda dt \quad (253)$$

Integrando tra 0 e t (dove a $t = 0$ i nuclei sono N_0):

$$\ln N = -\lambda t + \text{cost} \implies N(t) = N_0 e^{-\lambda t} \quad (254)$$

Il contatore Geiger misura i decadimenti per unità di tempo (il tasso di conteggio):

$$m(t) \propto -\frac{dN}{dt} = \lambda N_0 e^{-\lambda t} = m_0 e^{-t/\tau} \quad (255)$$

Per usare il metodo dei minimi quadrati lineari, passiamo ai logaritmi:

$$\ln m(t) = \ln m_0 - \frac{t}{\tau} \quad (256)$$

Che è l'equazione di una retta $y = ax + b$ dove:

- $y_i = \ln m(t_i)$
- $x_i = t_i$
- $a = -1/\tau$
- $b = \ln m_0$

Sapendo che i conteggi seguono una statistica di Poisson, l'errore sul singolo conteggio è $\sigma_{m_i} = \sqrt{m_i}$. Poiché abbiamo applicato una trasformazione logaritmica ($y = \ln m$), dobbiamo usare la **propagazione degli errori** per trovare σ_{y_i} :

$$\sigma_{y_i}^2 = \left(\frac{\partial \ln m}{\partial m} \right)^2 \sigma_{m_i}^2 = \left(\frac{1}{m_i} \right)^2 m_i = \frac{1}{m_i} \implies \sigma_{y_i} = \frac{1}{\sqrt{m_i}} \quad (257)$$

Faremo un fit lineare pesato utilizzando pesi $w_i = 1/\sigma_{y_i}^2 = m_i$.

Nota: Questo metodo funziona bene se m_i è abbastanza grande (dell'ordine delle decine), perché la Poissoniana si può approssimare a una Gaussiana. Il logaritmo inoltre amplifica enormemente le differenze per piccoli valori (mentre $\ln 10 \sim \ln 11$, tra $\ln 1$ e $\ln 2$ c'è molta differenza). Le asimmetrie naturali della Poissoniana a bassi conteggi verrebbero amplificate dalla distorsione del logaritmo, invalidando i presupposti dei minimi quadrati gaussiani.

Codice Python: Generazione Distribuzioni χ^2

Di seguito il codice Python utilizzato per esplorare la forma analitica della distribuzione del χ^2 , i suoi limiti per grandi gradi di libertà ($\nu \geq 30$) e la linearizzazione per ν piccolo tramite la variabile ausiliaria $\sqrt{2\chi^2}$.

```
# -*- coding: utf-8 -*-
"""Distribuzione del chi quadro"""

import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import chi2, norm

# 1. Valori di gradi di libert  (generale)
ndf_values = [2, 5, 10, 30, 50]
x = np.linspace(0, 100, 1000)

plt.figure(figsize=(10, 6))
for ndf in ndf_values:
    y = chi2.pdf(x, df=ndf)
    plt.plot(x, y, label=f'$\chi^2$ (n={ndf})')

# Sovrapposizione gaussiana per n grande
ndf_large = 50
mean = ndf_large
std = np.sqrt(2 * ndf_large)
gauss = norm.pdf(x, loc=mean, scale=std)
plt.plot(x, gauss, 'k--', linewidth=2, label=f'Gaussiana (n={ndf_large})')

plt.title('Distribuzione $\chi^2$ per diversi gradi di libert ')
plt.xlabel('$\chi^2$')
plt.ylabel('Densit  di probabilit ')
plt.legend()
plt.grid()
plt.show()

# 2. Zoom per grandi valori di gradi di libert 
ndf_values = [30, 50]
plt.figure(figsize=(10, 6))
for ndf in ndf_values:
    y = chi2.pdf(x, df=ndf)
    plt.plot(x, y, label=f'$\chi^2$ (n={ndf})')
    mean = ndf
    std = np.sqrt(2 * ndf)
    gauss = norm.pdf(x, loc=mean, scale=std)
    plt.plot(x, gauss, '--', linewidth=2, label=f'Gaussiana (n={ndf})')

plt.title('Distribuzione $\chi^2$ per grandi gradi di libert ')
plt.xlabel('$\chi^2$')
plt.ylabel('Densit  di probabilit ')
plt.legend()
plt.grid()
```

```

plt.show()

# 3. Zoom per piccoli valori di gradi di libert 
ndf_values = [5, 10]
x_small = np.linspace(0, 30, 300)
plt.figure(figsize=(10, 6))
for ndf in ndf_values:
    y = chi2.pdf(x_small, df=ndf)
    plt.plot(x_small, y, label=f'$\chi^2$ (n={ndf})')
    mean = ndf
    std = np.sqrt(2 * ndf)
    gauss = norm.pdf(x_small, loc=mean, scale=std)
    plt.plot(x_small, gauss, '--', linewidth=2, label=f'Gaussiana (n={ndf})')

plt.title('Distribuzione $\chi^2$ per piccoli gradi di libert ')
plt.xlabel('$\chi^2$')
plt.ylabel('Densit  di probabilit ')
plt.legend()
plt.grid()
plt.show()

# 4. Forma del chi quadro ridotto
ndf_values = [2, 5, 10, 30, 50]
plt.figure(figsize=(10, 6))
x_red = np.linspace(0, 3, 1000)

for ndf in ndf_values:
    y = chi2.pdf(x_red * ndf, df=ndf) * ndf # cambio variabile P(y)=P(x)*dx/dy
    plt.plot(x_red, y, label=f'$\chi^2$ ridotto (n={ndf})')

# Gaussiana di riferimento N(1, 2/n)
ndf_large = 50
mean = 1
std = np.sqrt(2 / ndf_large)
gauss = norm.pdf(x_red, loc=mean, scale=std)
plt.plot(x_red, gauss, ls='--', label=f'Gaussiana N(1, 2/n) (n={ndf_large})')

plt.title('Distribuzione $\chi^2$ ridotto per diversi gradi di libert ')
plt.xlabel('$\chi^2 / n$')
plt.ylabel('Densit  di probabilit ')
plt.legend()
plt.grid()
plt.show()

# 5. Plot della variabile ausiliaria radice di 2 * chi quadro
ndf_values = [5, 10]
x_aux = np.linspace(0, 10, 100)
plt.figure(figsize=(10, 6))

for ndf in ndf_values:
    y = chi2.pdf(x_aux**2 / 2, df=ndf) * x_aux # cambio variabile

```

```
plt.plot(x_aux, y, label=f'$\sqrt{{2\chi^2}}$ (n={ndf})')

mean = np.sqrt(2 * ndf - 1)
std = 1
gauss = norm.pdf(x_aux, loc=mean, scale=std)
plt.plot(x_aux, gauss, '--', linewidth=2, label=f'Gaussiana N($\sqrt{{2n-1}}$ , 1) (n={ndf})')

plt.title('Distribuzione di $\sqrt{{2\chi^2}}$ per piccoli gradi di liberta')
plt.xlabel('$\sqrt{{2\chi^2}}$')
plt.ylabel('Densita di probabilita')
plt.legend()
plt.grid()
plt.show()
```

Listing 12: Script per l'analisi della distribuzione del χ^2

18 Fit non lineari

18.1 Fit non lineare

Metodo di Gauss-Newton

Il metodo di Gauss-Newton è utilizzato per risolvere problemi di minimizzazione del χ^2 quando la funzione di fit $f(x, \theta)$ non è lineare rispetto ai parametri θ . Consideriamo un set di misurazioni fisiche date da variabili nella forma (x_i, y_i) , tali per cui vale la relazione teorica $y_i = f(x_i, \theta)$. Si procede definendo l' i -esimo residuo come:

$$r_i(\theta) = y_i - f(x_i, \theta) \quad (258)$$

Considerando le coordinate (x_i, y_i) fissate dai dati, il problema da risolvere è trovare il minimo della somma dei residui pesati (il χ^2):

$$\chi^2 = S(\theta) = \sum_i \frac{r_i^2(\theta)}{\sigma_{y_i}^2} = \sum_i w_i r_i^2(\theta)$$

dove si è indicato il peso $w_i = \frac{1}{\sigma_{y_i}^2}$.

Per minimizzare $S(\theta)$, si cerca di rendere il problema lineare nel parametro θ . Per farlo, si linearizzano i residui attorno a un valore iniziale θ sviluppando in **serie di Taylor troncata al primo ordine**:

$$r_i(\theta + \Delta\theta) \simeq r_i(\theta) + \frac{dr_i}{d\theta} \Delta\theta$$

Dalla definizione di $r_i(\theta)$ è chiaro che $\frac{dr_i}{d\theta} = -\frac{\partial f(x_i, \theta)}{\partial \theta}$. Per semplicità di scrittura, indichiamo:

$$A_i = \frac{\partial f(x_i, \theta)}{\partial \theta} \implies r_i(\theta + \Delta\theta) \simeq r_i(\theta) - A_i \Delta\theta \quad (259)$$

Supponiamo ora di partire da un *guess* (stima) iniziale sul parametro θ che indichiamo con $\theta^{(0)}$. Avremo che:

$$r_i(\theta^{(0)} + \Delta\theta) \simeq r_i^{(0)} - A_i\Delta\theta \quad (260)$$

dove $r_i^{(0)} = y_i - f(x_i, \theta^{(0)})$. Sostituiamo questa espressione linearizzata all'interno della formula di S :

$$S^{(0)}(\Delta\theta) = \sum_i w_i \left[r_i^{(0)} - A_i\Delta\theta \right]^2 \quad (261)$$

Questa equazione ora è semplice. Per trovare il minimo si annulla la derivata rispetto a $\Delta\theta$:

$$\frac{dS^{(0)}}{d\Delta\theta} = 0 \implies \sum_i w_i \cdot 2 \left[r_i^{(0)} - A_i\Delta\theta \right] (-A_i) = 0$$

Risolvendo rispetto a $\Delta\theta$ otteniamo l'aggiornamento per il parametro:

$$\Delta\theta = \frac{\sum_i w_i A_i r_i^{(0)}}{\sum_i w_i A_i^2} = \frac{\sum_i w_i A_i [y_i - f(x_i, \theta^{(0)})]}{\sum_i w_i A_i^2} \quad (262)$$

Trovato $\Delta\theta$, si calcola il nuovo valore $\theta^{(1)} = \theta^{(0)} + \Delta\theta$ e si reitera tutto il procedimento, calcolando un nuovo $\Delta\theta$ e continuando finché l'incremento diventa trascurabile ($\Delta\theta \simeq 0$) e il χ^2 si stabilizza ($S^{(k+1)} \simeq S^{(k)}$). Da notare che per la convergenza è **fondamentale partire da valori ragionevoli** per il guess iniziale $\theta^{(0)}$.

Fit con errore su x

Nel caso in cui il fit sia complicato dal fatto che non si possono ignorare gli errori sulle x (perché, ad esempio, le incertezze su x e y sono simili, o la funzione non è facilmente invertibile per scambiare semplicemente i ruoli di x e y), esistono metodi per continuare a utilizzare la minimizzazione del χ^2 . Vedremo in particolare due approcci:

- **Effective Variance** (Varianza Efficace)
- **Orthogonal Distance Regression** (ODR)

Effective Variance (Varianza Efficace)

In questo metodo l'errore su x viene "proiettato" e incluso nell'errore su y tramite la derivata prima della funzione f . Supponiamo che le misure siano distribuite normalmente: $x_i \sim \mathcal{N}(\hat{x}_i, \sigma_{x_i}^2)$ e $y_i \sim \mathcal{N}(\hat{y}_i, \sigma_{y_i}^2)$, con $\hat{y}_i = f(\hat{x}_i)$. La quantità $y - f(x)$ si può riscrivere aggiungendo e sottraendo il valore vero $\hat{y} = f(\hat{x})$:

$$y - f(x) = (y - \hat{y}) + (f(\hat{x}) - f(x))$$

Possiamo sviluppare in serie di Taylor $f(x)$ attorno al valore vero $\hat{x}$:

$$f(x) \simeq f(\hat{x}) + (x - \hat{x})f'(\hat{x}) \implies f(\hat{x}) - f(x) \simeq (\hat{x} - x)f'(\hat{x})$$

Sostituendo, otteniamo: $y - f(x) \simeq (y - \hat{y}) + (\hat{x} - x)f'(\hat{x})$. Calcoliamo ora la varianza di questa quantità, considerando che gli errori su x e y sono statisticamente indipendenti ($\text{Cov}(x, y) = 0$):

$$\begin{aligned} \text{var}(y - f(x)) &= \text{var}(y - \hat{y}) + (\hat{x} - x)f'(\hat{x}) \\ &= \text{var}(y - \hat{y}) + \text{var}((\hat{x} - x))[f'(\hat{x})]^2 \\ &= \sigma_y^2 + \sigma_x^2[f'(\hat{x})]^2 \simeq \sigma_y^2 + \sigma_x^2[f'(x)]^2 \end{aligned}$$

(nell'ultimo passaggio approssimiamo $f'(\hat{x})$ con la derivata valutata nel punto misurato, assumendo σ_x piccolo). Abbiamo così definito la **varianza efficace**:

$$\sigma_{\text{eff}}^2 = \sigma_y^2 + \sigma_x^2[f'(x)]^2 \quad (263)$$

La nuova formula del χ^2 da minimizzare diviene quindi:


$$\chi^2 = S(\theta) = \sum_i \frac{[y_i - f(x_i, \theta)]^2}{\sigma_{y_i}^2 + \sigma_{x_i}^2[f'(x_i, \theta)]^2} \quad (264)$$

Nota 1: Se $\sigma_{x_i} = 0$, la formula torna ad essere l'espressione classica del χ^2 .

Nota 2: E' importante notare un fatto: nella formula di χ^2 inserisco al numeratore i residui *osservati*, mentre al denominatore inserisco la varianza della "*variabile aleatoria residuo*". Ivi si evidenzia la natura "fisica" del χ^2 , il quale viene utilizzato per rapportare la discrepanza osservata con quella attesa. Utilizzando la variabile Z , con gaussiana centrata in 0 e deviazione standard 1: ogni addendo della somma è una variabile Z^2 con valore atteso $E[Z^2] = 1$. Di conseguenza, il χ^2 restituisce, se il modello è corretto, 1 per ogni termine della sommatoria. Il confronto $\chi^2 \approx NDF$ diventa quindi il criterio per stabilire se gli scarti osservati siano semplici fluttuazioni statistiche (1σ in media per punto) o segnali di un'inadeguatezza del modello. Vengono utilizzati gli NDF poichè i parametri sono stati stimati con gli stessi dati presi per stimare χ^2 , perdendo così, per ogni parametro un grado di libertà.

Orthogonal Distance Regression (ODR)

Un altro modo di affrontare il problema è cercare di minimizzare le **distanze ortogonali** dei punti sperimentali dalla curva teorica di fit, invece che minimizzare la sola distanza verticale come si fa nel χ^2 standard.



Se indichiamo con $(\tilde{x}_i, \tilde{y}_i)$ il punto sulla curva più vicino rispetto alle misurazioni (x_i, y_i) , la distanza quadratica pesata da minimizzare diviene:

$$D_i^2(\tilde{x}_i) = W_{x_i}(x_i - \tilde{x}_i)^2 + W_{y_i}[y_i - f(\tilde{x}_i)]^2 \quad (265)$$

dove i pesi sono inversamente proporzionali alle varianze: $W_{x_i} = 1/\sigma_{x_i}^2$ e $W_{y_i} = 1/\sigma_{y_i}^2$. La quantità totale da minimizzare è quindi $\chi^2 = \sum D_i^2$. Questo metodo è implementato in Python tramite librerie come `scipy.odr`.

Dal punto di vista pratico, i software online minimizzano le correzioni da apportare, che indichiamo con δx_i per le x_i e con ϵ_i per le y_i . Il vincolo imposto alla curva è:

$$y_i + \epsilon_i = f(x_i + \delta x_i, \theta) \implies \epsilon_i = -y_i + f(x_i + \delta x_i, \theta)$$

E la quantità da minimizzare assume la forma:

$$S = \sum_i \left(\frac{\delta x_i^2}{\sigma_{x_i}^2} + \frac{\epsilon_i^2}{\sigma_{y_i}^2} \right) \quad (266)$$

Per applicare la minimizzazione riutilizziamo il **metodo di Gauss-Newton**. Sviluppiamo in serie di Taylor la funzione f in **due variabili** (i residui e le dipendenze da θ e x):

$$f(x_i + \delta x_i, \theta + \Delta\theta) \simeq f(x_i, \theta) + \frac{\partial f}{\partial \theta} \Delta\theta + \frac{\partial f}{\partial x} \delta x_i$$

Se indichiamo come prima $r_i^{(0)} = y_i - f(x_i, \theta^{(0)})$ e definiamo le derivate valutate all'iterazione:

$$A_i = \frac{\partial f}{\partial \theta} \quad \text{e} \quad B_i = \frac{\partial f}{\partial x}$$

l'espressione al primo passaggio (per $\theta = \theta^{(0)}$) diventa per l'errore ϵ_i :

$$\epsilon_i \simeq -y_i + f(x_i, \theta^{(0)}) + A_i \Delta\theta + B_i \delta x_i = -r_i^{(0)} + A_i \Delta\theta + B_i \delta x_i$$

Elevando al quadrato ϵ_i all'interno della funzione somma da minimizzare si ha:

$$S^{(0)}(\Delta\theta, \delta x_i) = \sum_i \left[\frac{\delta x_i^2}{\sigma_{x_i}^2} + \frac{(-r_i^{(0)} + A_i \Delta\theta + B_i \delta x_i)^2}{\sigma_{y_i}^2} \right] \quad (267)$$

Per togliere la dipendenza da δx_i poniamo a zero la sua derivata parziale $\frac{\partial S^{(0)}}{\partial \delta x_i} = 0$ ⁵:

$$\frac{2\delta x_i}{\sigma_{x_i}^2} + \frac{2B_i}{\sigma_{y_i}^2}(-r_i^{(0)} + A_i \Delta\theta + B_i \delta x_i) = 0$$

Risolvendo per δx_i si trova analiticamente:

$$\delta x_i = \frac{B_i \sigma_{x_i}^2}{\sigma_{y_i}^2 + B_i^2 \sigma_{x_i}^2} (r_i^{(0)} - A_i \Delta\theta)$$

⁵facendo questo passaggio troviamo la minima distanza orizzontale per ogni spostamento verticale (dovuto a variazioni θ), minimizzeremo poi la distanza verticale (per variazioni di θ), trovando infine che il parametro θ stimato minimizzerà la distanza verticale e orizzontale, e, di conseguenza la distanza ortogonale

Sostituendo questo δx_i all'interno di $S^{(0)}$ otteniamo una forma sorprendentemente nota:

$$S^{(0)}(\Delta\theta) = \sum_i \frac{(r_i^{(0)} - A_i\Delta\theta)^2}{\sigma_{y_i}^2 + B_i^2\sigma_{x_i}^2} \quad (268)$$

Si nota immediatamente che il denominatore non è nient'altro che la **Varianza Efficace** trovata precedentemente ($\sigma_{\text{eff},i}^2 = \sigma_{y_i}^2 + B_i^2\sigma_{x_i}^2$). Minimizzando infine questa espressione rispetto a $\Delta\theta$ per trovare l'aggiornamento dei parametri:

$$\Delta\theta = \frac{\sum_i W_{\text{eff},i} A_i r_i^{(0)}}{\sum_i W_{\text{eff},i} A_i^2} \quad \text{con} \quad W_{\text{eff},i} = \frac{1}{\sigma_{\text{eff},i}^2} \quad (269)$$

La formula finale all'interno di ogni iterazione è **identica** a quella del fit in cui si minimizza verticalmente, a patto di sostituire σ_{y_i} con $\sigma_{\text{eff},i}$.

19 Test di Ipotesi

In molti casi, l'informazione che vogliamo dedurre dai dati non è una stima numerica di un parametro, bensì la risposta a una precisa domanda (Es: "*Il segnale segue un andamento lineare?*"). La branca della statistica che formalizza queste domande sotto forma di test numerici per decidere se accettare o rifiutare una teoria è detta **Test di Ipotesi**.

Il primo passaggio è formulare le ipotesi. Si definiscono generalmente:

- **L'ipotesi nulla** (H_0): è l'ipotesi di "nessun effetto" o l'ipotesi base. Di norma è quello che si cerca di confutare (ad esempio, l'ipotesi che i dati contengano solo rumore di fondo).
- **L'ipotesi alternativa** (H_1): è l'ipotesi contrapposta ad H_0 (ad esempio, l'ipotesi che ci sia il segnale fisico che stiamo cercando).

Quando scegliamo se accettare o rigettare un'ipotesi, possiamo incorrere in due tipi di **errori**:

1. **Errore di Tipo I (Falso positivo)**: Rigettare l'ipotesi H_0 quando in realtà essa era corretta.
2. **Errore di Tipo II (Falso negativo)**: Accettare l'ipotesi H_0 quando in realtà era sbagliata (cioè era vera l'alternativa H_1).

Per quantificare matematicamente questi errori si utilizzano la **Significatività** e la **Potenza** del test.

Statistica di test


Operativamente il test di ipotesi prevede la definizione di una variabile t , chiamata *statistica di test*, costruita a partire dai dati campionari. Fissati i dati, t è un numero; ma in generale, essendo costruita su campioni aleatori, t è una variabile aleatoria. Assumendo come vera H_0 , t seguirà una distribuzione di probabilità nota $P_0(t)$.

Significatività del test (α) e Valore Critico

Fissato il livello di significatività del test α , si determina una **soglia critica** t_s . Se il nostro valore misurato t è maggiore di t_s , **rigettiamo** H_0 in quanto troppo incompatibile con la distribuzione attesa. La regione $t > t_s$ prende il nome di *regione critica*.

L'integrale della $P_0(t)$ nella regione critica fornisce proprio α , ovvero la probabilità di commettere un Errore di Tipo I:

$$\alpha = \int_{t_s}^{\infty} P_0(t) dt \quad (270)$$




Rigettando $t > t_s$ stiamo escludendo la coda della distribuzione per cui giudichiamo troppo improbabile che il t misurato sia distribuito secondo P_0 . Tipicamente si sceglie $\alpha = 0.05$ (5%).

Test a due code

Se la distribuzione $P_0(t)$ non ha una sola coda ma è simmetrica (es. Gaussiana) e siamo interessati a discrepanze in entrambe le direzioni, definiamo due soglie t_{s1} e t_{s2} tali che l'area rigettata sia ripartita:

$$\frac{\alpha}{2} = \int_{-\infty}^{t_{s1}} P_0(t) dt = \int_{t_{s2}}^{\infty} P_0(t) dt$$



Si rigetta H_0 se $t_m \leq t_{s1}$ oppure $t_m \geq t_{s2}$.

Il p-value

Un'altra quantità strettamente collegata alla significatività è il **p-value**. Se t_m è il risultato calcolato per i nostri dati, il p-value è l'integrale della coda da t_m in poi:

$$p\text{-value} = \int_{t_m}^{\infty} P_0(t) dt$$

È la probabilità di ottenere un risultato uguale o più estremo di quello osservato assumendo H_0 vera.

- Se $p\text{-value} \leq \alpha \implies$ **rigetto** H_0 (equivale a $t_m \geq t_s$).
- Se $p\text{-value} > \alpha \implies$ **non rigetto** H_0 .

più è piccolo il p-value, meno è probabile che i risultati siano dovuti al caso.




Figura 25: L'area tratteggiata è la "zona di rigetto" con la soglia critica χ_s^2 , mentre l'area colorata è il p-value con il valore calcolato χ_m^2 , in questo caso $p\text{-value} > \alpha$

Potenza del test ($1 - \beta$)

Per valutare l'Errore di Tipo II, assumiamo sia vera l'ipotesi alternativa H_1 con distribuzione $P_1(t)$. La probabilità β di accettare erroneamente H_0 è data integrando P_1 nella regione di accettazione di H_0 :

$$\beta = \int_{-\infty}^{t_s} P_1(t) dt \quad (271)$$

La **Potenza del test** è la quantità $(1 - \beta)$ e rappresenta la capacità del test di rigettare correttamente H_0 quando H_1 è vera.

Esempio. *Test di Ipotesi (Binomiale) su 15 lanci di una moneta*

Sia X la variabile casuale che rappresenta il numero di successi (teste) in $n = 15$ lanci indipendenti. Sotto l'ipotesi nulla H_0 (moneta equa), assumiamo che la probabilità di successo sia $p = 0.5$, dunque:

$$X \sim B(n = 15, p = 0.5)$$

Le probabilità puntuali per i risultati estremi, calcolate tramite la formula binomiale, sono:




Figura 26: Distribuzione sotto l'ipotesi nulla P_0 (blu) e sotto l'ipotesi alternativa P_1 (rosso). L'area colorata rappresenta β , l'errore di Tipo II, nella regione di accettazione di H_0 .

- $P(15) = 0.003\%$
- $P(14) = 0.05\%$
- $P(13) = 0.3\%$
- $P(12) = 1.4\%$
- $P(11) = 4.2\%$

Vogliamo determinare il valore critico per un test bilaterale con un livello di significatività desiderato $\alpha = 0.10$ (cioè: se i lanci sono tali che rappresentano meno del 10% delle code, affermo che la moneta sia truccata)

Calcoliamo la probabilità per la coda destra ($X \geq 12$):

$$P(X \geq 12) = P(15) + P(14) + P(13) + P(12) = 1.8\%$$

Per un test bilaterale (considerando anche la simmetria della coda sinistra $X \leq 3$ (ottengo croce)):

$$\alpha_{\text{effettivo}} = 1.8\% \times 2 = 3.6\%$$

Questo valore è conservativo poiché $3.6\% < 10\%$.

Proviamo a includere il valore 11 per aumentare la potenza del test:

$$P(X \geq 11) = P(X \geq 12) + P(11) = 1.8\% + 4.2\% = 6.0\%$$

Il livello di significatività totale per il test bilaterale diventerebbe:

$$\alpha_{\text{effettivo}} = 6.0\% \times 2 = 12.0\%$$

Siccome $12.0\% > 10\%$, la soglia $X = 11$ non è accettabile.

19.1 Test del χ^2

Il test del χ^2 fa parte della categoria di test d'ipotesi in cui abbiamo effettuato un fit dei dati con una certa funzione $f(x, \theta)$ e ci chiediamo se l'ipotesi base (cioè che la funzione f descriva adeguatamente i dati) sia corretta.

Sappiamo che il parametro θ si ricava minimizzando:

$$\chi^2 = \sum_{i=1}^N \frac{[y_i - f(x_i, \theta)]^2}{\sigma_i^2}$$

La statistica χ^2 segue la distribuzione di probabilità:

$$P(\chi^2; m) = \frac{2^{-m/2}}{\Gamma(m/2)} (\chi^2)^{(m/2)-1} e^{-\chi^2/2} \quad (272)$$

dove m è il **numero di gradi di libertà**. In un processo di minimizzazione su N dati, se stimo p parametri e ho imposto k vincoli aggiuntivi, i gradi di libertà sono:

$$m = N - p - k \quad (273)$$

Nota: Se non ho bisogno di stimare i parametri, poichè sono già noti, allora $m = N$.

Dunque, la significatività del test del χ^2 è data da:

$$\alpha = \int_{\chi_s^2}^{\infty} P(\chi^2; m) d\chi^2 \quad (274)$$



e rappresenta la probabilità che una funzione f che descriva bene i dati produca un χ^2 maggiore di quello osservato. Questo fa capire perchè spesso la significatività è riportata come un risultato, e non scelta a priori.

Test del χ^2 di Pearson (Dati Binned)

Il test può essere effettuato anche sugli istogrammi. In questo caso prende il nome di **Test del χ^2 di Pearson**:

$$\chi^2 = \sum_{j=1}^m \frac{[n_j - \nu_j(\theta)]^2}{\nu_j(\theta)} \quad (275)$$

dove n_j è il numero di conteggi osservati nel bin j -esimo e $\nu_j(\theta) \simeq N \cdot P(x_j; \theta) \Delta x$ è il valore di aspettazione teorico del bin. È fondamentale che i bin siano grandi a sufficienza da contenere almeno 5 conteggi per evitare fluttuazioni che invalidino la statistica, ma abbastanza piccoli da mostrare i dettagli della distribuzione.



Implementazione Python del Test χ^2

In Python si usa 'scipy.stats.chi2'. Le funzioni principali sono:

- `chi2.isf(alpha, ndf)`: Inverse Survival Function. Restituisce la soglia critica χ_s^2 .
- `chi2.sf(chi2_m, ndf)`: Survival Function. Calcola direttamente il p-value a partire dal χ^2 calcolato dai dati.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import chi2

# valori di gradi di libert 
ndf_values = [2, 5, 10, 30, 50]
alpha = 0.05

plt.figure(figsize=(10, 6))
for ndf in ndf_values:
    # asse x adattivo per ogni curva
    x_max = chi2.ppf(0.999, ndf)
    x = np.linspace(0, x_max, 1000)

    y = chi2.pdf(x, df=ndf)
    plt.plot(x, y, label=f'$\chi^2$ (n={ndf})')

    # calcolo la soglia chi2_s per cui Prob(chi2_s)=0.05
    chi2_s = chi2.isf(alpha, ndf)
    plt.axvline(x=chi2_s, ls="--", label="$x = \chi^2_s$")

    # area della coda destra
    x_tail = np.linspace(chi2_s, x_max, 300)
    y_tail = chi2.pdf(x_tail, df=ndf)
    plt.fill_between(x_tail, y_tail, alpha=0.2)

plt.title('Distribuzione $\chi^2$ per diversi gradi di libert ')
plt.xlabel('$\chi^2$')
plt.ylabel('Densit  di probabilit ')
plt.legend()
plt.grid()
plt.show()
```

Listing 13: Script Python: Test del Chi-Quadro - Parte 1

```
# suppongo di avere un chi2_m proveniente dal nostro calcolo di 47
# con 58 gradi di libert 
chi2_m = 47
ndf = 58
alpha = 0.05

chi2_s = chi2.isf(alpha, ndf)
```




Figura 27: Distribuzioni del χ^2 al variare dei gradi di libertà, con relative soglie critiche.

```
print(f"Chi2 misurato: {chi2_m}, Soglia: {chi2_s:.2f}")

if chi2_m < chi2_s:
    print("Non posso rigettare l'ipotesi!")
else:
    print("Devo rigettare l'ipotesi!")

# controllo equivalente con il p-value
p_value = chi2.sf(chi2_m, ndf)
print(f"p-value: {p_value:.4f}")

plt.figure(figsize=(10, 6))
x_max = chi2.ppf(0.999, ndf)
x = np.linspace(0, x_max, 1000)
y = chi2.pdf(x, df=ndf)
plt.plot(x, y, label=f'$\chi^2$ (n={ndf})')

plt.axvline(x=chi2_s, ls="--", label="$x = \chi^2_s$ (Soglia)")
plt.axvline(x=chi2_m, ls="-.", c="r", label="$x = \chi^2_m$ (Misurato)")

x_tail = np.linspace(chi2_s, x_max, 300)
y_tail = chi2.pdf(x_tail, df=ndf)
plt.fill_between(x_tail, y_tail, alpha=0.2)

plt.title('Risultato del Test')
plt.xlabel('$\chi^2$')
plt.ylabel('Densita di probabilita')
plt.legend()
plt.grid()
plt.show()
```

Listing 14: Script Python: Test del Chi-Quadro - Parte 2




Figura 28: Posizione del valore osservato di χ^2 rispetto alla regione di rigetto.

19.2 Overfitting e Test F (Modelli Annidati)

Aumentando il grado del polinomio in un fit, il χ^2 ridotto apparentemente migliora. Tuttavia, avendo a disposizione più parametri, c'è il rischio che la funzione si adatti unicamente alle fluttuazioni casuali del campione (fenomeno dell'**overfitting**).

Per capire se il modello più complicato migliora abbastanza il fit da giustificare i parametri aggiuntivi, si usa il **Test F di Fisher-Snedecor**. Si applica ai *modelli annidati*: consideriamo un modello semplice M_1 (con p_1 parametri e statistica χ^2_1) e un modello più complesso M_2 (con $p_2 > p_1$ parametri e statistica χ^2_2). Per costruzione $\chi^2_2 \leq \chi^2_1$.

La variabile di Fisher nasce dal confronto tra due stime indipendenti della stessa varianza.

Supponiamo di avere due campioni estratti da popolazioni gaussiane con la stessa varianza reale σ^2 . Le varianze stimate ⁶ sono

$$V_1 = \frac{1}{N_1 - 1} \sum_{i=1}^{N_1} (x_i - \bar{x})^2, \quad V_2 = \frac{1}{N_2 - 1} \sum_{i=1}^{N_2} (y_i - \bar{y})^2.$$

La statistica di Fisher è definita come

$$F = \frac{V_1}{V_2}.$$

Se le due popolazioni hanno davvero la stessa varianza, questo rapporto dovrebbe oscillare attorno a 1.

Ora ricordiamo una proprietà fondamentale dei campioni gaussiani:

$$\frac{(N-1)V}{\sigma^2} \sim \chi^2_{N-1}.$$

⁶indichiamo con V la varianza campionaria e con σ^2 quella reale, ignota

Quindi

$$\frac{(N_1 - 1)V_1}{\sigma^2} \sim \chi_{\nu_1}^2, \quad \frac{(N_2 - 1)V_2}{\sigma^2} \sim \chi_{\nu_2}^2,$$

dove $\nu_1 = N_1 - 1, \nu_2 = N_2 - 1$. Facendo il rapporto otteniamo

$$F = \frac{(\chi_1^2/\nu_1)}{(\chi_2^2/\nu_2)} \sim F_{\nu_1, \nu_2}.$$

Quindi la distribuzione di Fisher è, il rapporto tra due variabili χ^2 normalizzate per i rispettivi gradi di libertà.

Nel confronto tra modelli la stessa idea compare in forma leggermente diversa. Riconsiderando i due modelli M_1 e M_2 , con χ_1^2 e χ_2^2

Il miglioramento del fit è misurato dalla differenza

$$\Delta\chi^2 = \chi_1^2 - \chi_2^2.$$

Si può dimostrare che:

$$\Delta\chi^2 \sim \chi_{p_2 - p_1}^2,$$

dove $p_2 - p_1$ è il numero di parametri aggiunti.

Mentre la stima della varianza residua del modello M_2 è


$$\frac{\chi_2^2}{N - p_2}.$$

La statistica di Fisher diventa allora:

$$F = \frac{\text{Quanto è migliorato il fit}}{\text{Quanto rumore resta nel modello migliore}} = \frac{(\chi_1^2 - \chi_2^2)/(p_2 - p_1)}{\chi_2^2/(N - p_2)} \quad (276)$$

- Al numeratore valutiamo il costo del miglioramento diviso per i gradi di libertà aggiunti.
- Il denominatore è il χ^2 ridotto del modello complesso, che agisce da stimatore della varianza del rumore.
- Se $F \simeq 1$, il miglioramento è dello stesso ordine di grandezza del rumore casuale (stiamo fittando il rumore).
- Se $F \gg 1$, il miglioramento è statisticamente significativo.

In Python, si usa `scipy.stats.f`. Le chiamate sono equivalenti al χ^2 , ma richiedono **due** gradi di libertà: `dfn = p_2 - p_1` e `dfd = N - p_2`.



19.3 Test di Kolmogorov-Smirnov

Il Test di Kolmogorov-Smirnov (KS) è un modo alternativo al test di Pearson per confrontare i dati con una distribuzione teorica. Si usa soprattutto quando il set di dati è talmente piccolo da non permettere un binning adeguato. Nel KS non si utilizzano istogrammi, evitando di perdere informazioni.

Invece degli istogrammi, si usano le **frequenze cumulative**. Si definisce la Funzione di Ripartizione Empirica (ECDF) ordinando i dati $x_1 \leq x_2 \leq \dots \leq x_N$:

$$\phi(x) = \frac{\#\{\text{dati} \leq x\}}{N}$$

Esempio 1. Sia il campione dati: $\{7, 3, 1\}$.


1. Riordino: $\{1, 3, 7\}$.

2. Per $x < 1$, $\phi(x) = 0$; per $1 \leq x < 3$, $\phi(x) = 1/3$; per $3 \leq x < 7$, $\phi(x) = 2/3$; per $x \geq 7$, $\phi(x) = 1$.

Il grafico è una funzione a gradino crescente.

La statistica di test D è definita come la **massima distanza assoluta** tra la cumulativa empirica $\phi(x)$ e la cumulativa teorica (funzione di ripartizione) $F(x) = \int_{-\infty}^x P(z)dz$:

$$D = \max_x |\phi(x) - F(x)| \quad (277)$$




Per calcolare i valori critici di D , dopo il quale l'ipotesi viene rigettata, si usa la distribuzione di Kolmogorov:

$$P(D) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 D^2 m} \quad (278)$$

la quale viene spesso approssimata oppure calcolata con metodi numerici (per campioni piccoli).

Nota: *Attenzione: le tabelle standard (e le funzioni scipy base come `kstest`) assumono che $F(x)$ sia nota a priori. Se i parametri di $F(x)$ vengono estratti (fittati) dai dati stessi, la statistica D non segue più la distribuzione attesa. In tal caso, si usa un **Toy Monte Carlo** per simulare la vera distribuzione nulla e trovare il p -value o il valore critico corretti.*



Inoltre, il KS test può essere usato per confrontare due campioni indipendenti. In tal caso $D = \max_x |\phi_1(x) - \phi_2(x)|$. In tal caso si agisce come precedentemente, calcolando i valori di soglia tramite una distribuzione di Kolmogorov simile a quella precedente.

Implementazione Python del Test KS (con Monte Carlo)

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import kstest

n = 100
# Caricamento di un set di dati d'esempio
dati = np.loadtxt("../Esercitazione_4/dati/conteggi_geiger_amb.txt", max_rows=n)
dati = dati * 1e-3

# Calcolo frequenze cumulative empiriche
dati_ordinati = np.sort(dati)
y_fc = np.arange(1, n + 1) / n

plt.figure(figsize=(10, 6))
plt.step(dati_ordinati, y_fc, label='Frequenza cumulativa empirica', where='post')
plt.xlabel("Tempo (s)")
plt.ylabel("Probabilita Cumulata")
plt.show()
```

Listing 15: Script Python: KS Test e Toy Monte Carlo - Parte 1




Figura 29: Funzione di Ripartizione Empirica (ECDF) costruita dai dati.

```
# Calcolo della cumulativa teorica esponenziale
def cdf_esponenziale(t, tau):
    return 1 - np.exp(-t / tau)

tau_hat = np.mean(dati) # Parametro stimato dai dati!
y_teorica = cdf_esponenziale(dati_ordinati, tau_hat)

D, pvalue = kstest(dati, cdf_esponenziale, args=(tau_hat,))
print(f"D: {D:.4f}, p-value base: {pvalue:.4f} (Inaffidabile per via della stima
!)" )

plt.figure(figsize=(10, 6))
plt.step(dati_ordinati, y_fc, label='Frequenza cumulativa empirica', where='post
')
plt.plot(dati_ordinati, y_teorica, 'r--', label='Frequenza cumulativa teorica')
plt.xlabel("Tempo (s)")
plt.ylabel("Probabilità Cumulata")
plt.legend()
plt.show()
```

Listing 16: Script Python: KS Test e Toy Monte Carlo - Parte 2




Figura 30: Confronto visivo per la ricerca della distanza massima D .

```
# -----
# Toy Monte Carlo per correggere il p-value
# -----
Ntoys = 10000
D_toys = np.zeros(Ntoys)

for i in range(Ntoys):
    # genero un fake dataset sotto H0
    u = np.random.uniform(0, 1, n)
    e = - tau_hat * np.log(1 - u)

    # ristimo tau sul fake dataset (cruciale!)
    tau_fake = np.mean(e)

    # ricalcolo KS usando il tau del singolo toy model
    D_fake, _ = kstest(e, cdf_esponenziale, args=(tau_fake,))
    D_toys[i] = D_fake


D_crit_5 = np.quantile(D_toys, 0.95)
print(f"Valore critico KS al 5% corretto = {D_crit_5:.5f}")

if D > D_crit_5:
    print("Rigetto H0 al 5%")
else:
    print("NON rigetto H0 al 5%")

plt.figure(figsize=(10, 6))
plt.hist(D_toys, bins=50, alpha=0.6, label="Monte Carlo")
plt.axvline(D, color='r', linestyle='--', label='D osservato')
plt.axvline(D_crit_5, color='k', linestyle=':', label='Soglia 5% (MC)')
plt.xlabel("Statistica KS (D)")
plt.ylabel("Conteggi")
```

```
plt.legend()
plt.show()
```

Listing 17: Script Python: KS Test e Toy Monte Carlo - Parte 3

Figura 31: Distribuzione vera della statistica D ricavata tramite Toy Monte Carlo.

Quanto detto in generale per la significatività del test ci aiuta a capire in che senso, quando si annuncia la scoperta di un nuovo fenomeno, si richiede una significatività di 5σ e di 3σ per l'evidenza. Il primo punto importante da chiarire è che in questo caso H_0 è l'ipotesi in cui i dati sono spiegati solo da rumore senza nessun segnale fisico in aggiunta; quindi è l'ipotesi in cui non c'è segnale nuovo nei dati (es. non c'è nuova fisica oppure è solo fondo).

A causa della complessità degli esperimenti (per esempio nel caso dei tipici esperimenti di fisica delle particelle) e delle fluttuazioni statistiche di vario genere nei dati, se si usasse $\alpha = 5\%$ come soglia per decidere se rigettare H_0 , si avrebbero troppi falsi positivi. Invece di α in percentuale si preferisce riportare il risultato in termini di σ di una gaussiana, quindi in termini dell'integrale delle code della normale standard.

Nel nostro caso possiamo vedere che nel test di ipotesi, in termini di p-value questo equivale a:

- $2\sigma \simeq 0.05$
- $3\sigma \simeq 0.003 \longrightarrow$ **Evidenza**
- $5\sigma \simeq 3 \times 10^{-7} \longrightarrow$ **Scoperta**

Quindi nel caso dell'evidenza potrei avere circa 3 falsi allarmi su 1000 esperimenti, mentre nel caso di 5σ ho 3 falsi allarmi su 10 milioni di esperimenti. Nel caso in cui la mia statistica di test ha una forma gaussiana, devo considerare α sia a destra che a sinistra della coda (test a due code), per questo posso fare in modo di avere vari valori da considerare.

20 Compatibilità tra due misure

Uno dei casi più comuni di test di ipotesi è verificare se il risultato tra due misure è **compatibile**, cioè se le due misure $x \pm \sigma_x$ e $y \pm \sigma_y$ sono imputabili alla stessa popolazione (vengono dallo stesso fenomeno fisico). La complicazione in questo caso è che, anche se le misure fossero dovute allo stesso fenomeno fisico, avrebbero comunque delle differenze dovute alle fluttuazioni statistiche. Bisogna quindi decidere se le differenze fra i due risultati sono imputabili a questi effetti casuali oppure indicano una vera differenza fra i due set di dati analizzati. Il problema somiglia al test del χ^2 , ma invece di confrontare i punti sperimentali con una distribuzione, si confrontano due punti sperimentali fra loro.


Partiamo dall'ipotesi che x e y siano due variabili aleatorie, ciascuna distribuita secondo una gaussiana con deviazione standard σ_x e σ_y rispettivamente, e supponiamole **indipendenti**. Analizziamo i vari casi in base alla complessità.

Caso 1: Misure singole con σ note

Il caso più semplice da considerare è quello in cui x e y sono due *singole misure* fatte con due apparati sperimentali di risoluzione nota data dal costruttore (σ_x e σ_y). Dire che x e y sono compatibili equivale a dire che la quantità $x - y$ è compatibile con zero. La variabile $x - y$ è una variabile aleatoria la cui varianza è:

$$\text{var}(x - y) = \text{var}(x) + \text{var}(y) = \sigma_x^2 + \sigma_y^2 \implies \sigma_{x-y} = \sqrt{\sigma_x^2 + \sigma_y^2} \quad (279)$$

In questo caso utilizziamo $x - y$ come statistica di test, dalle ipotesi segue che $x - y \sim \mathcal{N}(0, \sigma_{x-y})$ ⁷. Ha senso definire α in termini di σ : possiamo *rigettare* l'ipotesi che le due misure siano dovute allo stesso fenomeno se $|x - y| > 2\sigma_{x-y}$ (che equivale circa ad $\alpha = 5\%$ di prima; più precisamente per avere $\alpha = 5\%$ si dovrebbe usare $|x - y| > 1.96\sigma_{x-y}$).



⁷si è già imposta l'ipotesi H_0 : x e y sono compatibili, dunque è naturale che $x - y$ abbia una distribuzione centrata in 0

Un altro modo di vedere la stessa cosa è definire $\delta = x - y$. La mia H_0 è che le misure siano compatibili, quindi $\mathbb{E}[x] = \mathbb{E}[y] \implies \mathbb{E}[x - y] = \mathbb{E}[\delta] = 0$. Cerco di quante sigma si allontana il mio valore cercato con la quantità:

$$\frac{\delta - \mathbb{E}[\delta]}{\sigma_\delta} \sim \mathcal{N}(0, 1) \quad (280)$$

8

Esempio 2. Misuro con due apparati indipendenti il punto di fusione di due campioni di un certo materiale e le misure sono $m_1 = 202 \pm 3$ K e $m_2 = 209 \pm 4$ K. Ci chiediamo se effettivamente i due campioni sono della stessa sostanza.

Svolgimento: Calcolo $|m_1 - m_2| = |202 - 209| = 7$ K.

Mentre $\sigma_{m_1 - m_2} = \sqrt{3^2 + 4^2} = \sqrt{25} = 5$ K.

$$\frac{|m_1 - m_2|}{\sigma_{m_1 - m_2}} = \frac{7}{5} = 1.4 < 1.96$$

Quindi non posso rigettare la mia H_0 con una significatività del 5%. Posso considerare le misure compatibili, per cui i due campioni saranno probabilmente della stessa sostanza.

Caso 2: Medie di due set di dati con σ nota

Aumentando la complessità di calcolo, l'altro caso in cui ci si può imbattere è: x e y non sono singole misure ma *medie di due set di dati*. Quindi devo confrontare $\bar{x}$ e $\bar{y}$ e suppongo di conoscere le deviazioni standard delle due popolazioni σ_x e σ_y (caso molto raro in fisica). In tal caso posso calcolare le deviazioni standard delle medie come:

$$\sigma_{\bar{x}} = \frac{\sigma_x}{\sqrt{N_x}} \quad \text{e} \quad \sigma_{\bar{y}} = \frac{\sigma_y}{\sqrt{N_y}}$$

Si può quindi ripetere lo stesso ragionamento di prima: posso considerare $\bar{x}$ e $\bar{y}$ come due variabili aleatorie con distribuzione gaussiana e quindi confronto $\bar{x} - \bar{y}$ con la sua deviazione standard:

$$\sigma_{\bar{x} - \bar{y}} = \sqrt{\sigma_{\bar{x}}^2 + \sigma_{\bar{y}}^2} = \sqrt{\frac{\sigma_x^2}{N_x} + \frac{\sigma_y^2}{N_y}}$$

e rigetto l'ipotesi che le due misure vengano dallo stesso fenomeno con una significatività del 5% se $|\bar{x} - \bar{y}| > 1.96\sigma_{\bar{x} - \bar{y}}$.

Esempio 3. So a priori che la σ della distribuzione dei voti degli studenti in un certo esame è $\sigma = 2$. In un certo anno la media dei voti è 26.2 su 109 studenti; l'anno successivo la media è 26.4 su 123 studenti. Posso dire che il secondo gruppo di studenti è più bravo del primo?

Svolgimento: Ho $\sigma_x = \sigma_y = 2$. Le sigma delle medie sono:

$$\sigma_{\bar{x}} = \frac{2}{\sqrt{109}} \simeq 0.19 \quad \text{e} \quad \sigma_{\bar{y}} = \frac{2}{\sqrt{123}} \simeq 0.18$$

$$\sigma_{\bar{x} - \bar{y}} = \sqrt{(0.19)^2 + (0.18)^2} = 0.26$$

⁸ δ restituisce direttamente lo spostamento in unità di σ .

Calcolo la differenza: $|\bar{x} - \bar{y}| = |26.2 - 26.4| = 0.2$.

La mia statistica di test vale:

$$\frac{|\bar{x} - \bar{y}|}{\sigma_{\bar{x}-\bar{y}}} = \frac{0.2}{0.26} = 0.76 < 1.96$$

In questo caso $|\bar{x} - \bar{y}|$ è lontano meno di una $\sigma_{\bar{x}-\bar{y}}$ da zero, quindi non devo rigettare l'ipotesi: ovvero non c'è nessun miglioramento significativo.

Caso 3: Medie di due set di dati con σ ignota (Introduzione t-Student)

Consideriamo ora il caso più realistico: ho due misure ottenute come medie di un set di dati, $\bar{x}$ e $\bar{y}$, ma le σ_x e σ_y della popolazione *non sono note*. Devo quindi stimarle dagli scarti. Ricordiamo che:

$$\hat{\sigma}_x = s_x = \sqrt{\frac{\sum_i (x_i - \bar{x})^2}{N_x - 1}} \quad \text{e} \quad \hat{\sigma}_y = s_y = \sqrt{\frac{\sum_i (y_i - \bar{y})^2}{N_y - 1}}$$

Il fatto che le σ sono una *stima* invece del valore vero fa sì che non possiamo utilizzare le procedure descritte nel Caso 2, perché lì abbiamo assunto che $\frac{\bar{x}-\bar{y}}{\sigma_{\text{tot}}} \sim \mathcal{N}(0,1)$. L'equivalente quantità ottenuta sostituendo σ_x e σ_y con le rispettive stime **non è più una gaussiana** a causa dell'incertezza aggiunta dalla stima delle σ . In questo caso si usa un'altra distribuzione che si chiama **t-Student**.

20.1 Derivazione della Distribuzione t-Student

Per capire questa distribuzione bisogna considerare un caso più semplice. Supponiamo che $x \sim \mathcal{N}(\mu, \sigma^2)$, allora abbiamo visto che la quantità $z = \frac{x-\mu}{\sigma} \sim \mathcal{N}(0,1)$. Ora supponiamo di avere molte misure $\{x_1, \dots, x_N\}$ (variabili indipendenti distribuite gaussianamente). Allora:

$$\frac{\bar{x} - \mathbb{E}[\bar{x}]}{\sigma_{\bar{x}}} \sim \mathcal{N}(0,1) \implies z = \frac{\bar{x} - \mu}{\sigma/\sqrt{N}} \sim \mathcal{N}(0,1)$$

Se non conosciamo σ ma solo la sua stima $\hat{\sigma}$, come è distribuita la variabile $t = \frac{\bar{x}-\mu}{\hat{\sigma}/\sqrt{N}}$? Ricordiamoci che la varianza campionaria può essere calcolata in due modi:

- conoscendo μ : $\hat{\sigma}^2 = \frac{1}{N} \sum_i (x_i - \mu)^2$
- non conoscendo μ : $\hat{\sigma}^2 = \frac{1}{N-1} \sum_i (x_i - \bar{x})^2$

Se indico con n i gradi di libertà (che vale N nel primo caso e $N-1$ nel secondo), la quantità $c \equiv \frac{n\hat{\sigma}^2}{\sigma^2}$ è distribuita come un χ^2 con n gradi di libertà: $c \sim \chi_n^2$.

Nell'espressione di t posso moltiplicare e dividere per σ e ottengo:

$$t = \frac{\bar{x} - \mu}{\hat{\sigma}/\sqrt{N}} \cdot \frac{\sigma}{\sigma} = \frac{\bar{x} - \mu}{\sigma/\sqrt{N}} \cdot \frac{\sigma}{\hat{\sigma}} = z \sqrt{\frac{\sigma^2}{\hat{\sigma}^2}} = z \sqrt{\frac{n}{c}}$$

Quindi la possiamo scrivere come:

$$t = \frac{z}{\sqrt{c/n}} \quad (281)$$

Sapendo le p.d.f. di z e di c :

$$P_z(z) = \frac{e^{-z^2/2}}{\sqrt{2\pi}}, \quad P_c(c) = \frac{2^{-n/2}}{\Gamma(n/2)} c^{\frac{n}{2}-1} e^{-c/2}$$

Possiamo usare le regole del cambiamento di variabili per ricavare $P(t)$. Partiamo dalla distribuzione congiunta $P(t, c; n) = P(z, c; n) \left| \frac{\partial z}{\partial t} \right|$. Dalla (281) ricaviamo $z = t\sqrt{\frac{c}{n}} \implies \frac{\partial z}{\partial t} = \sqrt{\frac{c}{n}}$. Assumendo che z e c siano indipendenti (la media campionaria, da cui dipende z , e la varianza campionaria, da cui dipende c , lo sono per campioni gaussiani), si ha $P(z, c; n) = P_z(z)P_c(c)$:

$$P(t, c; n) = \frac{e^{-t^2 c/(2n)}}{\sqrt{2\pi}} \cdot \frac{2^{-n/2}}{\Gamma(n/2)} c^{\frac{n}{2}-1} e^{-c/2} \sqrt{\frac{c}{n}}$$

Riordinando i termini in c :

$$P(t, c; n) = \frac{1}{\sqrt{\pi n} 2^{(n+1)/2} \Gamma(n/2)} \cdot c^{\frac{n-1}{2}} e^{-\frac{c}{2} \left(\frac{t^2}{n} + 1 \right)}$$


Resta ora da integrare rispetto a c tra 0 e $+\infty$ per trovare la p.d.f. marginale $P(t)$. Possiamo usare l'integrale notevole per la funzione Gamma:

$$\int_0^{+\infty} x^m e^{-ax} dx = \frac{\Gamma(m+1)}{a^{m+1}}$$

con $m = \frac{n-1}{2}$ e $a = \frac{1}{2} \left(\frac{t^2}{n} + 1 \right)$. Pertanto $m+1 = \frac{n+1}{2}$. Sostituendo si ha:

$$P(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{\pi n} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad (282)$$

Questa è la distribuzione nota come **t-Student**. Essa somiglia molto ad una normale standard per n molto grandi, mentre per n piccoli le code tendono ad essere più lunghe.



Abbiamo quindi trovato che forma ha la p.d.f. della quantità:

$$t = \frac{\bar{x} - \mu}{\hat{\sigma}/\sqrt{N}}$$

e quindi si può usare con le stesse regole di qualunque altra statistica di test. Consente di verificare se la media $\bar{x}$ è compatibile con il valore di aspettazione della popolazione, note le stime della deviazione standard.

Ritorno al Caso 3: Medie con Varianze Ignote

Ora torniamo al problema da cui siamo partiti: voglio confrontare $\bar{x}$ e $\bar{y}$ (medie di due campioni) e consideriamo il caso semplice in cui si assume che le popolazioni di origine abbiano la stessa varianza vera $\sigma_x = \sigma_y = \sigma$. Abbiamo visto che se conoscessimo σ , la quantità $\frac{\bar{x}-\bar{y}}{\sigma\sqrt{1/N_x+1/N_y}}$ sarebbe una normale standard.

Se non conosco σ , devo trovare una stima. Si dimostra che la quantità che sostituisce σ^2 in questo caso è la **varianza globale** (o "pooled variance") S^2 , definita come la media pesata delle varianze campionarie:

$$S^2 = \frac{(N_x - 1)s_x^2 + (N_y - 1)s_y^2}{N_x + N_y - 2} \quad (283)$$

E la statistica di test diventa:

$$t = \frac{\bar{x} - \bar{y}}{S\sqrt{\frac{1}{N_x} + \frac{1}{N_y}}} \quad (284)$$

Questa variabile segue una distribuzione **t-Student con $n = N_x + N_y - 2$ gradi di libertà**.

Dimostrazione intuitiva: Sappiamo che:

$$(N_x - 1)\frac{s_x^2}{\sigma^2} \sim \chi_{N_x-1}^2 \quad \text{e} \quad (N_y - 1)\frac{s_y^2}{\sigma^2} \sim \chi_{N_y-1}^2$$

Se sommo queste due quantità, per le proprietà del χ^2 ho ancora una distribuzione χ^2 con gradi di libertà pari alla somma $n = (N_x - 1) + (N_y - 1) = N_x + N_y - 2$. La somma vale:

$$\frac{(N_x - 1)s_x^2 + (N_y - 1)s_y^2}{\sigma^2} = (N_x + N_y - 2)\frac{S^2}{\sigma^2} = n\frac{S^2}{\sigma^2} \equiv c' \sim \chi_n^2$$

Se prendiamo la relazione iniziale (con σ nota), la moltiplichiamo e dividiamo per σ :

$$t = \frac{\bar{x} - \bar{y}}{S\sqrt{\frac{1}{N_x} + \frac{1}{N_y}}} = \frac{\frac{\bar{x}-\bar{y}}{\sigma\sqrt{\frac{1}{N_x} + \frac{1}{N_y}}}}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{z'}{\sqrt{c'/n}}$$

dove il numeratore è distribuito come $\mathcal{N}(0, 1)$. Questa espressione ricalca esattamente la forma (281), quindi t segue una t-Student.

Set di dati dipendenti

Cosa succede nel caso in cui i miei campioni non siano indipendenti? Se x e y sono correlati (es. misure prese dalle stesse persone prima e dopo una cura):

$$\text{var}(x - y) = \text{var}(x) + \text{var}(y) - 2\rho\sigma_x\sigma_y = \sigma_x^2 + \sigma_y^2 - 2\rho\sigma_x\sigma_y$$

Spesso si assume $\rho \approx 1$ (massima correlazione), per cui $\text{var}(x - y) \simeq (\sigma_x - \sigma_y)^2$. Questa varianza si può usare per il Caso 1.

Tuttavia, il modo più pulito di procedere in questi casi (Caso 3 con dati appaiati) è, invece di calcolare le medie $\bar{x}$ e $\bar{y}$ separatamente, calcolare *direttamente* la differenza per ogni coppia di misure:

$$\delta_i = x_i - y_i$$

Poi si calcola la media di queste quantità $\bar{\delta}$ e la loro deviazione standard campionaria $\hat{\sigma}_{\delta}$. A questo punto si lavora direttamente con la variabile δ applicando un test t-Student a un campione (sulla differenza da 0):

$$t = \frac{\bar{\delta}}{\hat{\sigma}_{\delta}/\sqrt{N}} \sim \text{t-Student}(N-1)$$

Intervalli di confidenza

Nei test di ipotesi abbiamo parlato di significatività riferendoci all'integrale della p.d.f. *al di sopra* (le code) di un certo valore di soglia. Il **livello di confidenza** è un po' l'opposto: rappresenta l'area *centrale* della distribuzione.

Esempio 4. *Se so che una fabbrica che costruisce scatole di cereali le produce secondo una distribuzione gaussiana con media $\mu = 520$ g e $\sigma = 10$ g, allora mi aspetto che il 68% dei pacchetti prodotti avrà peso compreso tra 510 g e 530 g; oppure possiamo dire che il peso è tra 510 g e 530 g con un livello di confidenza del 68%.*

In certi casi può essere utile condensare l'informazione in termini di livelli di confidenza in un diagramma chiamato **diagramma di confidenza** (o *confidence belt*), che mostra come cambiano gli intervalli di confidenza al variare di un parametro della distribuzione (ad esempio per una gaussiana può essere la media μ).

Per costruirlo si stabilisce il livello di confidenza scelto (per esempio il 90%) e, *per ogni valore del parametro vero μ* , si possono determinare i bordi misurabili x_- e x_+ tali che:

$$\int_{x_-}^{x_+} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = 0.90$$

Viceversa, una volta fatta l'osservazione e ottenuto un valore sperimentale x (fissato), posso intersecare il diagramma in verticale per trovare i due valori μ_- e μ_+ che "shiftano" la gaussiana in modo che l'integrale a destra o a sinistra di x contenga rispettivamente una frazione di probabilità corrispondente ai rigetti (es. il 5% di code per lato nel caso di CL al 90%):

$$\int_x^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x'-\mu_-)^2}{2\sigma^2}} dx' = 0.05 \quad \text{e} \quad \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x'-\mu_+)^2}{2\sigma^2}} dx' = 0.05$$

Questi valori μ_- e μ_+ formano l'intervallo di confidenza per il parametro vero dato il valore misurato.

