Appunti di Statistica

Mirolo Manuele / Alessio Brusini / Michele Tedeschini

a.a. 2025/26

"Se noi non fossimo ignoranti non ci sarebbe probabilità, ci potrebbero essere solo certezze. Ma la nostra ignoranza non può essere assoluta, altrimenti non ci sarebbe più probabilità. Così i problemi di probabilità possono essere classificati a seconda della maggiore o minore profondità della nostra ignoranza."

— Henri Poincaré

Premessa

Le sotto sezioni in Rosso sono quelle che riguardano il ripasso di Bressan, tutte le altre (in nero) sono quelle che riguardano il programma dell'anno attuale.

Indice

0 Contatti e informazioni **4**

1 Introduzione / Ripasso di Bressan **5**
1.1 Definizioni di probabilità . . . 5
1.2 Definizione assiomatica di probabilità . . . 5
1.3 Proprietà della misura di probabilità . . . 5
1.3.1 Probabilità condizionata . . . 6
1.3.2 Probabilità delle cause . . . 6
1.4 Teorema di Bayes . . . 6
1.5 Indipendenza . . . 6
1.6 Cenni di calcolo combinatorio e fattoriale . . . 6
1.7 Variabili casuali e funzione di ripartizione . . . 7
1.7.1 Funzione di ripartizione . . . 7
1.8 Densità di probabiità . . . 8
1.8.1 Proprietà della funzione densità di probabilità . . . 8

2 Introduzione e Statistica **9**
2.0.1 Scatter Plot ed Errori . . . 9
2.0.2 Istogramma . . . 9
2.1 Grandezze Statistiche: Media e Varianza . . . 9
2.1.1 Parte di Bressan: Valore di Aspettazione . . . 9
2.1.2 Media Aritmetica . . . 10
2.1.3 Parte di Bressan: Varianza e Deviazione Standard . . . 10
2.1.4 Deviazione Standard e correzione di Bessel . . . 11
2.2 Propagazione degli Errori . . . 12
2.2.1 Parte di Bressan: Errore di sensibilità e distribuzione uniforme . . . 12
2.3 Errore di Sensibilità e Distribuzione Uniforme . . . 13

3 Metodo dei Minimi Quadrati **13**
3.0.1 Parte di Bressan: Metodo dei Minimi Quadrati . . . 13
3.1 Il Principio . . . 14
3.1.1 Parte di Bressan: Fit di una retta (Regressione Lineare) . . . 14
3.2 Fit Lineare ($y = mx + q$) . . . 15
3.2.1 Parte di Bressan: Caso non lineare . . . 16
3.3 Caso Non Lineare e Linearizzazione . . . 17

4 Momenti e Distribuzioni **18**
4.1 Momenti della funzione di distribuzione . . . 18
4.2 Distribuzione uniforme discreta . . . 19
4.3 Distribuzione uniforme continua . . . 19
4.4 Approfondimento sulla funzione caratteristica . . . 21
4.5 Distribuzione binomiale o di Bernoulli . . . 21
4.5.1 Proprietà della distribuzione binomiale . . . 22
4.5.2 Funzione generatrice dei momenti della Binomiale . . . 22

5 Codice python e Distribuizione di Poisson **24**
5.1 Esempi Python: La Distribuzione Binomiale . . . 24
5.1.1 Parte di Bressan: Distribuzione di Poisson . . . 25
5.2 Confronto: Poisson vs Binomiale . . . 26
5.3 Calcolo dei Momenti tramite la Funzione Generatrice dei Momenti . . . 27
5.3.1 Calcolo di Media e Varianza . . . 27
5.4 Relazione con la Binomiale e Somma di Variabili . . . 28
5.4.1 Limite della Funzione Generatrice dei Momenti Binomiale . . . 28
5.4.2 Confronto delle forme (Code della distribuzione) . . . 28

5.4.3 Somma di Poissoniane Indipendenti . . . 29
5.5 Esempi Python: Grafici e Confronti . . . 29
5.5.1 1. Visualizzazione della Distribuzione Binomiale . . . 29
5.5.2 2. Esercizio Poisson: La notte di San Lorenzo . . . 31
5.6 Rappresentazione grafica dei dati (Istogrammi) . . . 33

6 Funzione di distribuzione di Gauss **34**
6.0.1 Parte di Bressan: Distribuzione Normale . . . 34
6.0.2 Esempio di distribuzione di Gauss . . . 35
6.0.3 Dimostrazione Euristica . . . 35
6.1 Definizione di distribuzione normale . . . 36
6.2 Calcolo del Valore di Aspettazione e della Varianza . . . 36
6.3 Variabili Aleatorie e Combinazioni Lineari . . . 38

7 Teorema del Limite Centrale **39**
7.1 Caso Particolare: Variabili I.I.D. . . . 39
7.2 Dimostrazione (tramite Funzione Generatrice dei Momenti) . . . 40
7.3 Implicazioni del Teorema nell'Analisi Dati . . . 41
7.4 Generazione di Numeri Casuali Normali . . . 41
7.5 La Trasformazione di Box-Muller . . . 41

8 Distribuzione di Cauchy e Legge dei grandi numeri **44**
8.1 Distribuzione di Cauchy come rapporto di due normali standard . . . 44
8.2 Legge dei grandi numeri . . . 45
8.3 Distribuzione Esponenziale . . . 48

9 Distribuzione Esponenziale **50**
9.1 Funzione di Ripartizione e Densità di Probabilità . . . 50
9.2 Proprietà di Assenza di Memoria . . . 51

10 Distribuzione di Erlang **52**

11 Metodi Monte Carlo **52**
11.1 Metodo Accept-Reject . . . 52
11.2 Metodo della Funzione di Ripartizione (Inversione) . . . 53

12 da integrare dopo **54**
12.1 Distribuzione di Maxwell-Boltzmann . . . 54

13 Funzione di distribuzione per variabili casuali **56**

14 Funzione di distribuzione congiunta **59**
14.1 Stima dei parametri . . . 59

15 Confronto istogramma/gaussiana **60**

0 Contatti e informazioni

- Mail: agata.trovato@units.it
- Ufficio: Edificio F, primo piano, Aula 114

- Ricevimento: Giovedì dalle 14:00 alle 1:00

1 Introduzione / Ripasso di Bressan

Lezione del 2024

La probabilità è la misura del grado della credenza che un certo evento avvenga.

L'oggetto della teoria è un certo *esperimento causale*, la cui esecuzione è detta *prova*, il risultato è indicato con ω, l'insieme di tutti gli ω possibili è detto *spazio campione* Ω. Un *Evento A* è un sottoinsieme di Ω, se $\omega \in$ A allora esso realizza l'Evento. Se esso è l'unico elemento costituente di A allora esso è l'*evento elementare*, altrimenti A è un *evento composto*. Altre nomenclature sono legate alla teoria insiemistica (per esempio due eventi A e B sono disgiunti se l'insieme A non interseca l'insieme B).

1.1 Definizioni di probabilità

Si possono dare due definizioni di probabilità:

CLASSICA : dato uno spazio **finito** Ω, la probabilità è il rapporto:

$$P(E) = \frac{\text{casi favorevoli}}{\text{casi possibili}}$$

Questa funzione è utile quando i casi risultano essere **ugumente possibili**.

FREQUENTISTICA : emerge dal ragioanamento fondato sui risultati di un esperimento:

$$P(E) = \lim_{N \to \infty} \frac{n}{N}$$

dove n è il numero di volte che si verifica un evento, mentre N è le volte che viene ripetuto l'esperimento.

1.2 Definizione assiomatica di probabilità

Dato un evento A $\subseteq \Omega$ la misura di probabilità P è una funzione $P : \Omega \to \mathbf{R}$ le cui caratteristiche sono:

- $P(A) \geqslant 0$
- $P(evento\ certo) = 1$
- Se A e B sono eventi **disgiunti** (incompatibili), cioè $P(A \cap B) = 0$, allora $P(A \cup B) = P(A) + P(B)$, che nella forma generalizzata risulta essere:
$$P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

1.3 Proprietà della misura di probabilità

- Probabilità negazione: $P(\overline{A}) = 1 - P(A)$
- Estremi della misura di probabilità: $0 \leqslant P(A) \leqslant 1$
- Teorema delle probabilità totali (con $A \bigcap B \neq 0$):
$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$
$$P(A - B) = P(B) - P(A \cap B)$$
- Probabilità in relazione d'inclusione (con $A \subseteq B$): $P(A) \leqslant P(B)$

1.3.1 Probabilità condizionata

La probabilità che si verifichi A se si verifica B:

$$P(A|B) = \frac{P(A \bigcap B)}{P(B)}$$

Il **Teorema delle probabilità totale** mi enuncia che se ho che se ho n eventi e si ha che

$$P(M_i \cap M_j) = 0 \quad \forall i \neq j \qquad \& \qquad \bigcup_{i=0}^{n} M_i = \Omega$$

dove Ω è lo spazio campione; allora:

$$P(A) = \sum_{i=1}^{n} P(A|M_i)P(M_i)$$

Mentre per l'indipendenza si ha $P(A \cap B) = P(A)P(B)$

1.3.2 Probabilità delle cause

Ci chiediamo quale sia la probabilità che M_j sia la causa di un certo evento A.

1.4 Teorema di Bayes

Dato un certo set di ipotesi (M_i) e un certo evento A il teorema mi dice come la probabilità a "posteriori" $P(M_i|A)$ cambia dopo che l'evento A si è verificato.

Consideriamo un eveneto A e una classe completa di ipotesi (M_j):

$$\begin{cases} M_i \bigcap M_j = 0 \\ \bigcup_j M_j = \Omega \end{cases}$$

Utilizzando il teorema della probabilità condizionata e il fatto che $P(A \bigcap M_i) = P(M_i \bigcap A)$ posso ricavare la probabilità che una causa sia dovuta a un determinato evento

$$P(M_i|A) = \frac{P(A|M_I)P(M_i)}{P(A)} = \frac{P(A|M_i)P(M_i)}{\sum_{j=1}^{n} P(A|M_j)P(M_j)}$$

Dove:

P(M) : probabilità a priori/margianale (non tiene conto di A)

P(M | A) : probabilità condizionata/a posteriori, nota A

P(A | M) : probabità condizionata di A, nota M

P(A) : è la probabilità di A a priori, serve da costante di normalizzazione

1.5 Indipendenza

Si dicono due eventi indipendenti: $P(A \cap B) = P(A) \cdot P(B)$ e quindi $P(A|B) = P(A)$

Per esempio: nella misura del pendolo fermare il pendolo ad ogni misura rende le misure indipendenti fra di loro (una misura di un periodo sbagliato non influisce sulla misura successiva).

1.6 Cenni di calcolo combinatorio e fattoriale

Si chiama combinazione semplice quella in cui non importa l'ordine degli elementi e il numero di combinazioni $C_{n,r}$ è dato da:

$$C_{n,r} = \binom{n}{r} = \frac{n!}{r!(n-r)!}$$

Con la definizione di fattoriale:

$$n! = \prod_{k=1}^{n} k = 1 \cdot 2 \cdot 3 \cdots n = \prod_{i=0}^{n-1} (n-i)$$

Fattoriale di un numero negativo:

$$n! = \prod_{i=0}^{n-1}(n-i)$$

$$(c)^n n! = \prod_{i=0}^{n-1} c(n-i)$$

$$(-1)^n n! = \prod_{i=0}^{n-1} -1(n-i) = (-n)!$$

Fattoriale di un numero positivo:

$$x! = \Pi(x) = \int_0^{\infty} t^x e^{-t} dt$$

Che presenta la proprietà:

$$\Pi(x+1) = (x+1)\Pi(x)$$

Sempre Eulero introdusse la funzione Gamma Γ, con uno spostamneto di unità nelle variabili rispetto a Π:

$$\Gamma(z) = \int_0^{\infty} t^{z-1} e^{-t} dt$$

Difatti questa funzione è legata a Π da $\Pi(x) = \Gamma(x+1) = x$ e vale che $z\Gamma(z) = \Gamma(z+1)$

Da questa funzione sono definte le combinazioni semplici del tipo:

$$\binom{z}{k} = \frac{\Gamma(z+1)}{k!\Gamma(z-k+1)}$$

Importanti relazioni tra le funzioni Gamma sono:

$$\Gamma(z)\Gamma(1-z) = \frac{\pi}{\sin(\pi z)} \qquad \Gamma(z)\Gamma(-z) = -\frac{\pi}{\sin(\pi z)}$$

Da queste ricavo che $\Gamma(\frac{1}{2}) = \sqrt{\pi}$ e $\Gamma(-\frac{1}{2}) = -\sqrt{\pi}$, l'ultima importante relazione è invece:

$$\Gamma(n+\frac{1}{2}) = \frac{(2n-1)!!}{2^n}\sqrt{\pi}$$

1.7 Variabili casuali e funzione di ripartizione

Dato lo spazio di eventi elementare ω una *variabile casuale* è una funzione X tale che $X(\omega) = x$ dove $x \in \mathrm{R}$, dunque una funzione che mi prende un campione casuale dal mio spazio campionario e gli associa un numero(ex: valore, altezza, ...).

Essa può essere discreta (numerabile) oppure continua, se almeno idealmente posso considerare Ω continuo.

1.7.1 Funzione di ripartizione

Data una variabile casuale X, la funzione F che fa corrispondere a un valore x la probabilità cumulativa $P(X \geqslant x)$ viene detta funzione di ripartizione

$$F_X : \mathbf{R} \to [0,1] \; F_X(x) = P(X \leqslant x)$$

La funzione di ripartizione è definita sia per le variabili casuali discrete che per le variabili casuali continue.

Proprietà delle funzioni di ripartizioni:

1. $0 \geqslant F_X(x) \geqslant 1$
2. nel caso che il dominio sia $\mathbf{R}$, allora $\lim_{x\to-\infty} F_X(x) = 0$ e $\lim_{x\to\infty} F_X(x) = 1$
3. È una funzione monotona crescente;
4. $P(x_1 < X \leqslant x_2) = F_X(x_2) - F_X(x_1)$ dunque la funzione di ripartizione consente di stabilire la probabilità che la variabile casuale semplice X assuma valori compresi in intervalli di tipo $(x_1, x_2]$ dove $x_1, x_2 \in \mathbf{R}$, con $x_1 < x_2$. A partire da questo posso calcolare anche le altre probabilità, ad esempio:

$$P(x_1 \leqslant X < x_2) = F_X(x_2) - F_X(x_1) + P(X = x_1) - P(X = x_2)$$

5. Nel caso di una variabile casuale discreta, la funzione di ripartizione è continua a destra:

$$\lim_{x \to x_0^+} F_X(x) = F_X(x_0).$$

mentre a sinistra abbiamo una discontinuità di 1° specie (o salto):

$$\lim_{x \to x_0^-} F_X(x) \neq F_X(x_0)$$

Questo è dovuto al fatto che la probabilità di un evento elementare è diversa da zero, quindi la funzione di ripartizione ha un salto in corrispondenza di ogni valore che può assumere la variabile casuale discreta (pensa lancio dei dati dove cambia la probabilità)

In un intervallo posso avere una **Probabilità uniforme**, ossia eventi in cui la funzione di probabilità è costante (ex nel caso dei dadi la funz. di ripartizione è a gradini)

1.8 Densità di probabiità

Data la variabile casuale continua $X : \Omega \to \mathbf{R}$ che associa valori dallo spazio campionario all'intervallo (a, b), con $-\infty \leqslant a < b \leqslant +\infty$, la funzione di densità di probabilità (PDF) o funzione di distribuzione di probabilità è la funzione $f_X : \mathbf{R} \to \mathbf{R}^+$ che ad ogni x associa il limite per $dx \to 0$, del rapporto tra la probabilità che la variabile casuale assuma valori nell'intervallo $(x, x + dx]$ e l'ampiezza dx, ovverosia possiamo supporre la probabiità che un certo evento cada in un intervallo.

In simboli:

$$f_X : \mathbf{R} \to \mathbf{R}^+ : x \mapsto \lim_{dx \to 0} \left[\frac{P(x < X \leqslant x + dx)}{dx} \right] = \lim_{dx \to 0} \frac{F_X(x + dx) - F_X(x)}{dx}$$

Ogni evento deve essere ricondotto all'unione, negazione o intersezione di intervalli del tipo $(-\infty, x]$

Attenzione a non confondere la funzione di densità con una probabilità. Essa mi determina la densità di probabilità che la variabile casuale sia nell'intervallo dx.

Definimamo la **Funzione di distribuzione cumulativa**:

$$F(x) = \int_{x_{min}}^{x} f_X(t)dt$$

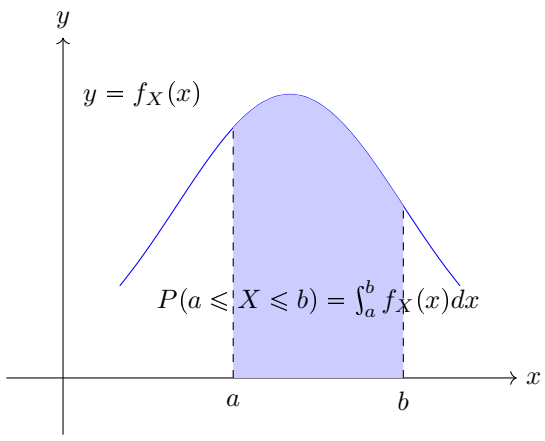

1.8.1 Proprietà della funzione densità di probabilità

- non può essere mai negativa (altrimenti avremmo una probabiità negativa per qualche X)
- condizione di normalizzazione:

$$\int_{-\infty}^{\infty} f(x) = 1$$

  dunque si deve avere che: $\lim_{x \to \pm\infty} f_X(x) = 0$
- la probabilità che una variabile casuale assuma un particolare valore dell'intervallo è $P(X = x) = 0$, infatti ad un singolo valore corrisponde un intervallo con ampiezza nulla; questo mi porta a poter escludere gli estremi

2 Introduzione e Statistica

Lezione del 6 Ottobre 2026

Le nostre misure saranno del tipo $x_1, x_2, ..., x_N$, il nostro obiettivo è quello di rappresentare questi dati per capire il fenomeno fisico che stiamo studiando.
Per quanto riguarda la parte grafica, la rappresentazione dipende dai dati a disposizione:

- **Istogramma**: Avendo molte misure di una sola grandezza, la rappresentazione tipica è l'istogramma. Per farlo si divide l'intervallo atteso delle misure in intervalli più piccoli detti *bin*, e si conta quante misure cadono in ogni intervallino.
- **Scatter Plot**: Avendo poche misure di due o più variabili correlate, la rappresentazione più utile è un plot a dispersione (punti (x, y) sul piano cartesiano).

2.0.1 Scatter Plot ed Errori

L'altra rappresentazione classica è lo scatter plot in cui plottiamo una grandezza rispetto all'altra e aggiungiamo per ogni punto gli errori di misura:

$$(x_i \pm \sigma_{x_i}, \quad y_i \pm \sigma_{y_i})$$

In questa rappresentazione è stato usato un numero per rappresentare una misura di x ed è stato associato ad esso una stima dell'errore fatto nella singola misura.

Gli errori da associare dipendono dalla situazione pratica:

- In alcuni casi si può fare un'analisi statistica ripetendo le misure molte volte.
- Nella maggior parte dei casi questo non si può fare (strumento non abbastanza sensibile o fenomeno non ripetibile). In tal caso si associa l'errore di sensibilità dello strumento.

2.0.2 Istogramma

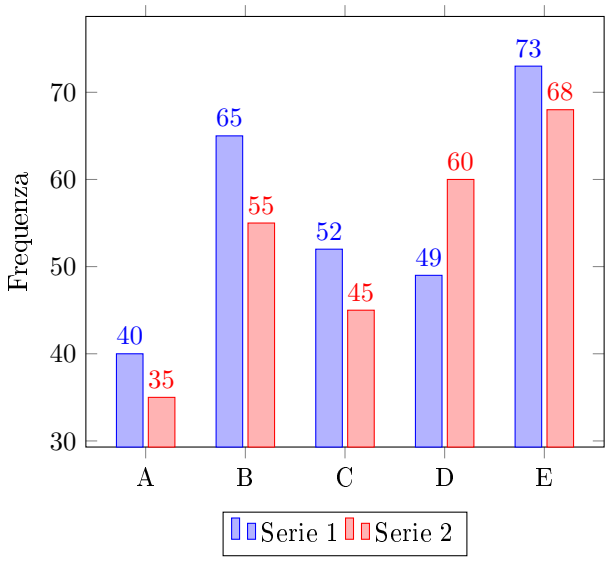

2.1 Grandezze Statistiche: Media e Varianza

2.1.1 Parte di Bressan: Valore di Aspettazione

Le caratteristiche principali delle distribuzioni di probabilità sono descritte attraverso specifici parametri: gli *indici di posizione*, che indicano attorno a quali valori è centrata la distribuzione, e gli *indici di dispersione*, che ne quantificano la "larghezza" o variabilità. Tra gli indici di posizione, riveste particolare importanza il **valore di aspettazione**.

Data una variabile casuale $X \in [a, b]$ e la funzione di densità di probabilità $f_X(x)$ ad essa associata, è possibile definire il valore di aspettazione di una generica funzione $g(x)$ come:

$$E[g(x)] = \int_a^b g(x) f_X(x) dx \qquad \text{(caso continuo)}$$

oppure, per il caso discreto:

$$E[g(x)] = \sum_{i=1}^{n} g(x_i)p_i$$

Si tratta, quindi, di una media dei valori assunti da $g(x)$, pesata con la rispettiva densità di probabilità (o probabilità p_i).

Il valore di aspettazione gode di proprietà analoghe a quelle di un'applicazione lineare.

Per una variabile casuale continua, il **valore di aspettazione** di X stesso è dato da:

$$\mu_x = E[x] = \int_{\Omega} x f_X(x) dx$$

Il parametro μ_x è definito come *valore medio*. Un ragionamento analogo si applica alle variabili casuali discrete (sostituendo l'integrale con la sommatoria).

Poiché μ_x è una costante e ha la stessa dimensione fisica della variabile casuale, vale la proprietà:

$$E[\mu_x] = \mu_x$$

Esso rappresenta un "indice di posizione" fondamentale all'interno del dominio della variabile.

2.1.2 Media Aritmetica

Consideriamo il caso ottimistico in cui si riesce a misurare tante volte la stessa grandezza nelle stesse condizioni. In questo caso, se si vuole usare un solo numero per descrivere le misure, il migliore è senz'altro la **media aritmetica**:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^{N} x_i \tag{1}$$

2.1.3 Parte di Bressan: Varianza e Deviazione Standard

Oltre alla media, esistono altri indici di posizione:

Moda : il valore di x in corrispondenza del quale la funzione $f_X(x)$ assume il suo massimo;

Quantili : valori associati alla probabilità che la variabile casuale cada in determinati intervalli, definiti tramite la funzione di distribuzione cumulativa:

$$\alpha = F(x) = \int_{-\infty}^{x} f(t)dt$$

Considerando la media campionaria $\bar{x}$ definita come $\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$, per definizione la somma degli scarti dalla media deve essere nulla:

$$\frac{1}{N} \sum_{i=1}^{N} (\bar{x} - x_i) = 0$$

Per ottenere informazioni sulla dispersione dei dati, si definisce la **varianza** della variabile casuale come la media dei quadrati degli scarti:

$$var(x) = \frac{1}{N} \sum (x_i - \bar{x})^2$$

Sviluppando il quadrato all'interno della sommatoria, si ottiene un'espressione utile per i calcoli:

$$\begin{aligned} var(x) &= \frac{1}{N} \sum (x_i^2 - 2\bar{x}x_i + \bar{x}^2) \\ &= \frac{1}{N} \sum x_i^2 - 2\bar{x}\frac{1}{N} \sum x_i + \frac{1}{N} \sum \bar{x}^2 \\ &= \overline{x^2} - 2\bar{x}^2 + \bar{x}^2 \\ &= \overline{x^2} - \bar{x}^2 \end{aligned}$$

Ovvero: la varianza è uguale alla media dei quadrati meno il quadrato della media.

La **deviazione standard** è definita come $\sigma_x = \sqrt{var(x)}$. Tuttavia, data la limitatezza del campione nelle misure reali, si applica spesso la *correzione di Bessel*, definendo la deviazione standard campionaria come:

$$\sigma_x = \sqrt{\frac{1}{N-1} \sum (x_i - \bar{x})^2}$$

2.1.4 Deviazione Standard e correzione di Bessel

La varianza ha però la scomodità di avere un'unità di misura al quadrato rispetto a x. Si preferisce quindi la **deviazione standard**:

$$\sigma_N = \sqrt{\mathrm{Var}(x)}$$

Osservazione 1 (Correzione di Bessel). La formula sopra è corretta se le misure rappresentano tutta la popolazione. Nella maggior parte dei casi x_i è solo un **campione**. Per tener conto del bias dovuto all'uso della media campionaria $\bar{x}$ invece della media vera μ, si usa $N-1$ al denominatore:

$$\sigma = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(x_i - \bar{x})^2} \tag{2}$$

Questa correzione diventa trascurabile per N grande, ma è fondamentale per piccoli set di dati.

Esempio (Python)

Di seguito mostriamo come calcolare media e deviazione standard (con e senza correzione) simulando delle misure gaussiane, simuliamo $N = 100$ misure con due strumenti diversi ($\sigma_1 = 1$ e $\sigma_2 = 0.2$).

```python
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulo N misure di una grandezza fisica (es. corrente)
N = 100
valore_simulato = 8.0 # Valore vero [mA]
# Caso 1: sigma = 1, Caso 2: sigma = 0.2
misure1 = np.random.normal(loc=valore_simulato, scale=1.0, size=N)
misure2 = np.random.normal(loc=valore_simulato, scale=0.2, size=N)

# 2. Calcolo Media
media1 = np.mean(misure1)
print(f"Media Caso 1: {media1:.4f} mA")

# 3. Calcolo Deviazione Standard (ddof=1 applica la correzione di Bessel N-1)
sigma1_corr = np.std(misure1, ddof=1)
print(f"Sigma Corretto (Bessel): {sigma1_corr:.4f}")

# 4. Istogramma
plt.hist(misure1, alpha=0.7, bins=30, edgecolor='black', label='Caso 1')
plt.hist(misure2, alpha=0.7, bins=30, edgecolor='black', label='Caso 2')
plt.xlabel('Misura, I [mA]')
plt.title('Istogramma delle misure ripetute')
plt.legend()
plt.show()
```

Listing 1: Calcolo di Media e Deviazione Standard

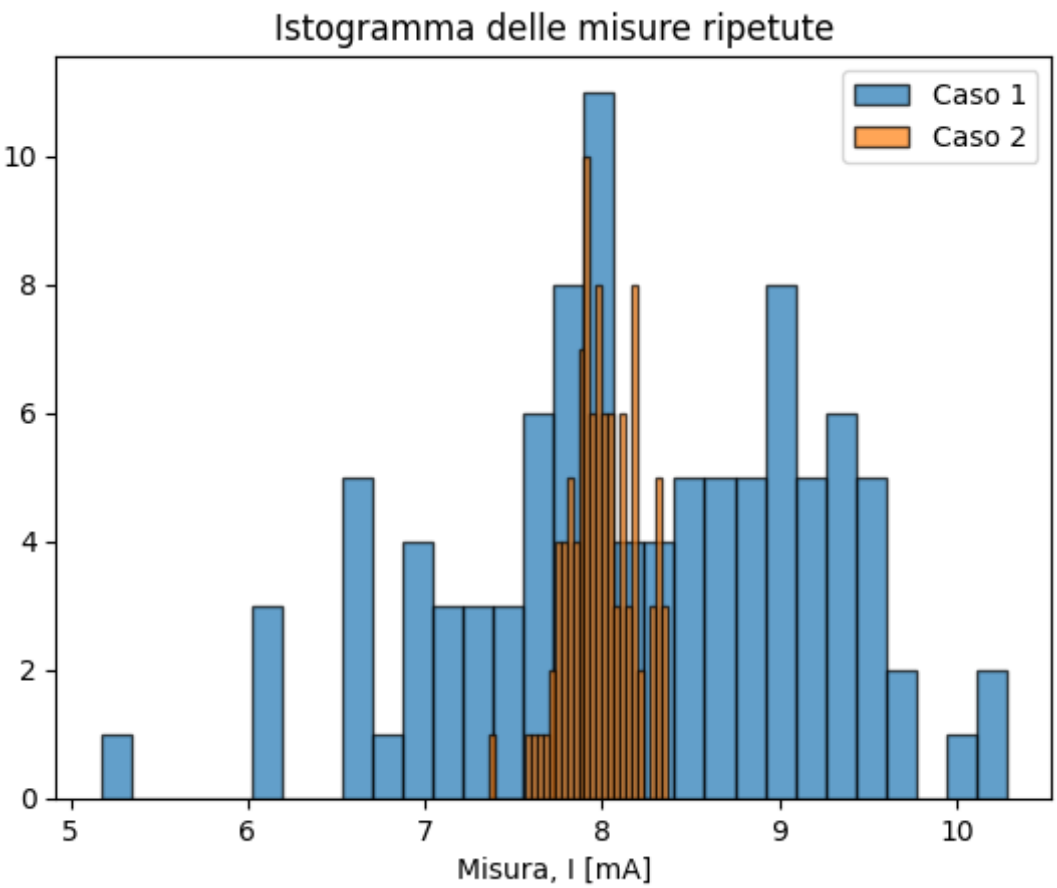

Figura 1: Istogramma comparativo delle due serie di misure simulate.

2.2 Propagazione degli Errori

Data una funzione $f(x, y)$ di variabili casuali indipendenti, la varianza si propaga come:

$$\sigma_f^2 = \left(\frac{\partial f}{\partial x}\right)^2 \sigma_x^2 + \left(\frac{\partial f}{\partial y}\right)^2 \sigma_y^2 \tag{3}$$

Esempio. ***Esempio numerico:*** *Calcolo dello spazio percorso in un moto uniformemente accelerato*
Dati: $v = 200 \pm 10\, m/s, \quad a = 12 \pm 2\, m/s^2, \quad t = 6\, s$ *(errore trascurabile).*

$$s = vt + \frac{1}{2}at^2 = (200 \cdot 6) + \frac{1}{2} \cdot 12 \cdot 6^2 = 1200 + 216 = 1416\, m$$

Errore associato σ_s*:*

$$\sigma_s^2 = \left(\frac{\partial s}{\partial v}\right)^2 \sigma_v^2 + \left(\frac{\partial s}{\partial a}\right)^2 \sigma_a^2 = (t)^2 \sigma_v^2 + \left(\frac{1}{2}t^2\right)^2 \sigma_a^2$$

$$\sigma_s = \sqrt{6^2 \cdot 10^2 + (18)^2 \cdot 2^2} = \sqrt{3600 + 1296} = \sqrt{4896} \approx 70\, m$$

Risultato: $s = 1416 \pm 70\, m$.

2.2.1 Parte di Bressan: Errore di sensibilità e distribuzione uniforme

Si definisce l'errore di sensibilità come la semiampiezza dell'intervallo di risoluzione: $\Delta x = \dfrac{X_{\max} - X_{\min}}{N}$. Il risultato della misura sarà espresso come $x \pm \Delta x$.

L'interpretazione statistica assume che il "valore vero" della grandezza appartenga a un insieme continuo di possibili valori x, ognuno associato a una probabilità $P(x)$. Poiché nel caso continuo la probabilità di un singolo punto è nulla, si utilizza la *densità di probabilità*, tale che:

$$P(x_1 < X < x_2) = \int_{x_1}^{x_2} P(x)\, dx$$

La probabilità totale su tutto il dominio deve essere unitaria (condizione di normalizzazione).

Nel caso continuo, il valore di aspettazione μ e la varianza σ^2 sono definiti rispettivamente come il baricentro e il momento di inerzia della distribuzione: $\sigma^2 = \int_{X_{\min}}^{X_{\max}} (x-\mu)^2 P(x)dx$.

Se all'interno dell'intervallo di misura tutti i valori sono *equiprobabili*, $P(x)$ segue una **distribuzione uniforme**:

$$P(x) = \begin{cases} c, & x \in [X_{\min}, X_{\max}] \\ 0, & \text{altrimenti} \end{cases}$$

Imponendo la condizione di normalizzazione ($\int P(x)dx = 1$), si ricavano i parametri della distribuzione:

- L'altezza della distribuzione è $c = \dfrac{1}{X_{\max} - X_{\min}}$.
- Ponendo per comodità l'origine al centro dell'intervallo (semiampiezza Δ), il valore medio è nullo: $\mu = \int_{-\Delta}^{+\Delta} x \dfrac{1}{2\Delta} dx = 0$.
- La deviazione standard risulta essere: $\sigma = \sqrt{\int_{-\Delta}^{+\Delta} (x-0)^2 \dfrac{1}{2\Delta} dx} = \sqrt{\dfrac{\Delta^2}{3}} = \dfrac{\Delta}{\sqrt{3}}$.

2.3 Errore di Sensibilità e Distribuzione Uniforme

Quando non è possibile ripetere molte volte la misura, associamo alle misure l'errore dovuto alla sensibilità dello strumento. Questo errore si ottiene leggendo il minimo scarto della variabile consentito dallo strumento (risoluzione):

$$\Delta x = \frac{x_{max} - x_{min}}{2}$$

Questo è l'errore massimo $x \pm \Delta x$. Statisticamente, assumere che il valore vero si trovi in $[x_{min}, x_{max}]$ equivale ad assumere una **densità di probabilità uniforme** $P(x)$ di larghezza 2Δ. La densità deve essere normalizzata a 1:

$$\int_{-\Delta}^{\Delta} C\, dx = 1 \implies C(2\Delta) = 1 \implies C = \frac{1}{2\Delta}$$

Quindi:

$$P(x) = \begin{cases} \frac{1}{2\Delta} & x \in [-\Delta, \Delta] \\ 0 & \text{altrove} \end{cases}$$

Per una distribuzione uniforme tra $[-\Delta, \Delta]$:

- Media: $\mu = 0$
- Varianza: $\sigma^2 = \int_{-\Delta}^{\Delta} x^2 \frac{1}{2\Delta} dx = \frac{\Delta^2}{3}$

Quindi, se si vuole convertire un errore massimo Δ in una deviazione standard σ:

$$\sigma = \frac{\Delta}{\sqrt{3}} \tag{4}$$

3 Metodo dei Minimi Quadrati

3.0.1 Parte di Bressan: Metodo dei Minimi Quadrati

Un metodo fondamentale per stimare i parametri di un modello è quello dei **minimi quadrati**. Consideriamo un set di misure $\vec{x} = (x_1, \ldots, x_n)$ e i corrispondenti valori osservati $\vec{y} = (y_1, \ldots, y_n)$. Si assume che esista una relazione funzionale $f(x; \lambda)$ che lega le variabili, dove $\vec{\lambda} = (\lambda_1, \ldots, \lambda_k)$ sono i parametri ignoti da stimare.

Il principio dei minimi quadrati stabilisce che la miglior stima dei parametri è quella che minimizza la somma degli scarti quadratici pesati:

$$\chi^2 = \sum_{i=1}^{n} w_i \left[y_i - f(x_i; \vec{\lambda}) \right]^2$$

Il peso w_i è legato all'incertezza della misura:

- Se tutte le misure hanno la stessa incertezza, il termine w_i può essere omesso (o posto uguale a 1).

- Se ogni misura ha un'incertezza diversa σ_i, allora $w_i = \frac{1}{\sigma_i^2}$. In questo caso la quantità minimizzata coincide con la variabile χ^2 (Chi-quadro).
- Se le variabili sono correlate, i pesi coinvolgeranno gli elementi della matrice di covarianza inversa.

Caso particolare: stima di una costante (Media Pesata) Se il modello è una costante $y = \lambda$ (cioè cerchiamo il miglior valore unico che rappresenti i dati), minimizzando il χ^2 si ottiene:

- Con errori uguali ($\sigma_i = \sigma$): Media aritmetica
$$\hat{\lambda} = \frac{1}{n}\sum_{i=1}^{n} y_i$$
- Con errori differenti (σ_i): Media pesata
$$\hat{\lambda} = \frac{\sum_{i=1}^{n} \frac{y_i}{\sigma_i^2}}{\sum_{j=1}^{n} \frac{1}{\sigma_j^2}}$$

3.1 Il Principio

L'obiettivo è dedurre informazioni fisiche dai dati (fit). Partiamo dalle ipotesi:

1. Ho effettuato misure (x_i, y_i) dove l'errore su x è trascurabile.
2. Per ogni x fisso, ho misurato y con incertezza σ_i.
3. Esiste una legge $y = f(x; p)$ (dove p sono i parametri).

Il metodo consiste nel minimizzare la somma degli scarti quadratici pesati, detta **Chi Quadro** χ^2:

$$\chi^2 = \sum_{i=1}^{N} \left[\frac{y_i - f(x_i; p)}{\sigma_i}\right]^2 \tag{5}$$

Minimizzare significa porre le derivate rispetto ai parametri uguali a zero: $\frac{\partial \chi^2}{\partial p} = 0$.

3.1.1 Parte di Bressan: Fit di una retta (Regressione Lineare)

Vogliamo determinare la retta che meglio descrive un set di dati $(x_i, y_i \pm \sigma_i)$. Utilizziamo la parametrizzazione $f(x) = mx + q$ (oppure $\theta_2 x + \theta_1$), dove i parametri da stimare sono la pendenza m e l'intercetta q. Per trovare il minimo, è necessario risolvere il sistema di equazioni ottenuto annullando le derivate parziali del χ^2:

$$\frac{\partial \chi^2}{\partial m} = 0 \quad \text{e} \quad \frac{\partial \chi^2}{\partial q} = 0$$

Caso 1: Errori uguali o trascurabili

Se gli errori σ_i sono tutti uguali, la funzione da minimizzare è:

$$X^2 = \sum_{i=1}^{N} (y_i - q - mx_i)^2$$

Introducendo i valori medi $\bar{x}, \bar{y}, \overline{x^2}, \overline{xy}$, le soluzioni per i parametri (stimatori) sono:

$$q = \hat{\theta}_1 = \frac{\bar{y} \cdot \overline{x^2} - \bar{x} \cdot \overline{xy}}{\overline{x^2} - \bar{x}^2}$$
$$m = \hat{\theta}_2 = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - \bar{x}^2}$$

Gli errori sui parametri si ricavano dalla legge di propagazione della varianza (assumendo $\sigma_y = \sigma$ costante per tutti i punti):

$$\sigma_q^2 = \sigma^2 \frac{\overline{x^2}}{N(\overline{x^2} - \bar{x}^2)} \quad , \quad \sigma_m^2 = \sigma^2 \frac{1}{N(\overline{x^2} - \bar{x}^2)}$$

Nota: Il termine al denominatore $(\overline{x^2} - \bar{x}^2)$ è la varianza dei valori x_i del campione.

Caso 2: Errori differenti (Fit pesato) Quando ogni misura ha un errore σ_i diverso, la probabilità di ottenere il set di misure osservato è data dal prodotto delle probabilità (Likelihood):

$$P(y_1, \ldots, y_N) \propto \prod_{i=1}^{N} \exp\left(-\frac{(y_i - q - mx_i)^2}{2\sigma_i^2}\right) = \exp\left(-\frac{1}{2}\sum_{i=1}^{N} \frac{(y_i - q - mx_i)^2}{\sigma_i^2}\right)$$

Massimizzare questa probabilità equivale a minimizzare l'esponente, ovvero il χ^2:

$$\chi^2 = \sum_{i=1}^{N} \frac{(y_i - q - mx_i)^2}{\sigma_i^2}$$

Definiamo le seguenti somme pesate per semplificare la notazione:

$$S = \sum \frac{1}{\sigma_i^2}, \quad S_x = \sum \frac{x_i}{\sigma_i^2}, \quad S_y = \sum \frac{y_i}{\sigma_i^2}, \quad S_{xx} = \sum \frac{x_i^2}{\sigma_i^2}, \quad S_{xy} = \sum \frac{x_i y_i}{\sigma_i^2}$$

Definiamo inoltre il determinante del sistema come $\Delta = S \cdot S_{xx} - S_x^2$. Le migliori stime per i parametri sono:

$$q = \frac{S_{xx} \cdot S_y - S_x \cdot S_{xy}}{\Delta} \quad , \quad m = \frac{S \cdot S_{xy} - S_x \cdot S_y}{\Delta}$$

Le varianze dei parametri, ottenute tramite la propagazione degli errori, sono:

$$\sigma_q^2 = \frac{S_{xx}}{\Delta} \quad , \quad \sigma_m^2 = \frac{S}{\Delta}$$

Il valore minimo del χ^2 può essere utilizzato per il *test delle ipotesi* (goodness of fit), per verificare se i dati sono compatibili con l'ipotesi lineare.

3.2 Fit Lineare ($y = mx + q$)

Nel caso di funzione lineare $f(x) = mx + q$ e $\sigma_i = \sigma$ costanti, risolvendo il sistema delle derivate parziali $\frac{\partial \chi^2}{\partial m} = 0$ e $\frac{\partial \chi^2}{\partial q} = 0$, si ottengono le stime analitiche:

Definiamo le somme:

$$S_x = \sum x_i, \quad S_y = \sum y_i, \quad S_{xx} = \sum x_i^2, \quad S_{xy} = \sum x_i y_i$$

$$D = NS_{xx} - (S_x)^2$$

Le stime dei parametri sono:

$$m = \frac{NS_{xy} - S_x S_y}{D}, \qquad q = \frac{S_{xx} S_y - S_x S_{xy}}{D} \tag{6}$$

E gli errori associati (tramite propagazione):

$$\sigma_m = \sqrt{\frac{N\sigma^2}{D}}, \qquad \sigma_q = \sqrt{\frac{\sigma^2 S_{xx}}{D}} \tag{7}$$

Esempio (Fit Lineare)

```python
# Dati simulati: Moto uniforme s = v*t + s0
t = np.array([0, 1, 2, 3, 4, 5])        # Tempo [s]
s = np.array([2, 17, 27, 37, 47, 63])   # Spazio [mm]
sigma_s = 2                             # Incertezza [mm]
N = len(t)

# Calcolo Somme
Sx = np.sum(t); Sy = np.sum(s)
Sxx = np.sum(t**2); Sxy = np.sum(t * s)

# Calcolo Parametri
D = N * Sxx - Sx**2
m = (N * Sxy - Sx * Sy) / D
q = (Sxx * Sy - Sx * Sxy) / D

```

```python
print(f"Velocita' (m): {m:.2f} mm/s")
print(f"Posizione init (q): {q:.2f} mm")

# Plot
plt.errorbar(t, s, yerr=sigma_s, fmt='o', label='Dati')
plt.plot(t, m*t + q, label='Fit Lineare')
plt.xlabel('Tempo [s]'); plt.ylabel('Spazio [mm]')
plt.legend(); plt.show()
```

Listing 2: Fit Lineare dei Minimi Quadrati

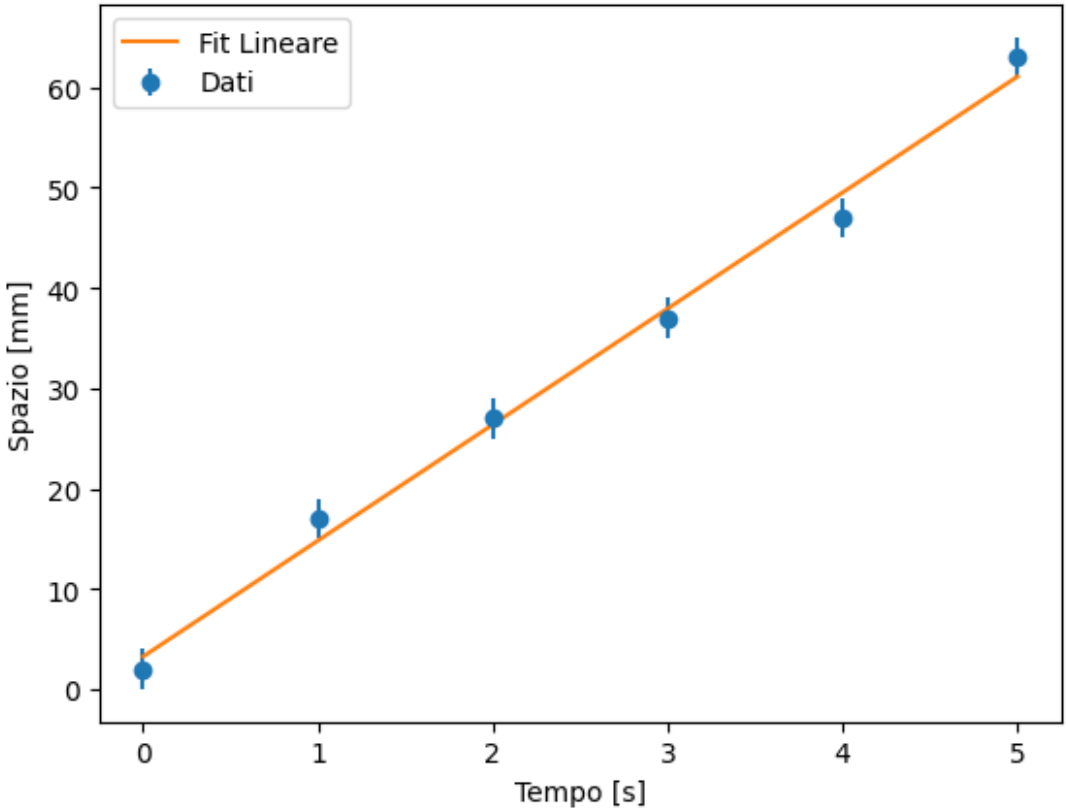

Figura 2: Fit Lineare

3.2.1 Parte di Bressan: Caso non lineare

Se la relazione tra le grandezze non è lineare, spesso è possibile "linearizzare" il problema con un cambio di variabile.

Esempio. *Consideriamo la legge del moto: $s = \frac{1}{2}gt^2$. Supponiamo di voler misurare g trascurando l'incertezza su s e considerando solo l'errore su t. Possiamo riscrivere l'equazione come:*

$$t = \sqrt{\frac{2}{g}}\sqrt{s}$$

Ponendo $y = t$, $x = \sqrt{s}$ e il parametro $m = \sqrt{\frac{2}{g}}$, otteniamo una relazione lineare $y = mx$ (con intercetta nulla).

Una volta stimato m e la sua varianza σ_m^2 con il metodo dei minimi quadrati, ricaviamo g invertendo la relazione: $g = \frac{2}{m^2}$. L'errore su g si ottiene con la propagazione:

$$\sigma_g = \left|\frac{\partial g}{\partial m}\right| \sigma_m = \left|-\frac{4}{m^3}\right| \sigma_m$$

Questo esempio evidenzia l'importanza della scelta delle variabili dipendenti e indipendenti.

Nei casi in cui la linearizzazione non è possibile, si ricorre all'espansione di Taylor del modello attorno a valori iniziali dei parametri o a metodi numerici iterativi.

3.3 Caso Non Lineare e Linearizzazione

se $f(x;p)$ non è lineare spesso si cerca un'espressione linearizzata cambiando variabili.

Esempio: Caduta grave $h = \frac{1}{2}gt^2$ oppure la formula inversa per calcolare g dai tempi:

$$t = \sqrt{\frac{2}{g}}\sqrt{d} + t_0$$

Questa equazione è del tipo $Y = mX + q$ se poniamo:

$$Y = t, \quad X = \sqrt{d}, \quad m = \sqrt{\frac{2}{g}}, \quad q = t_0$$

Una volta calcolato $\hat{m}$ con i minimi quadrati, inverto la relazione per trovare g:

$$\hat{m}^2 = \frac{2}{g} \implies g = \frac{2}{\hat{m}^2}$$

Per l'errore, uso la propagazione:

$$\sigma_g = \left|\frac{\partial g}{\partial m}\right| \sigma_m = \left|-\frac{4}{m^3}\right| \sigma_m$$

Esempio Computazionale (Linearizzazione)

```python
# Dati: Tempo t vs Spazio s
t = np.array([0.16, 0.40, 0.58, 0.72, 0.97])
s = np.array([0.20, 1.0, 2.0, 3.0, 5.0])
rad_s = np.sqrt(s) # Variabile linearizzata X

# ... (Codice per calcolo m e q su t vs rad_s omesso per brevita'...)
# Supponiamo m sia stato calcolato:
m_calc = 0.45
sigma_m = 0.01

# Calcolo fisico
g = 2 / m_calc**2
sigma_g = (4 / m_calc**3) * sigma_m

print(f"g misurato: {g:.2f} +/- {sigma_g:.2f} m/s^2")
```

Listing 3: Linearizzazione per calcolo di g

4 Momenti e Distribuzioni

Lezione del 23 Febbraio 2026

4.1 Momenti della funzione di distribuzione

Il valore di aspettazione e la varianza di una variabile casuale sono due particolari "momenti" della funzione densità di probabilità $f_X(x) \equiv f(x)$.

Possiamo distinguere tra momenti calcolati rispetto all'origine e momenti calcolati rispetto al valore di aspettazione (la media). In entrambi i casi, si tratta di valori di aspettazione (dunque quantità numeriche) delle potenze di x o di $x - \mu_x$. Nello specifico, definiamo:

Definizione: **Momento algebrico di ordine k** (o k-esimo momento algebrico): calcolato rispetto all'origine.

$$\mu_k = E[x^k] = \int_\Omega x^k f(x)dx$$

Osservazioni:

- Per $k = 0 \quad \rightarrow \quad \mu_0 = \int_\Omega f(x)dx = 1$ (Normalizzazione della funzione di probabilità).
- Per $k = 1 \quad \rightarrow \quad \mu_1$ rappresenta il valore di aspettazione o media (il baricentro della distribuzione).

Definizione: **Momenti centrali di ordine k**:

$$\bar{\mu}_k = E[(x-\mu)^k] = \int_\Omega (x-\mu)^k f(x)dx$$

Osservazione:

- Per $k = 0 \quad \rightarrow \quad \bar{\mu}_0 = \displaystyle\int_\Omega f(x)dx = 1.$
- Per $k = 1 \quad \rightarrow \quad \bar{\mu}_1 = 0.$
  Dimostrazione: $\displaystyle\int_\Omega (x-\mu)f(x)dx = \int_\Omega xf(x)dx - \mu\int_\Omega f(x)dx = \mu - \mu \cdot 1 = 0.$
- Per $k = 2 \quad \rightarrow \quad \bar{\mu}_2 = \sigma^2$ (Varianza).
- Per $k = 3 \quad \rightarrow \quad \bar{\mu}_3$ è legato all'*indice di asimmetria* (o *skewness*). Esso indica quanto la distribuzione sia simmetrica rispetto alla media:
  - per una distribuzione simmetrica (es. Gaussiana) $\bar{\mu}_3 = 0$;

Simmetrica ($\bar{\mu}_3 = 0$)

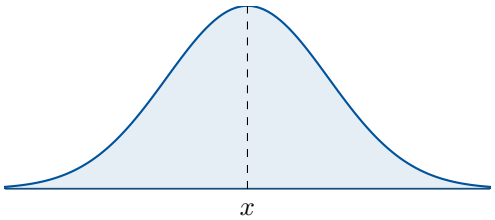

  - per una distribuzione asimmetrica a destra (es. Maxwell-Boltzmann) $\bar{\mu}_3 > 0$;

Asimmetrica a destra ($\bar{\mu}_3 > 0$)

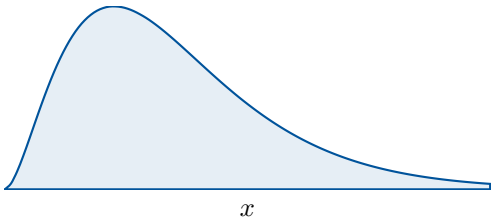

  - per una distribuzione asimmetrica a sinistra $\bar{\mu}_3 < 0$

Asimmetrica a sinistra ($\bar{\mu}_3 < 0$)

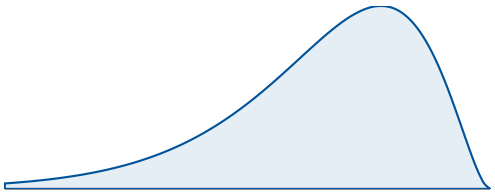

x

- Per $k = 4 \quad \rightarrow \quad \bar{\mu}_4$ è legato all'*indice di curtosi* (o *kurtosis*). Questo parametro valuta il peso delle "code" della distribuzione, ovvero l'influenza dei valori estremi (*outliers*).

4.2 Distribuzione uniforme discreta

Consideriamo una variabile X che può assumere n valori discreti. Se tutti i valori sono equiprobabili, imponendo la condizione di normalizzazione si ottiene che la probabilità per ogni valore è $p = 1/n$. Di conseguenza, il valore medio è:

$$\mu_x = \frac{1}{n}\sum_{i=1}^{n} x_i$$

che corrisponde alla media aritmetica dei possibili valori (analogo al lancio di un dado). La varianza è data da:

$${\sigma_x}^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_x)^2$$

4.3 Distribuzione uniforme continua

Una variabile casuale continua definita nell'intervallo (a, b) possiede una distribuzione uniforme se la sua densità di probabilità è costante, ovvero $f_X(x) = \text{cost}$. Affinché sia soddisfatta la condizione di normalizzazione (l'area sotto la curva deve essere 1), la funzione deve essere:

$$f_X(x) = \frac{1}{b-a}$$

Il valore medio si calcola come:

$$\mu_x = \int_a^b x f(x) dx = \frac{a+b}{2}$$

Per la varianza, sfruttando la proprietà $E[x^2] - E[x]^2$, si ottiene:

$${\sigma_x}^2 = \frac{(b-a)^2}{12}$$

Nota: Collegamento con la trattazione degli errori.
Quando si passa dalla teoria degli errori massimi a quella statistica, il risultato di una misura viene espresso come $x \pm \Delta x$. Questo intervallo corrisponde a una distribuzione uniforme di larghezza $b - a = 2\Delta x$.
Sostituendo nella formula della varianza ricavata sopra ($\sigma_x^2 = \frac{(b-a)^2}{12}$), otteniamo la deviazione standard:

$$\sigma_x = \frac{b-a}{2\sqrt{3}} \quad \Rightarrow \quad \Delta x = \sigma_x\sqrt{3}$$

È interessante calcolare la probabilità che il valore x cada all'interno dell'intervallo di una deviazione standard dalla media ($\mu_x \pm \sigma_x$). Tale probabilità risulta essere:

$$P(\mu_x - \sigma_x < x \leqslant \mu_x + \sigma_x) = \frac{1}{\sqrt{3}} \approx 0.577$$

Dimostrazione:

$$\int_{\mu_x-\sigma_x}^{\mu_x+\sigma_x} f(x)dx = \frac{1}{b-a}\int_{\mu_x-\sigma_x}^{\mu_x+\sigma_x} dx = \frac{1}{b-a}(2\sigma_x) = \frac{2\sigma_x}{2\sigma_x\sqrt{3}} = \frac{1}{\sqrt{3}}$$

L'introduzione dei momenti risulta utile per diversi motivi. Un risultato fondamentale è il seguente: se due variabili casuali X e Y possiedono gli stessi momenti, allora le loro funzioni di distribuzione di probabilità (f_X e f_Y) sono identiche.

Definizione: **Funzione generatrice dei momenti**: La funzione generatrice dei momenti, indicata con $M_x(t)$, è definita come il valore atteso di e^{tx}. La sua espressione varia a seconda che la variabile casuale sia continua o discreta:

$$M_x(t) = E[e^{tx}] = \begin{cases} \displaystyle\int_\Omega e^{tx} f(x)dx & \text{caso continuo} \\ \displaystyle\sum_i p_i e^{tx_i} & \text{caso discreto} \end{cases}$$

Questa funzione è fondamentale perché permette di "generare" i momenti della distribuzione (come media, varianza, ecc.) attraverso l'operazione di derivazione. Calcolando la derivata m-esima rispetto a t e valutandola in $t = 0$, si ottiene il momento m-esimo semplice:

$$\left[\frac{\partial^m M_x}{\partial t^m}\right]_{t=0} = E[x^m] = \mu_m$$

Dimostrazione: Per dimostrare questa proprietà, sviluppiamo e^{tx} in serie di Maclaurin:

$$e^{tx} = \sum_{k=0}^{\infty} \frac{(tx)^k}{k!}$$

Sostituendo questo sviluppo nell'integrale della definizione (assumendo il caso continuo per generalità) e sfruttando la linearità dell'integrale, otteniamo:

$$M_x(t) = \int_\Omega \left(\sum_{k=0}^{\infty} \frac{(tx)^k}{k!}\right) f(x)dx = \sum_{k=0}^{\infty} \frac{t^k}{k!} \int_\Omega x^k f(x)dx$$

Poiché l'integrale $\int_\Omega x^k f(x)dx$ corrisponde esattamente al momento k-esimo μ_k, possiamo scrivere:

$$M_x(t) = \sum_{k=0}^{\infty} \frac{t^k}{k!}\mu_k = \mu_0 + \mu_1 t + \frac{\mu_2 t^2}{2!} + \dots$$

Se calcoliamo la derivata prima rispetto a t:

$$\frac{\partial M_x}{\partial t} = \mu_1 + \frac{2\mu_2 t}{2!} + \dots = \mu_1 + \mu_2 t + \dots$$

Ponendo $t = 0$, tutti i termini con t si annullano, lasciando solo il coefficiente μ_1:

$$\left[\frac{\partial M_x}{\partial t}\right]_{t=0} = \mu_1 = E[x]$$

Definizione: **Funzione generatrice dei momenti centrali**: Analogamente, è possibile definire la funzione che genera i momenti rispetto alla media μ (momenti centrali):

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = \begin{cases} \displaystyle\int_\Omega e^{t(x-\mu)} f(x)dx & \text{caso continuo} \\ \displaystyle\sum_i p_i e^{t(x-\mu_i)} & \text{caso discreto} \end{cases}$$

Anche in questo caso vale la proprietà delle derivate:

$$\left[\frac{\partial^m \bar{M}_x}{\partial t^m}\right]_{t=0} = E[(x-\mu)^m] = \bar{\mu}_m$$

Esiste una relazione diretta tra la funzione generatrice dei momenti semplici e quella dei momenti centrali. Sfruttando le proprietà dell'esponenziale e la linearità del valore atteso, si ha:

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = E[e^{tx}e^{-t\mu}] = e^{-t\mu}E[e^{tx}] = e^{-t\mu}M_x(t)$$

Infine se due variabili casuali X e Y possiedono la stessa funzione generatrice dei momenti ($M_x(t) = M_y(t)$) o la stessa funzione generatrice dei momenti centrali ($\bar{M}_x(t) = \bar{M}_y(t)$), allora le loro distribuzioni di probabilità (f_X e f_Y) sono identiche.

Definizione: **Funzione caratteristica**: Una variante importante è la funzione caratteristica, definita come:

$$\phi(x) = E[e^{itx}] = \int_{\Omega} e^{itx} f(x)dx$$

Questa corrisponde formalmente alla **Trasformata di Fourier** della densità di probabilità.

Consideriamo una variabile aleatoria $Z = X + Y$, somma di due variabili aleatorie **indipendenti** X e Y. La funzione generatrice dei momenti della somma è il prodotto delle singole funzioni generatrici:

$$M_Z(t) = E[e^{tZ}] = E[e^{t(X+Y)}] = E[e^{tX}e^{tY}]$$

Essendo X e Y indipendenti, il valore atteso del prodotto è il prodotto dei valori attesi:

$$M_Z(t) = E[e^{tX}]E[e^{tY}] = M_X(t)M_Y(t)$$

Questo è dovuto al fatto che $\Omega_X \cap \Omega_Y = 0$, dunque vale che $f_{X+Y}(x) = f_X(x)f_Y(x)$

4.4 Approfondimento sulla funzione caratteristica

Quella che noi abbiamo visto come i momenti algebrici e centrali, in realtà sono solo due casi particolari di una famiglia più ampia di momenti, che possono essere generati da funzioni più generali. La funzione caratteristica è un esempio di funzione generatrice dei momenti che utilizza l'esponenziale complesso e^{itx} invece di e^{tx}.
La funzione caratteristica è la trasformata della mia p.d.f (probability density function); essa è ben definita valendo $f_X(x) \in L^2[\mathbb{R}]$

$$\phi(t) = \int_{-\infty}^{\infty} e^{itx} f_X(x)dx = E[e^{itx}]$$

In questo caso vale la stessa dimostrazione attraverso l'espansione dell'esponenziale per mostrare come da questa si possono ricavare i momenti, dove i momenti sono definiti come:

$$E[x^m] = \mu_m = \left[\frac{\partial^m \phi(t)}{\partial(it)^m}\right]_{t=0}$$

La funzione caratteristica è particolarmente utile perché, essendo la trasformata di Fourier della p.d.f., permette di ricavare la distribuzione di probabilità a partire dalla funzione caratteristica stessa tramite la trasformata inversa di Fourier:

$$f_X(x) = \frac{1}{2\pi}\int_{-\infty}^{\infty} e^{-itx}\phi(t)dt$$

Dunque due distribuzioni di probabilità che hanno gli stessi momenti (dunque la stessa funzione caratteristica), sono la stessa distribuzione di probabilità. Questo è dovuto al fatto che la $\mathcal{F}$-trasformata in $L^2[\mathbb{R}]$ rappresenta una biezione tra due spazi.

4.5 Distribuzione binomiale o di Bernoulli

Questa parte è stata integrata con gli appunti di Bressan

La distribuzione binomiale descrive un fenomeno che può verificarsi solo con due modalità mutualmente esclusive: successo (con probabilità p) o insuccesso (con probabilità $q = 1 - p$).

Se ripetiamo l'esperimento n volte, la probabilità di ottenere esattamente k successi è data dalla funzione:

$$P(k; n, p) = \binom{n}{k} p^k q^{n-k} = \frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Casi particolari immediati:

- Probabilità di n successi (tutti): p^n
- Probabilità di 0 successi (nessuno): q^n
- Probabilità di 1 successo: npq^{n-1} (nota: il coefficiente binomiale $\binom{n}{1} = n$)
- Probabilità di $n-1$ successi: $np^{n-1}q$

Esempio. *Consideriamo 3 oggetti ($n = 3$) chiamati A, B, C. Vogliamo sceglierne 2 ($k = 2$). Le possibili combinazioni sono: AB, BC, AC. Calcolando con la formula del coefficiente binomiale otteniamo conferma:*

$$\binom{3}{2} = \frac{3!}{2!(3-2)!} = \frac{3 \cdot 2 \cdot 1}{2 \cdot 1 \cdot 1} = 3$$

4.5.1 Proprietà della distribuzione binomiale

- **Normalizzazione**: La somma di tutte le probabilità è 1. Questo deriva dallo sviluppo del binomio di Newton:

$$\sum_{k=0}^{n} \binom{n}{k} p^k q^{n-k} = (p+q)^n = (1)^n = 1$$

- **Calcolo diretto della media**: Possiamo derivare la media manipolando la sommatoria. Derivando l'identità $(p+q)^n$ rispetto a p:

$$p\frac{\partial}{\partial p}(p+q)^n = p \cdot n(p+q)^{n-1} \quad \xrightarrow{p+q=1} \quad np$$

  Dall'altro lato della sommatoria:

$$p\frac{\partial}{\partial p}\sum_{k=0}^{n} \binom{n}{k} p^k q^{n-k} = \sum_{k=0}^{n} k\binom{n}{k} p^k p^{-1} q^{n-k} \cdot p = \sum_{k=0}^{n} k\binom{n}{k} p^k q^{n-k} = E[k]$$

  Uguagliando i risultati otteniamo il valore atteso: $E[k] = np$.

- **Varianza**: La varianza è data da $\sigma_x^2 = E[x^2] - E[x]^2 = npq$.

4.5.2 Funzione generatrice dei momenti della Binomiale

Calcoliamo il momento generatore per la binomiale:

$$M_k(t) = E[e^{tk}] = \sum_{k=0}^{n} e^{tk}\binom{n}{k} p^k q^{n-k} = \sum_{k=0}^{n} \binom{n}{k} (pe^t)^k q^{n-k}$$

Riconoscendo la forma del binomio di Newton $(a+b)^n$ con $a = pe^t$ e $b = q$, otteniamo:

$$M_k(t) = (pe^t + q)^n$$

Da qui possiamo ricalcolare i momenti derivando rispetto a t:

1. **Valore atteso (Media)**: Calcoliamo la derivata prima:

$$M_k'(t) = n(pe^t + q)^{n-1} \cdot pe^t$$

   Ponendo $t = 0$ (ricordando che $e^0 = 1$ e $p + q = 1$):

$$\mu = M_k'(0) = n(p+q)^{n-1}p = np$$

2. **Varianza**: Calcoliamo la derivata seconda (regola del prodotto):

$$M_k''(t) = n(n-1)(pe^t + q)^{n-2}(pe^t)^2 + n(pe^t + q)^{n-1}pe^t$$

   Ponendo $t = 0$:

$$E[x^2] = M_k''(0) = n(n-1)p^2 + np$$

   Ora calcoliamo la varianza usando $Var(x) = E[x^2] - E[x]^2$:

$$\sigma^2 = [n(n-1)p^2 + np] - (np)^2 = n^2p^2 - np^2 + np - n^2p^2 = np - np^2 = np(1-p) = npq$$

3. **Asimmetria (Terzo momento centrale)**: Il terzo momento centrale è $\bar{\mu_3} = npq(1-2p)$. Questo indice ci dice la forma della distribuzione:
   - Se $\bar{\mu_3} > 0$: distribuzione **asimmetrica positiva** (coda a destra).
   - Se $\bar{\mu_3} = 0$: distribuzione **simmetrica**.
   - Se $\bar{\mu_3} < 0$: distribuzione **asimmetrica negativa** (coda a sinistra).

Limiti della Binomiale: La distribuzione binomiale è estremamente importante in fisica perché, al limite per $n \to \infty$, approssima altre distribuzioni fondamentali:

- Tende alla **distribuzione di Gauss** se p rimane costante.
- Tende alla **distribuzione di Poisson** se il prodotto np rimane costante (ovvero se $p \to 0$ mentre $n \to \infty$).

Applicazione agli istogrammi: Consideriamo un istogramma dove n è il numero totale di eventi e ci focalizziamo su un particolare intervallo (bin) i. Il numero atteso di eventi in quell'intervallo è $E[n_i] = np_i$.

La varianza del numero di eventi nell'intervallo è data dalla binomiale:

$$\sigma_{n_i}^2 = np_i(1-p_i) = n_i(1-p_i) \simeq n_i\left(1-\frac{n_i}{n}\right)$$

Se stimiamo la probabilità p_i tramite i dati misurati come $\hat{p}_i = n_i^{mis}/n$, nel caso in cui la probabilità sia molto piccola ($p \to 0$, regime di Poisson), il termine $(1-p_i) \approx 1$. Di conseguenza, l'errore standard (deviazione standard) sul conteggio di un bin è approssimabile con la radice quadrata del conteggio stesso:

$$\sigma_{n_i} \approx \sqrt{n_i^{mis}}$$

5 Codice python e Distribuizione di Poisson

Lezione del 26 Febbraio 2026

5.1 Esempi Python: La Distribuzione Binomiale

In questo esercizio simuliamo il lancio di una moneta per applicare la distribuzione binomiale. **Problema:** Lanciamo una moneta $n = 10$ volte. Qual è la probabilità di ottenere esattamente $k = 6$ teste?

Poiché una moneta può dare testa o croce, la probabilità di successo (testa) è $p = 0.5$. Utilizzeremo la distribuzione binomiale con i parametri:

- $n = 10$ (numero di lanci)
- $k = 6$ (numero di successi richiesti)
- $p = 0.5$ (probabilità singolo evento)

1. Calcolo Analitico e con Librerie

Possiamo calcolare la probabilità sia implementando la formula matematica, sia utilizzando la libreria `scipy`.

```python
import math
from scipy.stats import binom

# Parametri del problema
k = 6
n = 10
p = 0.5

# METODO 1: Formula matematica
# P = coeff_binomiale * (p^k) * ((1 - p)^(n - k))
coeff_binomiale = math.comb(n, k)
P = coeff_binomiale * (p**k) * ((1 - p)**(n - k))

print(f"Probabilita' (formula): {P}")

# METODO 2: Libreria Scipy
# Esiste una funzione dedicata per ottenere lo stesso risultato
P_scipy = binom.pmf(k, n, p)

print(f"Probabilita' (scipy): {P_scipy}")
```

Listing 4: Calcolo probabilità Binomiale

Il risultato ottenuto è circa 0.205. Questo significa che, se ripetiamo molte volte l'esperimento dei 10 lanci, nel $\approx 20\%$ dei casi otterremo esattamente 6 teste.

2. Simulazione Monte Carlo

Possiamo verificare il risultato teorico simulando l'esperimento più volte. Prima simuliamo un singolo set di 10 lanci, poi ripetiamo l'esperimento 100 volte per contare la frequenza del risultato "6 teste".

```python
import random

# --- Parte A: Singola simulazione di 10 lanci ---
testa = 0
croce = 0
for i in range(10):
    lancio = random.randint(0, 1) # 0 = Testa, 1 = Croce
    if lancio == 0:
        testa += 1
    else:
        croce += 1
print(f"Esito singolo: {testa} Teste e {croce} Croci")

# --- Parte B: Ripetiamo l'esperimento 100 volte ---
```

```python
testa_l = [] # Lista per salvare i risultati di ogni esperimento

for i in range(100): # 100 esperimenti totali
    testa = 0 # Azzero il contatore per il nuovo esperimento
    for j in range(10): # Ogni esperimento consiste in 10 lanci
        lancio = random.randint(0, 1)
        if lancio == 0:
            testa += 1
    # Fine dei 10 lanci, salvo il risultato
    testa_l.append(testa)

# Contiamo quante volte e' uscito esattamente 6
risultato = testa_l.count(6)
print(f"Su 100 esperimenti, ho ottenuto 6 teste {risultato} volte")
```

Listing 5: Simulazione dei lanci

5.1.1 Parte di Bressan: Distribuzione di Poisson

La distribuzione di Poisson è un caso limite fondamentale, spesso utilizzato in fisica nucleare, e serve per indicare la probabilità di osservare k eventi in un determinato intervallo di tempo t, basandosi su tre ipotesi principali:

- **Indipendenza:** la presenza o assenza di un evento non dipende da ciò che è accaduto prima del tempo t (processo senza memoria).
- **Proporzionalità:** la probabilità che accada un evento in un intervallo infinitesimo dt è proporzionale all'ampiezza dell'intervallo stesso.
- **Non simultaneità:** la probabilità di avere due eventi contemporaneamente in un intervallo infinitesimo è nulla.

Si tratta del caso limite della distribuzione binomiale in cui la probabilità di successo p è molto piccola e il numero di prove $n \to \infty$. La formula generale è:

$$P_k(t) = \frac{(\mu t)^k}{k!} e^{-\mu t}$$

dove μ rappresenta il tasso medio di eventi per unità di tempo.

Derivazione della formula

1. Probabilità di 0 eventi:
Consideriamo la probabilità di non avere eventi nell'intervallo $(0, t + dt)$. Questo richiede che non ci siano eventi fino a t e che non se ne verifichino nell'intervallo successivo dt:

$$P_0(t + dt) = P_0(t)(1 - \mu dt)$$

Qui abbiamo imposto che la probabilità di avere un evento in dt sia μdt (e quindi di non averne è $1 - \mu dt$, trascurando termini di ordine superiore). Riorganizzando i termini e passando al limite per $dt \to 0$:

$$\frac{P_0(t + dt) - P_0(t)}{dt} = -\mu P_0(t) \quad \Rightarrow \quad \frac{dP_0}{dt} = -\mu P_0(t)$$

Imponendo la condizione iniziale $P_0(0) = 1$, la soluzione è:

$$P_0(t) = e^{-\mu t}$$

2. Probabilità di k eventi:
La probabilità di avere 1 evento al tempo $t + dt$ è data dalla somma di due possibilità: avere 1 evento a t e nessuno in dt, oppure avere 0 eventi a t e uno in dt:

$$P_1(t + dt) = P_1(t)(1 - \mu dt) + P_0(t)(\mu dt)$$

Che porta all'equazione differenziale:

$$\frac{dP_1}{dt} = -\mu(P_1(t) - P_0(t))$$

Procedendo in maniera ricorsiva, si trova che la probabilità di avere m eventi varia secondo:

$$\frac{dP_m}{dt} = -\mu(P_m(t) - P_{m-1}(t))$$

La soluzione generale di questo sistema è:

$$P_k(t) = \frac{(\mu t)^k}{k!} e^{-\mu t} = \frac{m^k}{k!} e^{-m}$$

dove abbiamo posto $m = \mu t = E[k]$, che rappresenta il valore di aspettazione (il numero medio) di eventi nell'intervallo t.

Proprietà della distribuzione

La distribuzione di Poisson è correttamente normalizzata. Infatti, ricordando lo sviluppo di Taylor dell'esponenziale:

$$\sum_{k=0}^{\infty} P_k = e^{-m} \sum_{k=0}^{\infty} \frac{m^k}{k!} = e^{-m} \cdot e^{m} = 1$$

Il valore di aspettazione è:

$$E[k] = \sum_{k=0}^{\infty} k P_k = m$$

E la varianza coincide con la media:

$$\sigma^2 = E[k^2] - E[k]^2 = m$$

Si nota dunque che la distribuzione di Poisson non è altro che il limite per $n \to \infty$ della distribuzione di Bernoulli (Binomiale).

5.2 Confronto: Poisson vs Binomiale

La distribuzione **Binomiale** descrive casi in cui un risultato particolare si ottiene in un numero preciso e finito di tentativi (n).

La distribuzione di **Poisson**, invece, si usa per descrivere casi in cui si contano eventi rari in un continuo (tempo o spazio), dove non si ha un'idea precisa del numero di tentativi totali, né ha senso parlare di casi "sfavorevoli" nel senso classico.

Esempi:

- Il numero di fulmini durante un temporale: sarà un numero intero, ma non ha senso parlare di "non-fulmini" (non esiste un non-evento osservabile come nel caso "Testa o Croce").

In questi processi si vuole stimare la probabilità k di eventi, noto il numero medio λ (o μ) di eventi che generalmente si presentano. Il processo non ha memoria: un evento verificatosi non influenza la probabilità dei successivi.

Dimostrazione del limite

Matematicamente, la Poisson si ottiene dalla Binomiale attraverso i limiti:

$$n \to \infty \quad \text{e} \quad p \to 0$$

in modo tale che il loro prodotto $\lambda = np$ rimanga costante ($\lambda = \text{cost}$).

Supponiamo di attenderci λ eventi in un certo intervallo di tempo Δt. Dividiamo questo intervallo in n sotto-intervalli $\Delta t'$ molto piccoli ($n \to \infty$), talmente piccoli che la probabilità che due eventi cadano nello stesso sia trascurabile (al massimo un evento per intervallo). La probabilità che un evento si verifichi in un singolo $\Delta t'$ è:

$$p = \frac{\lambda}{n}$$

La probabilità di trovare k eventi negli n intervallini è data dalla distribuzione Binomiale con $p = \lambda/n$:

$$P\left(k; n, \frac{\lambda}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k} = \frac{n!}{k!(n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

Riorganizziamo i termini per calcolare il limite:

$$P\left(k; n, \frac{\lambda}{n}\right) = \frac{\lambda^k}{k!} \cdot \underbrace{\frac{n!}{(n-k)!\, n^k}}_{(A)} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{n-k}}_{(B)}$$

1. Il termine fattoriale (A):

$$\frac{n!}{(n-k)!} = n \cdot (n-1) \cdot (n-2) \cdots (n-k+1)$$

Ci sono esattamente k termini al numeratore. Per $n \to \infty$, possiamo trascurare le sottrazioni rispetto a n (es. $n-1 \approx n$). Quindi:

$$\lim_{n\to\infty} \frac{n!}{(n-k)!} \approx \underbrace{n \cdot n \cdots n}_{k \text{ volte}} = n^k$$

(Esempio con $k=5$: $\frac{n(n-1)(n-2)(n-3)(n-4)}{1} \to n^5$). Di conseguenza, il rapporto tende a 1:

$$\lim_{n\to\infty} \frac{n!}{(n-k)!\, n^k} = \frac{n^k}{n^k} = 1$$

2. Il termine esponenziale (B): Scriviamo il termine $\left(1-\frac{\lambda}{n}\right)^{n-k}$ come prodotto di due fattori:

$$\left(1-\frac{\lambda}{n}\right)^n \cdot \left(1-\frac{\lambda}{n}\right)^{-k}$$

Per $n \to \infty$, il secondo fattore tende a $(1-0)^{-k} = 1$. Il primo fattore è un limite notevole dell'analisi matematica:

$$\lim_{n\to\infty} \left(1+\frac{x}{n}\right)^n = e^x \implies \lim_{n\to\infty} \left(1-\frac{\lambda}{n}\right)^n = e^{-\lambda}$$

Sostituendo i limiti calcolati ($n \to \infty, p \to 0, np = \lambda$) nell'espressione della binomiale, otteniamo la forma chiusa della distribuzione. La probabilità di ottenere k eventi, dato un numero medio di eventi attesi λ, è:

$$\boxed{P(k;\lambda) = \frac{e^{-\lambda}\lambda^k}{k!} \quad \text{con } 0 \leqslant k < \infty} \tag{8}$$

Condizioni di validità: Il modello è valido per eventi rari in un continuo, dove il numero di prove tende all'infinito. Un esempio classico è il **decadimento radioattivo**, in quanto il numero di decadimenti nucleari in un intervallo di tempo è discreto e casuale, ma con un tasso medio ben definito.

5.3 Calcolo dei Momenti tramite la Funzione Generatrice dei Momenti

Per calcolare valore atteso e varianza in modo elegante, utilizziamo la **Funzione Generatrice dei Momenti**, definita come il valore atteso di e^{tk}:

$$M_k(t) = E[e^{tk}] = \sum_{k=0}^{+\infty} e^{tk} P(k;\lambda) = \sum_{k=0}^{+\infty} e^{tk} \frac{e^{-\lambda}\lambda^k}{k!}$$

Portiamo fuori dalla sommatoria i termini costanti rispetto a k (il termine $e^{-\lambda}$) e accorpiamo le potenze di k:

$$M_k(t) = e^{-\lambda} \sum_{k=0}^{+\infty} \frac{(e^t\lambda)^k}{k!}$$

Riconosciamo nella sommatoria lo sviluppo in serie di Taylor dell'esponenziale $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}$, dove in questo caso l'argomento è $x = \lambda e^t$.

$$M_k(t) = e^{-\lambda} \cdot e^{(\lambda e^t)} = e^{\lambda e^t - \lambda}$$

Possiamo quindi scrivere la forma finale della Funzione Generatrice dei Momenti per la Poissoniana:

$$\boxed{M_k(t) = e^{\lambda(e^t-1)}} \tag{9}$$

5.3.1 Calcolo di Media e Varianza

Dalle proprietà della Funzione Generatrice dei Momenti sappiamo che la derivata prima valutata in $t=0$ fornisce la media, mentre la derivata seconda fornisce il momento secondo.

1. Media (Valore Atteso): Deriviamo $M_k(t)$ rispetto a t:

$$\frac{\partial M_k}{\partial t} = \frac{\partial}{\partial t}\left(e^{\lambda(e^t-1)}\right) = e^{\lambda(e^t-1)} \cdot \frac{\partial}{\partial t}(\lambda e^t - \lambda) = e^{\lambda(e^t-1)} \cdot \lambda e^t$$

Valutiamo in $t = 0$:

$$E[k] = \left[\frac{\partial M_k}{\partial t}\right]_{t=0} = e^{\lambda(1-1)} \cdot \lambda \cdot 1 = 1 \cdot \lambda = \lambda$$

Risultato: $\mu = \lambda$. Questo conferma che il parametro λ rappresenta il numero medio di eventi.

2. Varianza: Per la varianza usiamo la relazione $\mathrm{Var}(k) = E[k^2] - (E[k])^2$. Calcoliamo la derivata seconda (derivata del prodotto $f(t) \cdot g(t)$ dove f è l'esponenziale composto e g è λe^t):

$$\frac{\partial^2 M_k}{\partial t^2} = \frac{\partial}{\partial t}\left(\underbrace{e^{\lambda(e^t-1)}}_{f(t)} \cdot \underbrace{\lambda e^t}_{g(t)}\right)$$

$$= \underbrace{e^{\lambda(e^t-1)}\lambda e^t}_{f'(t)} \cdot \lambda e^t + \underbrace{e^{\lambda(e^t-1)}}_{f(t)} \cdot \underbrace{\lambda e^t}_{g'(t)}$$

Raccogliendo i termini:

$$\frac{\partial^2 M_k}{\partial t^2} = e^{\lambda(e^t-1)}(\lambda^2 e^{2t} + \lambda e^t)$$

Valutando in $t = 0$:

$$E[k^2] = 1 \cdot (\lambda^2 + \lambda) = \lambda^2 + \lambda$$

Ora calcoliamo la varianza sottraendo il quadrato della media:

$$\mathrm{Var}(k) = (\lambda^2 + \lambda) - (\lambda)^2 = \lambda$$

Conclusione: Per la distribuzione di Poisson, media e varianza coincidono.

$$\boxed{\mu = \lambda, \quad \sigma^2 = \lambda} \tag{10}$$

5.4 Relazione con la Binomiale e Somma di Variabili

5.4.1 Limite della Funzione Generatrice dei Momenti Binomiale

Si può dimostrare formalmente che la Funzione Generatrice della Binomiale tende a quella della Poissoniana. La Funzione Generatrice dei Momenti della Binomiale è $M_{bin}(t) = (pe^t + 1 - p)^n = [1 + p(e^t - 1)]^n$. Sostituendo $p = \lambda/n$:

$$M_{bin}(t) = \left[1 + \frac{\lambda(e^t - 1)}{n}\right]^n$$

Utilizzando il limite notevole $\lim_{n\to\infty}(1 + \frac{a}{n})^n = e^a$ con $a = \lambda(e^t - 1)$, otteniamo:

$$\lim_{n\to\infty} M_{bin}(t) = e^{\lambda(e^t-1)}$$

Che è esattamente la Funzione Generatrice dei Momenti della Poissoniana derivata in precedenza.

5.4.2 Confronto delle forme (Code della distribuzione)

- **Varianza:** La varianza della Poissoniana è $\lambda = np$. La varianza della Binomiale è $np(1-p)$. Poiché $(1-p) < 1$, la varianza binomiale è sempre minore di quella Poissoniana equivalente.
- **Code:** La distribuzione binomiale è limitata superiormente ($k \leqslant n$). La Poissoniana non ha limite superiore ($0 \leqslant k < \infty$). Questo, unito alla varianza maggiore, implica che la Poissoniana ha **code più lunghe**: è relativamente più probabile osservare valori lontani dalla media rispetto a una binomiale, specialmente quando la media è piccola.

5.4.3 Somma di Poissoniane Indipendenti

Se abbiamo due processi Poissoniani indipendenti A e B con medie λ_a e λ_b, la variabile somma $k = k_a + k_b$ segue ancora una distribuzione di Poisson con media $\lambda_{tot} = \lambda_a + \lambda_b$.

Dimostrazione: La Funzione Generatrice dei Momenti della somma di variabili indipendenti è il prodotto delle Funzione Generatrice dei Momenti.

$$M_{tot}(t) = M_a(t) \cdot M_b(t) = e^{\lambda_a(e^t-1)} \cdot e^{\lambda_b(e^t-1)} = e^{(\lambda_a+\lambda_b)(e^t-1)}$$

Questa forma corrisponde a una Poissoniana con parametro $\lambda_a + \lambda_b$. *Esempio fisico:* Un contatore Geiger che rileva radiazioni da due sorgenti diverse non distinguibili; il conteggio totale sarà ancora Poissoniano.

5.5 Esempi Python: Grafici e Confronti

Di seguito riportiamo il codice per visualizzare le distribuzioni e verificare numericamente le proprietà discusse.

5.5.1 1. Visualizzazione della Distribuzione Binomiale

Questo script mostra come varia la forma della distribuzione binomiale al variare di n (numero di prove) e p (probabilità).

```python
import math
from matplotlib import pyplot as plt
import numpy as np

def binomiale_manual(k, n, p):
    return math.comb(n, k) * (p**k) * ((1 - p)**(n - k))

# Creiamo una matrice di grafici 2x2 per vedere diversi n
fig, axes = plt.subplots(2, 2, figsize=(8, 6))
axes = axes.flatten()

n_list = [5, 15, 30, 50]
p = 0.5

for ax, n in zip(axes, n_list):
    k_values = range(n + 1)
    P_binom = [binomiale_manual(k, n, p) for k in k_values]
    ax.bar(k_values, P_binom)

    # Linee per media e deviazione standard
    mu = n * p
    sigma = np.sqrt(n * p * (1 - p))

    ax.axvline(mu, linestyle="--", color="orange", label=f"$\mu$={mu:.1f}")
    y_lvl = max(P_binom)/2
    ax.plot([mu-sigma, mu+sigma], [y_lvl, y_lvl], color="red", label=f"$\sigma$={sigma:.1f}")

    ax.set_title(f"n={n}, p={p}")
    ax.legend()
    ax.grid(True)

plt.tight_layout()
plt.show()
```

Listing 6: Plot della Binomiale al variare di n e p

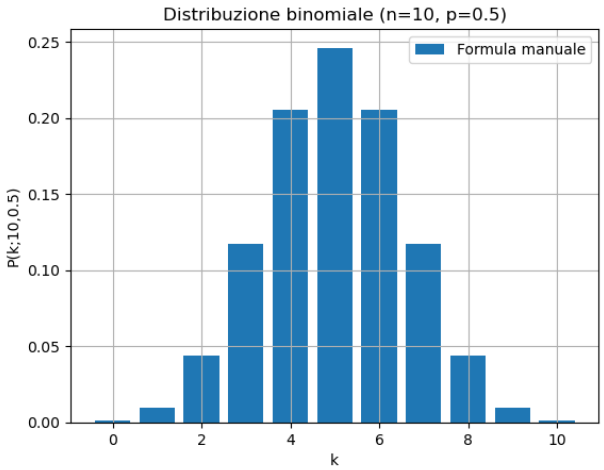

(a)

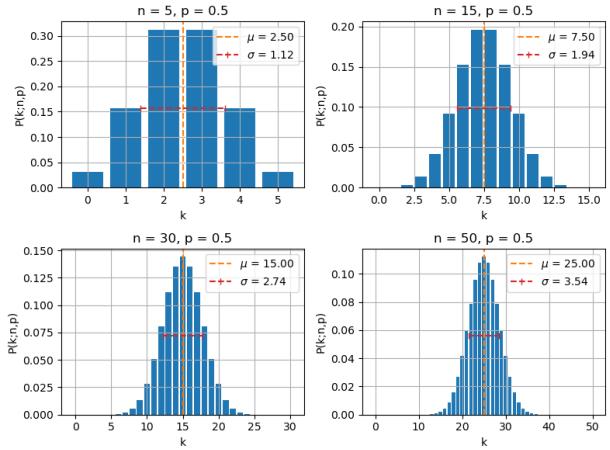

(b)

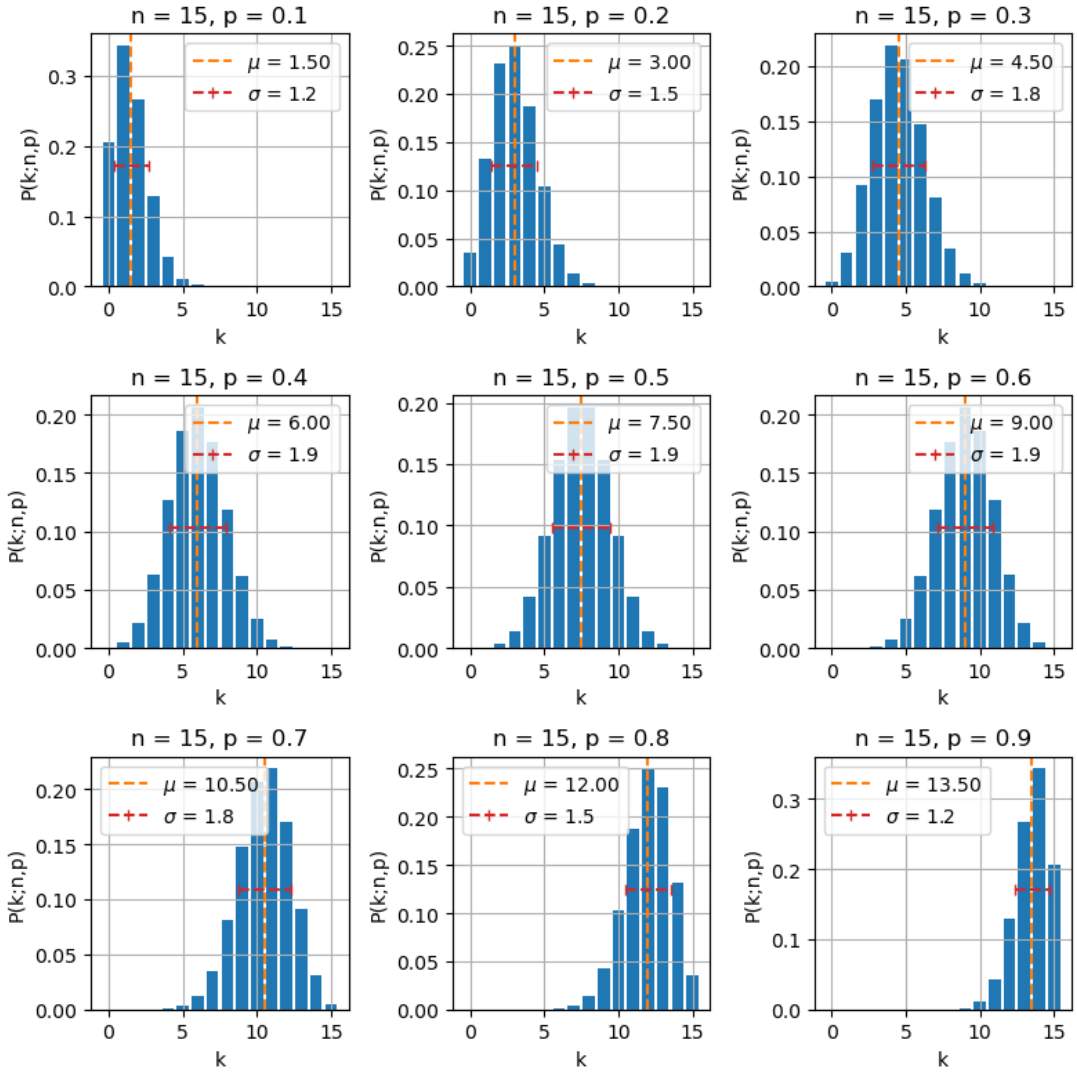

(c)

Figura 3: Distribuzioni Binomiale

5.5.2 2. Esercizio Poisson: La notte di San Lorenzo

Problema: Se ci si aspetta di osservare 15.7 stelle cadenti all'ora, qual è la probabilità di osservarne meno di 5 in 30 minuti?

```python
from scipy.stats import binom, poisson
import math
import matplotlib.pyplot as plt

# --- PARTE 1: Calcolo Probabilita' ---
frequenza_h = 15.7
frequenza_30min = 15.7 / 2  # Il nostro lambda per 30 min

somma_prob = 0
print("Probabilita' di osservare k stelle in 30 min:")
for k in range(5): # k da 0 a 4
    prob = poisson.pmf(k, frequenza_30min)
    print(f"k={k}: {prob*100:.2f}%")
    somma_prob += prob

print(f"Probabilita' totale (< 5 stelle): {somma_prob*100:.2f}%")


# --- PARTE 2: Confronto Grafico Binomiale vs Poisson ---
# Mostriamo che per n grande e p piccolo le due coincidono

def confronto_binom_poiss(p, n_list):
    fig, axes = plt.subplots(2, 2, figsize=(8, 6))
    axes = axes.flatten()

    for ax, n in zip(axes, n_list):
        l = n * p # Lambda fissato da n*p
        n = int(n)

        # Definiamo il range di k interessante (attorno alla media)
        sigma = math.sqrt(l)
        k_max = int(l + 4*sigma)
        k_values = range(k_max)

        # Calcolo con librerie (piu' stabile per n grandi)
        P_binom = binom.pmf(k_values, n, p)
        P_poiss = poisson.pmf(k_values, l)

        ax.plot(k_values, P_poiss, "o", label="Poisson")
        ax.plot(k_values, P_binom, "x", label="Binomiale", alpha=0.7)
        ax.set_title(f"n={n}, p={p}, $\lambda$={l:.1f}")
        ax.legend()
        ax.grid(True)

    plt.tight_layout()
    plt.show()

# Eseguiamo il confronto al limite
# Caso limite: p molto piccolo, n molto grande
confronto_binom_poiss(p=0.01, n_list=[100, 1000, 5000, 10000])
```

Listing 7: Calcolo Poisson e confronto con Binomiale

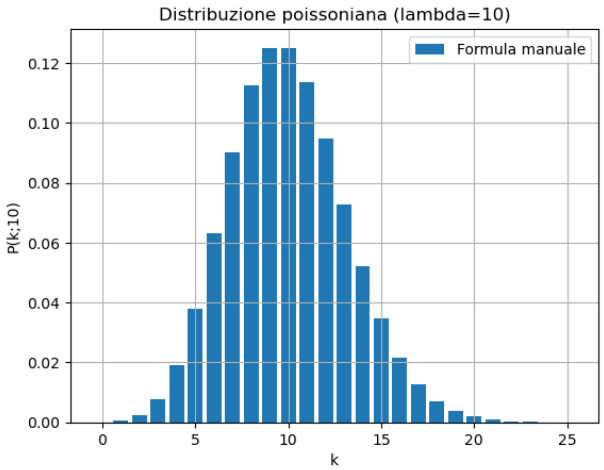

(a)

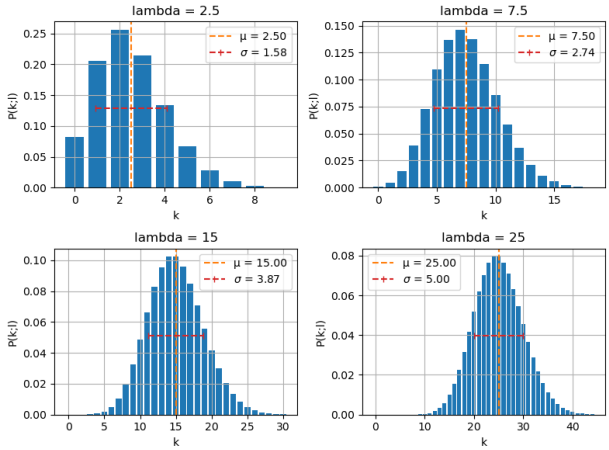

(b)

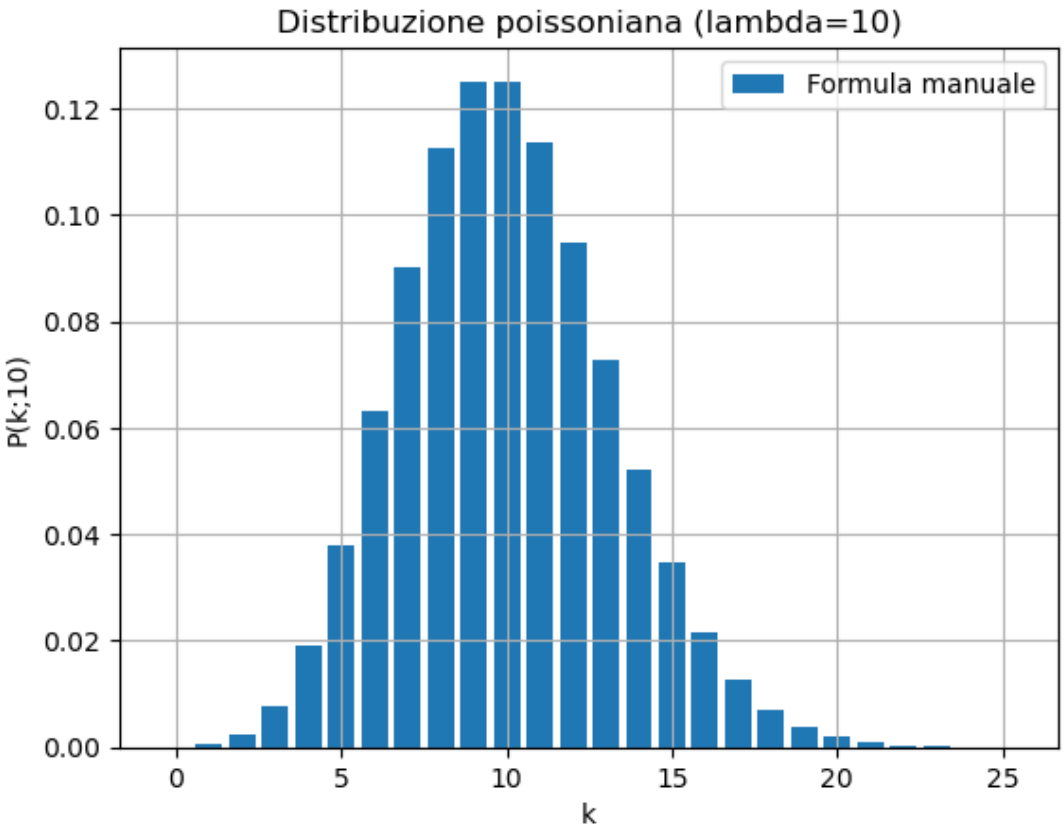

(c)

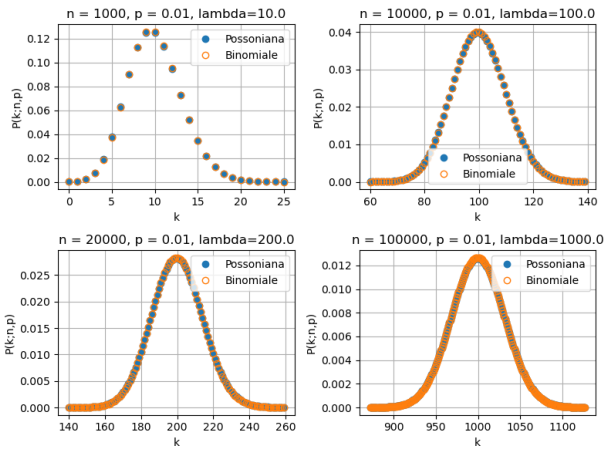

(d)

Figura 4: Distribuzioni di Poisson e nel limite e confronto binomiale/poissoniana

5.6 Rappresentazione grafica dei dati (Istogrammi)

Consideriamo un esperimento volto a misurare una grandezza fisica continua X. Il modello teorico che descrive il fenomeno fornisce una densità di probabilità $P(x)$, tale che:

$$\int_{-\infty}^{+\infty} P(x)\,dx = 1 \tag{11}$$

Si effettuano N misure indipendenti di X, ottenendo un campione di dati $\{x_1, x_2, \ldots, x_N\}$. Questi dati vengono rappresentati graficamente tramite un istogramma, suddividendo l'asse delle x in intervalli adiacenti chiamati *bin*. Considerando un generico bin i, definito nell'intervallo $[x_i, x_{i+1}]$, il numero di eventi M_i che cadono in tale intervallo è una variabile aleatoria discreta. La probabilità teorica che una singola misura cada nel bin i è data da:

$$P_i = \int_{x_i}^{x_{i+1}} P(x)\,dx \approx P\left(x_i + \frac{\Delta x}{2}\right)\Delta x \tag{12}$$

dove si assume che il bin sia sufficientemente stretto (Δx) da poter considerare $P(x)$ costante al suo interno, approssimandola con il valore nel punto centrale.

La variabile M_i segue una statistica binomiale, poiché per ogni singola misura si verificano due sole possibilità: il conteggio cade nel bin i (successo) oppure no (insuccesso). Il valore di aspettazione di M_i è $\langle M_i \rangle = NP_i$, mentre la varianza è $V_i = NP_i(1 - P_i)$. Al limite, per P_i piccolo e N grande, la distribuzione degli eventi tende a una Poissoniana. In questo caso, il valore di aspettazione è semplicemente M_i e la deviazione standard è stimata come $\sigma = \sqrt{M_i}$. Per questo motivo, quando si rappresenta un istogramma, si aggiungono spesso delle barre di errore verticali che rappresentano la deviazione standard $\sqrt{M_i}$.

È fondamentale sottolineare che l'istogramma non è una distribuzione di probabilità continua, ma una stima basata su un numero finito di eventi. Il fatto che la fluttuazione dei conteggi nei bin segua una statistica binomiale (o approssimativamente Poissoniana) riguarda il processo di misura e campionamento, ed è concettualmente distinto dalla forma funzionale $P(x)$ del processo fisico sottostante.

Se P_i fosse nota a priori, per un confronto visivo con l'istogramma si potrebbe graficare la curva teorica sopra i dati. Tuttavia, è necessario scalare opportunamente la funzione, poiché l'istogramma riporta il numero di conteggi $M_i \approx P(x_{\text{centro}})\Delta x N$.

> ***Nota:***
>
> 1. *L'approssimazione binomiale e Poissoniana per i conteggi nei bin è valida propriamente se N non è fissato a priori, ma è esso stesso una variabile aleatoria (ad esempio, se si acquisiscono conteggi per un intervallo di tempo fissato, il numero totale N di eventi varierà da esperimento a esperimento). Se invece N è fissato rigorosamente (si decide di acquisire esattamente un certo numero di eventi totali), la distribuzione congiunta dei conteggi nei vari bin segue una distribuzione* ***multinomiale****.*
>
> 2. *Qualunque confronto tra l'istogramma e la curva teorica $P(x)$ basato sulla sovrapposizione grafica è puramente qualitativo. Esistono metodi statistici quantitativi (test di bontà del fit) per valutare la compatibilità, che verranno trattati in seguito.*

Esempio. *Se abbiamo una generazione causale di numeri che segue una distribuzione uniforme: $U(0,1)$, allora avrò:*

$$P_i = \int_{x_i}^{x_{i+1}} 1\,dx = \Delta x$$

poichè la distribuzione è fatta così

$$U(0,1) = \begin{cases} \textit{cost.} & \textit{se } x \in \textit{(0,1)} \\ 0 & \textit{altrimenti} \end{cases}$$

poichè deve essere normalizzata deve essere cost. $= 1$

6 Funzione di distribuzione di Gauss

Lezione del 02 Marzo 2026

6.0.1 Parte di Bressan: Distribuzione Normale

Data una variabile casuale x, la funzione di densità di probabilità normale è definita come:

$$f(x) = N(\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Quarck!

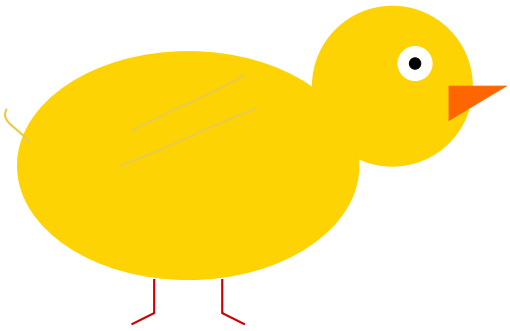

Questa funzione rispetta le proprietà fondamentali delle distribuzioni di probabilità:

- **Normalizzazione:**
$$\frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx = 1$$
- **Valore di aspettazione:** corrisponde a μ
$$E[x] = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} x\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx = \mu$$
- **Varianza:** vale σ^2
$$\mathrm{Var}(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} (x-\mu)^2\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx = \sigma^2$$

Per centrare la distribuzione in 0, si applica la sostituzione $y = x - \mu$ (con $dy = dx$), ottenendo:

$$f(y; 0, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{y^2}{2\sigma^2}}$$

Per standardizzarla (centrata in 0 e con varianza $\sigma^2 = 1$), si pone $y = \frac{x-\mu}{\sigma}$ (con $dy = \frac{dx}{\sigma}$), ottenendo la **distribuzione normale standard**:

$$f(y; 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

È interessante notare che, per la distribuzione standard, la funzione di ripartizione $F(x)$ gode della proprietà di simmetria:

$$F(-x) = 1 - F(x)$$

Se vogliamo calcolare la probabilità che x cada in un intervallo $[a, b]$:

$$P(a \leqslant x \leqslant b) = P(x \leqslant b) - P(x \leqslant a) = F(b) - F(a)$$

Passando alla variabile standardizzata $z = \frac{x-\mu}{\sigma}$:

$$P\left(\frac{a-\mu}{\sigma} \leqslant \frac{x-\mu}{\sigma} \leqslant \frac{b-\mu}{\sigma}\right) = F\left(\frac{b-\mu}{\sigma}\right) - F\left(\frac{a-\mu}{\sigma}\right)$$

Scegliendo intervalli simmetrici rispetto alla media, ovvero $a = \mu - n\sigma$ e $b = \mu + n\sigma$:

$$P(\mu - n\sigma \leqslant x \leqslant \mu + n\sigma) = F(n) - F(-n) = F(n) - [1 - F(n)] = 2F(n) - 1$$

Si può concludere che è molto improbabile (o "anormale") trovare valori molto distanti dalla media. Ad esempio, per $n = 3$, la probabilità di cadere all'interno dell'intervallo è circa 0.997 (o 99.7%).

Graficamente:

- Il picco della campana si trova in $x = \mu$.
- L'altezza del picco è $f(\mu) = \frac{1}{\sqrt{2\pi}\sigma} \approx \frac{0.399}{\sigma}$.
- Il valore a metà altezza (FWHM) corrisponde a una larghezza di $2\sqrt{2\ln(2)}\sigma \approx 2.355\sigma$.

6.0.2 Esempio di distribuzione di Gauss

Consideriamo un esempio basato sulla distribuzione binomiale per modellare gli errori di misura. Assumiamo le seguenti ipotesi:

- L'errore di misura è definito come $u = x - a$ (dove x è il valore misurato e a è il valore vero).
- L'errore totale è la somma di n contributi elementari (errori piccoli), ciascuno di valore ε.

Ogni contributo ε può essere positivo o negativo con probabilità 50/50 (analogia con il cammino casuale). Se indichiamo con k il numero di contributi positivi, allora $(n-k)$ saranno i contributi negativi. L'errore totale sarà:

$$u_k = k\varepsilon - (n-k)\varepsilon = (2k-n)\varepsilon$$

Il valore di aspettazione è $E[u_k] = 0$. Per il teorema del limite centrale, quando $n \to \infty$, la distribuzione di questi errori tende a una gaussiana centrata in 0.

6.0.3 Dimostrazione Euristica

Vogliamo giustificare euristicamente perché la distribuzione degli errori accidentali è gaussiana. Come visto sopra, se abbiamo k deviazioni positive su n totali, l'errore e la sua probabilità (data dalla binomiale) sono:

$$u_k = (2k-n)\varepsilon \qquad P(k) = \frac{n!}{k!(n-k)!}\left(\frac{1}{2}\right)^n$$

Considerando due valori successivi k e $k+1$, possiamo definire un valore medio per l'errore e l'incremento:

$$u^M \approx (2k-n+1)\varepsilon \qquad \Delta u = u_{k+1} - u_k = 2\varepsilon$$

Per $\Delta u \to 0$ (cioè ε molto piccolo e n grande), possiamo passare al continuo. La **densità di probabilità** $y(u)$ può essere approssimata considerando la variazione di probabilità. Definiamo la variazione relativa della probabilità:

$$\frac{\Delta P}{P} \approx \frac{P(k+1) - P(k)}{P(k)}$$

Svolgendo i calcoli con i fattoriali, si trova che questa variazione è legata all'errore u da una relazione del tipo:

$$\frac{dy}{y} = -\frac{u}{\sigma^2}\,du$$

dove $\sigma^2 \propto n\varepsilon^2$. Questa è un'equazione differenziale la cui soluzione è:

$$\ln y = -\frac{u^2}{2\sigma^2} + C \implies y(u) = Ae^{-\frac{u^2}{2\sigma^2}}$$

Imponendo la normalizzazione, si ottiene la forma gaussiana:

$$y(u) = \frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{u^2}{2\sigma^2}}$$

Breve riassunto

- Definizione di variabile casuale discreta e continua.
- Definizione di funzione di ripartizione $F_x(x)$.
- Definizione di funzione di distribuzione (densità di probabilità).
- Valori di aspettazione come indici di posizione (media) e dispersione (varianza).
- Esempi di funzioni di distribuzione (Binomiale, Poisson, Gaussiana).

6.1 Definizione di distribuzione normale

La funzione di distribuzione di Gauss, o distribuzione normale, è descritta dalla seguente funzione (Gauss la utilizzò per descrivere gli errori di misura, notando che molti fenomeni naturali tendono a distribuirsi attorno a un valore medio):

$$P(x;\mu,\sigma) = N(\mu,\sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \tag{13}$$

dove il simbolo N indica che si tratta di una distribuzione normale. Graficamente ha la forma di una campana simmetrica centrata in $x = \mu$. La larghezza della curva è determinata dal parametro σ, che rappresenta la deviazione standard della distribuzione (mentre μ rappresenta il valore atteso): se σ è grande, la distribuzione risulta molto allargata; viceversa, se σ è piccolo, la distribuzione è stretta. Variare μ equivale a traslare la distribuzione lungo l'asse x senza alterarne la forma, mentre variare σ modifica l'ampiezza della curva senza cambiarne il centro.

Nel caso specifico in cui $\mu = 0$ e $\sigma^2 = 1$, si parla di **distribuzione normale standard**, indicata con $N(0,1)$:

$$N(0,1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \tag{14}$$

È importante notare che, attraverso il cambiamento di variabile $z = \frac{x-\mu}{\sigma}$, una qualsiasi gaussiana può essere ridotta alla forma normale standard in funzione di z:

$$P_z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \tag{15}$$

Da un punto di vista pratico, questa proprietà è molto utile per i calcoli: se x è una variabile con distribuzione $N(\mu,\sigma^2)$ e z ha una densità di probabilità $N(0,1)$, possiamo passare da z a x utilizzando la formula di trasformazione:

$$z = \frac{x-\mu}{\sigma} \tag{16}$$

Utilizzando la formula inversa, possiamo ricavare x noto z:

$$z\sigma = x - \mu \implies x = \mu + z\sigma \tag{17}$$

> ***Nota:*** *[Note sul Cambio di Variabile] Quando si effettua un cambio di variabile, la condizione di normalizzazione della probabilità deve essere preservata:*
>
> $$\int_{-\infty}^{+\infty} P_z(z)\,dz = \int_{-\infty}^{+\infty} P_x(x)\,dx = 1$$
>
> *La relazione tra le densità di probabilità è data da:*
>
> $$P_z(z) = P_x[x(z)] \left|\frac{dx}{dz}\right|$$
>
> *Dato che $x(z) = \mu + z\sigma$, la derivata risulta $\frac{dx}{dz} = \sigma$. Sostituendo nella formula precedente si ottiene:*
>
> $$P_z(z) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$
>
> *che conferma il passaggio alla forma standard.*

6.2 Calcolo del Valore di Aspettazione e della Varianza

Come per le altre distribuzioni, possiamo utilizzare la funzione generatrice dei momenti per calcolare il valore di aspettazione e la varianza. A differenza delle distribuzioni discrete viste in precedenza, notiamo che in questo caso x è una variabile continua.

Partiamo dalla funzione generatrice dei momenti centrali:

$$\bar{M}_x(t) = E[e^{t(x-\mu)}] = \int_{-\infty}^{+\infty} e^{t(x-\mu)} P(x)\,dx \tag{18}$$

Sostituendo l'espressione di $P(x)$:

$$\bar{M}_x(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} e^{t(x-\mu)} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,dx = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} \exp\left[t(x-\mu) - \frac{(x-\mu)^2}{2\sigma^2}\right] dx \tag{19}$$

Per risolvere l'integrale, riscriviamo l'esponente completando il quadrato:

$$t(x-\mu) - \frac{(x-\mu)^2}{2\sigma^2} = -\frac{\left[(x-\mu)-\sigma^2 t\right]^2}{2\sigma^2} + \frac{\sigma^2 t^2}{2} \tag{20}$$

Infatti, svolgendo il quadrato al numeratore si verifica l'uguaglianza:

$$-\frac{\left[(x-\mu)-\sigma^2 t\right]^2}{2\sigma^2} = -\frac{(x-\mu)^2 - 2\sigma^2 t(x-\mu) + \sigma^4 t^2}{2\sigma^2} = -\frac{(x-\mu)^2}{2\sigma^2} + t(x-\mu) - \frac{\sigma^2 t^2}{2} \tag{21}$$

Quindi, il termine aggiuntivo $-\frac{\sigma^2 t^2}{2}$ viene compensato aggiungendo $+\frac{\sigma^2 t^2}{2}$. L'integrale diventa:

$$\begin{aligned} \bar{M}_x(t) &= \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} \exp\left[-\frac{\left[(x-\mu)-\sigma^2 t\right]^2}{2\sigma^2} + \frac{\sigma^2 t^2}{2}\right] dx \\ &= e^{\frac{\sigma^2 t^2}{2}} \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} e^{-\frac{\left[(x-\mu)-\sigma^2 t\right]^2}{2\sigma^2}} dx}_{=1} \end{aligned} \tag{22}$$

L'integrale evidenziato vale 1 poiché rappresenta l'area totale di una gaussiana con media $\mu' = \mu + \sigma^2 t$ e varianza σ^2. Pertanto otteniamo:

$$\boxed{\bar{M}_x(t) = e^{\frac{\sigma^2 t^2}{2}}} \tag{23}$$

Da questo risultato possiamo ricavare la funzione generatrice dei momenti rispetto all'origine $M_x(t)$ usando la relazione $M_x(t) = E[e^{tx}] = E[e^{t(x-\mu)} e^{\mu t}] = e^{\mu t} \bar{M}_x(t)$:

$$M_x(t) = e^{\mu t} \bar{M}_x(t) \tag{24}$$

Nel caso particolare di una gaussiana centrata in zero ($\mu = 0$) con varianza unitaria ($\sigma^2 = 1$), si ha $\bar{M}_x(t) = M_x(t)$. Per una gaussiana generale si ottiene quindi:

$$\boxed{M_x(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)} \tag{25}$$

Ora possiamo calcolare il valore di aspettazione derivando $M_x(t)$:

$$\frac{dM_x}{dt} = \frac{d}{dt}\left[\exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)\right] = \left(\mu + \sigma^2 t\right) e^{\mu t + \frac{\sigma^2 t^2}{2}} \tag{26}$$

Valutando la derivata in $t = 0$:

$$\left.\frac{dM_x}{dt}\right|_{t=0} = \mu = E[x] \tag{27}$$

Per calcolare la varianza è conveniente utilizzare la derivata seconda della funzione generatrice dei momenti centrali (o continuare a derivare M_x):

$$\left.\frac{d\bar{M}_x}{dt}\right|_{t=0} = 0 \quad \text{e} \quad \left.\frac{d^2\bar{M}_x}{dt^2}\right|_{t=0} = \sigma^2 \tag{28}$$

Se calcoliamo la derivata seconda di $M_x(t)$:

$$\frac{d^2 M_x}{dt^2} = \left[\sigma^2 + (\mu + \sigma^2 t)^2\right] e^{\mu t + \frac{\sigma^2 t^2}{2}} \tag{29}$$

Tuttavia, usando la funzione generatrice dei momenti centrali $\bar{M}_x(t) = e^{\frac{\sigma^2 t^2}{2}}$, la derivata prima è $\sigma^2 t e^{\frac{\sigma^2 t^2}{2}}$ e la seconda:

$$\frac{d^2\bar{M}_x}{dt^2} = (\sigma^2 + \sigma^4 t^2) e^{\frac{\sigma^2 t^2}{2}} \tag{30}$$

Per $t = 0$, l'esponenziale diventa 1, quindi:

$$\left.\frac{d^2\bar{M}_x}{dt^2}\right|_{t=0} = \sigma^2 = \mathrm{Var}(x) \tag{31}$$

Procedendo con le derivate successive si può osservare che tutti i momenti centrali di ordine dispari sono nulli ($\mu_3 = 0$, ecc.), il che conferma la simmetria della distribuzione.

In particolare, per la normale standard $N(0,1)$, si ha:

$$M_x(t) = \bar{M}_x(t) = e^{\frac{t^2}{2}} \tag{32}$$

6.3 Variabili Aleatorie e Combinazioni Lineari

Si può dimostrare un importante teorema: una combinazione lineare di variabili casuali normali e statisticamente indipendenti è anch'essa distribuita secondo una legge normale. Per la dimostrazione utilizziamo la funzione generatrice dei momenti. Supponiamo di avere $X_1, X_2, \ldots, X_M$ variabili aleatorie indipendenti, ognuna descritta da una gaussiana $N_i(\mu_i, \sigma_i^2)$. Una loro combinazione lineare può essere scritta come:

$$S = \sum_{i=1}^{k} a_i x_i \tag{33}$$

dove a_i sono i coefficienti scalari. Definendo $y_i = a_i x_i$, vogliamo dimostrare che S ha una densità di probabilità gaussiana. La funzione generatrice di momenti per ogni x_i è:

$$M_{x_i}(t) = \exp\left(\mu_i t + \frac{1}{2}\sigma_i^2 t^2\right) \tag{34}$$

Sappiamo che per la somma di variabili indipendenti $z = \sum x_i$ vale la proprietà:

$$M_z(t) = \prod_i M_{x_i}(t) \tag{35}$$

Inoltre, per il prodotto di una variabile per una costante $y = ax$, vale:

$$M_y(t) = E[e^{ty}] = E[e^{tax}] = M_x(at) \tag{36}$$

Applicando queste proprietà alla nostra somma $S = \sum_i y_i$ (dove $y_i = a_i x_i$), otteniamo:

$$M_s(t) = \prod_i M_{y_i}(t) = \prod_i M_{x_i}(a_i t) \tag{37}$$

Sostituendo la forma funzionale della gaussiana:

$$M_s(t) = \prod_i \left[\exp\left(\mu_i(a_i t) + \frac{1}{2}\sigma_i^2 (a_i t)^2\right)\right] \tag{38}$$

Utilizzando la proprietà degli esponenziali per cui il prodotto di esponenziali è l'esponenziale della somma degli esponenti:

$$M_s(t) = \exp\left[\left(\sum_i \mu_i a_i\right) t + \frac{1}{2}\left(\sum_i \sigma_i^2 a_i^2\right) t^2\right] \tag{39}$$

Il risultato mostra che la funzione generatrice di S ha la stessa forma funzionale di una gaussiana. Dunque, una variabile dipendente linearmente da altre variabili normali indipendenti avrà anch'essa distribuzione normale, con parametri:

$$\mu_s = \sum_i \mu_i a_i \tag{40}$$

$$\sigma_s^2 = \sum_i \sigma_i^2 a_i^2 \tag{41}$$

È importante notare che la gaussiana è l'unica distribuzione a varianza finita che gode di questa proprietà (stabilità rispetto alle combinazioni lineari). Ad esempio, per la distribuzione di Poisson, la somma di variabili indipendenti $y = \sum x_i$ è ancora una Poissoniana, ma la moltiplicazione per una costante non preserva la distribuzione. Se $y = ax$, la funzione generatrice diventa:

$$M_y(t) = M_x(at) = \exp\left[\lambda(e^{at} - 1)\right] \tag{42}$$

Questa espressione corrisponde a una Poissoniana solo se $a = 1$. Il motivo per cui il "trucco" funziona per la gaussiana risiede nel fatto che l'esponente della sua $M_x(t)$ è un polinomio di secondo grado in t: la sostituzione $t \to at$ mantiene il polinomio di secondo grado, preservando così la forma della distribuzione.

7 Teorema del Limite Centrale

Lezione del 05 Marzo 2026

Il Teorema del Limite Centrale è un risultato fondamentale della statistica. Esso giustifica l'utilizzo della distribuzione gaussiana (o normale) per descrivere i risultati di misurazioni fisiche, specialmente quando queste sono affette da molteplici cause di errore indipendenti.

Teorema. *Consideriamo un insieme di n variabili aleatorie* ***indipendenti*** $\{x_1, \ldots, x_n\}$. *Assumiamo che ciascuna variabile x_i abbia una densità di probabilità $P_i(x)$ e che il suo valore atteso (media) $E[x_i] = \mu_i$ e la sua varianza $var(x_i) = \sigma_i^2$* ***esistano e siano finiti****.*

Definiamo la variabile aleatoria S come la somma delle n variabili:

$$S = \sum_{i=1}^{n} x_i$$

Il valore atteso e la varianza di S sono dati da (proprietà dimostrabili per variabili indipendenti):

$$E[S] = \sum_{i=1}^{n} \mu_i \qquad\qquad var(S) = \sum_{i=1}^{n} \sigma_i^2$$

Il teorema afferma che, per $n \to \infty$, la distribuzione di S tende a una distribuzione normale:

$$S \overset{n\to\infty}{\sim} \mathcal{N}\left(\sum_{i=1}^{n} \mu_i, \sum_{i=1}^{n} \sigma_i^2\right)$$

Nella pratica, l'approssimazione è spesso già accettabile per $n \geqslant 10$.

È possibile riformulare il teorema utilizzando la variabile standardizzata. Applicando la trasformazione $z = \frac{\text{valore}-\text{media}}{\text{dev.std}}$, otteniamo:

$$Z_n = \frac{S - \sum_{i=1}^{n} \mu_i}{\sqrt{\sum_{i=1}^{n} \sigma_i^2}} \overset{n\to\infty}{\sim} \mathcal{N}(0,1)$$

7.1 Caso Particolare: Variabili I.I.D.

Un caso molto comune è quello in cui le variabili x_i sono **indipendenti e identicamente distribuite** (I.I.D.). In questo scenario, le ipotesi si semplificano:

- Tutte le variabili hanno la stessa distribuzione: $P_i(x) = P(x)$;
- Stessa media: $\mu_i = \mu$;
- Stessa deviazione standard: $\sigma_i = \sigma$.

Di conseguenza, i parametri della somma S diventano:

- $E[S] = \sum_{i=1}^{n} \mu = n\mu$
- $\text{var}(S) = \sum_{i=1}^{n} \sigma^2 = n\sigma^2$

La variabile standardizzata assume quindi la forma:

$$Z_n = \frac{S - n\mu}{\sqrt{n\sigma^2}} = \frac{S - n\mu}{\sigma\sqrt{n}} \tag{43}$$

Dividendo numeratore e denominatore per n, possiamo esprimere il risultato in termini della **media campionaria** $\bar{x} = \frac{S}{n} = \frac{\sum x_i}{n}$:

$$Z_n = \frac{\frac{S-n\mu}{n}}{\frac{\sigma\sqrt{n}}{n}} = \frac{\frac{S}{n} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \tag{44}$$

Questo implica che, per $n \to \infty$:

$$\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1) \tag{45}$$

Ovvero, la media campionaria $\bar{x}$ tende a distribuirsi secondo una normale con media μ e varianza ridotta:

$$\bar{x} \overset{n\to\infty}{\sim} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Per tornare alla variabile non standardizzata, invertiamo la relazione:

$$z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \implies \bar{x} = \mu + z\frac{\sigma}{\sqrt{n}}$$

7.2 Dimostrazione (tramite Funzione Generatrice dei Momenti)

Dimostriamo il teorema nel caso I.I.D., ovvero proviamo che:

$$\lim_{n\to\infty} \frac{S - n\mu}{\sigma\sqrt{n}} \sim \mathcal{N}(0,1)$$

Per semplificare i calcoli, partiamo dalle variabili standardizzate delle singole x_i. Definiamo:

$$y_i = \frac{x_i - \mu}{\sigma}$$

Analizziamo le proprietà di y_i:

- Valore atteso:
$$E[y_i] = E\left[\frac{x_i - \mu}{\sigma}\right] = \frac{1}{\sigma}(E[x_i] - \mu) = \frac{1}{\sigma}(\mu - \mu) = 0$$
- Varianza:
$$\mathrm{var}(y_i) = \mathrm{var}\left(\frac{x_i - \mu}{\sigma}\right) = \frac{1}{\sigma^2}\mathrm{var}(x_i) = \frac{\sigma^2}{\sigma^2} = 1$$

(Nota: abbiamo usato le proprietà $E[x - c] = E[x] - c$ e $\mathrm{var}(a(x + c)) = a^2 E[(x + c)^2]$).

Definiamo ora la variabile somma standardizzata Z:

$$Z = \frac{\sum_{i=1}^{n} y_i}{\sqrt{n}}$$

Si noti che questa espressione è equivalente a $\frac{S-n\mu}{\sigma\sqrt{n}}$.

Calcoliamo la **Funzione Generatrice dei Momenti** (MGF) di Z, indicata con $M_Z(t)$. Poiché le y_i sono indipendenti, la MGF della somma è il prodotto delle MGF. Inoltre, ricordando che $M_{aX}(t) = M_X(at)$, otteniamo:

$$M_Z(t) = \prod_{i=1}^{n} M_{y_i}\left(\frac{t}{\sqrt{n}}\right) \tag{46}$$

Essendo le y_i identicamente distribuite, tutte le M_{y_i} sono uguali a una generica M_y:

$$M_Z(t) = \left[M_y\left(\frac{t}{\sqrt{n}}\right)\right]^n \tag{47}$$

Sviluppiamo $M_y(k) = E[e^{ky}]$ in serie di Taylor attorno a $k = 0$, ponendo $k = t/\sqrt{n}$:

$$e^{ky} = 1 + ky + \frac{k^2y^2}{2} + \cdots \implies e^{ty/\sqrt{n}} = 1 + \frac{ty}{\sqrt{n}} + \frac{t^2y^2}{2n} + o\left(\frac{1}{n}\right) \tag{48}$$

Passando ai valori attesi e ricordando che $E[y] = 0$ e $E[y^2] = \mathrm{var}(y) + E[y]^2 = 1$:

$$E\left[e^{ty/\sqrt{n}}\right] = 1 + \frac{t}{\sqrt{n}}\underbrace{E[y]}_{0} + \frac{t^2}{2n}\underbrace{E[y^2]}_{1} + \cdots \simeq 1 + \frac{t^2}{2n} \tag{49}$$

Sostituendo questo risultato nella formula di $M_Z(t)$:

$$M_Z(t) \simeq \left(1 + \frac{t^2}{2n}\right)^n \tag{50}$$

Calcoliamo il limite per $n \to \infty$ sfruttando il limite notevole $(1 + \frac{a}{n})^n \to e^a$:

$$\lim_{n\to\infty} M_Z(t) = e^{t^2/2} \tag{51}$$

La funzione $e^{t^2/2}$ è esattamente la funzione generatrice dei momenti della normale standard $\mathcal{N}(0,1)$. Per il teorema di unicità delle funzioni generatrici, concludiamo che Z converge in distribuzione alla normale standard.

7.3 Implicazioni del Teorema nell'Analisi Dati

Il teorema ha implicazioni cruciali: ci assicura che l'effetto cumulativo di molte piccole perturbazioni indipendenti produce una distribuzione gaussiana, indipendentemente dalla forma della distribuzione di partenza.

Nelle misure fisiche, se ripetiamo una misura n volte, la media aritmetica $\bar{x}$ tende a distribuirsi come $\mathcal{N}(\mu, \sigma^2/n)$. Questo significa che l'incertezza associata alla *media* (deviazione standard della media) è:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \tag{52}$$

dove σ è la deviazione standard della singola misura.

In un esperimento reale, non conosciamo il vero σ, ma lo stimiamo con la deviazione standard campionaria s:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}}$$

Il risultato finale di n misure ripetute viene quindi riportato come:

$$\text{Risultato} = \bar{x} \pm \frac{s}{\sqrt{n}} \tag{53}$$

Questo intervallo ha un preciso significato probabilistico (intervalli di confidenza):

- $\bar{x} \pm 1\sigma_{\bar{x}}$ copre il 68.3% di probabilità;
- $\bar{x} \pm 2\sigma_{\bar{x}}$ copre il 95.5% di probabilità;
- $\bar{x} \pm 3\sigma_{\bar{x}}$ copre il 99.7% di probabilità.

7.4 Generazione di Numeri Casuali Normali

Una delle applicazioni informatiche del teorema è la generazione di numeri pseudo-casuali con distribuzione normale a partire da un generatore uniforme (disponibile in tutti i linguaggi di programmazione).

Consideriamo n variabili $\{u_1, \ldots, u_n\}$ con distribuzione uniforme in $[0, 1]$. Per la distribuzione uniforme:

- Densità: $P(u) = 1$ per $u \in [0, 1]$, 0 altrimenti.
- Media: $E[u] = \int_0^1 u\, du = \frac{1}{2}$.
- Secondo momento: $E[u^2] = \int_0^1 u^2\, du = \frac{1}{3}$.
- Varianza: $\text{var}(u) = E[u^2] - E[u]^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$.

Applicando il Teorema del Limite Centrale alla somma, la variabile standardizzata è:

$$Z = \frac{\sum u_i - nE[u]}{\sqrt{n\text{var}(u)}} = \frac{\sum u_i - n/2}{\sqrt{n/12}} \sim \mathcal{N}(0, 1) \tag{54}$$

Per semplificare il calcolo, si sceglie spesso $n = 12$. In questo caso il denominatore diventa $\sqrt{12/12} = 1$ e la formula si riduce a:

$$Z \approx \sum_{i=1}^{12} u_i - 6 \tag{55}$$

Quindi: si sommano 12 numeri uniformi e si sottrae 6. *Nota:* Questo metodo è veloce ma approssimato; le "code" della distribuzione (oltre 6σ) sono troncate, poiché la somma di variabili limitate è comunque limitata.

7.5 La Trasformazione di Box-Muller

Un metodo matematicamente esatto per generare numeri normali da numeri uniformi è la **trasformazione di Box-Muller**.

Questo metodo si basa sul cambiamento di variabili per le densità di probabilità. Se abbiamo variabili casuali x legate a variabili y da una trasformazione invertibile, la densità di probabilità congiunta si trasforma secondo:

$$P_y(y_1, \ldots, y_n) = P_x(x_1, \ldots, x_n) \cdot |J| \tag{56}$$

dove $|J|$ è il valore assoluto del determinante Jacobiano della trasformazione inversa (da y a x).

Siano x_1, x_2 due variabili indipendenti uniformi in $[0,1]$. Definiamo due nuove variabili y_1, y_2:

$$y_1 = \sqrt{-2\ln x_1}\cos(2\pi x_2) \tag{57}$$
$$y_2 = \sqrt{-2\ln x_1}\sin(2\pi x_2) \tag{58}$$

Per dimostrare che y_1 e y_2 sono gaussiane standard indipendenti, invertiamo il sistema per esprimere x in funzione di y:

- Dal rapporto $y_2/y_1 = \tan(2\pi x_2)$ otteniamo $x_2 = \frac{1}{2\pi}\arctan(y_2/y_1)$.
- Dalla somma dei quadrati $y_1^2 + y_2^2 = -2\ln x_1$ otteniamo $x_1 = \exp\left[-\frac{1}{2}(y_1^2+y_2^2)\right]$.

La densità congiunta delle variabili uniformi è $P_x(x_1,x_2) = 1$ (nel quadrato unitario). Calcoliamo lo Jacobiano $J = \det\frac{\partial(x_1,x_2)}{\partial(y_1,y_2)}$:

$$J = \det\begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix}$$

Calcolo delle derivate parziali:

- $\frac{\partial x_1}{\partial y_1} = -y_1 e^{-\frac{1}{2}(y_1^2+y_2^2)}$
- $\frac{\partial x_1}{\partial y_2} = -y_2 e^{-\frac{1}{2}(y_1^2+y_2^2)}$
- $\frac{\partial x_2}{\partial y_1} = \frac{1}{2\pi}\frac{1}{1+(y_2/y_1)^2}\left(-\frac{y_2}{y_1^2}\right) = -\frac{1}{2\pi}\frac{y_2}{y_1^2+y_2^2}$
- $\frac{\partial x_2}{\partial y_2} = \frac{1}{2\pi}\frac{1}{1+(y_2/y_1)^2}\left(\frac{1}{y_1}\right) = \frac{1}{2\pi}\frac{y_1}{y_1^2+y_2^2}$

Calcolando il determinante:

$$\begin{aligned} J &= \left(-y_1 e^{-\cdots}\right)\left(\frac{y_1}{2\pi(y_1^2+y_2^2)}\right) - \left(-y_2 e^{-\cdots}\right)\left(-\frac{y_2}{2\pi(y_1^2+y_2^2)}\right) \\ &= -\frac{1}{2\pi}e^{-\frac{1}{2}(y_1^2+y_2^2)}\left(\frac{y_1^2+y_2^2}{y_1^2+y_2^2}\right) \\ &= -\frac{1}{2\pi}e^{-\frac{1}{2}(y_1^2+y_2^2)} \end{aligned}$$

Prendendo il valore assoluto per la densità di probabilità:

$$P_y(y_1,y_2) = 1\cdot|J| = \frac{1}{2\pi}e^{-\frac{y_1^2+y_2^2}{2}} = \left(\frac{1}{\sqrt{2\pi}}e^{-y_1^2/2}\right)\cdot\left(\frac{1}{\sqrt{2\pi}}e^{-y_2^2/2}\right) \tag{59}$$

Il risultato è il prodotto di due densità normali standard. Quindi y_1 e y_2 sono variabili $\mathcal{N}(0,1)$ indipendenti.

```python
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats

def gaussian_pdf(x, mu=0, sigma=1):
    return (1 / (sigma * np.sqrt(2 * np.pi))) * np.exp(-((x - mu) ** 2) / (2 * sigma ** 2))

# definisco una funzione che dato un array, costruisce l'istogramma e sovrappone una normale standard
def plot_histo_gauss(x, titolo):
    # Parametri richiesti
    # x: array di cui fare l'istogramma
    # titolo: stringa contenente il titolo dell'istogramma

    h, bins, _ = plt.hist(x, range=(-4,4), bins=80, alpha=0.6, label="istogramma")
    delta_x = bins[1] - bins[0]
    centri = (bins[:-1] + bins[1:]) / 2
    # aggiungo una barra di errore seguendo l'approssimazione di Poisson
    plt.errorbar(centri, h, np.sqrt(h), delta_x/2, c='tab:grey', lw=1, fmt='none',label="errore statistico")
    plt.plot(centri, gaussian_pdf(centri)*delta_x*len(x),label='normale standard')
```

```
    plt.xlabel("x")
    plt.ylabel("Conteggi")
    plt.title(titolo)
    plt.legend()
    plt.show()

n = 12
m = 10000

# lista dove salvare i numeri generati
lista_gauss =[]
for i in range (m):
    # genero n numeri random tra 0 e 1
    u = np.random.uniform(0, 1, n)

    # li sommo e sottraggo 6
    x = np.sum(u) - 6

    # aggiungo il numero ottenuto alla lista
    lista_gauss.append(x)

# ora faccio un istogramma degli elementi della lista e sovrappongo una normale standard
plot_histo_gauss(lista_gauss, "Generazione da teorema del limite centrale")

# -- Caso della formula di Box-Muller --

# genero m numeri random e ottengo da essi due array x1 e x2 contenenti rispettivamente la
    prima e la seconda meta' dell'array
x = np.random.uniform(0,1,m)
x1 = x[0:int(m/2)]
x2 = x[int(m/2):m]

print(f"elementi di x {len(x)}, elementi di x1 {len(x1)}, elementi di x2 {len(x2)}")
print(x1[-1],x2[0])

# uso la trasformazione di Box-Muller per ottenere valori distribuiti secondo una normale
    standard
y1 = np.sqrt(-2*np.log(x1))*np.cos(2*np.pi*x2)
y2 = np.sqrt(-2*np.log(x1))*np.sin(2*np.pi*x2)
y = np.concatenate((y1,y2))
print(f"elementi di y {len(y)}, elementi di y1 {len(y1)}, elementi di y2 {len(y2)}")

plot_histo_gauss(y, "Generazione da Box-Muller")
```

Listing 8: Generazione numeri casuali: Teorema del Limite Centrale e Box-Muller

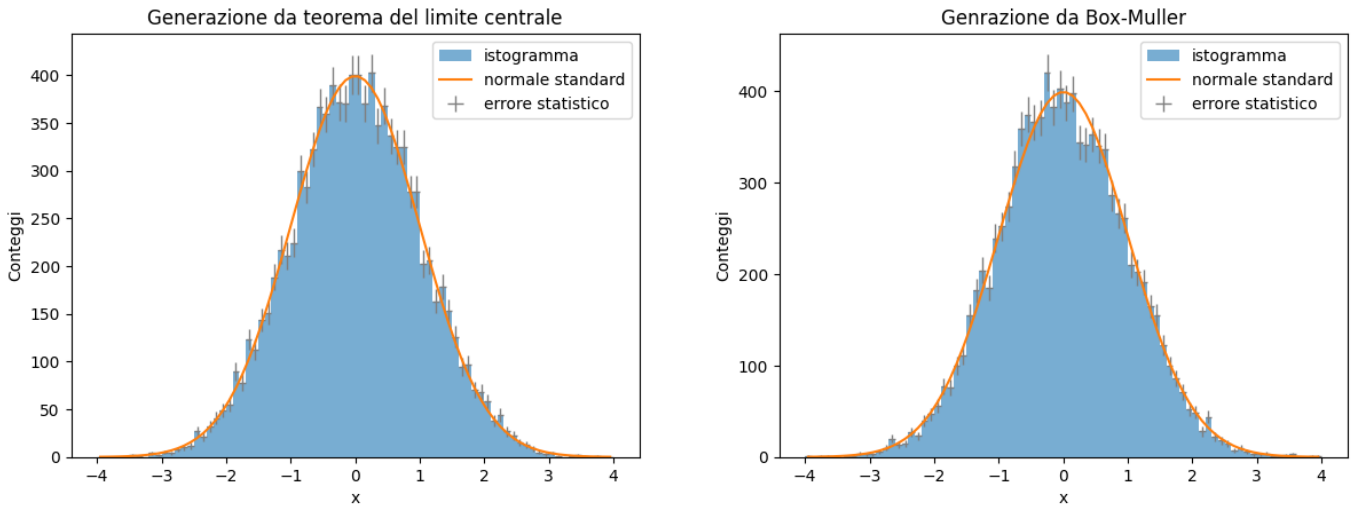

Figura 5: A sinistra: generazione di una normale standard tramite il Teorema del Limite Centrale. A destra: generazione tramite il metodo di Box-Muller. Entrambi si sovrappongono perfettamente alla curva teorica.

8 Distribuzione di Cauchy e Legge dei grandi numeri

Lezione del 16 Marzo 2026

8.1 Distribuzione di Cauchy come rapporto di due normali standard

Supponiamo che x_1, x_2 sono due variabili aleatorie indipendenti normali standard. La loro densità di probabilità congiunta è

$$P_x(x_1, x_2) = \frac{1}{2\pi} \exp\left[-(x_1^2 + x_2^2)/2\right]$$

Quello che ci interessa è studiare la variabile

$$y_1 = \frac{x_1}{x_2}$$

Per comodità ci conviene introdurre la variabile $y_2 = x_2$, in modo che la trasformazione diventi:

$$\begin{cases} y_1 = x_1/x_2 \\ y_2 = x_2 \end{cases} \quad \text{e viceversa} \quad \begin{cases} x_1 = y_1 y_2 \\ x_2 = y_2 \end{cases}$$

Così facendo lo jacobiano della trasformazione è semplicemente

$$\frac{\partial x_1}{\partial y_1}\frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2}\frac{\partial x_2}{\partial y_1} = y_2 - y_1 \cdot 0 = y_2$$

Si ha quindi che

$$P_y(y_1, y_2) = \frac{1}{2\pi} \exp\left[-(x_1^2 + x_2^2)/2\right] |y_2|$$

Ora scrivo l'esponente in termini di y_1 e y_2 e ho

$$-(x_1^2 + x_2^2)/2 = -\frac{(y_1 y_2)^2 + y_2^2}{2} = -\frac{y_2^2(y_1^2 + 1)}{2}$$

quindi sostituendo ho

$$P_y(y_1, y_2) = \frac{|y_2|}{2\pi} \exp\left[-\frac{y_2^2(y_1^2 + 1)}{2}\right]$$

Ora a me serve calcolare $P_y(y_1)$ e per farlo marginalizzo rispetto a y_2 cioè integro $P_y(y_1, y_2)$ rispetto a y_2

$$P_y(y_1) = \int_{-\infty}^{+\infty} \frac{|y_2|}{2\pi} \exp\left[-\frac{y_2^2(y_1^2 + 1)}{2}\right] dy_2$$

Essendo la funzione integranda pari in y_2 avremo

$$P_y(y_1) = 2\int_{0}^{+\infty} \frac{y_2}{2\pi} \exp\left[-\frac{y_2^2(y_1^2 + 1)}{2}\right] dy_2$$

L'integrale che resta è del tipo $\int_0^\infty xe^{-ax^2}dx$ con $a = \frac{y_1^2+1}{2}$. Questo integrale si può risolvere facendo il cambiamento di variabile $u = ax^2 \implies du = 2ax\,dx \implies x\,dx = \frac{1}{2a}du$

$$\int_0^\infty xe^{-ax^2}dx = \int_0^\infty \frac{1}{2a}du\,e^{-u} = \frac{1}{2a}\int_0^\infty e^{-u}du = \frac{1}{2a}\left[-e^{-u}\right]_0^\infty = \frac{1}{2a}$$

Sostituendo si ha quindi che

$$P_y(y_1) = \frac{1}{\pi}\frac{1}{1+y_1^2}$$

La distribuzione di probabilità trovata è la funzione di Cauchy standard, il che dimostra che il rapporto fra due variabili normali segue la distribuzione di Cauchy.
Questa distribuzione, anche conosciuta come distribuzione di Breit-Wigner è molto usata in fisica delle particelle in cui la forma di solito è quella che si ottiene con un cambiamento di variabili del tipo $y_1 = \frac{x-x_0}{\Gamma} \implies x = \Gamma y_1 + x_0$

$$P_X(x) = \frac{1}{\pi}\frac{1}{1+\left(\frac{x-x_0}{\Gamma}\right)^2}\cdot\left|\frac{dy_1}{dx}\right| = \frac{1}{\pi}\frac{\Gamma^2}{\Gamma^2+(x-x_0)^2}\cdot\frac{1}{\Gamma} = \frac{1}{\pi}\frac{\Gamma}{\Gamma^2+(x-x_0)^2}$$

Di solito questa funzione viene usata perché è una buona approssimazione per descrivere la massa invariante delle risonanze in fisica delle particelle o le intensità delle righe spettrali di emissione o assorbimento negli atomi. Nella formula x_0 rappresenta la locazione delle risonanze e Γ ha a che fare con la sua larghezza.

La caratteristica di questa distribuzione è che, anche se è simmetrica rispetto a x_0 (oppure 0 nella formulazione di Cauchy) si vede che gli integrali

$$\int_{-\infty}^0 xP(x)dx \quad \text{e} \quad \int_0^{+\infty} xP(x)dx$$

sono individualmente divergenti, il primo fa $-\infty$ e il secondo $+\infty$ e quindi tecnicamente il valore di aspettazione non è definito.
Intuitivamente il problema è che la distribuzione di Cauchy ha code così alte che la media non riesce a stabilizzarsi a un valore preciso. Quando si calcola la media di n eventi, al crescere di n, si vede che all'inizio sembra che la media si stabilizzi a zero poi si iniziano a presentare dei salti che spostano la media. Questo perché visto che i valori nelle code della distribuzione non sono tanto rari, ne viene aggiunto uno alla somma con l'effetto di spostare la media.
Analogamente la varianza e tutti i momenti di ordine superiore sono divergenti.

8.2 Legge dei grandi numeri

La legge dei grandi numeri è un altro dei teoremi fondamentali della statistica che serve a capire perché ha senso usare la media aritmetica. In sostanza dice che se ripetiamo un esperimento molte volte, la media dei risultati ottenuti tende al valore di aspettazione della densità di probabilità alla base del fenomeno.
In realtà esistono varie formulazioni, quella descritta è la legge debole dei grandi numeri.
Per formularla in maniera più formale indichiamo con il simbolo $\text{Prob}(A)$ la probabilità che si verifichi un certo evento A. Più precisamente se X è una variabile aleatoria con densità di probabilità $P(x)$ allora

$$\text{Prob}(X > a) = \int_a^{+\infty} P(x)dx$$

Nel caso discreto cioè se X non è reale e ad ogni x_i posso associare una certa p_i allora si avrà che

$$\text{Prob}(X > a) = \sum_{x_i > a}^{+\infty} p_i$$

che si può scrivere anche $\text{Prob}(X > a) = \sum_{x_i>a} p_i$.

Matematicamente il modo in cui si formula la legge è: date n variabili aleatorie $\{X_1, X_2, \ldots, X_n\}$ indipendenti e con la stessa densità di probabilità, quindi con lo stesso valore di aspettazione $E[X_i] = E[X] = \mu$ e varianza $\text{Var}(X_i) = \text{Var}(X) = \sigma^2$ che devono esistere finite, allora $\forall\varepsilon > 0$

$$\lim_{n\to\infty} \text{Prob}(|\bar{x} - \mu| \geqslant \varepsilon) = 0$$

cioè la probabilità che la media aritmetica di n variabili differisca dal valore di aspettazione va a zero per n che tende a infinito.

Dimostrazione

La dimostrazione richiede vari passaggi e dimostrazioni intermedie. Per semplicità consideriamo il caso di variabili discrete (si può passare al caso continuo sostituendo le sommatorie con gli integrali) e parto da una probabilità simile a quella della tesi ma non esattamente uguale cioè

$$\text{Prob}(|X-\mu| \geqslant \varepsilon) = \sum_{|x_i-\mu|\geqslant\varepsilon} p_i$$

quindi in questo caso la sommatoria è estesa solo ai valori di X_i che soddisfano $|x_i - \mu| \geqslant \varepsilon$ dove $\mu = E[X]$.
Per arrivare a dire qualcosa su questa probabilità usiamo la definizione di varianza nel caso discreto

$$\sigma^2 = E[(X-\mu)^2] = \sum_i p_i(x_i-\mu)^2$$

dove in questo caso la sommatoria è estesa a tutti i valori di i per cui x_i esiste (tipicamente $-\infty, +\infty$). Se consideriamo solo i valori di $x_i : |x_i - \mu| \geqslant \varepsilon$ allora avremo un sottoinsieme di tutti i valori possibili di x_i, quindi

$$\sigma^2 \geqslant \sum_{|x_i-\mu|\geqslant\varepsilon} p_i(x_i-\mu)^2 \geqslant \sum_{|x_i-\mu|\geqslant\varepsilon} p_i\varepsilon^2$$

dove l'ultimo passaggio viene dal fatto che dato che la sommatoria vale per $|x_i - \mu| \geqslant \varepsilon$ varrà in particolar quando vale $|x_i - \mu| = \varepsilon$ quindi se lo sostituisco dentro la sommatoria avrò in generale qualcosa di più piccolo.
Nella sommatoria che rimane ε^2 non dipende da i e quindi si può portare fuori:

$$\sigma^2 \geqslant \varepsilon^2 \sum_{|x_i-\mu|\geqslant\varepsilon} p_i$$

Qui posso sostituire la definizione iniziale

$$\sigma^2 \geqslant \varepsilon^2 \text{Prob}(|X-\mu| \geqslant \varepsilon)$$

E quindi invertendo ho

$$\text{Prob}(|X-\mu| \geqslant \varepsilon) \leqslant \frac{\sigma^2}{\varepsilon^2}$$

Questa disuguaglianza è nota come **disuguaglianza di Chebyshev** che si può trovare in letteratura anche nella forma che si ottiene da questa ponendo $\varepsilon = K\sigma$ cioè

$$\text{Prob}(|X-\mu| \geqslant K\sigma) \leqslant \frac{1}{K^2}$$

Useremo questa disuguaglianza per dimostrare la legge dei grandi numeri, ma prima vale la pena notare le sue implicazioni in generale. Senza aver fatto nessuna assunzione sulla densità di probabilità, questa disuguaglianza dà dei limiti superiori a quanto una qualunque variabile aleatoria X si possa allontanare da μ. Per esempio per $K = 2$ si ha che $\text{Prob}(|X-\mu| \geqslant 2\sigma) \leqslant \frac{1}{4} = 0.25$
cioè la probabilità che $|X - \mu| \geqslant 2\sigma$ non può superare il 25% o al contrario almeno nel 75% dei casi si ha $|X - \mu| < 2\sigma$. Ovviamente questo è un limite inferiore e vale per qualsiasi distribuzione. Abbiamo visto che nel caso della gaussiana vale in particolare $P(|X - \mu| < 2\sigma) \sim 95\%$.

```python
import numpy as np
import matplotlib.pyplot as plt
import math

# Parametri della gaussiana
mu = 0
sigma = 1

# Funzione densità di probabilità (PDF) della gaussiana con normale come default
def gaussian_pdf(x, mu=0, sigma=1):
    return (1 / (sigma * math.sqrt(2 * math.pi))) * np.exp(-((x - mu) ** 2) / (2 * sigma
        ** 2))

# Calcolo l'integrale con il metodo numerico dei rettangoli
def integra(a, b, n=200000):
    # a partire dall'intervallo [a,b] costruisco n rettangolini tutti larghi uguali con
        base:
```

```python
    base = (b - a) / n
    somma = 0.0
    # ora sommo le altezze di tutti i rettangolini
    for k in range(n):
        x_mid = a + (k + 0.5) * base
        somma += gaussian_pdf(x_mid)
    # uso la formula base*altezza per calcolare la somma delle aree di tutti i rettangolini
    return base * somma

print("Integrazione numerica della gaussiana standard\n")

for sigma in [1, 2, 3]:
    area = integra(-sigma, sigma)
    print(f"La probabilità che x assuma valori compresi entro {sigma} deviazioni standard è {area:.6f}")
    print(f"Viceversa la probabilità che x>{sigma}sigma è {1-area:.6f}\n")

# Metodo alternativo: estraggo numeri casuali con densità di probabilità gaussiana,
# creo un istogramma con questi numeri e poi sommo i contenuti dei bin

# estrazione dei numeri casuali
N = 300000
campioni = np.random.normal(0, 1, N)

# creo l'istogramma senza la parte grafica al momento
bins = np.linspace(-4, 4, 81)  # larghezza bin = 0.1
conteggi, bordi = np.histogram(campioni, bins=bins)

bin_width = bordi[1] - bordi[0]
centri = (bordi[:-1] + bordi[1:]) / 2

# Creo una mappa dei colori per intervalli sigma che userò successivamente per il grafico
for sigma, colore in zip([1,2,3], ['green','orange','purple']):
    colors =[]
    area = 0
    for c, h in zip(centri, conteggi):
        if abs(c) <= sigma:
            colors.append(colore)
            area += h
        else:
            colors.append('white')

    print(f"Area tra -{sigma} sigma e {sigma} sigma = {area/N:.6f}")

    # Disegno istogramma usando delle barre colorate con la mappa di prima
    plt.figure(figsize=(8,5))
    plt.bar(centri, conteggi, width=bin_width, color=colors, alpha=0.5, label = f"Integrale = {area/N:.4f}")

    # Gaussiana teorica moltiplicata per deltax e per N
    x = np.linspace(-4,4,1000)
    plt.plot(x, gaussian_pdf(x)*bin_width*np.sum(conteggi), 'r', linewidth=2, label="Gaussiana teorica")

    # Linea sigma
    plt.axvline(sigma, linestyle='--', color=colore, label=f"$\pm$ {sigma} sigma")
    plt.axvline(-sigma, linestyle='--', color=colore)

    plt.title("Istogramma con colori per intervalli ±n$\sigma$")
    plt.xlabel("$x$")
    plt.ylabel("Densità di probabilità")
    plt.legend()
    plt.grid(True)
    plt.margins(x=0)
    plt.show()
```

Listing 9: Calcolo probabilità e plot della Gaussiana (1, 2 e 3 deviazioni standard)

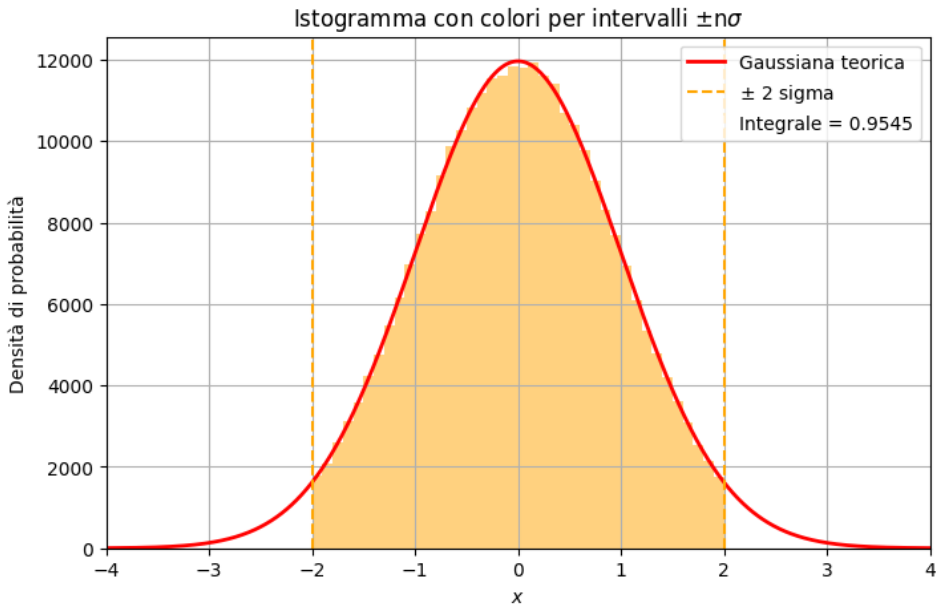

Figura 6: Visualizzazione dell'area sottesa alla gaussiana standard nell'intervallo $\pm 2\sigma$. Come previsto dalla teoria, l'area copre circa il 95.4% dei casi, un limite ben più stringente del 75% garantito dalla disuguaglianza di Chebyshev.

Torniamo ora al caso della media $\bar{x}$ e applicando la disuguaglianza di prima avremo

$$\text{Prob}(|\bar{x} - E[\bar{x}]| \geqslant \varepsilon) \leqslant \frac{\text{Var}(\bar{x})}{\varepsilon^2}$$

dove $E[\bar{x}] = E\left[\frac{\sum_i x_i}{n}\right] = \frac{1}{n}\sum_i E[x_i] = \frac{1}{n} n\mu = \mu$
mentre $\text{Var}(\bar{x}) = \text{Var}\left(\frac{1}{n}\sum_i x_i\right) = \frac{1}{n^2}\sum_i \text{Var}(x_i) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$
Sostituendo si ha quindi

$$\text{Prob}(|\bar{x} - \mu| \geqslant \varepsilon) \leqslant \frac{\sigma^2}{n\varepsilon^2}$$

Al limite per $n \to \infty$, $\frac{1}{n} \to 0$ per cui questo dimostra che

$$\lim_{n\to\infty} \text{Prob}(|\bar{x} - \mu| \geqslant \varepsilon) = 0$$

$\star$ $\text{Prob}(|X - \mu| \geqslant K\sigma) = 1 - \text{Prob}(|X - \mu| < K\sigma) \leqslant \frac{1}{K^2}$
$\implies \text{Prob}(|X - \mu| < K\sigma) \geqslant 1 - \frac{1}{K^2}$

8.3 Distribuzione Esponenziale

$$P_{\exp}(x;\tau) = \frac{1}{\tau} e^{-x/\tau} \qquad 0 \leqslant x \leqslant +\infty$$

Il valore di aspettazione e la varianza si calcolano facilmente dalla funzione generatrice dei momenti

$$M_X(t) = E[e^{tx}] = \int_0^\infty e^{tx} \frac{1}{\tau} e^{-x/\tau} dx = \frac{1}{\tau}\int_0^\infty e^{(t-1/\tau)x} dx$$

$$= \frac{1}{\tau}\frac{1}{t - 1/\tau}\left[e^{(t-1/\tau)x}\right]_0^\infty = \frac{1}{t\tau - 1}[0 - 1] = \frac{1}{1 - t\tau}$$

Per calcolare il valore di aspettazione la derivo:

$$M'_X(t) = \frac{-1}{(1 - t\tau)^2}(-\tau) = \frac{\tau}{(1 - t\tau)^2}$$

$$M'_X(0) = \tau = E[X]$$

Calcolo la derivata seconda ($D(x^{-2}) = -2x^{-3}$)

$$M''_X(t) = -\frac{2\tau}{(1-t\tau)^3}(-\tau) = \frac{2\tau^2}{(1-t\tau)^3}$$

$$M''_X(0) = 2\tau^2 = E[X^2]$$

Ora calcolo la varianza come

$$\mathrm{Var}(X) = E[X^2] - (E[X])^2 = 2\tau^2 - \tau^2 = \tau^2$$

9 Distribuzione Esponenziale

Lezione del 19 Marzo 2026

La distribuzione esponenziale descrive il tempo che intercorre tra due eventi consecutivi in un processo di Poisson.

Ricaviamola dalla **Distribuzione di Poisson**. Se un fenomeno segue la **distribuzione di Poisson**, la probabilità di osservare k eventi, dato un numero medio di eventi attesi ν, è:

$$P(k;\nu) = \frac{e^{-\nu}\nu^k}{k!} \tag{60}$$

Se definiamo λ come il numero di eventi attesi per **unità di tempo**, allora il numero medio di eventi attesi in un intervallo t è λt. La probabilità di osservare k eventi nell'intervallo t diventa:

$$P(k;\lambda t) = \frac{e^{-\lambda t}(\lambda t)^k}{k!} \tag{61}$$

Definiamo una nuova variabile casuale T come l'intervallo di tempo che intercorre tra due eventi successivi. Affinché il tempo di attesa T sia maggiore di un certo valore t ($T > t$), non deve verificarsi alcun evento nell'intervallo $[0, t]$.

Pertanto, la probabilità che $T > t$ coincide con la probabilità di osservare zero eventi nel periodo t:

$$\text{Prob}(T > t) = P(0;\lambda t) = \frac{e^{-\lambda t}(\lambda t)^0}{0!} = e^{-\lambda t} \tag{62}$$

9.1 Funzione di Ripartizione e Densità di Probabilità

La **funzione di ripartizione** (o distribuzione cumulativa $F_X(x)$) indica la probabilità che una variabile x' assuma un valore minore o uguale a x:

$$F_X(x) = \text{Prob}(x' \leqslant x) = \int_{-\infty}^{x} P_X(z)\,dz \tag{63}$$

Dalle proprietà della probabilità, segue la normalizzazione: $\int_{-\infty}^{+\infty} P_X(x)\,dx = 1$.

Per la variabile tempo T, la funzione di ripartizione è:

$$F_T(t) = \text{Prob}(T \leqslant t) = 1 - \text{Prob}(T > t) = 1 - e^{-\lambda t} \tag{64}$$

La **densità di probabilità** $P_T(t)$ si ottiene derivando la funzione di ripartizione:

$$P_T(t) = \frac{d}{dt}F_T(t) = \frac{d}{dt}(1 - e^{-\lambda t}) = \lambda e^{-\lambda t} \tag{65}$$

Questa è la densità di probabilità esponenziale. Indica che i tempi di attesa brevi sono più probabili, mentre quelli lunghi sono meno probabili.

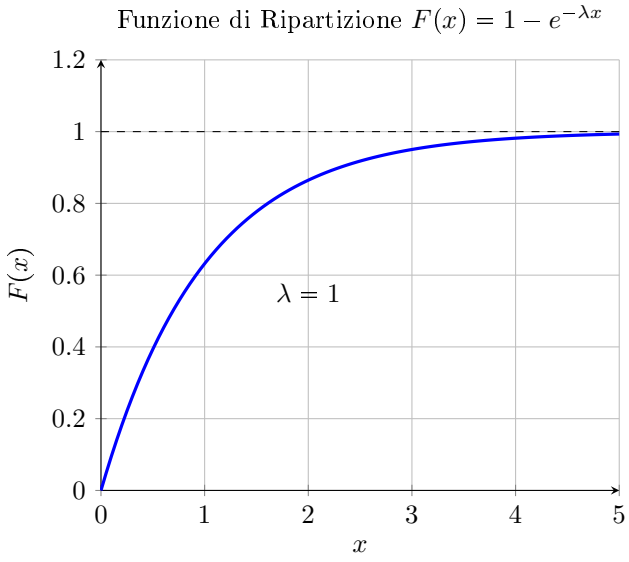

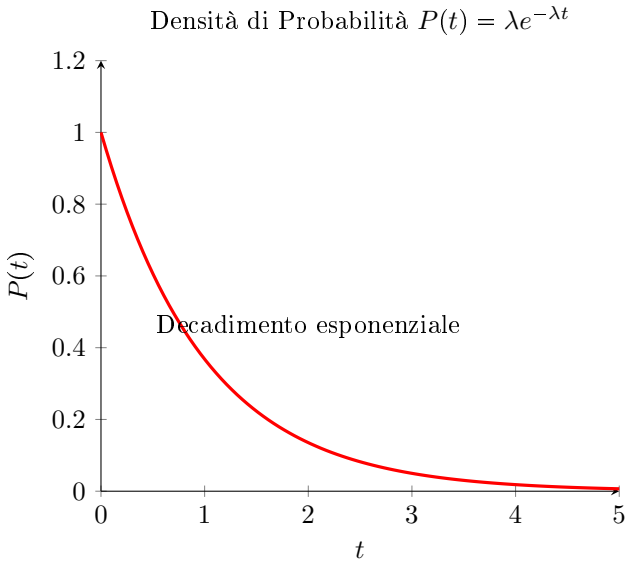

$$P_t(t) = \frac{d}{dt}(1 - e^{-\lambda t}) = \lambda e^{-\lambda t}$$

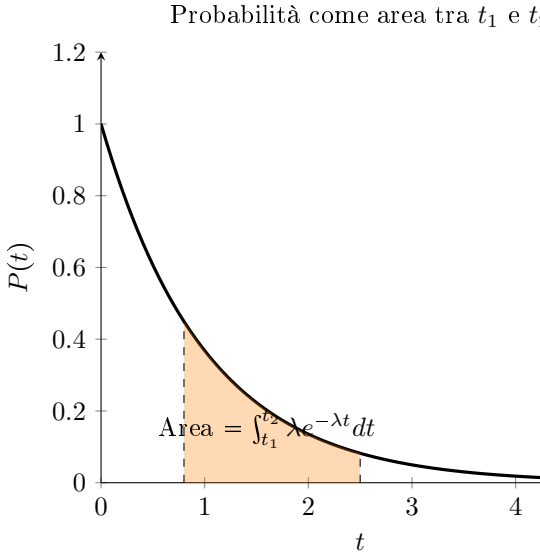

il risultato vuol dire che itempi di attesa piccoli sono più grandi di quelli grandi

9.2 Proprietà di Assenza di Memoria

Una caratteristica fondamentale è l'**assenza di memoria**: il tempo che resta da aspettare affinché un evento si verifichi è indipendente da quanto abbiamo già aspettato. Usando la probabilità condizionata $\text{Prob}(A|M) = \frac{\text{Prob}(A \cap M)}{\text{Prob}(M)}$:

- s: tempo già aspettato.
- t: tempo addizionale da aspettare.
- $A \to T > s + t$
- $M \to T > s$

$$\text{Prob}(T > s + t \mid T > s) = \frac{\text{Prob}(T > s + t)}{\text{Prob}(T > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(T > t) \tag{66}$$

Parametrizzazione con τ Spesso si scrive la distribuzione utilizzando $\tau = 1/\lambda$, dove τ rappresenta il **tempo medio** tra due eventi (mentre λ è la frequenza):

$$P_{exp}(x; \tau) = \frac{1}{\tau} e^{-x/\tau} \quad \text{per } 0 \leqslant x \leqslant +\infty \tag{67}$$

10 Distribuzione di Erlang

La distribuzione di Erlang è una generalizzazione della distribuzione esponenziale. Mentre l'esponenziale regola il tempo tra due eventi successivi ($k = 1$), la distribuzione di Erlang regola il tempo di attesa per il **k-esimo evento**.

Sia T_k il tempo di attesa fino al k-esimo evento.

- $P_1(t;\lambda) = \lambda e^{-\lambda t}$ (Esponenziale)
- Per P_2, supponiamo che il primo evento avvenga a x ($0 < x < t$) e il secondo nel tempo restante $t - x$:

$$P_2(t;\lambda) = \int_0^t P_1(x;\lambda)P_1(t-x;\lambda)\,dx = \int_0^t \lambda e^{-\lambda x}\lambda e^{-\lambda(t-x)}\,dx = \lambda^2 t e^{-\lambda t} \tag{68}$$

Procedendo per induzione per P_3:

$$P_3(t;\lambda) = \int_0^t P_2(x;\lambda)P_1(t-x;\lambda)\,dx = \int_0^t \lambda^2 x e^{-\lambda x}\lambda e^{-\lambda(t-x)}\,dx = \frac{t^2}{2}\lambda^3 e^{-\lambda t} \tag{69}$$

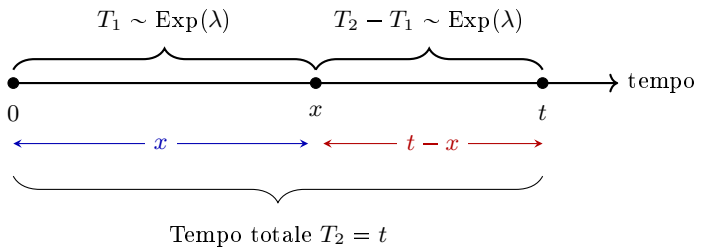

Continuando ricorsivamente, si ottiene la densità di probabilità di Erlang:

$$P_k(t;\lambda) = \frac{t^{k-1}}{(k-1)!}\lambda^k e^{-\lambda t} \tag{70}$$

Momenti della distribuzione:

- Valore di aspettazione: $E[t] = \frac{k}{\lambda}$
- Varianza: $Var(t) = \frac{k}{\lambda^2}$

11 Metodi Monte Carlo

I metodi Monte Carlo sono algoritmi computazionali che sfruttano la generazione di numeri casuali per risolvere problemi matematici complessi.

Esempio Per calcolare l'area di una superficie irregolare:
1. Si lancia un numero N di chicchi di riso a caso su un foglio di area nota.
2. Si conta quanti chicchi cadono dentro l'area cercata (N_{in}).
3. Il rapporto N_{in}/N fornisce una stima dell'area, che diventa più accurata al crescere di N.

11.1 Metodo Accept-Reject

È un metodo generale per generare variabili continue secondo una distribuzione $f(x)$ non standard. Dati un intervallo $[x_{min}, x_{max}]$ e un valore massimo della funzione f_{max}:

1. Si genera x_i con distribuzione uniforme tra x_{min} e x_{max}: $x_i = x_{min} + r_1(x_{max} - x_{min})$.
2. Si genera y_i con distribuzione uniforme tra 0 e f_{max}.
3. Se $y_i < f(x_i)$, si **accetta** il valore x_i; altrimenti lo si rifiuta.

L'efficienza η è il rapporto tra l'area sotto $f(x)$ e l'area del rettangolo:

$$\eta = \frac{1}{(x_{max} - x_{min})f_{max}} \int_{x_{min}}^{x_{max}} f(x)\,dx \tag{71}$$

11.2 Metodo della Funzione di Ripartizione (Inversione)

Un metodo più efficiente dell'Accept-Reject si basa sull'inversione della CDF. Dato che $F(x) = \int_{-\infty}^{x} P(z)\,dz$ ha valori compresi tra 0 e 1, se generiamo un numero casuale $u \sim \mathcal{U}(0,1)$, allora:

$$x = F^{-1}(u) \tag{72}$$

Il valore x così ottenuto sarà distribuito secondo la $P(x)$ originale.

Esempio per la distribuzione esponenziale:

- $P(x) = \frac{1}{\tau}\exp\left(-\frac{x}{\tau}\right)$
- $F(x) = 1 - \exp\left(-\frac{x}{\tau}\right) = u$
- Invertendo: $x = -\tau \ln(1-u)$

12 da integrare dopo

12.1 Distribuzione di Maxwell-Boltzmann

Si considera un gas con peso molare $M = N_A m$ in equilibrio termodinamico a temperatura T. La costante dei gas è $R = N_A k \approx 8.31\,\mathrm{J\,K^{-1}mol^{-1}}$.

La velocità quadratica media delle molecole del gas è legata alla temperatura dalla relazione:

$$v_{\mathrm{qm}} = \sqrt{\langle v^2 \rangle} = \sqrt{\frac{3RT}{M}}$$

Tuttavia, le singole molecole hanno velocità che si discostano da questo valore medio.

Maxwell nel 1859 derivò la distribuzione di probabilità delle velocità $f(v)$:

$$f(v) = 4\pi \left(\frac{M}{2\pi RT}\right)^{3/2} v^2 \exp\left[-\frac{Mv^2}{2RT}\right] = 4\pi \left(\frac{m}{2\pi kT}\right)^{3/2} v^2 \exp\left[-\frac{mv^2}{2kT}\right]$$

All'aumentare della temperatura, il picco della distribuzione (velocità più probabile) si sposta verso valori più elevati.

Le curve sono normalizzate in modo che l'integrale della probabilità sia sempre uguale a 1.

La distribuzione fu ottenuta da Maxwell attraverso un ragionamento particolarmente ingegnoso:

- introduciamo prima alcune definizioni:

$$\rho(\vec{r}) = \frac{dm}{dV} \quad \text{densità del gas,}$$

$$\eta(\vec{r}) = \frac{\rho(\vec{r})}{m} \quad \text{densità di particelle,}$$

$$dn = \eta(\vec{r})\, dV \quad \text{numero di particelle in } dV.$$

- da cui ricaviamo che la distribuzione delle particelle nello spazio è:

$$p(\vec{r}) = \frac{\eta(\vec{r})}{n_T}$$

- introduciamo una densità di particelle nello spazio delle velocità, in modo analogo a quello tridimensionale:

$$dn(\vec{v}) = \eta(\vec{v}) d^3 v$$

- introduciamo ora la funzione di distribuzione normalizzata della velocità $f(\vec{v})$:

$$f(\vec{v}) = \frac{\eta(\vec{v})}{n_T}$$

- se la distribuzione della velocità è isotropa, allora la funzione di distribuzione dipende solo dal modulo e non solo dal verso;

- Il numero di particelle dn comprese nell'elemento $\mathrm{d}\vec{v} = \mathrm{d}^3 v$ dello spazio delle velocità vale:

$$dn(v) = n_T\, p(K)\, \mathrm{d}v_x\, \mathrm{d}v_y\, \mathrm{d}v_z$$

  che in coordinate e angoli polari si può scrivere:

$$dn(v) = n_T\, p(K)\, v^2\, \mathrm{d}v\, \mathrm{d}\Omega = n_T\, p(K)\, v^2\, \mathrm{d}v \sin\theta\, \mathrm{d}\theta\, \mathrm{d}\phi$$

- dato che ho dei valori che non dipendono dagli angoli posso trovare che:

$$dn(v) + c = 4\pi n_T p(K) v^2 dv$$

> ***Nota:*** *Ricordiamo la definizione di angolo solido:*
> *Vogliamo sapere quante molecole hanno il vettore velocità compreso fra $\vec{v}$ e $v + \vec{dv}$ Passiamo alle coordinate polari sferiche (r, θ, ψ), l'area A identificata dal vettore $\vec{v}$ sarà l'intersenzione della superfice sferica di due cerchi la cui latitudine differisce per $d\theta$ e due la cui longitudine differisce per $d\psi$. Di conseguenza si ha:*
>
> $$dA = (rd\psi)(r\sin(\theta)d\psi)$$
>
> *L'angolo solido sarà definito da:*
>
> $$d\omega = \frac{dA}{r^2} = \sin(\theta)d\theta d\psi$$
>
> *Il numero di particelle con velocità $v + \vec{dv}$ sarà: $dn(v)\frac{d\omega}{4\pi}$ essendo 4π l'angolo solido massimo. Questa espressione ci dice che non c'è una direzione preferenziale per le velocità*
> *Se consideriamo inoltre che moleco possono scontrarsi fra di loro prima di colpire l'area A, dobbiamo limitarci a considerare un cilindro di lunghezza $vd\tau$ dove τ è talmente piccolo che non avvengono urti fra le molecole, esso vale $dV = vd\tau\cos(\theta)dA$.*
> *Il numero di molecole che urterà l'area dA sarà $dn(v)\frac{d\omega}{4\pi}\frac{dV}{v}$*

- La probabilità che l'urto accada è
  $$P = Cp(K_1)p(K_2)$$
  ovvero è proporzionale alla probabiità di avere le due particelle con K_1 e K_2 e dopo K_1' e K_2'
  Posso ora considerare due particelle che hanno energia cinetica inziale
  $$P = Cp(K_1')p(K_2')$$
  e, e che dopo urto abbiamo K_1 e K_2.
  Il processo può essere visto da ambo le parti, $C = C'$
- il gas è essendo in equilibrio termodinamico deve essere che l'energie cinetiche si equivalgono e si conservano, dunque:
  $$P = p(K_1)p(K_2)P = p(K_1')p(K_2') = p(K_1 + x)p(K_2 - x)$$
  dove x rappresenta un incremento ($\pm$) dell'energia
- dunque l'unica funzione che soddisfi questi requisiti è:
  $$p(K) = Ae^{-\beta\frac{mv^2}{2}}$$
  dove β (> 0) è una costante che mi serve per rendere il mio esponente adimensionale. Quindi:
  $$dn(v) + c = 4\pi n_T Ae^{-\beta\frac{mv^2}{2}}v^2dv$$

> ***Nota:***
> *le costanti A e β sono da determinare, per la prima integriamo da 0 a ∞ (tutte le velocità), arriviamo a $A = \left(\frac{\frac{1}{2}m\beta}{\pi}\right)^{\frac{1}{2}}$*
> *quindi per β utilizzamo la definizone della media quadratica di tutte le velocità*
>
> $$\langle v^2\rangle = \frac{1}{N}\int_0^\infty v^2\,dn(v).$$
>
> *Sostituendo l'espressione di $dn(v)$, si ha*
>
> $$\langle v^2\rangle = 4\pi A^3\int_0^\infty v^4\exp\left[-\beta\left(\tfrac{1}{2}mv^2\right)\right]dv$$
>
> *Il cui valorè è: $\frac{3}{m\beta}$*
> *Dalle supposizioni abbiamo che l'unica energia è quella cinetica, dal teorema di equipartizione dell'energia, essendoci 3 gradi di libertà:*
>
> $$\tfrac{1}{2}m\langle w^2\rangle = \tfrac{3}{2}k\theta \to \frac{1}{2}m\frac{3}{m\beta} = \frac{3}{2}k\theta,$$
>
> *cioè*
>
> $$\beta = \frac{1}{k\theta}.$$

- imponendo le condizioni di contorno, ovvero $\int_V dn_v = n_T$ e $\int_V K dn_v = \frac{3}{2} n_T K T$ ottengo che:

$$p(v)\,dv = 4\pi \left(\frac{m}{2\pi kT}\right)^{3/2} v^2 \exp\left[-\frac{mv^2}{2kT}\right] dv$$

- la funzione presenta un massimo in $v_M = \sqrt{\frac{2kT}{m}} \to kT = \frac{1}{2} m {v_M}^2$, la velocità più probabile!!
- Usando la funzione di distribuzione di Maxwell-Boltzmann, posso ricavare la velocità media (in modulo) delle molecole:

$$\mu_v = E[v] = \frac{4}{\sqrt{\pi}} \frac{1}{v_M^3} \int_0^\infty v^3 \exp\left[-\frac{v^2}{v_M^2}\right] dv = \frac{2}{\sqrt{\pi}} v_M = \sqrt{\frac{8kT}{m}}$$

Mentre la velocità quadratica media introdotta in precedenza vale:

$$v_{\text{qm}} = \sqrt{\langle v^2 \rangle} = \sqrt{\int_0^\infty v^2 p(v)\,dv} = \sqrt{\frac{3kT}{m}}$$

Costante di normalizzazione	Probabilità di occupazione del livello energetico	Spazio delle fasi

$$p(v)dv = \left\{4\pi \left(\frac{m}{2\pi kT}\right)^{3/2}\right\} \left\{\exp\left[-\frac{mv^2}{2kT}\right]\right\} \left\{v^2 dv\right\}$$

Essa mi garantisce:

- La costante di normalizzazione assicura che l'integrale della $p(v)$ esteso a tutte le velocità possibili sia uguale a 1.
- La statistica di Boltzmann tiene conto della probabilità di occupazione di uno stato avente una data energia in funzione della temperatura del sistema.
- Infine lo spazio delle fasi tiene conto della molteplicità del livello energetico, vale a dire in quanti "modi" è possibile ottenere una configurazione che abbia la stessa energia. Nel nostro caso questo corrisponde al volume di una corteccia di sfera di raggio interno v e spessore dv. A tutti i punti di questo volume corrisponde la medesima energia $K = \frac{mv^2}{2}$.

13 Funzione di distribuzione per variabili casuali

Se la funzione di densità di probabilità dipende da più variabili si ha, per il valore di aspettazione

$$E(x_1, \ldots, x_n) = \int \vec{x} f(\vec{x}) d\vec{x}$$

dove $\vec{x} = (x_1, \ldots, x_n)$.

Per un singolo valore x_i si ha

$$E(x_i) = \int x_i f(\vec{x}) d\vec{x}$$

Si definisce allora l' elemento di posizione ij della*matrice della covarianza*:

$$V_{ij} = E[(x_i - \mu_i)(x_j - \mu_j)] = \int (x_i - \mu_i)(x_j - \mu_j) f(\vec{x}) d\vec{x}$$

si ha allora che:

- $\sigma_i^2 = V_{ii} = \sigma^2$
- la *covarianza* è un qualsiasi elemento della matrice $i \neq j$

E' utile definire il *coefficente di correlazione*:

$$\rho(x_i, x_j) = \frac{Cov(x_i, x_j)}{\sigma_i \sigma_j}$$

Si ha così una nuova definizione di variabili indipendenti:

$f_X(x_1, \dots, x_n) = f_1(x_1)f_2(x_2)\dots f_n(x_n)$

$E(x_i, x_j) = E(x_i)E(x_j) \to Cov(x_i, x_j) = 0$ e $\rho(x_i, x_j) = 0$

è la probabilità che la n variabili causali cadano all'interno di certi intervalli contemporaneamente ,essa ha le stesse proprità della funzioe di distribuzione usuale, si può così definire la funzione di distribuzione marginale per una variabile x_i, ottenuta integrando la funzione citata sopra sui vari intervalli dove $x_j \neq x_i$

Posso costruire il valore di aspettazione di due variabili causali (**covarianza**), il cui valore è 0 se le variabili sono indipendenti fra loro

$$Cov(X, Y) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

Se le variabili sono indipendenti la funzione di distribuzione di Gauss diviene:

$$f(x_i) = \frac{1}{\sqrt{2\pi}\sigma_i}e^{-\frac{(x_i-\mu_i)^2}{2\sigma_i^2}}$$

La distribuzione congiunta

$$f(x_1, ..., x_n) = \prod f(x_i) = \frac{1}{(2\pi)^n \prod \sigma_i}e^{-\frac{1}{2}\sum_{i=1}^{n}\frac{(x_i-\mu_i)^2}{\sigma_i^2}}$$

Se le varianze sono i valori medi:

$$f(x_1, ..., x_n) = \frac{1}{(2\pi)^n \prod \sigma_i}e^{\sum_{i=1}^{n}\frac{(x_i-\mu_i)^2}{2\sigma^2}}$$

Data $y = y(x)$ variabile casuale dipendente da un altra variabile casuale x, nel caso di **corrispondenza biunivoca** (ex. $y = ax - b$)si deve avere:

$$f(x_a)dx = g(y_a)dy$$

dove $y_a = f(x_a)$, allora la detrminazione di $g(y)$ si riduce ad una trasformazione di varibile. Ossia le funzioni di distribuzioni devono essere identiche, se esiste la funzione inversa $x = x(y)$ si ha:

$$g(y) = f(x(y))\left|\frac{dx(y)}{dy}\right|$$

Nel caso invece di funzioni **non biunivoche**, cioè esistono m valori x_i tali che $y = y(x_i)$ (ex. $y = ax^2$), allora "sommo le diverse componenti biunivuche":

$$g(y) = \sum_{i=0}^{n} f(x_i(y))\left|\frac{dx_i(y)}{dy}\right|$$

Se è difficile calcolare la $g(y)$, utilizzo il valore di aspettazione

$$\mu_y = E[y] = \int yg(y)dy = E[y(x)] = \int y(x)f(x)dx$$

$$\sigma_y^2 = E[(y(x) - \mu_y)] = \int (y(x) - \mu_y)^2 f(x)dx$$

Calcolo dunque il valore di aspettazione e la varianza

Se l'andamento è lineare $y(x) = ax + b$ si ha:

$$E[y(x)] = aE(x) + b$$

Utilizzando questo è facile verificare che:

$$\sigma_y^2 = E[y^2] - \mu_y^2 = a^2\sigma_x^2$$

Che è quanto si ottiene dalla legge di propagazione della varianza.

Se $y(x)$ non è lineare utilizzo l'approssimazione lineare intorno a μ_x e tronco al secondo ordine:

$$\begin{aligned}
\mu_y = E[y] &= E\left[y(\mu_x) + \left(\frac{dy}{dx}\right)_{x=\mu_x}(x - \mu_x) + \frac{1}{2}\left(\frac{d^2y}{dx^2}\right)_{x=\mu_x}(x - \mu_x)^2 + \cdots\right] \\
&= E[y(\mu_x)] + \left(\frac{dy}{dx}\right)_{x=\mu_x} E[(x - \mu_x)] + \frac{1}{2}\left(\frac{d^2y}{dx^2}\right)_{x=\mu_x} E[(x - \mu_x)^2] + \cdots \\
&\approx y(\mu_x) + \frac{1}{2}\left(\frac{d^2y}{dx^2}\right)_{x=\mu_x}\sigma_x^2
\end{aligned}$$

Dove il secondo termine scompare perchè $E[x] = \mu_x$

Per la varianza

$$\sigma_y^2 = E[y^2] - \mu_y^2 = E\left[\left(y(\mu_x) + \left(\frac{dy}{dx}\right)_{x=\mu_x}(x-\mu_x) + \frac{1}{2}\left(\frac{d^2y}{dx^2}\right)_{x=\mu_x}(x-\mu_x)^2 + \cdots\right)^2\right] - \mu_y^2 =$$

$$E\left[(y(\mu_x))^2\right] + 2y(\mu_x)\left(\frac{dy}{dx}\right)_{x=\mu_x} E[(x-\mu_x)] + \left(\left(\frac{dy}{dx}\right)_{x=\mu_x}\right)^2 E[(x-\mu_x)^2] + \cdots - \mu_y^2 =$$

$$\approx \left(\left(\frac{dy}{dx}\right)_{x=\mu_x}\right)^2 \sigma_x^2$$

Esattamente ciò che si ottiene con la **legge di propagazione della varianza**.

Sapendo che per variabili indipendenti $E[x_1, x_2] = E[x_1]E[x_2]$

Per funzioni a più variabili

$$y(x_1, x_2, \cdots, x_n) = \sum_{k_1=0}^{\infty}\sum_{k_2=0}^{\infty}\cdots\sum_{k_n=0}^{\infty}\frac{(x_1-\mu_{x_1})^{k_1}(x_2-\mu_{x_2})^{k_2}\cdots(x_n-\mu_{x_n})^{k_n}}{k_1!k_2!\cdots k_n!}\left[\frac{\partial^{k_1k_2\cdots k_n}y}{\partial x_1^{k_1}\cdots\partial x_n^{k_n}}\right]_{\bar{x}=\bar{\mu}_x} =$$

$$y(\mu_{x_1}, \mu_{x_2}, \cdots, \mu_{x_n}) + \sum_{i=1}^{n}(x_i-\mu_{x_i})\left[\frac{\partial y}{\partial x_i}\right]_{\bar{x}=\bar{\mu}_x} + \frac{1}{2}\sum_{i=1}^{n}(x_i-\mu_{x_i})^2\left[\frac{\partial^2 y}{\partial x_i^2}\right]_{\bar{x}=\bar{\mu}_x} + \sum_{i=1}^{n}\sum_{j=i+1}^{n}(x_i-\mu_{x_i})(x_j-\mu_{x_j})\left[\frac{\partial^2 y}{\partial x_i\partial x_j}\right]_{\bar{x}=\bar{\mu}_x}$$

Ricordiamo inoltre che se $y = \sum_{i=1}^{n} x_i^{\alpha_i}$ allora:

$$\frac{\sigma_y^2}{y^2} = \sum_{i=1}^{n}\alpha_i^2\left(\frac{\sigma_{x_i}}{x_i}\right)^2$$

da cui si può ricavare quali sono gli errori trascurabili.

Vediamo il caso di n misure:

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

La varianza sarà:

$$\sigma_x^2 = \sum_{i=1}^{n}\left(\frac{\partial\overline{x}}{\partial x_i}\right)^2\sigma_{x_i}^2$$

Essendo che questa derivata vale sempre $\frac{1}{n^2}$ allora:

$$\sigma_{\overline{x}}^2 = \frac{1}{n^2}\sum_{i=1}^{n}\sigma_i^2 \to \sigma_{\overline{x}} = \frac{\sigma_i}{\sqrt{n}}$$

Se ho compiuto 2 misure e mi chiedo se esse siano **compatbili**, costruisco una funzione derivata come $y = x_1 - x_2$ (differenza fra le misure), supponiamo $\sigma_1 \neq \sigma_2$ e $E[x_1] = E[x_2] = \mu$

$$E[y] = E[x_1 - x_2] = 0$$

$$\sigma_y^2 = \sum_{i=1}^{n}\left(\frac{\partial y}{\partial x_i}\right)^2\sigma_{x_i}^2 = \sigma_1^2 + \sigma_2^2$$

La funzione di distribuzioe Gaussiana

$$f(y) = \frac{1}{\sqrt{2\pi\sigma_y^2}}e^{-\frac{y^2}{2\sigma_y^2}}$$

Si ha compatibilità quando

$$|x_1 - x_2| \leqslant 3\sqrt{\sigma_1^2 + \sigma_2^2}$$

14 Funzione di distribuzione congiunta

Da un set di misure indipendenti posso costruire la "funzione di distribuzione congiunta" (prodotto fra le funzioni gaussiane delle n variabili):

$$f(x_1, x_2, \ldots, x_n) = \frac{1}{(2\pi)^{n/2} \prod_{i=1}^{N} \sigma_i} e^{-\sum_{i=1}^{n} \frac{(x_i-\mu_i)^2}{2\sigma_i^2}} \quad per\ \mu\ e\ \sigma = cost. \rightarrow \frac{1}{(2\pi)^{n/2}\sigma^n} e^{\frac{-\sum_{i=1}^{n}(x_i-\mu)^2}{2\sigma^{2n}}}$$

$$P(x_1^m - \Delta x \leqslant x_1 \leqslant x_1^m + \Delta x, \ldots, x_n^m - \Delta x \leqslant x_n \leqslant x_n^m + \Delta x) = \frac{(\Delta x)^n}{(2\pi)^{n/2}\sigma^n} e^{-\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{2\sigma^2}}$$

14.1 Stima dei parametri

Posso ottenere una stima dei parametri della funzione di distribuzione, voglio che sia a minima varianza (rispetto ai dati sperimentali che ho raccolto) e che il valore sia centrato nel valore vero, posso usare:

- **Metodo della massima verosimiglianza** (o Likelihood)
- **Metodo dei minimi quadrati**, meno preciso rispetto al primo

Dato un set di misure ho che la funzione di distribuzione cumuluativa (o congiunta) $f(x_1, \ldots, x_n, \lambda_1, \ldots \lambda_n)$, dove λ_i sono i parametri da stimare. Voglio trovare i valori $\lambda_1, \ldots \lambda_m$ che minimizzano il valore di $\mathfrak{L} = f(x_1^m, \ldots, x_n^m, \lambda_1, \ldots \lambda_m)$, dove x_i^m sono i valori misurati.

Questo perchè voglio massimizzare la probabilità di trovare i miei valori misurati all'interno di $x_i \pm \Delta x$

In realtà però si punta a massimizzare il logaritmo di $\mathfrak{L}$, per esempio per delle misure con distribuzione gaussiana

$$\ln(\mathfrak{L}) = \ln \frac{1}{2\pi\sigma^n} - \frac{\sum_{i=1}^{n}(x_i - \mu_x)^2}{2\sigma_x^2}$$

Le equazioni di Likelihood sono:

$$\frac{\partial \mathfrak{L}}{\partial \mu} = 0 \quad \frac{\partial^2 \mathfrak{L}}{\partial \sigma^2} < 0$$

Da cui si ottengono:

$$\mu = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad e \qquad \sigma^2 = \sum_{i=1}^{n} \frac{(x_i - \mu)^2}{n}$$

ma facendo qualche calcolo

$$(x-\mu)^2 = (x - \overline{x} + \overline{x} - \mu)^2 = (x - \overline{x})^2 + -2(\overline{x} - \mu)(x - \overline{x}) + (\overline{x} - \mu)^2$$

da cui:

$$E\left[(x-\mu)^2\right] = E\left[(x-\overline{x})^2\right] + E\left[2(\overline{x}-\mu)(x-\overline{x})\right] + \left[(\overline{x}-\mu)^2\right]$$

$$\sigma^2 = E\left[(x-\overline{x})^2\right] + \frac{\sigma^2}{n}$$

e raccogliendo

$$\sigma^2 = \frac{1}{n-1}\sum (x_i - \overline{x})^2$$

Supponiamo di avere più misure con σ differenti, in questo caso allora la misura x_1 avrà una funzione di distribuzione gaussiana e la distribuzione congiunta sarà una produttoria di queste funzioni. In questo caso la funzione di distribuzione manterrà la sommatoria anche per i σ_i:

$$f(x_1, x_2, \cdots, x_n) = \frac{1}{(2\pi)^{n/2}\sigma_x^n} e^{-\sum_{i=1}^{n} \frac{(x_i-\mu_x)^2}{2\sigma_{x_i}^2}}$$

Utilizzando le equazioni di Likelihood si ottengono:

$$\mu = \frac{\sum_{i=1}^{n} \frac{x_i^m}{\sigma_i^2}}{\frac{1}{\sum_{j=1}^{n} \sigma_i^2}}$$

Ovvero una media pesata delle misure per le loro varianze dal termine, in cui la sommatoria del fattore di peso è uguale a 1, le misure più precise hanno peso maggiore.

$$\sigma_\mu = \frac{1}{\sum_{i=1}^{n} \frac{1}{\sigma_i^2}}$$

15 Confronto istogramma/gaussiana

Date 100 misure che cadono in k intervalli di valore centrale x^k e larghezza Δx, ci chiediamo quale sia la funzione di distribuzione che mi definisca la probabilità che un certo dato cada in un certo intervallo (successo), questa è la **funzione di distribuzione binomiale**:

Sapendo che la probabilità per un intervallo k è: $P_k = \binom{n}{l} p^l (1-p)^{n-l}$, dove p è la probabilità di successo e l il numero di successi, so che $E[l] = np$ e $\sigma^2 = np(1-p)$.

Considerando ora una distribuzione di tipo Gaussiano la funzione che la descrive é la classica e la probabilità che un certo valore cada in un intervallo è:

$$P_k = \int_{x_i - \frac{\Delta x}{2}}^{x_i + \frac{\Delta x}{2}} f(x, \hat{\mu}, \sigma^2) dx \simeq f(\bar{x}_k) \Delta x.$$

da cui ottengo il numero di eventi atteso all'interno dell'intervallo n_k e per ogni intervallo ho un certo σ, per ognuno di questi intervalli posso fare un confronto per verificare la compatibilità

$$|{n_k}^s - {n_k}^m| \leqslant 3\sigma_k$$

dove m sta per eventi misurati ed s per eventi attesi, avremo quindi un grafico con un valore atteso di eventi con barra di errore di larghezza σ, dunque in un grafico mi aspetto che:

- il 68% deve toccare con le barre di errore il valore di aspettazione
- il 27% si trova a 2 σ
- il 5% si trova a 3 σ

La deviazione standard della binomiale è circa $\sqrt{n_k^m}$ se $n_{tot} >>> n_k^c$, che in realtà è un approssimazione che va bene quando $n_k^c > 5$