Appunti di Statistica e Analisi Dati

Alessio Brusini, Manuele Mirolo, Michele Tedeschini

2025/2026

Indice

1 Intoduzione e Statistica **2**
1.1 I Dati e la Rappresentazione Grafica . . . 2
1.1.1 Scatter Plot ed Errori . . . 2
1.2 Grandezze Statistiche: Media e Varianza . . . 2
1.2.1 Media Aritmetica . . . 2
1.2.2 Dispersione e Varianza . . . 2
1.2.3 Deviazione Standard e correzione di Bessel . . . 3
1.3 Errore di Sensibilità e Distribuzione Uniforme . . . 4
1.4 Propagazione degli Errori . . . 5

2 Metodo dei Minimi Quadrati **5**
2.1 Il Principio . . . 5
2.2 Fit Lineare ($y = mx + q$) . . . 5
2.3 Caso Non Lineare e Linearizzazione . . . 7

3 SS **8**

1 Intoduzione e Statistica

Lezione del 6 Ottobre 2025

1.1 I Dati e la Rappresentazione Grafica

Innanzitutto riflettiamo su cosa sono i dati: nel caso degli esperimenti di fisica si tratterà di un insieme di misure di una certa grandezza fisica:

$$\{x_1, x_2, \dots, x_N\}$$

Il minimo che si può fare per analizzarli è produrre un **grafico** e provare a riassumere il loro comportamento con qualche grandezza. Per quanto riguarda la parte grafica, la rappresentazione dipende dai dati a disposizione:

- **Istogramma**: Avendo molte misure di una sola grandezza, la rappresentazione tipica è l'istogramma. Per farlo si divide l'intervallo atteso delle misure in intervalli più piccoli detti *bin*, e si conta quante misure cadono in ogni intervallino.
- **Scatter Plot**: Avendo poche misure di due o più variabili correlate, la rappresentazione più utile è un plot a dispersione (punti (x, y) sul piano cartesiano).

1.1.1 Scatter Plot ed Errori

L'altra rappresentazione classica è lo scatter plot in cui plottiamo una grandezza rispetto all'altra e aggiungiamo per ogni punto gli errori di misura:

$$(x_i \pm \sigma_{x_i}, \quad y_i \pm \sigma_{y_i})$$

In questa rappresentazione è stato usato un numero per rappresentare una misura di x ed è stato associato ad esso una stima dell'errore fatto nella singola misura.

Gli errori da associare dipendono dalla situazione pratica:

- In alcuni casi si può fare un'analisi statistica ripetendo le misure molte volte.
- Nella maggior parte dei casi questo non si può fare (strumento non abbastanza sensibile o fenomeno non ripetibile). In tal caso si associa l'errore di sensibilità dello strumento.

1.2 Grandezze Statistiche: Media e Varianza

1.2.1 Media Aritmetica

Consideriamo il caso ottimistico in cui si riesce a misurare tante volte la stessa grandezza nelle stesse condizioni. In questo caso, se si vuole usare un solo numero per descrivere le misure, il migliore è senz'altro la **media aritmetica**:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^{N} x_i \tag{1}$$

1.2.2 Dispersione e Varianza

La media però non è sufficiente a descrivere i dati perché serve aggiungere un altro numero che mostri la **dispersione** attorno alla media. Fare la media delle deviazioni $(x_i - \bar{x})$ è inutile perché fa zero:

$$\frac{1}{N} \sum (x_i - \bar{x}) = \frac{1}{N} \sum x_i - \frac{1}{N} \sum \bar{x} = \bar{x} - \bar{x} = 0$$

Si considera quindi il quadrato delle dispersioni, ottenendo la **varianza**:

$$\mathrm{Var}(x) = \frac{1}{N}\sum_{i=1}^{N}(x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2 \tag{2}$$

Si può dimostrare una formula alternativa molto utile per i calcoli:

$$\begin{aligned}\mathrm{Var}(x) &= \frac{1}{N}\sum(x_i - \bar{x})^2 = \frac{1}{N}\sum(x_i^2 - 2x_i\bar{x} + \bar{x}^2)\\ &= \frac{1}{N}\sum x_i^2 - \frac{2\bar{x}}{N}\sum x_i + \frac{1}{N}\sum \bar{x}^2\\ &= \overline{x^2} - 2\bar{x}\cdot\bar{x} + \bar{x}^2 = \overline{x^2} - \bar{x}^2\end{aligned}$$

Cioè la varianza è la media dei quadrati meno il quadrato della media.

1.2.3 Deviazione Standard e correzione di Bessel

La varianza ha però la scomodità di avere un'unità di misura al quadrato rispetto a x. Si preferisce quindi la **deviazione standard**:

$$\sigma_N = \sqrt{\mathrm{Var}(x)}$$

Osservazione 1 (Correzione di Bessel). La formula sopra è corretta se le misure rappresentano tutta la popolazione. Nella maggior parte dei casi x_i è solo un **campione**. Per tener conto del bias dovuto all'uso della media campionaria $\bar{x}$ invece della media vera μ, si usa $N - 1$ al denominatore:

$$\sigma = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(x_i - \bar{x})^2} \tag{3}$$

Questa correzione diventa trascurabile per N grande, ma è fondamentale per piccoli set di dati.

Esempio (Python)

Di seguito mostriamo come calcolare media e deviazione standard (con e senza correzione) simulando delle misure gaussiane, simuliamo $N = 100$ misure con due strumenti diversi ($\sigma_1 = 1$ e $\sigma_2 = 0.2$).

```python
import numpy as np
import matplotlib.pyplot as plt

# 1. Simulo N misure di una grandezza fisica (es. corrente)
N = 100
valore_simulato = 8.0 # Valore vero [mA]
# Caso 1: sigma = 1, Caso 2: sigma = 0.2
misure1 = np.random.normal(loc=valore_simulato, scale=1.0, size=N)
misure2 = np.random.normal(loc=valore_simulato, scale=0.2, size=N)

# 2. Calcolo Media
media1 = np.mean(misure1)
print(f"Media Caso 1: {media1:.4f} mA")

# 3. Calcolo Deviazione Standard (ddof=1 applica la correzione di Bessel N
    -1)
sigma1_corr = np.std(misure1, ddof=1)
print(f"Sigma Corretto (Bessel): {sigma1_corr:.4f}")

# 4. Istogramma
plt.hist(misure1, alpha=0.7, bins=30, edgecolor='black', label='Caso 1')
plt.hist(misure2, alpha=0.7, bins=30, edgecolor='black', label='Caso 2')
plt.xlabel('Misura, I [mA]')
```

```python
plt.title('Istogramma delle misure ripetute')
plt.legend()
plt.show()
```

Listing 1: Calcolo di Media e Deviazione Standard

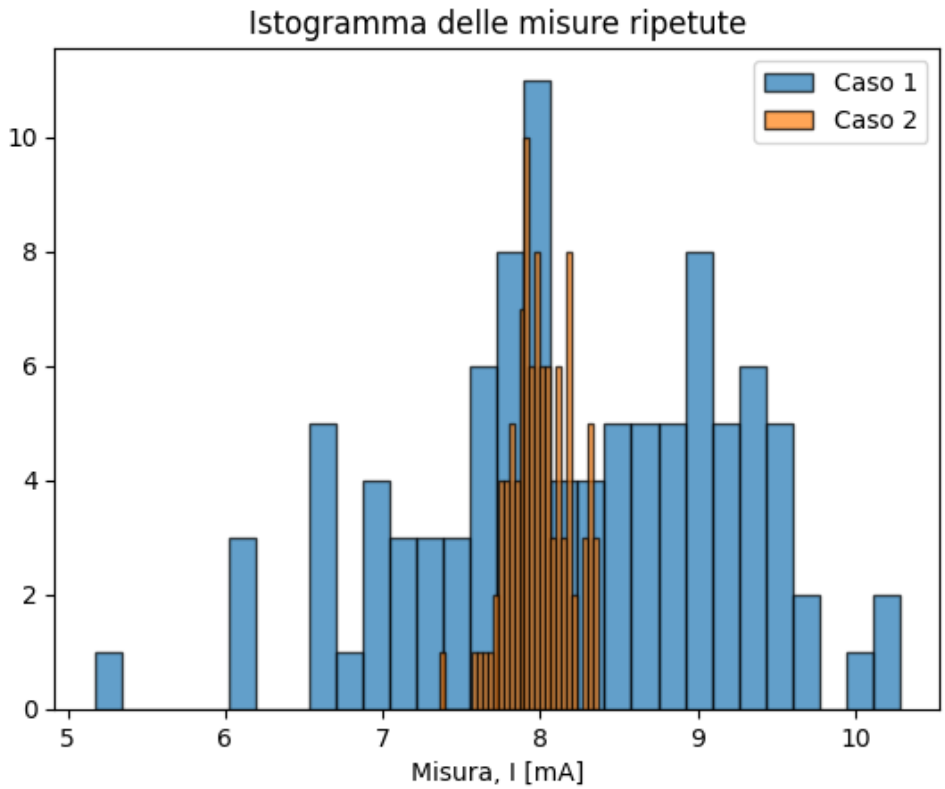

Figura 1: Istogramma comparativo delle due serie di misure simulate.

1.3 Errore di Sensibilità e Distribuzione Uniforme

Quando non è possibile ripetere molte volte la misura, associamo alle misure l'errore dovuto alla sensibilità dello strumento. Questo errore si ottiene leggendo il minimo scarto della variabile consentito dallo strumento (risoluzione):

$$\Delta x = \frac{x_{max} - x_{min}}{2}$$

Questo è l'errore massimo $x \pm \Delta x$. Statisticamente, assumere che il valore vero si trovi in $[x_{min}, x_{max}]$ equivale ad assumere una **densità di probabilità uniforme** $P(x)$ di larghezza 2Δ. La densità deve essere normalizzata a 1:

$$\int_{-\Delta}^{\Delta} C\,dx = 1 \implies C(2\Delta) = 1 \implies C = \frac{1}{2\Delta}$$

Quindi:

$$P(x) = \begin{cases} \frac{1}{2\Delta} & x \in [-\Delta, \Delta] \\ 0 & \text{altrove} \end{cases}$$

Per una distribuzione uniforme tra $[-\Delta, \Delta]$:

- Media: $\mu = 0$
- Varianza: $\sigma^2 = \int_{-\Delta}^{\Delta} x^2 \frac{1}{2\Delta} dx = \frac{\Delta^2}{3}$

Quindi, se si vuole convertire un errore massimo Δ in una deviazione standard σ:

$$\sigma = \frac{\Delta}{\sqrt{3}} \tag{4}$$

1.4 Propagazione degli Errori

Data una funzione $f(x, y)$ di variabili indipendenti, la varianza si propaga come:

$$\sigma_f^2 = \left(\frac{\partial f}{\partial x}\right)^2 \sigma_x^2 + \left(\frac{\partial f}{\partial y}\right)^2 \sigma_y^2 \tag{5}$$

Esempio numerico: Calcolo dello spazio percorso in un moto uniformemente accelerato
Dati: $v = 200 \pm 10\, m/s$, $a = 12 \pm 2\, m/s^2$, $t = 6\, s$ (errore trascurabile).

$$s = vt + \frac{1}{2}at^2 = (200 \cdot 6) + \frac{1}{2} \cdot 12 \cdot 6^2 = 1200 + 216 = 1416\, m$$

Errore associato σ_s:

$$\sigma_s^2 = \left(\frac{\partial s}{\partial v}\right)^2 \sigma_v^2 + \left(\frac{\partial s}{\partial a}\right)^2 \sigma_a^2 = (t)^2\sigma_v^2 + \left(\frac{1}{2}t^2\right)^2 \sigma_a^2$$

$$\sigma_s = \sqrt{6^2 \cdot 10^2 + (18)^2 \cdot 2^2} = \sqrt{3600 + 1296} = \sqrt{4896} \approx 70\, m$$

Risultato: $s = 1416 \pm 70\, m$.

2 Metodo dei Minimi Quadrati

2.1 Il Principio

L'obiettivo è dedurre informazioni fisiche dai dati (fit). Partiamo dalle ipotesi:

1. Ho effettuato misure (x_i, y_i) dove l'errore su x è trascurabile.
2. Per ogni x fisso, ho misurato y con incertezza σ_i.
3. Esiste una legge $y = f(x; p)$ (dove p sono i parametri).

Il metodo consiste nel minimizzare la somma degli scarti quadratici pesati, detta **Chi Quadro** χ^2:

$$\chi^2 = \sum_{i=1}^{N} \left[\frac{y_i - f(x_i; p)}{\sigma_i}\right]^2 \tag{6}$$

Minimizzare significa porre le derivate rispetto ai parametri uguali a zero: $\frac{\partial \chi^2}{\partial p} = 0$.

2.2 Fit Lineare ($y = mx + q$)

Nel caso di funzione lineare $f(x) = mx + q$ e $\sigma_i = \sigma$ costanti, risolvendo il sistema delle derivate parziali $\frac{\partial \chi^2}{\partial m} = 0$ e $\frac{\partial \chi^2}{\partial q} = 0$, si ottengono le stime analitiche:

Definiamo le somme:

$$S_x = \sum x_i, \quad S_y = \sum y_i, \quad S_{xx} = \sum x_i^2, \quad S_{xy} = \sum x_i y_i$$

$$D = NS_{xx} - (S_x)^2$$

Le stime dei parametri sono:

$$m = \frac{NS_{xy} - S_x S_y}{D}, \qquad q = \frac{S_{xx}S_y - S_x S_{xy}}{D} \tag{7}$$

E gli errori associati (tramite propagazione):

$$\sigma_m = \sqrt{\frac{N\sigma^2}{D}}, \qquad \sigma_q = \sqrt{\frac{\sigma^2 S_{xx}}{D}} \tag{8}$$

Esempio (Fit Lineare)

```python
# Dati simulati: Moto uniforme s = v*t + s0
t = np.array([0, 1, 2, 3, 4, 5])        # Tempo [s]
s = np.array([2, 17, 27, 37, 47, 63])   # Spazio [mm]
sigma_s = 2                             # Incertezza [mm]
N = len(t)

# Calcolo Somme
Sx = np.sum(t); Sy = np.sum(s)
Sxx = np.sum(t**2); Sxy = np.sum(t * s)

# Calcolo Parametri
D = N * Sxx - Sx**2
m = (N * Sxy - Sx * Sy) / D
q = (Sxx * Sy - Sx * Sxy) / D

print(f"Velocita' (m): {m:.2f} mm/s")
print(f"Posizione init (q): {q:.2f} mm")

# Plot
plt.errorbar(t, s, yerr=sigma_s, fmt='o', label='Dati')
plt.plot(t, m*t + q, label='Fit Lineare')
plt.xlabel('Tempo [s]'); plt.ylabel('Spazio [mm]')
plt.legend(); plt.show()
```

Listing 2: Fit Lineare dei Minimi Quadrati

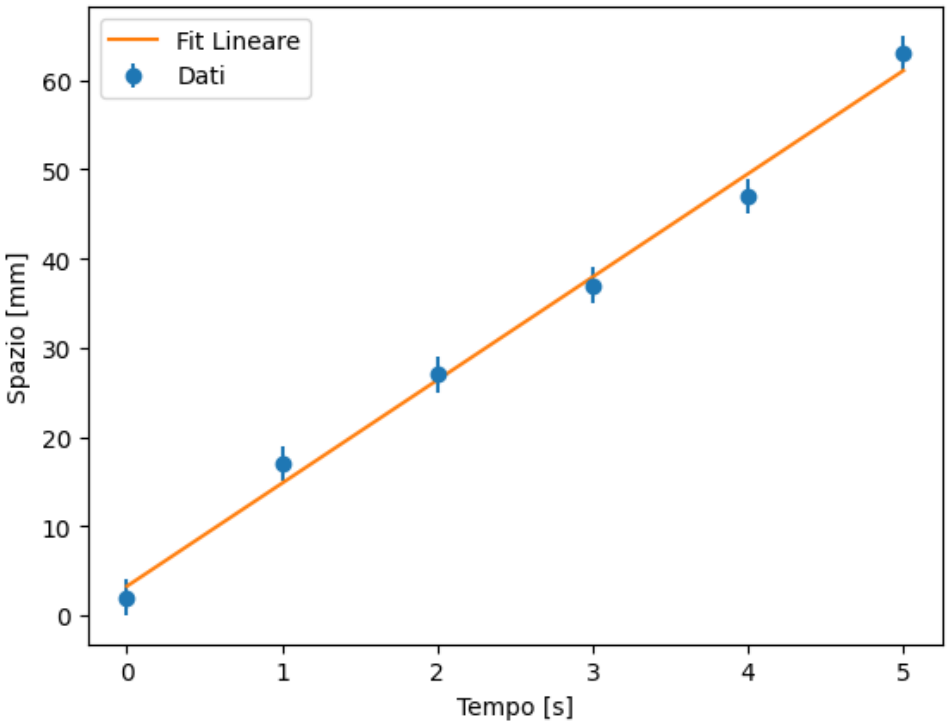

Figura 2: Fit Lineare

2.3 Caso Non Lineare e Linearizzazione

se $f(x; p)$ non è lineare spesso si cerca un'espressione linearizzata cambiando variabili.

Esempio: Caduta grave $h = \frac{1}{2}gt^2$ oppure la formula inversa per calcolare g dai tempi:

$$t = \sqrt{\frac{2}{g}}\sqrt{d} + t_0$$

Questa equazione è del tipo $Y = mX + q$ se poniamo:

$$Y = t, \quad X = \sqrt{d}, \quad m = \sqrt{\frac{2}{g}}, \quad q = t_0$$

Una volta calcolato $\hat{m}$ con i minimi quadrati, inverto la relazione per trovare g:

$$\hat{m}^2 = \frac{2}{g} \implies g = \frac{2}{\hat{m}^2}$$

Per l'errore, uso la propagazione:

$$\sigma_g = \left|\frac{\partial g}{\partial m}\right| \sigma_m = \left|-\frac{4}{m^3}\right| \sigma_m$$

Esempio Computazionale (Linearizzazione)

```python
# Dati: Tempo t vs Spazio s
t = np.array([0.16, 0.40, 0.58, 0.72, 0.97])
s = np.array([0.20, 1.0, 2.0, 3.0, 5.0])
rad_s = np.sqrt(s) # Variabile linearizzata X

# ... (Codice per calcolo m e q su t vs rad_s omesso per brevita'...)
# Supponiamo m sia stato calcolato:
m_calc = 0.45
sigma_m = 0.01

# Calcolo fisico
g = 2 / m_calc**2
sigma_g = (4 / m_calc**3) * sigma_m

print(f"g misurato: {g:.2f} +/- {sigma_g:.2f} m/s^2")
```

Listing 3: Linearizzazione per calcolo di g

3 SS

Lezione del 23 Febbraio